



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

Facultad de Matemática

EPG4002 - Aprendizaje No Supervisado

Profesor: Jonathan Acosta

Fecha de entrega: 19/06/2026 a las 23:59 horas (vía canvas)

Instrucciones: Pueden trabajar en grupos de 2 estudiantes.

Laboratorio N°1

Segundo bimestre

Objetivo: Aplicar las técnicas de conglomerados jerárquicos y no jerárquico (K-means y sus variantes) e interpretar sus resultados utilizando Python como herramienta computacional.

Preguntas: Utilice el conjunto de datos “USArrests” disponibles en **Python**.

1. **(5pts)** De acuerdo con la definición de las variables, ¿cuales de ellas utilizaría para realizar clústers? Justifique su respuesta.
2. **(5pts)** Realice una pequeña descripción estadística de las variables. ¿se justifica o no una estandarización de las variables cuantitativas?.
3. Considere que busca realizar 3 grupos con el conjunto de datos anterior a partir de métodos Jerárquicos.
 - (a) **(8pts)** Agrupar los observaciones mediante enlace simple, completo y ward, junto con las métricas Euclidiana y Manhattan. Visualice los agrupamiento mediante sus respectivos dendrograma.
 - (b) **(2pts)** Escoja uno de los métodos aglomerativos (métrica y enlace), indique porque la elección.
 - (c) **(10pts)** A partir del método escogido en (3b), crear los 3 grupos y comparar los clúster obtenidos, en términos de promedio, desviación estándar y boxplot para cada variable en cada grupo. Compare los grupos a partir de los anteriores. ¿Cuál o cuáles variables representan mejor a cada grupo?
4. Considere que busca realizar 3 grupos con el conjunto de datos anterior a partir de métodos No-Jerárquicos:
 - (a) **(4pts)** Realice un agrupamiento considerando 3 grupos utilizando la técnica K-medias.
 - (b) **(4pts)** Realice un agrupamiento considerando 3 grupos utilizando la técnica K-medoids, utilice una disimilaridad diferente de la Euclidiana.
 - (c) **(2pts)** Escoja entre el algoritmo k-medias y k-medoids, indique porque la elección.
 - (d) **(10pts)**) A partir del método escogido en (3b), crear los 3 grupos y comparar los clúster obtenidos, en términos de promedio, desviación estándar y boxplot para cada variable en cada grupo. Compare los grupos a partir de los anteriores. ¿Cuál o cuáles variables representan mejor a cada grupo?
5. **(10pts)** ¿Cuál de las dos metodologías aplicadas en los ítems 3b y 4c considera que particiona mejor al conjunto de datos? Justifique.

Formato de Entrega: El laboratorio debe ser entregado mediante un script (notebook) con el desarrollo, parte de la evaluación será que el script compile sin problemas.