

Aprendizaje No Supervisado

Clase 1

Jonathan Acosta


Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



- 1 Introducción
 - Análisis de clústeres
 - Medidas de Similitud y Disimilitud

Introducción



Introducción

- Técnicas descriptivas clásicas, normalmente se analizan variables de manera individual o por pares.
- Por ejemplo:
 - histogramas,
 - medidas de tendencia central,
 - correlación,
 - regresión lineal.
- Sin embargo, en muchos problemas modernos los datos contienen una gran cantidad de variables observadas simultáneamente.
- En estos contextos surgen preguntas distintas:
 - ¿Existen grupos naturales?
 - ¿Qué observaciones son similares?
 - ¿Existen anomalías?
 - ¿Cómo resumir la estructura global de los datos?

¿Qué es el Aprendizaje No Supervisado?

Introducción

- Corresponde al aprendizaje “sin profesor”.
- El Aprendizaje No Supervisado es aquel donde no se conoce la respuesta.
- Desde el punto de vista de la formulación matemática solo observamos $\mathbf{X}$.
- Desde una perspectiva general, en aprendizaje supervisado, se tiene $P(\mathbf{X}, Y)$, donde el interés está en



$$P(Y|\mathbf{X}) = \frac{P(\mathbf{X}, Y)}{P(\mathbf{X})}$$

incluso más específicamente en $\mathbb{E}[Y|\mathbf{X}]$, sin embargo, no se discute sobre $P(\mathbf{X})$.

Introducción

- Desde el punto de vista de Aprendizaje No Supervisado, el interés está en $P(\mathbf{X})$.
- No se requiere inferir cómo cambian las propiedades de $P(\mathbf{X})$, condicionadas por los valores cambiantes de otro conjunto de variables.
- Al no contar con Y , se asume que todas las variables son de interés.
- Las propiedades de interés suelen ser más complicadas que las estimaciones de localización.
- En general, se cuenta con una gran dimensionalidad, por el contrario, en aprendizaje supervisado típicamente Y suele ser unidimensional.


Introducción



- En problemas de baja dimensión (digamos ≤ 3), hay una variedad de métodos no paramétricos eficaces para estimar directamente la densidad $P(\mathbf{X})$ en sí misma en todos los valores de $\mathbf{X}$, y representarla gráficamente.
- Sin embargo, debido a la maldición de la dimensionalidad, estos métodos fallan en dimensiones altas.
- Simplemente, hay que conformarse con estimar modelos globales bastante burdos, como las mezclas gaussianas o diversos estadísticos descriptivos simples que caracterizan $P(\mathbf{X})$.

- En el contexto del aprendizaje no supervisado, no existe esa medida directa del éxito.
- Es difícil determinar la validez de las inferencias extraídas de los resultados de la mayoría de los algoritmos.
- Hay que recurrir a argumentos heurísticos no sólo para motivar los algoritmos, sino también para juzgar la calidad de los resultados.
- Esta incómoda situación ha dado lugar a una gran proliferación de métodos, ya que la eficacia es una cuestión de opinión y no puede verificarse directamente.

Ejemplo de Aplicación: Publicidad Segmentada



Introducción

Suponga que se mide información sobre distintos individuos (Agresti “Categorical Data Analysis”):

Individuo	Peso	Estatura	Color Ojos	Color Pelo	Lateralidad	Sexo
1	68	140	Verde	Rubio	Diestro	F
2	73	185	Cafe	Negro	Diestro	M
3	67	165	Azul	Rubio	Diestro	M
4	64	120	Cafe	Negro	Diestro	F
5	76	210	Cafe	Negro	Zurdo	M

¿Cómo determinar qué individuos son más similares entre sí?

- Consiste en un conjunto de técnicas descriptivas para agrupar datos.
- La cantidad de Grupos es **desconocida**.
- El agrupamiento se realiza en base a **similitudes** o **distancias**.
- Existen dos tipos Cluster:
 - Agrupamiento Jarárquico.
 - Agrupamiento No Jarárquico.

- La idea fundamental detrás de muchos métodos de agrupamiento es que observaciones similares deberían pertenecer al mismo grupo.
- Por lo tanto, el problema central consiste en cuantificar qué tan “cerca” o “lejos” se encuentran dos observaciones.
- Esta noción de cercanía depende:
 - del tipo de variables,
 - de la escala de medición,
 - y del contexto del problema.
- No existe una medida universalmente correcta de similitud.

Medidas de Similaridad y Proximidad

Considere los items

$$\mathbf{X} = (X_1, X_2, \dots, X_p)$$

$$\mathbf{Y} = (Y_1, Y_2, \dots, Y_p)$$

¿Cómo medir la cercanía entre $\mathbf{X}$ e $\mathbf{Y}$?

Definición (Disimilaridad)

Una relación $d : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$ es una medida de disimilaridad si satisface:

- ❶ $d(\mathbf{x}, \mathbf{y}) \geq 0 \quad \forall \mathbf{x}, \mathbf{y}.$
- ❷ $d(\mathbf{x}, \mathbf{y}) = 0 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{y}.$
- ❸ $d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x})$

Medidas de Similaridad: Ejemplos

- Distancia Euclideana

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2} = \sqrt{(\mathbf{x} - \mathbf{y})^\top (\mathbf{x} - \mathbf{y})}$$

- Distancia Euclideana Generalizada o Ponderada

$$d_{\mathbf{A}}(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^p \sum_{j=1}^p a_{ij} (x_i - y_i)(x_j - y_j)} = \sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{A} (\mathbf{x} - \mathbf{y})}$$

Obs.: Si $\mathbf{A} = \mathbf{S}^{-1}$ dicha distancia se llama Mahalanobis.

- Distancia de Manhattan y Minkowski

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^p |x_i - y_i| \quad \wedge \quad d(\mathbf{x}, \mathbf{y}) = \left[\sum_{i=1}^p |x_i - y_i|^m \right]^{1/m}$$

Medidas de Similaridad: Ejemplos

- Métrica de Canberra

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^p \frac{|x_i - y_i|}{|x_i| + |y_i|}$$

- Coeficiente de Czekanowski o coeficiente de Sørensen-Dice

$$d(\mathbf{x}, \mathbf{y}) = 1 - \frac{2 \sum_{i=1}^p \min\{|x_i|, |y_i|\}}{\sum_{i=1}^p |x_i| + |y_i|}$$

¿Es necesario estandarizar o normalizar las variables antes de aplicar la distancia?

Medidas de Similaridad: Escalas

- Algunas medidas de distancia son sensibles a la escala de las variables.
- Por ejemplo:
 - Edad: valores entre 20 y 30.
 - Ingreso: valores entre 1 000 y 100 000.

En distancia Euclideana o Manhattan, la variable ingreso podría dominar completamente la distancia total.

- Por esta razón, frecuentemente se requiere:
 - normalizar,
 - estandarizar,
 - o ponderar las variables.

Definición (Similitud)

Una relación $s : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$ es una medida de similitud si satisface:

- ❶ $0 \leq s(\mathbf{x}, \mathbf{y}) \leq 1 \quad \forall \mathbf{x}, \mathbf{y}.$
- ❷ $s(\mathbf{x}, \mathbf{y}) = 1 \quad \Longleftrightarrow \quad \mathbf{x} = \mathbf{y}.$
- ❸ $s(\mathbf{x}, \mathbf{y}) = s(\mathbf{y}, \mathbf{x})$

Observaciones:

- $d(\mathbf{x}, \mathbf{y}) = 1 - s(\mathbf{x}, \mathbf{y})$
- $s(\mathbf{x}, \mathbf{y}) = \frac{1}{1 + d(\mathbf{x}, \mathbf{y})}$
- $s(\mathbf{x}, \mathbf{y}) = \exp\{-d(\mathbf{x}, \mathbf{y})\}$

Medidas de Similaridad y Proximidad

- El coeficiente de correlación de Pearson (r) no es una medida de similaridad.
- Sin embargo, es útil para definir medidas asociadas:

$$\begin{aligned}r^*(\mathbf{x}, \mathbf{y}) &= |r(\mathbf{x}, \mathbf{y})| \\r^*(\mathbf{x}, \mathbf{y}) &= \frac{1 + r(\mathbf{x}, \mathbf{y})}{2}\end{aligned}$$

- Si se estandarizan previamente las variables, se puede probar que

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{2[1 - r(\mathbf{x}, \mathbf{y})]}$$

donde $d(\cdot, \cdot)$ es la distancia Euclidea.

Medidas de Similaridad y Proximidad

- Una variante de la correlación de Pearson es la similitud coseno, la cuál se aplica principalmente a variables positivas:

$$s(\mathbf{x}, \mathbf{y}) = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

- Para el caso de variables categóricas ordinales con M categorías, se puede realizar la transformación:

$$\frac{i - 0,5}{M}, \quad i = 1, 2, \dots, M.$$

Luego son tratadas como variables continuas.

- Para el caso de variables categóricas nominales con M categorías, se suele asumir una disimilaridad 0 ó 1, donde es 0 se obtiene cuando coinciden en la categoría y 1 en otro caso.

Medidas de Similaridad y Proximidad

Para el caso especial de variable binarias, considere las filas s y t del conjunto de datos

		fila x		
		1	0	Total
fila y	1	a	b	$a + b$
	0	c	d	$c + d$
Total		$a + c$	$b + d$	$a + b + c + d = p$

Se proponen las siguientes métricas

❶ $s = \frac{a + d}{a + b + c + d}$ (Simple Matching).

❷ $s = \frac{2(a + d)}{2(a + d) + c + b}$ (Double Matching)

❸ $s = \frac{a}{a + c + b}$ (Jaccard)

Medidas de Similaridad y Proximidad

Ejemplo: Considere (Agresti “Categorical Data Analysis”)

Individuo	X_1	X_2	X_3	X_4	X_5	X_6
1	68	140	Verde	Rubio	Diestro	F
2	73	185	Cafe	Negro	Diestro	M
3	67	165	Azul	Rubio	Diestro	M
4	64	120	Cafe	Negro	Diestro	F
5	76	210	Cafe	Negro	Zurdo	M

- X_1 : peso medido en kilogramos.
- X_2 : estatura medida en centímetros.
- X_3 : color de ojos.
- X_4 : color de pelo.
- X_5 : mano predominante.
- X_6 : sexo.

Medidas de Similaridad y Proximidad

Se definen

$$\begin{aligned} Y_1 &= \mathbb{I}_{\{X_1 \geq 72\}} & Y_3 &= \mathbb{I}_{\{X_3 = \text{Cafe}\}} & Y_5 &= \mathbb{I}_{\{X_5 = \text{Diestro}\}} \\ Y_2 &= \mathbb{I}_{\{X_2 \geq 150\}} & Y_4 &= \mathbb{I}_{\{X_4 = \text{Rubio}\}} & Y_6 &= \mathbb{I}_{\{X_6 = \text{F}\}} \end{aligned}$$

Individuo	Y_1	Y_2	Y_3	Y_4	Y_5	Y_6
1	0	0	0	1	1	1
2	1	1	1	0	1	0
3	0	1	0	1	1	0
4	0	0	1	0	1	1
5	1	1	1	0	0	0

Se obtiene usando Simple Matching

$$S = \begin{pmatrix} 1 & & & & & \\ 1/6 & 1 & & & & \\ 4/6 & 3/6 & 1 & & & \\ 4/6 & 3/6 & 2/6 & 1 & & \\ \textcolor{red}{0} & \textcolor{blue}{5/6} & 2/6 & 2/6 & 1 & \end{pmatrix}$$

- Binarizar es un primer paso para tratar con datos mixtos; sin embargo, lo más apropiado es utilizar similitudes y distancias que puedan aplicarse directamente a este tipo de datos.
- El agrupamiento depende críticamente de cómo se define la similitud entre observaciones.
- Distintas métricas pueden producir agrupamientos diferentes.
- Más que encontrar una única solución correcta, el objetivo suele ser descubrir estructuras útiles, interpretables y coherentes con el contexto del problema.

¿Alguna consulta?

L. Kaufman, P. J. Rousseeuw. *Finding Groups in Data: An Introduction to Cluster Analysis*. John Wiley & Sons, 2005.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.