

Aprendizaje No Supervisado

Clase 3

Jonathan Acosta

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



1 Métodos Jerárquicos

2 Métodos No Jerárquicos

- K-Medias
- K-Medoids

Métodos Jerárquicos


- Adicionalmente, desde el punto de vista aglomerativo, también existen los enlaces: Ward, WPGMA, WPGMC y UPGMC.
- Uno de los métodos que viene por defecto en algunos programas es el Ward, también conocido como criterio de Varianza Mínima de Ward (propuesto por Ward, 1963).
- Tal como especifica su nombre dicho método consiste en evaluar una función objetivo en cada etapa, así los clúster que se unen son aquellos minimizan la varianza dentro o del error.
- Este último principio también se utiliza en el método de K-medias, donde abordaremos más detalles.
- Se debe tener en cuenta que las disimilitudes se elevan al cuadrado antes de la actualización del clúster.

K-Medias

Método de K-medias

- El algoritmo K-means es uno de los métodos de agrupación por descenso iterativo más populares.
- Está pensado para situaciones en las que todas las variables son de tipo cuantitativo, y la distancia euclidiana al cuadrado es usada como medida de disimilaridad.
- Es una metodología de agrupamiento que divide una muestra de tamaño n en K clases.
- La rutina se puede resumir en:
 - i Escoger los primeros K centros de forma aleatoria.
 - ii Agrupar los datos de la muestra al centro más cercano.
 - iii Una vez agrupados los datos, calcular el centro de cada grupo.
 - iv El punto (ii) y (iii) se iteran hasta un criterio de parada

Método de K-medias



Método de K-medias

Para definir el criterio de parada hay que considerar de donde proviene el algoritmo. La cantidad

$$V_T = \sum_{j=1}^K \sum_{i=1}^{n_j} \|\mathbf{X}_{ij} - \overline{\mathbf{X}}\|^2 \quad \text{variabilidad total}$$

donde $\overline{\mathbf{X}}$ es el promedio total por variable. A su vez se puede calcular la variabilidad dentro de cada grupo y entre los grupos, donde

$$V_D = \sum_{j=1}^K \sum_{i=1}^{n_j} \|\mathbf{X}_{ij} - \overline{\mathbf{X}}_j\|^2 \quad \text{varianza dentro}$$

$$V_E = \sum_{j=1}^K n_j \|\overline{\mathbf{X}}_j - \overline{\mathbf{X}}\|^2 \quad \text{varianza entre}$$

Luego la función objetivo es minimizar la variabilidad dentro.

Método de K-medias

Así es posible definir criterios de parada como:

- Iterar hasta que no se reduzca la varianza dentro.
- La convergencia esta asegurada pero podría quedar en un óptimo local.
- Hartigan y Wong (1979) propuso iniciar el algoritmo con muchas opciones aleatorias diferentes para las medias iniciales, y elegir la solución que tenga el menor valor de la función objetivo.
- Sin embargo, si se agrega el criterio parar hasta que ninguna observación cambie de grupo el algoritmo podría no converger, en ese caso se detiene hasta que alcance un cierto número de iteraciones.

K-Medias: Ejemplo



Considere las siguientes observaciones

i	1	2	3	4	5	6
x_i	10	8	34	9	46	68
y_i	4	99	44	50	77	30

Utilizar el algoritmo k-medias con $k=2$ (sin escalar las variables).

¿Cuándo conviene escalar las variables?

K-Medias: Ejemplo



K-Medias: Ejemplo

- Se deben escoger al azar dos centros, los que podrían ser

$$C_1 = (15, 20) \quad C_2 = (50, 50)$$

- Luego se deben calcular las distancias al cuadrado de cada observación a los centros:

obs.	C_1	C_2	Asignar
1	281	3716	G1
2	6290	4165	G2
3	937	292	G2
4	936	1681	G1
5	4210	745	G2
6	2909	724	G2

Es decir, los grupos son $G_1 = \{1, 4\}$ y $G_2 = \{2, 3, 5, 6\}$

K-Medias: Ejemplo

- Así los nuevos centro son:




$$C_1 = (9,5; 27,0) \quad C_2 = (39,0; 62,5)$$

- Luego se repite el proceso

obs.	C_1	C_2	Asignar
1	529.25	4263.25	G1
2	5186.25	2293.25	G2
3	889.25	367.25	G2
4	529.25	1056.25	G1
5	3832.25	259.25	G2
6	3431.25	1897.25	G2

Es decir, los grupos son $G_1 = \{1, 4\}$ y $G_2 = \{2, 3, 5, 6\}$ (se mantienen).

K-Medias: Ejemplo



K-Medias: Generalizaciones

La principal restricción del K-medias es el uso de datos numéricos producto de la distancia Euclidiana. Por lo que surge una necesidad de extender el método.

Algunas variantes del K-Medias son:

- K-Mode: Utilizado para datos categóricos.
- K-Prototype: Utilizado para mezcla de datos (categóricos y numéricos). Corresponde a una mezcla entre K-means y K-mode.
- K-Medoids: Se utiliza para todo tipo de datos (con una disimilaridad apropiada). Para que resulte se cambia la forma de buscar el centro.
- K-Mediana: Utilizado en el mismo contexto que k-medias, pero reemplazando el promedio como centro por la mediana.

K-Medoids

Método de K-Medoids

- Como se dijo el algoritmo K-means surge cuando la medida de disimilitud se toma como distancia euclidiana al cuadrado, donde el centro del cluster corresponde al promedio.
- Una adaptación consiste en cambiar la medida de disimilaridad o bien cambiar el centro. Adaptaciones de este tipo se denominan K-Medoids.
- Esto requiere un método de optimización en cada etapa, ya que al cambiar la distancia, ya no se conoce cual es el valor optimo para el centro.
- Por lo tanto, K-medoids es mucho más intensivo desde el punto de vista computacional que K-means.

Método de K-Medoids

- A diferencia del K-means, el K-Medoids considera como centro un punto de la muestra.
- Suponga que se han establecido K cluster. Sea $C(i) = k$ un codificador, que asigna la i -ésima observación al clúster k y sea $d_{ij} = d(\mathbf{x}_i, \mathbf{x}_j)$.
- En general, la dispersión total de puntos,

$$T = \frac{1}{2} \sum_{k=1}^K \sum_{i=1}^n \sum_{j=1}^n d_{ij} = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \left(\sum_{C(j)=k} d_{ij} + \sum_{C(j) \neq k} d_{ij} \right),$$

es constante para un conjunto de datos fijo, independiente de la asignación de clusters.

Método de K-Medoids

- Luego podemos definir

$$W(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(j)=k} d_{ij} \quad \text{Within-Cluster}$$

$$B(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(j) \neq k} d_{ij} \quad \text{Between-Cluster}$$

tal que $T = W(C) + B(C)$.

- Como el objetivo es asignar los puntos cercanos al mismo clúster, una función de pérdida natural (o “energía”) sería

$$\min\{W(C)\} \quad \vee \quad \max\{B(C)\}$$

- En el caso del K-means, se sabe que $W(C)$ es minimizado en el promedio.

Método de K-Medoids: Algoritmo

- i. Para una asignación de clústeres dada C , encuentre la observación en el clúster que minimiza la distancia total a otros puntos en ese clúster:

$$i_k^* = \operatorname{argmin}_{\{i: (C(i)=k)\}} \sum_{C(j)=k} d_{ij}$$

Entonces $m_k = \mathbf{x}_{i_k^*}$, $k = 1, 2, \dots, K$ son las estimaciones actuales de los centros de los clusters.

- ii. Dado un conjunto actual de centros de cluster $\{m_1, \dots, m_K\}$, minimizar el error total asignando cada observación al centro de cluster más cercano (actual):

$$C(i) = \operatorname{argmin}_{k=1, \dots, K} d(\mathbf{x}_i, m_k)$$

- iii. Repita los pasos 1 y 2 hasta que las asignaciones no cambien.

Método de K-Medoids: Algoritmo PAM

- La búsqueda anterior se denomina exhaustiva, la cual es muy costosa.
- La aplicación práctica más común de k-medoids es el algoritmo Partición Alrededor de Medoids (PAM) propuestom por Kaufman y Rousseeuw (1990):
 - i. Seleccionar K de los n puntos como el medoid.
 - ii. Asociar cada punto al medoid más cercano.
 - iii. Mientras el costo de la configuración disminuya:
 - Intercambiar un medoid con otro punto de los datos y recalcular la distancia de los puntos a sus medoids.
 - Si la distancia total de la configuración aumentó en el paso anterior, deshacer el intercambio.

K-Medoids: Ejemplo

Considere las siguientes observaciones

i	1	2	3	4	5	6
x_i	10	8	34	9	46	68
y_i	4	99	44	50	77	30

Utilizar el algoritmo k-medoids con $k=2$ (sin escalar las variables) y usando la distancia de Manhattan.

K-Medoids: Ejemplo

- Se deben escoger al azar dos centros (de los datos), los que podrían ser

$$C_1 = (10, 4) \quad C_2 = (46, 77)$$

- Luego se deben calcular las distancias de cada observación a los centros:

obs.	C_1	C_2	Asignar	$d(\mathbf{x}_i, m_k)$
1	—	—	—	—
2	97	60	G2	60
3	64	45	G2	45
4	47	64	G1	47
5	—	—	—	—
6	84	69	G2	69

Es decir, los grupos son $G_1 = \{1, 4\}$ y $G_2 = \{2, 3, 5, 6\}$ con costo (distancia total) 221.

K-Medoids: Ejemplo

- Ahora se debe modificar un centro

$$C_1 = (10; 4) \quad C_2 = (68; 30)$$

- Luego se repite el proceso

obs.	C_1	C_2	Asignar	$d(\mathbf{x}_i, m_k)$
1	—	—	—	—
2	97	129	G1	97
3	64	48	G2	48
4	47	79	G1	47
5	109	69	G2	69
6	—	—	—	—

Es decir, los grupos son $G_1 = \{1, 2, 4\}$ y $G_2 = \{3, 5, 6\}$ (cambian), pero el costo es 261 aumenta, por lo tanto, se debe deshacer el cambio.

¿Alguna consulta?

L. Kaufman, P. J. Rousseeuw. *Finding Groups in Data: An Introduction to Cluster Analysis*. John Wiley & Sons, 2005.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.