

Aprendizaje No Supervisado

Clase 4

Jonathan Acosta

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



1 ¿Como determinar el valor de K ?

- Método del Codo
- Método de $CH(K)$
- Método $H(K)$
- Método Silhouette
- Método Gap-Statistic

2 Componentes Principales

- Preliminares
- Metodología
- Aplicaciones y Ejemplos



Procedimientos para encontrar K

- Sin duda el problema más difícil en clustering es la determinación de la cantidad de clases, K .
- La dificultad se debe a la carencia de una función de pérdida que cuantifique el grado de ajuste de los datos.
- Muchos autores a lo largo del tiempo han definido algunas métricas de utilidad que podrían ser usadas para estimar K .
- Estas técnicas son independientes del método con el que se realizó el agrupamiento, es decir, su punto de partida son los grupos ya establecidos.
- En la mayoría de los casos se compara el rendimiento de $K \in \{1, 2, 3, \dots, K_{\text{máx}}\}$, donde $K_{\text{máx}}$ se fija previamente.



Método del Codo o Pliegue

- Para cada $K \in \{1, 2, 3, \dots, K_{\text{máx}}\}$ calcular W_K la within-cluster.
- En la mayoría de los casos W_K es decreciente en K , luego se propone como $\hat{K}$ aquel valor en el que se observa una estabilización de la gráfica W_K versus K .
- Como $W_K + B_K = T$, donde B_K es la between-cluster y T la suma de dispersión total (la cual es fija para el conjunto de datos). También es frecuente encontrar
 - B_K versus K
 - $W_K/T * 100$ versus K
 - $B_K/T * 100$ versus K
- Los últimos dos tienen la ventaja de representa el porcentaje de explicación de la suma de dispersión total, por lo tanto una estrategia sería proponer como $\hat{K}$ el primer valor que alcanza un 80 % o 90 % de suma entre $(B_K/T * 100)$.

Método del Codo o Pliegue



Método del Codo o Pliegue



Método del Codo o Pliegue

- Por lo simple del método, es uno de los más populares.
- Sin embargo, el método del codo es netamente visual, por lo tanto, agrega un grado de subjetividad a los ya mencionados al momento de crear los cluster.
- A continuación veremos varios métodos que intentan proponer un método “objetivo” para determinar la cantidad de cluster.

Método de CH(K)

Calinsky & Harabasz (1974) propusieron

$$CH(K) = \frac{\frac{B_K}{K-1}}{\frac{W_K}{n-K}}$$

luego,

$$\hat{K} = \operatorname{argmax}_{K \in \{2, 3, \dots, K_{max}\}} CH(K)$$

- Note que $CH(1)$ no está definido, aunque su valor en $K = 1$ debería ser 0, ya que $B_1 = 0$.
- Como $CH(K) > 0$ si $K > 1$ entonces nunca se escogerá $K = 1$.

Hartigan (1975) propuso el estadístico

$$H(K) = \frac{\frac{W_K}{W_{K+1}} - 1}{n - K - 1}$$

- Inicializa con $K = 1$ y añade un nuevo cluster siempre y cuando $H(K)$ sea suficientemente grande.
- Hartigan sugiere adherir un cluster si $H(K) > 10$.
- Por lo tanto, el número de cluster es el menor valor de K tal que $H(K) \leq 10$.

Método Silhouette

Kaufman & Rousseeuw (1990) propusieron el estadístico silhouette:

- Para cada observación i , definen:

$$a(i) = \frac{1}{|k_i| - 1} \sum_{C(j)=k_i, i \neq j} d_{ij} \quad \wedge \quad b(i) = \min_{l \neq i} \frac{1}{|k_l|} \sum_{C(j)=l} d_{ij}$$

donde k_i es el cluster donde se encuentra la observación i , y $|k_i|$ es la cardinalidad del cluster k_i .

- El estadístico silhouette se define como

$$s_K(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- Kaufman & Rousseeuw (1990) propusieron

$$\hat{K} = \operatorname{argmax}_{K \in \{2, 3, \dots, K_{max}\}} \bar{s}(K)$$

Note que el estadístico no está definido para $K = 1$.

Método Gap-Statistic

Tibshirani, Walther & Hastie (2001) propusieron el estadístico GAP:

- Generar M conjuntos de datos de referencia y obtener W_{Km}^* , $m = 1, 2, \dots, M$, $K = 1, 2, \dots, K_{\text{máx}}$. Luego, calcular

$$\text{Gap}(K) = \frac{1}{M} \sum_m \ln(W_{Km}^*) - \ln(\overline{W}_K)$$

- Calcular

$$\bar{l} = \frac{1}{M} \sum_m \ln(W_{Km}^*) : \quad sd_K^2 = \frac{1}{M} \sum_m \ln(W_{Km}^*) - \bar{l})^2; \quad s_K = sd_K \sqrt{1 + \frac{1}{M}}$$

- Estimar K mediante

$$\hat{K} = \text{el menor } K, \text{ tal que } \text{Gap}(K) \geq \text{Gap}(K+1) - s_{k+1}$$

Componentes Principales: Resumen

Sea $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, se define $\mathbf{Y} = \mathbf{A}\mathbf{X}$, de modo que esta combinación lineal maximice la varianza de $\mathbf{Y}$ con la condición que las componentes de $\mathbf{Y}$ sean ortogonales.

Se seleccionan las k primeras componentes de modo de alcanzar la mayor cantidad de variabilidad de $\mathbf{X}$.

Resultado: La matriz generada por los vectores propios de $\boldsymbol{\Sigma}$ solucionan el problema de optimización. Y sus valores propios estandarizados corresponden a la fracción de varianza.

Componentes Principales: Resumen

Las componentes principales permiten:

- Reducir la dimensión (variables).
- Detectar puntos atípicos.
- Mostrar visualmente la variabilidad de un problema de dimensión grande.

Componentes Principales: Preliminares

Resultado: Sea $\mathbf{B}_{p \times p}$ simétrica y semi-definida positiva con

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

sus valores propios, y $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_p$ los respectivos vectores propios ortonormales. Sea $\mathbf{l}$ un vector unitario ($\mathbf{l}^\top \mathbf{l} = 1$). Entonces:

- ❶ $\max \mathbf{l}^\top \mathbf{B} \mathbf{l} = \lambda_1$. Alcanzado en $\mathbf{l} = \mathbf{q}_1$.
- ❷ $\min \mathbf{l}^\top \mathbf{B} \mathbf{l} = \lambda_p$. Alcanzado en $\mathbf{l} = \mathbf{q}_p$.
- ❸ $\max \mathbf{l}^\top \mathbf{B} \mathbf{l} = \lambda_j$. Alcanzado en $\mathbf{l} = \mathbf{q}_j$, sugeto a $\mathbf{l}^\top \mathbf{q}_i = 0, i = 1, \dots, j - 1$.

Componentes Principales: Preliminares

Idea: $B = Q\Lambda Q^\top$, donde

$$\Lambda = \begin{pmatrix} \lambda_1 & & \mathbf{0} \\ & \ddots & \\ \mathbf{0} & & \lambda_p \end{pmatrix} \quad Q = (\mathbf{q}_1 | \cdots | \mathbf{q}_p)$$

Luego,

$$\mathbf{l}^\top B \mathbf{l} = (\mathbf{l}^\top Q) \Lambda (\underbrace{Q^\top \mathbf{l}}_{\mathbf{f}}) = \mathbf{f}^\top \Lambda \mathbf{f} = \sum_{i=1}^p \lambda_i f_i^2$$

Como $\mathbf{f}^\top \mathbf{f} = \sum_{i=1}^p f_i^2 = 1$. Por lo tanto,

$$\lambda_p \underbrace{\sum_{i=1}^p f_i^2}_1 \leq \mathbf{l}^\top B \mathbf{l} \leq \lambda_1 \underbrace{\sum_{i=1}^p f_i^2}_1$$

Componentes Principales: Metodología

Sea $\mathbf{X}$ un vector aleatorio p -dimensional, tal que $\mathbb{E}[\mathbf{X}] = \mathbf{0}$ y $\mathbb{V}[\mathbf{X}] = \mathbf{\Sigma}$.

Asuma que $\mathbf{\Sigma}$ es conocido y que $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ son sus valores propios, y $\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_p$ son los respectivos vectores propios ortonormales.

Luego,

$$\left. \begin{aligned} \mathbf{C} &= (\mathbf{c}_1 | \dots | \mathbf{c}_p) \\ \mathbf{\Lambda} &= \begin{pmatrix} \lambda_1 & & \mathbf{0} \\ & \ddots & \\ \mathbf{0} & & \lambda_p \end{pmatrix} \end{aligned} \right\} \implies \mathbf{\Sigma} = \mathbf{C} \mathbf{\Lambda} \mathbf{C}^\top$$

Componentes Principales: Metodología

Se aprecian las combinaciones lineales:

$$\mathbf{C}^\top \mathbf{X} = \begin{pmatrix} \mathbf{c}_1^\top \mathbf{X} \\ \vdots \\ \mathbf{c}_p^\top \mathbf{X} \end{pmatrix}$$

Luego,

$$\mathbb{V}[\mathbf{C}^\top \mathbf{X}] = \mathbf{C}^\top \boldsymbol{\Sigma} \mathbf{C} = \boldsymbol{\Lambda}$$

Notar que $\mathbb{V}[\mathbf{c}_i^\top \mathbf{X}] = \lambda_i$ para todo i .

Idea: Compara la variabilidad de $\mathbf{C}^\top \mathbf{X}$ con la variabilidad de $\mathbf{X}$.

Definición (Varianza Generalizada)

Corresponde a una medida global de la variabilidad de un vector aleatorio $\mathbf{X}$. Es decir, $g : \mathbb{R}^{p \times p} \rightarrow \mathbb{R}$. Existen varias alternativas:

- ❶ $g(\Sigma) = |\Sigma|$
- ❷ $g(\Sigma) = \text{tr}(\Sigma)$ (usada en componentes principales)
- ❸ $g(\Sigma) = \|\Sigma\|_2$

Componentes Principales: Metodología

Notar que:

$$|\mathbf{\Sigma}| = |\mathbf{\Lambda}| = \prod_{i=1}^p \lambda_i \quad \wedge \quad \text{tr}(\mathbf{\Sigma}) = \text{tr}(\mathbf{\Lambda}) = \sum_{i=1}^p \lambda_i$$

Luego,

$$\begin{array}{l} \text{La proporción de la varianza} \\ \text{de las primeras } k \text{ componentes} \end{array} = \frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_p}$$

Componentes Principales: Metodología

Suponiendo que $\sum_{i=k+1}^p \lambda_i$ es pequeño comparado con $\sum_{i=1}^k \lambda_i$.

Entonces, podemos usar

$$\begin{pmatrix} Y_1 \\ \vdots \\ Y_k \end{pmatrix} = \begin{pmatrix} \mathbf{c}_1^\top \mathbf{X} \\ \vdots \\ \mathbf{c}_k^\top \mathbf{X} \end{pmatrix} \Leftrightarrow \mathbf{Y} = \mathbf{A}\mathbf{X}$$

Criterio: Si $\frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_p} * 100 \geq 80$, entonces es razonable usar las primeras k componentes.

Obs.: Si las variables tienen unidades diferentes es conveniente usar $\mathbf{R}$ (matriz de correlación) en vez de $\mathbf{\Sigma}$.

Recordar que las componentes principales permiten:

- Reducir la dimensión (variables).
- Detectar puntos atípicos.
- Mostrar visualmente la variabilidad de un problema de dimensión grande.

Componentes Principales: Aplicaciones y Ejemplos

Ejemplo: Fisher (1936) analizó las variedades de lirio (Iris disponible en R

- X_1 : Longitud del Sépalo.
- X_2 : Ancho del Sépalo.
- X_3 : Longitud del Pétalo.
- X_4 : Ancho del Pétalo.

Etapas de análisis

- 1 Obtener S a partir de los datos.
- 2 Calcular y ordenar los valores y vectores propios de S .
- 3 Identificar las componentes principales.

Componentes Principales: Aplicaciones y Ejemplos

1

$$S = \begin{pmatrix} 0,69 & -0,04 & 1,27 & 0,52 \\ -0,04 & 0,19 & -0,33 & -0,12 \\ 1,27 & -0,33 & 3,12 & 1,30 \\ 0,52 & -0,12 & 1,30 & 0,58 \end{pmatrix}$$

2 $(\lambda_1, \lambda_2, \lambda_3, \lambda_4) = (4,23; 0,24; 0,08; 0,02)$, y

$$C = \begin{pmatrix} \mathbf{c}_1 & \mathbf{c}_2 & \mathbf{c}_3 & \mathbf{c}_4 \\ 0,36 & -0,66 & -0,58 & 0,32 \\ -0,08 & -0,73 & 0,60 & -0,32 \\ 0,86 & 0,17 & 0,08 & -0,48 \\ 0,36 & 0,08 & 0,55 & 0,75 \end{pmatrix}$$

Componentes Principales: Aplicaciones y Ejemplos

③ Proporción: 92,46 97,77 99,48 100,00

④ Por lo tanto,

$$\begin{aligned} Y_1 = & 0,36(X_1 - \bar{X}_1) - 0,08(X_2 - \bar{X}_2) \\ & + 0,86(X_3 - \bar{X}_3) + 0,36(X_4 - \bar{X}_4) \end{aligned}$$

$$\begin{aligned} Y_2 = & -0,66(X_1 - \bar{X}_1) - 0,73(X_2 - \bar{X}_2) \\ & + 0,17(X_3 - \bar{X}_3) + 0,08(X_4 - \bar{X}_4) \end{aligned}$$

Ejercicio: Realizar el mismo análisis con la matriz de correlación.

Componentes Principales: Aplicaciones y Ejemplos




Figura 1: Primera versus Segunda Componente de la data iris

¿Alguna consulta?

L. Kaufman, P. J. Rousseeuw. *Finding Groups in Data: An Introduction to Cluster Analysis*. John Wiley & Sons, 2005.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.