

Aprendizaje No Supervisado

Clase 5

Jonathan Acosta

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre, 2026



- 1 Mean Shift
 - Estimación de Densidad por Kernel
 - Metodología del Mean Shift

- 2 DBScan

Mean Shift

- Propuesto por Fukunaga & Hostetler (1975).
- Esta basado en localizar los máximos de una función de densidad.
- Es una técnica de agrupación no paramétrica que no requiere un conocimiento previo del número de conglomerados y no restringe la forma de los mismos.
- Es un procedimiento iterativo que desplaza cada punto de datos a la media de los puntos de datos en su vecindad.
- Mean Shift es un algoritmo de escalada de colinas que implica el desplazamiento iterativo de este núcleo a una región de mayor densidad en cada paso hasta la convergencia.
- Para desarrollar la idea anterior se necesita la definición de un Kernel (multivariado circular), el cual nos permitirá tener un estimador para la media del grupo.

Estimación de Densidad por Kernel

- Sea X una variable aleatoria, tal que $Rec(X) \subset \mathbb{R}$, un estimador natural de la densidad de X en el punto x_0 es:

$$\hat{f}_X(x_0) = \frac{\#\{x_i : x_i \in V(x_0)\}}{\lambda n} = \frac{\#x_i \in (x_0 - \lambda/2; x_0 + \lambda/2]}{\lambda n}$$

donde $V(x_0)$ es una vecindad métrica de x_0 con ancho λ , y n la cantidad total de observaciones.

- Considere la función

$$K(x) = \begin{cases} 1; & -\frac{1}{2} \leq x < \frac{1}{2} \\ 0; & \text{otro caso} \end{cases} \Rightarrow \hat{f}_X(x_0) = \frac{1}{\lambda n} \sum_{i=1}^n K\left(\frac{x_0 - x_i}{\lambda}\right)$$

Este último es conocido como estimador de Kernel de caja de la densidad.

Estimación de Densidad por Kernel

- La función K anterior puede ser extendida a cualquier función que cumpla con:

$$K(x) \geq 0 \quad \forall x \in \mathbb{R}; \quad K(x) = K(-x); \quad \int_{-\infty}^{\infty} K(x) dx = 1$$

Es decir, una función de densidad simétrica en el origen.

- Algunos ejemplos de Kernel son

Gaussiano $K(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in \mathbb{R}$


Triangular $K(x) = 1 - |x|, \quad -1 \leq x < 1$

Epanechnikov $K(x) = \frac{3(1 - x^2)}{4}, \quad -1 \leq x < 1$

Estimación de Densidad por Kernel


X : Temperatura diaria, en grados Celsius, a las 14:00 horas en Santiago.

$$\begin{aligned} X_1 &= 23, & X_2 &= 28, & X_3 &= 25, & X_4 &= 26, & X_5 &= 26, & X_6 &= 24, \\ X_7 &= 20, & X_8 &= 29, & X_9 &= 32, & X_{10} &= 31, & X_{11} &= 18, & X_{12} &= 24, \\ X_{13} &= 25, & X_{14} &= 27, & X_{15} &= 27, & X_{16} &= 29, & X_{17} &= 25, & X_{18} &= 30, \\ X_{19} &= 30, & X_{20} &= 28, & X_{21} &= 25, & X_{22} &= 26, & X_{23} &= 26, & X_{24} &= 27 \end{aligned}$$




Estimación de Densidad por Kernel

kernel de caja




N = 24 Bandwidth = 1.156

kernel gaussiano




N = 24 Bandwidth = 1.156

kernel triangular



N = 24 Bandwidth = 1.156

kernel Epanechnikov



N = 24 Bandwidth = 1.156

Kernel Multivariado

Sea $\mathbf{x} = (x_1, \dots, x_p)$ un vector en $\mathbb{R}^p$, se dice que $\mathbf{K}$ es un kernel en $\mathbb{R}^p$, si $\mathbf{K} : \mathbb{R}^p \rightarrow \mathbb{R}$, y satisface:

- $\mathbf{K}(\mathbf{x}) = \mathbf{K}(-\mathbf{x})$.
- $\int_{\mathbb{R}^p} \mathbf{K}(\mathbf{x}) d\mathbf{x} = 1$.

Ejemplos:

- $\mathbf{K}(\mathbf{x}) = K_1(x_1)K_2(x_2) \cdot \dots \cdot K_p(x_p)$
- $\mathbf{K}(\mathbf{x}) = K_0(\|\mathbf{x}\|)$.

Donde $K_0, K_1, \dots, K_p$ son kernel univariados. Claramente existen muchos otros tipos de Kernel.

Definición (profile)

Una función $k : [0, +\infty) \rightarrow [0, +\infty)$ se dice que es un profile, si satisface:

- (i) k es no creciente.
- (ii) k es continua por partes.
- (iii) $\int_0^{+\infty} k(x)dx < +\infty$

Definición (Kernel)

Una función $K : \mathbb{R}^p \rightarrow \mathbb{R}$ se dice que es un Kernel, si existe un profile k tal que

$$K(\mathbf{x}) = k(\|\mathbf{x}\|_2^2)$$

Mean Shift

Sea $D \subset \mathbb{R}^p$ sea un conjunto de datos finito, $w : D \rightarrow (0, +\infty)$ una función de peso, y K un kernel. La media muestral con el Kernel K en $\mathbf{x} \in \mathbb{R}^p$ es definido como

$$m(\mathbf{x}) = \frac{\sum_{\mathbf{y} \in D} K(\mathbf{y} - \mathbf{x})w(\mathbf{y})\mathbf{y}}{\sum_{\mathbf{y} \in D} K(\mathbf{y} - \mathbf{x})w(\mathbf{y})}$$

Sea $T \subset \mathbb{R}^p$ sea un conjunto finito de centros de cluster. La evolución de T en forma de iteraciones esta dada por

$$T \leftarrow m(T) \quad \text{con} \quad m(T) = \{m(\mathbf{y}) : \mathbf{y} \in T\}$$

se denomina **algoritmo de desplazamiento medio**.

Mean Shift: Algoritmo

- 1 Se define una ventana de tamaño arbitrario.
- 2 Se ubica un punto $\mathbf{x}$ en el centro de la ventana y se calcula la media, mediante $m(\mathbf{x})$, correspondiente al conjunto de puntos pertenecientes a la vecindad.
- 3 Se reemplaza el valor del punto por el valor obtenido en el cálculo de la media.
- 4 Seguimos desplazando la ventana corregida de acuerdo con la media hasta que no hay dirección en la que un desplazamiento pueda acomodar más puntos dentro del núcleo.
- 5 Este proceso de pasos se realiza con muchas ventanas hasta que todos los puntos se encuentran dentro de una ventana. A continuación, los puntos de datos se agrupan según la ventana deslizante en la que residen.

Mean Shift

- El algoritmo de desplazamiento de la media es un procedimiento iterativo muy general, hasta el punto de que algunos algoritmos de agrupación conocidos son sus casos especiales.
- El conocido algoritmo k-means es un caso límite del algoritmo de Mean Shift. Sin embargo, a pesar de ser un método muy general, no es muy popular debido el coste computacional, $O(n^2)$ (Cheng, 1995).
- El algoritmo de agrupación de máxima entropía (MEC) (Rose et al., 1990), es otro ejemplo. En este caso T y D son conjuntos separados,

$$G^\beta(\mathbf{x}) = e^{-\beta\|\mathbf{x}\|^2}, \quad (\text{Kernel}) \quad \wedge \quad w(\mathbf{y}) = \frac{1}{\sum_{t \in T} G^\beta(\mathbf{y} - \mathbf{t})}, \quad \mathbf{y} \in D$$


Mean Shift: Ejemplo

Considere las siguientes observaciones


i	1	2	3	4	5	6
x_i	10	8	34	9	46	68
y_i	4	99	44	50	77	30

Utilizar el algoritmo mean shift (sin escalar las variables).

Mean Shift: Ejemplo



Mean Shift: Ejemplo



¿Que se concluye con este ejemplo?

- Propuesto por Martin, et al.(1996).
- **DBSCAN**: Density-based spatial clustering of applications with noise o El agrupamiento espacial basado en densidad de aplicaciones con ruido.
- Es algoritmo de agrupamiento basado en densidad, específicamente, agrupa basándose en la estimación de la distribución de densidad de los nodos correspondientes.
- Tiene ventajas por sobre Mean Shift en tiempo de computo.
- Se debe definir dos parámetros; una distancia ϵ , la cual definirá el conjunto de vecinos de un punto dado. Y un número mínimo de puntos, n_{min} en el vecindario.

DBScan: Algoritmo

- ❶ Comienza con un punto de datos de inicio arbitrario que no ha sido visitado.
- ❷ Si hay un número suficiente de puntos dentro de este vecindario, entonces el proceso de agrupación comienza y el punto de datos actual se convierte en el primer punto del nuevo grupo. De lo contrario, el punto será etiquetado como ruido. El punto se marca como visitado.
- ❸ Para este primer punto en el nuevo clúster, los puntos dentro de su vecindario también pasan a formar parte del mismo clúster. Al cluster deben incluir los vecino de los vecinos.
- ❹ El proceso de pasos 2 y 3 se repite hasta que todos los puntos en el clúster son determinados, es decir, todos los puntos dentro del vecindario del clúster han sido visitados y etiquetados.
- ❺ Una vez que terminamos con el clúster actual, se recupera y procesa un nuevo punto no visitado, lo que conduce al descubrimiento de otro clúster o ruido.

- Este proceso anterior se repite hasta que todos los puntos se marcan como visitados.
- Dado que al final se han visitado todos los puntos, cada uno de ellos se marcará como perteneciente a un clúster o como ruido.
- Permite detectar outlier.
- No es necesario seleccionar el número de clústeres,
- Tiene problemas con datos que presentan los clústeres son de densidad variable, dado que ϵ es fijo.

BDSan: Ejemplo


Considere las siguientes observaciones

i	1	2	3	4	5	6
x_i	10	8	34	9	46	68
y_i	4	99	44	50	77	30

Al utilizar el algoritmo BDSan (sin escalar las variables) con $n_{min} = 2$ y $\epsilon \in \{20, 30, 40, 50\}$ se tiene

	$\epsilon = 20$	$\epsilon = 30$	$\epsilon = 40$	$\epsilon = 50$
Ruido	$\{1, 2, 3, 4, 5, 6\}$	$\{1, 2, 5, 6\}$	$\{1, 2\}$	$\emptyset$
Grupos	$\emptyset$	$\{3, 4\}$	$\{3, 4, 5, 6\}$	$\{1, 2, 3, 4, 5, 6\}$

BDScan: Ejemplo



¿Alguna consulta?

- Cheng, Y. (1995). Mean shift, mode seeking, and clustering. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 17(8):790–799
- Guojun Gan, Chaoqun Ma, and Jianhong Wu (2007) *Data Clustering: Theory, Algorithms, and Applications*, ASA-SIAM Series on Statistics and Applied Probability.
- Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.
- Leonard Kaufman, and Peter J. Rousseeuw (1990) *Finding Groups in Data: An Introduction to Cluster Analysis*, Hoboken, New Jersey: John Wiley & Sons.