

Aprendizaje No Supervisado

Clase 6

Jonathan Acosta

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre, 2026



- 1 Gaussian Mixtures y Expectation Maximization
 - Gaussian Mixtures
 - Expectation Maximization
 - Procedimiento de agrupación basado en modelos
- 2 Descomposición en Valores Singulares (SVD)

- Los algoritmos de clustering también pueden ser basados en modelos de probabilidad, como los modelos de mezcla finita para densidades de probabilidad.
- La idea intuitiva es que cada una de las densidad de probabilidad que se mezclan generan un cluster.
- Por lo tanto, se puede esperar que un método de clustering concreto funcione bien cuando los datos se ajustan al modelo.
- En teoría se pueden utilizar cualquier densidad de probabilidad, pero en particular analizaremos la mezcla de densidades Gaussianas.

Gaussian Mixtures

- **Gaussian Mixtures** es una técnica de agrupamiento basada en modelos de probabilidad.
- Sea $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ un conjunto de observaciones.
- Sea $f_j(\mathbf{x}_i \mid \boldsymbol{\theta}_j)$, $j = 1, \dots, K$; la densidad de una observación $\mathbf{x}_i$ del j -ésimo componente, y K el número de componentes de la mezcla.
- La densidad de la distribución normal multivariada es

$$f_j(\mathbf{x}_i \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}_j|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)^\top \boldsymbol{\Sigma}_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) \right\}$$

donde d es la dimensión de los datos.

Celeux y Govaert (1995) presentan cuatro supuestos comúnmente utilizados en las matrices de varianza de los componentes:

- $\Sigma_1 = \dots = \Sigma_K = \sigma^2 \mathbf{I}$.
- $\Sigma_1 = \dots = \Sigma_K = \text{diag}\{\sigma_1^2, \dots, \sigma_d^2\}$.
- $\Sigma_1 = \dots = \Sigma_K = \Sigma$.
- $\Sigma_1, \dots, \Sigma_K$, sin restricciones.

Para describir la forma de la agrupación, se descompone

$$\Sigma_j = \lambda_j \mathbf{U}_j \mathbf{A}_j \mathbf{U}_j^\top \quad \text{donde} \quad \lambda_j = |\Sigma_j|^{1/d}.$$

La forma de Σ_j se tiene en cuenta en el proceso de estimación.

Gaussian Mixtures

- Mixture likelihood: Consiste en asumir que la función de verosimilitud es la suma de las densidades ponderadas de los componentes.

$$\mathcal{L}(\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K; \tau_1, \dots, \tau_K \mid D) = \prod_{i=1}^n \sum_{j=1}^K \tau_j f_j(\mathbf{x}_i \mid \boldsymbol{\theta}_j)$$

donde $\tau_j \geq 0$ es la probabilidad de que una observación pertenezca a la j -ésima componente y $\sum_{j=1}^K \tau_j = 1$.

- ¿Cómo estimar los $\boldsymbol{\theta}_j$?

En este contexto el **algoritmo EM** es el más utilizado para estimar los parámetros.

Expectation Maximization

- El algoritmo EM es un método estadístico general de estimación de máxima verosimilitud, en presencia de datos incompletos, que puede utilizarse para el propósito de la agrupación.
- Es un método iterativo de estimación que consiste en dos Etapas:
 - **Etapa E:** Se computa la esperanza de la verosimilitud mediante la inclusión de variables latentes como si fueran observables.
 - **Etapa M:** Se computan estimadores de máxima verosimilitud de los parámetros, mediante la maximización de la verosimilitud esperada del paso E.
- La salida de la Etapa M, sirve como entrada para la Etapa E, y así sucesivamente.

Expectation Maximization

- Asuma que $\mathbf{y}$ son los datos observados; y $\mathbf{x}$ los datos no observados directamente (solo observados a través de $\mathbf{y}$)
- $\mathbf{y}$, se denomina la data incompleta; y $\mathbf{x}$ se la data completa.
- Sean $f(\mathbf{x} \mid \boldsymbol{\theta})$ la familia de densidades de muestreo para datos completos, y $g(\mathbf{y} \mid \boldsymbol{\theta})$ la familia de densidades de muestreo para datos incompletos.

$$g(\mathbf{y} \mid \boldsymbol{\theta}) = \int f(\mathbf{x} \mid \boldsymbol{\theta}) d\mathbf{x}$$

- El objetivo del algoritmo EM es encontrar el valor de $\boldsymbol{\theta}$ que maximiza $g(\mathbf{y} \mid \boldsymbol{\theta})$ dado $\mathbf{y}$.

Expectation Maximization

- Sea Q una función definida como

$$Q(\boldsymbol{\theta}' \mid \boldsymbol{\theta}) = \mathbb{E}[\ln(f(\mathbf{x} \mid \boldsymbol{\theta})) \mid \mathbf{y}, \boldsymbol{\theta}]$$

- Entonces la iteración EM (pasar de $\boldsymbol{\theta}^{(i)}$ a $\boldsymbol{\theta}^{(i+1)}$) se define como sigue:
 - Etapas E:** Calcular $Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(i)})$.
 - Etapas M:** Obtener $\boldsymbol{\theta}^{(i+1)} = \operatorname{argmax}_{\boldsymbol{\theta}} Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(i)})$
- En particular, si $f(\mathbf{x} \mid \boldsymbol{\theta})$ es de la forma de la familia exponencial

$$f(\mathbf{x} \mid \boldsymbol{\theta}) = b(\mathbf{x}) \exp \left(\boldsymbol{\theta} t(\mathbf{x})^\top \right) / a(\boldsymbol{\theta}),$$

Entonces,

$$Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(i)}) = -\ln(a(\boldsymbol{\theta})) + \mathbb{E}[\ln(b(\mathbf{x})) \mid \mathbf{y}, \boldsymbol{\theta}^{(i)}] + \boldsymbol{\theta} t^{(i)\top}$$

Procedimiento de agrupación basado en modelos

Dado el conjunto de datos D .

Repetir

- 1 Realizar un agrupamiento de los datos, con c grupos.
- 2 Escoger la forma de la covarianza, digamos M .
- 3 Utilizar la partición del paso anterior para calcular los coeficientes de mezcla, las medias y las covarianzas de cada conglomerado.
- 4 Inicialice los parámetros del algoritmo EM utilizando los valores calculados en el paso anterior y aplique el EM para obtener las estimaciones finales.
- 5 Calcule el valor BIC (o AIC) para este c y M .

Hasta se obtiene el BIC (o AIC) más bajo

Procedimiento de agrupación basado en modelos

- Una vez obtenido el mejor modelo (el número de conglomerados y la forma de la matriz de covarianza), los objetos se agrupan según su probabilidad posterior (Clasificación).
- Sea $\Theta = \{\tau_1, \tau_2, \dots, \tau_{c-1}, \boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_c\}$, los parámetros del modelo, los cuales son estimados usando el algoritmo EM.
- La probabilidad posterior de que un objeto $\mathbf{x}_i$ pertenezca al j -ésimo cluster viene dada por

$$\hat{p}_{ji} = \mathbb{P}[G = j \mid \mathbf{x}_i] = \frac{\hat{\tau}_j \phi(\mathbf{x}_i \mid \hat{\boldsymbol{\mu}}_j, \hat{\boldsymbol{\Sigma}}_j)}{\sum_{s=1}^c \hat{\tau}_s \phi(\mathbf{x}_i \mid \hat{\boldsymbol{\mu}}_s, \hat{\boldsymbol{\Sigma}}_s)}$$

- Finalmente, el cluster j , esta formado por

$$C_j = \{\mathbf{x}_i : \hat{p}_{ji} = \operatorname{argmax}_s \hat{p}_{si}\}$$

Gaussian Mixtures: Ejemplo

Considere las siguientes observaciones

i	1	2	3	4	5	6
x_i	10	8	34	9	46	68
y_i	4	99	44	50	77	30

Al utilizar el 2 Gaussian Mixtures se tiene las siguientes Log-lik

	C1	C2
1	-11.24	21.19
2	-10.02	-45144999999978.81
3	-8.38	-10879999999978.81
4	-8.81	-10584999999978.81
5	-8.57	-33124999999978.81
6	-10.09	-20199999999978.81

Por lo tanto, los grupos son: $G_1 = \{2, 3, 4, 5, 6\}$ y $G_2 = \{1\}$.

Gaussian Mixtures: Ejemplo

Al utilizar 3 Gaussian Mixture se tiene las siguientes Log-lik

	C1	C2	C3
1	-12.35	21.19	-45144999999978.80
2	-12.89	-45144999999978.81	21.19
3	-7.83	-10879999999978.81	-18504999999978.80
4	-8.74	-10584999999978.81	-12009999999978.81
5	-9.01	-33124999999978.81	-9639999999978.81
6	-9.35	-20199999999978.81	-41804999999978.80

Por lo tanto, los grupos son:

$$G_1 = \{3, 4, 5, 6\}, G_2 = \{1\}, \text{ y } G_3 = \{2\}.$$

Descomposición en Valores Singulares

Definición (Valores Singulares)

Sea $\mathbf{A}$ una matriz $n \times m$, los **valores singulares** de $\mathbf{A}$, son la raíz cuadrada de los valores propios de la matriz $\mathbf{A}^\top \mathbf{A}$, cuya notación estándar es $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m$. Sin embargo en estadística se suelen denotar por $d_1 \geq d_2 \geq \dots \geq d_m$

Definición (Descomposición en Valores Singulares)

Sea $\mathbf{A}$ una matriz $n \times m$, ($n > m$), entonces existe una factorización de la forma

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

con $\mathbf{U} \in \mathbb{R}^{n \times m}$, $\mathbf{V} \in \mathbb{R}^{m \times m}$ ortogonales y $\mathbf{D} \in \mathbb{R}^{m \times m}$ una matriz formada con los Valores Singulares de $\mathbf{A}$ en su diagonal principal ordenados de mayor a menor.

Descomposición en Valores Singulares

- Sea $\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)^\top$ una matriz de dimensión $n \times p$.
- Suponga que $\text{rango}(\mathbf{X}) = p$.
- Considere el modelo lineal, de rango q , para representar $\mathbf{X}$, como

$$f(\boldsymbol{\lambda}) = \boldsymbol{\mu} + \mathbf{V}_q \boldsymbol{\lambda}$$

donde $\boldsymbol{\mu} \in \mathbb{R}^p$ es la localización, $\mathbf{V}_q$ es una matriz de orden $p \times q$, con q vectores unitarios ortogonales como columnas, y $\boldsymbol{\lambda}$ es un vector de q parámetros.

- Ajustar este modelo a los datos por mínimos cuadrados equivale a

$$\min_{\boldsymbol{\mu}, \boldsymbol{\lambda}, \mathbf{V}_q} \|\mathbf{x}_i - \boldsymbol{\mu} - \mathbf{V}_q \boldsymbol{\lambda}_i\|^2$$

Descomposición en Valores Singulares

- Resolviendo el problema con respecto a $\boldsymbol{\mu}$ y λ , se tiene

$$\begin{aligned}\hat{\boldsymbol{\mu}} &= \bar{\mathbf{x}} \\ \hat{\lambda}_i &= \mathbf{V}_q^\top (\mathbf{x}_i - \bar{\mathbf{x}})\end{aligned}$$

- Para encontrar la matriz ortogonal $\mathbf{V}_q$:

$$\min_{\mathbf{V}_q} \|\mathbf{x}_i - \bar{\mathbf{x}} - \mathbf{V}_q \mathbf{V}_q^\top (\mathbf{x}_i - \bar{\mathbf{x}})\|^2$$

- Sin pérdida de generalidad podemos asumir $\bar{\mathbf{x}} = \mathbf{0}$. Mientras que la matriz $\mathbf{H} = \mathbf{V}_q \mathbf{V}_q^\top$ es una matriz de proyección.

Descomposición en Valores Singulares

- El problema anterior se resuelve realizando la SVD de $\mathbf{X}$, es decir,

$$\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$$

- Para cada rango q , la solución $\mathbf{V}_q$ está formada por las primeras q columnas de $\mathbf{V}$.
- Las columnas de $\mathbf{U}\mathbf{D}$ se denominan componentes principales de $\mathbf{X}$.
- Finalmente, los n valores $\hat{\lambda}_i$ óptimos, están dados por las primeras q componentes principales, es decir, las n filas de la matriz $\mathbf{U}_q\mathbf{D}_q$.

Descomposición en Valores Singulares

Aplicación 1 (Compresión de imágenes). Una de las principales aplicaciones de la SVD es su utilización en la compresión de imágenes digitales de modo que puedan ser transmitidas de manera eficiente por medios electrónicos (internet, satélite, etc).

Aplicación 2 (Dígitos escritos a mano). Al tener una serie de imágenes de un mismo dígito, es posible utilizar la SVD para caracterizar las diferentes formas de escribir un mismo dígito.

- Notar que el caso anterior corresponde a $n \ll p$, ya que p es la dimensión de la imagen y n la cantidad de ellas.
- Para resolver el problema se calculan los valores propios de $\mathbf{X}\mathbf{X}^\top$.

¿Alguna consulta?

- Leonard Kaufman, and Peter J. Rousseeuw (1990) *Finding Groups in Data: An Introduction to Cluster Analysis*, Hoboken, New Jersey: John Wiley & Sons.
- Guojun Gan, Chaoqun Ma, and Jianhong Wu (2007) *Data Clustering: Theory, Algorithms, and Applications*, ASA-SIAM Series on Statistics and Applied Probability.
- Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.
- Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.
- R. Agrawal, T. Imielinski, A. Swami (1993) *Mining Association Rules Between Sets of Items in Large Databases*, SIGMOD Conference, 207-216