

Aprendizaje No Supervisado

Clase 7

Jonathan Acosta

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre, 2026



- 1 Reglas de Asociación
 - El algoritmo Apriori
 - Evaluación de las Reglas
- 2 Introducción a la Modelización de Documentos
 - Bad of Words

Reglas de Asociación

Agrawal et al. (1993) define una regla de asociación, se define como una implicación del tipo:

$$\text{“si } X \text{ entonces } Y\text{”} \quad \text{o bien} \quad X \Rightarrow Y$$

donde X se denomina antecedente e Y consecuente, tal que $X \cap Y = \emptyset$.

Desde una perspectiva general, existen dos conjuntos:

- $I = \{i_1, i_2, \dots, i_n\}$ un conjunto de n atributos binarios llamados items.
- $D = \{t_1, t_2, \dots, t_m\}$ un conjunto de transacciones almacenadas en una base de datos.

Así $X, Y \subseteq I$ y cada transacción en D tiene un ID (identificador) único y contiene un subconjunto de items de I .

Objetivo: Determinar aquellos “ X ” que impliquen “ Y ” con una alta confianza.

Reglas de Asociación

Ejemplo: Imagine que tiene la información de una tienda, donde usted conoce el detalle de los artículos comprados de cada boleta. Un caso particular podría ser:

- Boleta 1: “a”, “b”, “c”, “e”.

- Boleta 2: “a”, “b”.

- Boleta 3: “a”, “b”, “d”.

- Boleta 4: “c”, “e”.

- Boleta 5: “a”, “b”, “d”, “e”.

- Boleta 6: “b”, “d”, “e”.

- Boleta 7: “a”, “b”, “e”.

Note que:

a	b	c	d	e
5	6	2	3	5

De las boletas anteriores (también denominadas transacciones), podemos hacernos preguntas como:

- Si una persona comprar el artículo “a” cual es la confianza que compre “b”.
- Si una persona comprar los artículos “a” y “b” cual es la confianza que compre “d” y “e”.

Para poder responder a las preguntas anteriores, se necesitan los conceptos de Soporte y Confianza.

Definición (Soporte)

Corresponde a la probabilidad de un ítem o conjunto de ítems (itemset). Se denota por *supp*.

Ejemplos:

- $supp(\{a\}) = \frac{5}{7}$ ($\{a\}$ aparece en 5 de las 7 transacciones).
- $supp(\{a, b\}) = \frac{5}{7}$ ($\{a, b\}$ aparece en 5 de las 7 transacciones).

Definición (Confianza)

Corresponde la probabilidad condicional del ítemset Y dado el ítemset X , es decir, $\mathbb{P}[Y \mid X]$. Se denota por

$$\text{conf}(X \Rightarrow Y) = \frac{\text{supp}(\{Y, X\})}{\text{supp}(\{X\})}$$

Ejemplo: $\text{conf}(\text{"a entonces b"}) = 1$, ya que

$$\text{supp}(\{a, b\}) = \frac{5}{7} \quad \wedge \quad \text{supp}(\{a\}) = \frac{5}{7}$$

Obs.: Note que $\text{conf}(X \Rightarrow Y)$ y $\text{conf}(Y \Rightarrow X)$ no necesariamente son iguales.

- Buscar todas las reglas de asociación es complejo computacionalmente.
- Solo se buscan aquellas que tienen un soporte mínimo y una confianza mínima.
- Incluso lo anterior puede ser complejo computacionalmente.
- Para resolver el problema existe varios algoritmos que buscan identificar las mejores reglas. Entre estos se encuentran:
 - El algoritmo Apriori
 - El algoritmo Eclat

El algoritmo Apriori

- Realiza una búsqueda por nivel, desechando las reglas infrecuentes en cada etapa.
- Comienza analizando los singleton y solo se queda con aquellos que tienen un soporte mínimo.
- Cuando encuentra un itemset infrecuente, lo desecha y también cualquier itemset posterior que lo contenga.

El algoritmo Apriori

Ejemplo: Considerando el ejemplo anterior, suponga que se fija un soporte mínimo de 0.5 (50 %) y una confianza mínima es 0.8 (80 %).

En primer lugar se analiza el soporte de forma individual:

a	b	c	d	e
0.7142857	0.8571429	0.2857143	0.4285714	0.7142857

- Por lo tanto, son infrecuente los items $\{c\}$ y $\{d\}$.
- Así, cualquier otro conjunto (itemsets) que los contenga dichos ítems será infrecuente.

El algoritmo Apriori

Ahora se procede analizar los itemset de dos elementos

itemset	frecuencia	supp
$\{a,b\}$	5	0.7142857
$\{a,e\}$	3	0.4285714
$\{b,e\}$	4	0.5714286
$\{a,c\}$	1	0.1428571

- Son frecuentes $\{a,b\}$ y $\{b,e\}$.
- Note que $\{a, c\}$ es infrecuente, ya se sabía porque $\{c\}$ es infrecuente.

Finalmente, se procede analizar los itemset de tres elementos

itemset	frecuencia	supp
$\{a,b,e\}$	3	0.4285714

- Es infrecuente.

El algoritmo Apriori

Con los itemsets frecuentes encontrados se procede a calcular las reglas de asociación:

- Por cada itemset frecuente I , obtener todos los posibles subsets de I .
Para cada subset s de I , crear la regla $s \Rightarrow (I - s)$.
- Descartar todas las reglas que no superen un mínimo de confianza.

itemset	frecuencia	supp
$\{a,b\}$	$a \Rightarrow b$	1.0000
$\{a,b\}$	$b \Rightarrow a$	0.8333
$\{b,e\}$	$b \Rightarrow e$	0.6667
$\{b,e\}$	$e \Rightarrow b$	0.8000

Luego las reglas que tienen una confianza mayor al 80 %, son:

$$a \Rightarrow b \quad b \Rightarrow a \quad e \Rightarrow b$$

Evaluación de las Reglas

- **Lift:** el estadístico lift compara la frecuencia observada de una regla con la frecuencia esperada simplemente por azar (si la regla no existe realmente). Es decir

$$lift(X \Rightarrow Y) = \frac{supp(X \cup Y)}{supp(X) * supp(Y)} = \frac{conf(X \Rightarrow Y)}{soporte(Y)}$$

Cuanto más se aleje el valor de lift de 1, más evidencias de que la regla no se debe a un artefacto aleatorio, es decir, mayor la evidencia de que la regla representa un patrón real.

- **Coverage:** es el soporte de la parte izquierda de la regla (antecedente). Se interpreta como la frecuencia con la que el antecedente aparece en el conjunto de transacciones.

Evaluación de las Reglas

- **Fisher exact test:** devuelve el p-value asociado a la probabilidad de observar la regla solo por azar.

Obs.: Para las tablas de 2×2 , la hipótesis nula de independencia condicional es equivalente a la hipótesis de que los odds ratio es igual a uno.

Ejemplo: Considerando el ejemplo anterior

Regla	soporte	confianza	coverage	lift	Fisher(p-value)
$\{a\} \Rightarrow \{b\}$	0.7143	1.0000	0.7143	1.1667	0.2857
$\{b\} \Rightarrow \{a\}$	0.7143	0.8333	0.8571	1.1667	0.2857
$\{e\} \Rightarrow \{b\}$	0.5714	0.8000	0.7143	0.9333	1.0000

Evaluación de las Reglas

- En este contexto, es frecuente encontrarnos con muchas reglas, por lo que es conveniente ordenarlas, donde, por lo general, se ordenan por soporte.
- También es común realizar filtrado de reglas que contengan algún ítem específico, ya sea en el antecedente, consecuente o alguno de los dos.
- Adicionalmente, podemos encontrarnos con reglas que no entregan mayor aporte en el sentido que estas están incluidas en otras reglas, estas se denominan reglas redundante.
- Finalmente, las reglas que entregan mayor información se denominan reglas maximales.

Evaluación de las Reglas

Definición (Reglas Maximales)

Un itemset es maximal si no existe otro itemset que sea su superset. Una regla de asociación se define como regla maximal si está generada con un itemset maximal.

Definición (Reglas Redundantes)

Suponga que una regla tiene en su antecedente los mismos ítems que forman el antecedente de la otra, junto con algunos ítems adicionales. La regla más genérica se considera redundante, ya que no aporta información adicional. Es decir,

- $X \Rightarrow Y$ es redundante si existe un subset X' tal que:

$$\text{conf}(X' \Rightarrow Y) \geq \text{conf}(X \Rightarrow Y).$$

Ejemplo: En el ejemplo anterior, todas las reglas son maximales y no existen reglas redundantes.

Bad of Words

- El Bag of Words es una técnica de minería de texto.
- La minería de texto es el proceso de extraer información procesable del texto.
- Bag of Words representa una forma de contar términos, o n-grams, en una colección de documentos.
- Bag of Words puede ser tan simple o compleja como desee.
- La complejidad surge tanto en la decisión de cómo diseñar el vocabulario de palabras conocidas (o fichas) como en la forma de puntuar la presencia de palabras conocidas.
- El Bag of Words busca determinar características comunes de diferentes textos.




Bag of Words

Ejemplo: Considere el texto, del libro Hands-On Machine Learning with R:

- `text1` = “We intend this work to be a practitioner’s guide to the machine learning process and a place where one can come to learn about the approach and to gain intuition about the many commonly used, modern, and powerful methods accepted in the machine learning community.”
- `text2` = “If you are familiar with the analytic methodologies, this book may still serve as a reference for how to work with the various R packages for implementation.”
- `text3` = “While an abundance of videos, blog posts, and tutorials exist online, we have long been frustrated by the lack of consistency, completeness, and bias towards singular packages for implementation. This is what inspired this book.”

¿Como extraer información de estos textos?

Bag of Words



Bag of Words

- El primer paso del BoW es individualizar cada palabra dentro de cada texto. Este proceso se denomina **tokenización**.
- El siguiente paso es crear un vocabulario de todas las palabras únicas que aparecen en todos los documentos del conjunto de entrenamiento.
- Finalmente se vectorizan las palabras.
- Sin embargo, notar que palabras como “This” y “this” son diferentes, por la mayúscula.
- Signos de puntuación como “.” son palabras dentro de un texto.
- Como se puede apreciar es necesario limpiar los textos antes de identificar los elementos más frecuentes.



Algunas prácticas útiles para limpiar los textos son:

- Elimine todo el texto entre corchetes (p. Ej., “Es (tan) genial” se convierte en “Es genial”)
- Reemplazar los números con sus equivalentes de palabras (por ejemplo, “2” se convierte en “dos”)
- Reemplazar las abreviaturas con sus equivalentes de texto completo (por ejemplo, “Sr” se convierte en “Senior”)
- Convertir las contracciones a sus palabras básicas (por ejemplo, “shouldn’t” se convierte en “should not”).
- Reemplazar los símbolos comunes con sus equivalentes de palabras (por ejemplo, “\$” se convierte en “dólar”).

- Adicional, a las recomendaciones anteriores, es frecuente eliminar del análisis las **palabra vacías**.
- Las palabras vacías son aquellas que por si solas no tienen un sentido, ejemplo de estas son los pronombres.
- En la mayoría de los de los software existen vocabularios con estas palabras vacías. Naturalmente, los vocabularios dependen del idioma en que se está trabajando.
- Ahora se esta en condiciones de crear un Corpus. Un corpus es una colección de documentos.
- El corpus permite la vectorización de las palabras.
- Incluso, después de creado el corpus, es posible limpiar las palabras.

Bag of Words

La palabras mas frecuentes, considerando todos los textos, son:



Matrices Documento-Término: La matriz documento-término (a veces denominada TDM, por sus siglas en inglés) permite visualizar la frecuencia de las palabras de cada texto del Corpus.

Estas matrices permiten realizar un análisis descriptivo del documento.

Considerando el ejemplo inicial se tiene

Bag of Words

	text 1	text 2	text 3
abundance	0	0	1
accepted	1	0	0
analytic	0	1	0
approach	1	0	0
bias	0	0	1
blog	0	0	1
book	0	1	1
can	1	0	0
come	1	0	0
commonly	1	0	0
community	1	0	0
completeness	0	0	1
consistency	0	0	1
exist	0	0	1
familiar	0	1	0
frustrated	0	0	1
gain	1	0	0
guide	1	0	0
implementation	0	1	1
inspired	0	0	1
intend	1	0	0
intuition	1	0	0
lack	0	0	1
learn	1	0	0
learning	2	0	0

	text 1	text 2	text 3
long	0	0	1
machine	2	0	0
many	1	0	0
may	0	1	0
methodologies	0	1	0
methods	1	0	0
modern	1	0	0
one	1	0	0
online	0	0	1
packages	0	1	1
place	1	0	0
posts	0	0	1
powerful	1	0	0
practitioner's	1	0	0
process	1	0	0
reference	0	1	0
serve	0	1	0
singular	0	0	1
still	0	1	0
towards	0	0	1
tutorials	0	0	1
used	1	0	0
various	0	1	0
videos	0	0	1
work	1	1	0

¿Como medir la asociación entre los 3 textos del corpus?

Una alternativa es considerar la matriz de correlación

$$\begin{array}{l} \text{text 1} \\ \text{text 2} \\ \text{text 3} \end{array} \begin{pmatrix} 1,00 & -0,41 & -0,68 \\ -0,41 & 1,00 & -0,15 \\ -0,68 & -0,15 & 1,00 \end{pmatrix}$$

Sin embargo, en esta literatura es común utilizar la similitud coseno.

No obstante, se puede utilizar cualquier medida de distancia o bien técnicas de agrupamiento si lo que se requiere es crear cluster.

Similitud-Coseno:

- Permite medir la distancia entre los documentos de un Corpus.
- Corresponde a una medida de similitud, así mientras más cercano a 1 los textos son más similares, y mientras más cercano a 0 menos similares (o más disimiles).
- Corresponde al coseno del ángulo entre vectores.
- Si los documentos tuvieran media 0, entonces la similitud coseno es equivalente a la correlación.
- Por lo general, existen librerías que permiten realizar el cálculo de manera directa.

Matriz de Similitud-Coseno:


$$\begin{array}{l} \text{text 1} \\ \text{text 2} \\ \text{text 3} \end{array} \begin{pmatrix} 1,00 & 0,05 & 0,00 \\ 0,05 & 1,00 & 0,20 \\ 0,00 & 0,20 & 1,00 \end{pmatrix}$$

Similitud basada en la correlación:

$$\begin{array}{l} \text{text 1} \\ \text{text 2} \\ \text{text 3} \end{array} \begin{pmatrix} 1,00 & 0,30 & 0,16 \\ 0,30 & 1,00 & 0,42 \\ 0,16 & 0,42 & 1,00 \end{pmatrix}$$

Bag of Words

Desde el punto de vista de visualización, los **Word Cloud** presentan una buena alternativa. Estos se basan en las frecuencias absolutas de las palabras.



Limitaciones de BOW:

- **Significado semántico:** el enfoque básico de BOW no considera el significado de la palabra en el documento. Ignora por completo el contexto en el que se utiliza. La misma palabra se puede usar en varios lugares según el contexto o las palabras cercanas.
- **Tamaño del vector:** para un documento grande, el tamaño del vector puede ser enorme, lo que genera muchos cálculos y tiempo. Es posible que deba ignorar palabras en función de la relevancia para su caso de uso.
- Un problema con la puntuación de la frecuencia de las palabras es que las palabras muy frecuentes comienzan a dominar en el documento (p. ej., una puntuación más alta), pero es posible que no contengan tanto “contenido informativo” para el modelo como las palabras más raras pero quizás específicas del dominio.

Bag of Words

- Un enfoque es volver a escalar la frecuencia de las palabras según la frecuencia con la que aparecen en todos los documentos, de modo que se penalicen las puntuaciones de palabras frecuentes como “el” que también son frecuentes en todos los documentos.
- Este enfoque de puntuación se denomina Frecuencia de término - Frecuencia de documento inversa, o TF-IDF para abreviar, donde:
 - **Frecuencia de término:** es una puntuación de la frecuencia de la palabra en el documento actual.
 - **Frecuencia inversa del documento:** es una puntuación de cuán rara es la palabra en los documentos.
- Las puntuaciones son una ponderación donde no todas las palabras son igual de importantes o interesantes.
- Las puntuaciones tienen el efecto de resaltar palabras que son distintas (contienen información útil) en un documento determinado.

¿Alguna consulta?

Bibliografía

R. Agrawal, T. Imielinski, A. Swami (1993) *Mining Association Rules Between Sets of Items in Large Databases*, SIGMOD Conference, 207-216

Leonard Kaufman, and Peter J. Rousseeuw (1990) *Finding Groups in Data: An Introduction to Cluster Analysis*, Hoboken, New Jersey: John Wiley & Sons.

Guojun Gan, Chaoqun Ma, and Jianhong Wu (2007) *Data Clustering: Theory, Algorithms, and Applications*, ASA-SIAM Series on Statistics and Applied Probability.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.

Blei, David M.; Ng, Andrew Y.; Jordan, Michael I (2003) *Latent Dirichlet*