

EPG4001 - Aprendizaje Supervisado

Clase 2: Regresión Lineal

Jorge Luis Bazán

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



- 1 Regresión Lineal
 - Modelización
 - Estimación
 - Bondad de Ajuste
 - Predicción
 - Inferencia
 - Criterios de Selección de Variables
 - Métodos de Contracción
 - Multicolinealidad
 - Herramientas de diagnóstico

Modelización y Estimación

1. Regresión Lineal

1.1. Modelización

Asuma que Y es continua y suponga que $Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$

Cuya versión matricial es $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, donde

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix} \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- Note que el valor de Y quedará perfectamente especificado en terminos de las X 's si conociéramos los valores de los parámetros β 's.
- El método de mínimos cuadrados proporciona una estrategia para estimar $\boldsymbol{\beta}$ sin tener que realizar supuestos distribucionales.
- Sin embargo, desde el punto de vista estadístico es conveniente asumir un modelo de probabilidad para Y , de modo de poder emplear test de hipótesis que nos discriminan la significancia de cada variable.

1. Regresión Lineal

1.2. Estimación

El método de mínimos cuadrados consiste en minimizar $\sum_{i=1}^n \varepsilon_i^2$ con respecto a β , de donde se obtiene

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

En el caso particular, del modelo de regresión lineal simple (un solo regresor), el estimador se reduce a

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \text{y} \quad \hat{\beta}_1 = \frac{S_{XY}}{S_X^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

Dicho estimador es insesgado y consistente cuando se asume que

$$\mathbb{E}[\varepsilon_i] = 0 \quad \text{y} \quad \mathbb{V}[\varepsilon_i] = \sigma^2$$

En consecuencia,

$$\mathbb{E}[\hat{\beta}] = \beta \quad \text{y} \quad \mathbb{V}[\hat{\beta}] = \sigma_{\beta}^2 = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

Se definen:

- Los valores ajustados como

$$\hat{Y} = \mathbf{X}\hat{\beta}$$

- Los residuos como:

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}}$$

- Un estimador de σ^2 :

$$S_e^2 = \frac{\mathbf{e}^\top \mathbf{e}}{n - p - 1} = \frac{1}{n - p - 1} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

- En consecuencia, un estimador de σ_{β}^2 , es:

$$S_{\beta}^2 = S_e^2 \left(\mathbf{X}^\top \mathbf{X} \right)^{-1}$$

1. Regresión Lineal

1.3. Bondad de Ajuste

Proposición: Los residuos cumplen:

$$\sum_{i=1}^n e_i = 0 \quad \text{y} \quad \sum_{i=1}^n e_i x_{ik} = 0 \quad \text{para cada } k = 1, \dots, p.$$

Obs: La variabilidad de la variable respuesta esta representada por

$$\sum_{i=1}^n (Y_i - \bar{Y})^2$$

Definición Se definen las sumas de cuadrados:

$$SCT = \sum_{i=1}^n (Y_i - \bar{Y})^2 : \text{ Totales}$$

$$SCR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 : \text{ Regresión}$$

$$SCE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 : \text{ Error}$$

Resultado: $SCT = SCR + SCE$.

Definición:

Definición (Coeficiente de Determinación)

El coeficiente de Determinación, se define como:

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}$$

El problema es que R^2 crece a medida que p crece.

Definición (Coeficiente de Determinación Ajustado)

El coeficiente de **Determinación Ajustado**, se define como:

$$R_{adj}^2 = 1 - \frac{SCE/(n - p - 1)}{SCT/(n - 1)}$$

1. Regresión Lineal

1.4. Predicción

Sea $\mathbf{x}_0$ un vector fila con los valores de las covariables, entonces:

Caso 1(Valor Medio): $\hat{Y}_0 = \mathbf{x}_0\hat{\boldsymbol{\beta}}$.

$$\mathbb{E}[\hat{Y}_0] = \mathbf{x}_0\boldsymbol{\beta} = Y_0$$

$$\mathbb{V}[\hat{Y}_0] = \mathbf{x}_0\boldsymbol{\sigma}_{\boldsymbol{\beta}}^2\mathbf{x}_0^\top = \sigma_{\mathbb{E}[Y_0]}^2$$

$$S_{\mathbb{E}[Y_0]}^2 = S_e^2\mathbf{x}_0(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{x}_0^\top$$

Caso 2(Valor Individual): $\hat{Y}_0 = \mathbf{x}_0\hat{\boldsymbol{\beta}} + \varepsilon_0$.

$$\mathbb{E}[\hat{Y}_0] = \mathbf{x}_0\boldsymbol{\beta} = Y_0$$

$$\mathbb{V}[\hat{Y}_0] = \mathbf{x}_0\boldsymbol{\sigma}_{\boldsymbol{\beta}}^2\mathbf{x}_0^\top + \sigma^2 = \sigma_{Y_0}^2$$

$$S_{Y_0}^2 = S_e^2 \left[\mathbf{x}_0(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{x}_0^\top + 1 \right]$$

Ejemplo 1.1: La información obtenida a partir de una muestra de tamaño 12 sobre la relación existente entre la inversión realizada y el rendimiento obtenido en cientos de miles de Euros para la explotación agrícola es la siguiente:

Inv. (X)	11	14	16	15	16	18	20	21	14	20	19	11
Rend. (Y)	2	3	5	6	5	3	7	10	6	10	5	6

Obtenga el modelo de regresión lineal y prediga el valor del rendimiento para una inversión es 8.


Solución: Aplicando las formulas anteriores, se tiene

$$\hat{\beta}_0 = -1,68; \quad \hat{\beta}_1 = 0,45; \quad R^2 = 0,382;$$

- Así la ecuación de regresión es $\hat{Y} = -1,68 + 0,45X$.
- Al evaluar en $X = 8$, se obtiene $Y = 1,94$.
- Notar que $S_e^2 = 4,24$, obteniendo

$$\begin{aligned} S_{\mathbb{E}[Y_0]}^2 &= 2,61 \quad \Rightarrow \quad \text{IC}_{95\%}(Y_0) = 1,94 \mp 3,60 \\ S_{Y_0}^2 &= 6,85 \quad \Rightarrow \quad \text{IC}_{95\%}(Y_0) = 1,94 \mp 5,83 \end{aligned}$$

Predicted Values with Confidence Bands



- En R se puede utilizar la función base `lm()` para realizar la regresión lineal.
- Para construir los intervalos anteriores es necesario asumir un modelo de probabilidad.
- Por lo general se asume que $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.
- La distribución de probabilidad también entrega una herramientas útiles en la selección de modelos.
- Desde un punto de vista técnico, el modelo de regresión lineal tiene varios supuestos, los cuales se requieren que sean verificados.

1. Regresión Lineal

1.5. Inferencia

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \text{ donde asumiremos } \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$$

$$\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta} \quad \text{y} \quad \mathbb{V}[\hat{\boldsymbol{\beta}}] = \sigma^2 \left(\mathbf{X}^\top \mathbf{X} \right)^{-1}$$

$$S_e^2 = \frac{SCE}{n - p - 1} \quad \Rightarrow \quad S_{\boldsymbol{\beta}}^2 = S_e^2 \left(\mathbf{X}^\top \mathbf{X} \right)^{-1}$$

$$\hat{\boldsymbol{\beta}} \sim \mathcal{N}_{p+1} \left(\boldsymbol{\beta}, \sigma^2 \left(\mathbf{X}^\top \mathbf{X} \right)^{-1} \right) \quad \Rightarrow \quad T_j = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{[S_{\boldsymbol{\beta}}^{-2}]_{j+1,j+1}}} \sim t_{n-p-1}$$

donde $[S_{\boldsymbol{\beta}}^{-2}]_{ii}$ es el elemento i -ésimo de la diagonal de la inversa de $S_{\boldsymbol{\beta}}^2$.

Esta distribución nos permite realizar los test-t de significancia de cada parámetro.

Bajo el supuesto de normalidad es posible verificar que los grados de libertad de las respectivas sumas de cuadrados son:

$$SCT \rightsquigarrow n - 1; \quad SCR \rightsquigarrow p; \quad SCE \rightsquigarrow n - p - 1$$

De esta forma se definen la suma de cuadrados medios como

$$MCT = \frac{SCT}{n - 1}; \quad MCR = \frac{SCR}{p}; \quad MCE = \frac{SCE}{n - p - 1}$$

Esto puede ser resumido en una Tabla de Análisis de Varianzas (ANOVA):

Fuente	Suma ²	G. Libertad	Suma ² Medios	Razón F
Regresión	SCR	p	MCR	$F = \frac{MCR}{MCE}$
Error	SCE	n-p-1	MCE	
Total	SCT	n-1	MCT	

Cuadro 1: Representación de Tabla Anova

Finalmente, $F \sim F_{p, n-p-1}$. Esto nos permite tener una idea global sobre la calidad de ajuste del modelo.

Criterios de Selección de Variables

1. Regresión Lineal

1.6. Criterios de Selección de Variables

Es natural pensar que no todas las covariables son significativas en un modelo de Regresión Lineal Múltiple.

Para poder seleccionar las covariables más representativas se pueden usar alguno de los siguientes criterios:

- **Criterio del p-valor de los parámetros del modelo:** Quitar aquellas variables cuyo p-valor sea mayor a la significancia establecida.
- **Criterio del R^2_{ajustado} :** Eliminar aquellas variables que no aporten de manera significativa en este coeficiente, se puede establecer un porcentaje mínimo de mejora.
- **Tabla ANOVA o diferencia de Deviance:** Corresponde a un test de hipótesis que se utiliza para modelos anidados, donde la hipótesis nula establece que el modelo reducido es casi tan bueno como el modelo mayor.

- **Criterio de Información:** Son criterios basados en la verosimilitud, incorporando una penalización, de modo de encontrar un balance entre ajuste y cantidad de parámetros:
 - **AIC:** Criterio de información de Akaike.
 - **BIC:** Criterio de información de Schwartz (o Bayesiano).

Están dados por:

$$AIC = -2\ell(\hat{\boldsymbol{\theta}}) + 2p$$


$$BIC = -2\ell(\hat{\boldsymbol{\theta}}) + \log(n) * p$$

Donde p es el número de parámetros estimados por el modelo. El criterio consiste en después el modelo cuyo AIC o BIC sea menor.

Observaciones:

- Para cualquier criterio de selección se debe proceder de forma iterativa hasta obtener el mejor modelo según el criterio establecido.
- Los métodos de selección a un paso se pueden programar para una selección automatizada. Estos se denominan Stepwise: Backward, Forward o Both.
- En caso de sospechar que varias covariables queden fuera del modelo en un solo paso, se puede usar el test por bloque.
- En R se utiliza la función base *step()*, para ejecutar los métodos de selección automática utilizando AIC o BIC.

Ejemplo (Calentamiento Global): Considere el índice de temperatura media del hemisferio norte desde 1880 hasta 2000.



Suponga que realizamos ajustes a través de regresiones lineales, del tipo polinomial:


$$\text{Modelo 1: } y = \beta_0 + \beta_1 \times t + \varepsilon_t$$

$$\text{Modelo 2: } y = \beta_0 + \beta_1 \times t + \beta_2 \times t^2 + \varepsilon_t$$

$$\text{Modelo 3: } y = \beta_0 + \beta_1 \times t + \beta_2 \times t^2 + \beta_3 \times t^3 + \varepsilon_t$$

- ¿Alguno de los modelos anteriores les parece adecuado?
- ¿Qué modelo propondría usted?

Northern Hemisphere Temperature



¿Qué se puede concluir al respecto?

Según la Tabla ANOVA, se tiene:

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
mod1	119	2.6292				
mod1-mod2	118	2.4663	1	0.162830	7.7865	0.006148 **
mod2-mod3	117	2.4467	1	0.019676	0.9409	0.334042

	AIC	BIC	R^2	R_a^2
mod1	-113.94	-105.55	0.6209	0.6178
mod2	-119.68	-108.49	0.6445	0.6385
mod3	-118.65	-104.67	0.6474	0.6383

Obs.: De estos tres modelos, se concluye que el mejor es el modelo cuadrático.

Ejercicio: Aplicando los otros criterios de selección, ¿se concluirá lo mismo?

Métodos de Contracción

1. Regresión Lineal

1.7. Métodos de Contracción

- El problema de selección de variables adecuadas también puede ser abordado incorporando restricciones sobre los parámetros.
- Estos métodos se denominan métodos de contracción.
- Tener presente que al considerar un subconjunto de predictores y descartar el resto, la selección de subconjuntos produce un modelo interpretable y con un error de predicción posiblemente menor que el modelo completo.
- Sin embargo, como es un proceso discreto -las variables se retiran o se descartan-, suele presentar una varianza elevada, por lo que no reduce el error de predicción del modelo completo.
- En cambio, los métodos de contracción son más continuos y no sufren tanto la alta variabilidad.

- Los métodos de contracción más utilizados son:
 - Regresión Ridge o Regularización L_2
 - Regresión Lasso o Regularización L_1
- En el caso de la regresión Ridge se incorpora una penalización del tipo:

$$\min_{\beta} \left\{ \epsilon^{\top} \epsilon + \frac{\lambda}{2} \sum_{j=1}^p \beta_j^2 \right\} \iff \min_{\beta} \{ \epsilon^{\top} \epsilon \} \text{ s.a. } \sum_{j=1}^p \beta_j^2 \leq t$$

- En el caso de la regresión Lasso se incorpora una penalización del tipo:

$$\min_{\beta} \left\{ \frac{1}{2} \epsilon^{\top} \epsilon + \lambda \sum_{j=1}^p |\beta_j| \right\} \iff \min_{\beta} \{ \epsilon^{\top} \epsilon \} \text{ s.a. } \sum_{j=1}^p |\beta_j| \leq t$$

- En el caso de la regresión Ridge, la solución es explícita cuando se centran las covariables. En este caso $\mathbf{X}$ tiene p columnas (no $p+1$), y los parámetros estimados son

$$\hat{\beta}_0 = \bar{Y} \quad \text{y} \quad \hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^\top \mathbf{Y},$$

donde $\boldsymbol{\beta}^\top = (\beta_1, \dots, \beta_p)$.

- En el caso de la regresión Lasso, los coeficientes $\hat{\beta}_j$ se estiman numéricamente, resolviendo un problema de programación cuadrática.
- En el caso de regresión Lasso, debido a la naturaleza de la restricción, hacer t suficientemente pequeño hará que algunos de los coeficientes sean exactamente cero. Así, este criterio hace una especie de selección continua de subconjuntos.

- Adicionalmente, es posible combinar ambos tipos de regularizaciones, dicho método se denomina **Elastic Net**, donde el problema a resolver es:

$$\min_{\beta} \left\{ \frac{1}{2} \varepsilon^{\top} \varepsilon + \lambda \left(\alpha \sum_{j=1}^p |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^p \beta_j^2 \right) \right\}$$

- En todos los casos el parámetro λ se determina mediante una validación cruzada o bien mediante los grados de libertad que dan cuenta de la complejidad del modelo.
- En R se puede utilizar la función *glmnet*, del paquete *glmnet*, para ejecutar los modelos de regresión contraídos.

El problema de Multicolinealidad

1. Regresión Lineal

1.8. Multicolinealidad

Recordar que

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}, \quad S_{\beta}^2 = S_e^2 (\mathbf{X}^\top \mathbf{X})^{-1}, \quad S_e^2 = \frac{\mathbf{e}^\top \mathbf{e}}{n - p - 1}$$

- Notar que ambos términos dependen de $(\mathbf{X}^\top \mathbf{X})^{-1}$.
- Si las columnas de $\mathbf{X}$ son colineales entonces $(\mathbf{X}^\top \mathbf{X})^{-1}$.
- Si las columnas de $\mathbf{X}$ son aproximadamente colineales (denominado multicolinealidad) entonces $\det(\mathbf{X}^\top \mathbf{X}) \approx 0$.
- En consecuencia, la varianza de $\hat{\beta}$ es muy grande, lo que se conoce como varianza inflada. Además, los parámetros podrían no ser significativos.
- El análisis de multicolinealidad puede permitir descartar algunas variables antes de realizar la selección de modelos.

- Para reparar el problema de la multicolinealidad, se debe quitar del modelo aquella o aquellas variables que son aproximadamente colineales.
- Una estrategia para esto último es pensar en que cada covariable se pueda modelar por el resto de las variables (sin considerar la variable dependiente).
- Se define el Factor de inflación de varianza para la variable x_j , como

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el coeficiente de determinación obtenido al modelar la variable x_j con respecto a las demás covariables.

- Criterio empírico: Descartar aquella covariable con $\text{VIF}_j \geq 10$.

Diagnóstico del Modelo de Regresión Lineal

1. Regresión Lineal

1.9. Herramientas de diagnóstico

La verificación de los supuestos del modelo de regresión se denomina: **Diagnóstico.**

Recordemos que el modelo de regresión lineal tiene los siguientes supuestos:

- 1 Los errores ε_i son independientes.
- 2 Los errores ε_i son homocedásticos.
- 3 Los errores ε_i son normales.
- 4 Las variables predictoras son linealmente independientes.

Cuidado: Para poder interpretar adecuadamente los resultados del modelo de regresión lineal, se deben cumplir obligatoriamente los 4 supuestos anteriores

Prueba de autocorrelación

H_0 : Los errores no presentan autocorrelación

versus

H_1 : Los errores presentan autocorrelacións

- Para una inspección visual es conveniente graficar e_i vs e_{i-1} .
- En el gráfico anterior se debe observar un patrón completamente aleatorio.
- También es posible inspeccionar de forma visual el gráfico de e_i vs e_{i-k} , par avarios valores de k .
- Finalmente tener en cuenta que el orden de las observaciones no importa por lo tanto si puede permutar los residuos y luego realizar las gráficas.
- Algunos test específicos son: Durbin-Watson (`dwtest`) y Breusch-Godfrey (`bgtest`) de la librería *lmtest* y Ljung-Box o Box-Pierce (`Box.test`) de la librería *stats* (funciones base).

Prueba de Homocedasticidad

H_0 : Los errores son homocedásticos

versus

H_1 : Los errores no son homocedásticos

- Para una inspección visual es conveniente graficar $\hat{Y}_i$ vs e_i .
- También es conveniente graficar $\hat{x}_{ji}$ vs e_i .
- En ambos gráficos anteriores se debe observar un patrón completamente aleatorio.
- Las gráficas anteriores pueden ser usadas para dividir la data en dos partes y luego realizar el test de igualdad de varianzas de dos poblaciones normales (`var.test`).
- Algunos test específicos son: Goldfeld-Quandt (`gqtest()`) y Breush-Pagan (`bptest()`), disponibles en el paquete *lmtest*

Prueba de Normalidad

H_0 : La distribución es Normal

versus

H_1 : La distribución no es Normal

- Para una inspección visual es conveniente graficar quantile vs. quantile (`qqplot` - `qqnorm`).
- En el gráfico anterior se traza una linea recta de pendiente 1 que pasa por el origen (`qqline`).
- Se inspecciona si hay desviaciones de sobre la linea recta.
- Algunos test específicos son: Kolmogorov-Smirnov (`ks.test()`) o Shapiro-Wilk (`shapiro.test()`) que son funciones base. Los tests Lilliefors (`lillie.test()`) o Anderson-Darling (`ad.test()`) del paquete *nortest* y Jarque-Bera (`jarque.bera.test()` del paquete *tseries*).

¿Alguna consulta?

Julian J. Faraway (2016) *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*, Boca Raton: Chapman Hall/CRC.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.