

Pontificia Universidad Católica de Chile

**Aprendizaje Supervisado**

**Material complementario**

**Clase1MIApSu.pdf**

**Dr. Jorge Luis Bazán**  
jlbazan@uc.cl

# 1. Introducción

El lenguaje R es ampliamente utilizado en análisis estadístico y ciencia de datos, pues permite organizar, visualizar y procesar grandes conjuntos de datos de manera eficiente mediante herramientas intuitivas y reproducibles. El uso de software especializado facilita la aplicación de métodos estadísticos complejos, reduciendo errores y mejorando la precisión de los resultados, al mismo tiempo que promueve la reproducibilidad y la comunicación clara de los análisis, aspectos fundamentales en la investigación moderna.

Además, existe el entorno RStudio el cual es un entorno de desarrollo integrado diseñado para trabajar con el lenguaje R y se complementa con una amplia variedad de paquetes que extienden sus funcionalidades, permitiendo realizar desde manipulación de datos hasta modelamiento estadístico avanzado y visualización gráfica. Estos paquetes incluyen conjuntos de datos de ejemplo que facilitan el aprendizaje y la experimentación, y también permiten importar información desde múltiples fuentes externas, como archivos CSV, Excel o bases de datos así como también generar reportes estadísticos en formatos como Látex o HTML, lo que hace posible trabajar tanto con datos propios como con datos disponibles dentro del ecosistema del software.

## 2.Instalación de paquetes

Un paquete en RStudio es un conjunto organizado de funciones, datos y documentación que extiende las capacidades básicas del software. Estos paquetes permiten realizar tareas específicas como visualización, modelamiento o manipulación de datos sin tener que programar todo desde cero, facilitando así el trabajo y haciendo más eficiente el análisis estadístico. La instalación de paquetes se puede realizar a través de la sentencia `install.package(Nombredelpaquete)`

Algunos de los paquetes más utilizados en el curso son los siguientes:

```
install.packages("ISLR") #contiene bases de datos a trabajar
install.packages("MASS") #contiene herramientas estadísticas para análisis de regresión
install.packages("tree") #contiene herramientas estadísticas para métodos supervisados
install.packages("class") #contiene herramientas estadísticas para métodos supervisados
install.packages("e1071") #contiene herramientas estadísticas para métodos supervisados
install.packages("mlbench") #contiene bases de datos a trabajar
install.packages("pROC") #contiene herramientas para métodos supervisados y visualización
install.packages("caret") #contiene herramientas estadísticas para métodos supervisados
install.packages("psych")
```

Una vez instalados los paquetes, estos deben ser llamados para poder acceder a todas las funciones y documentación que poseen mediante el comando `library(Nombredelpaquete)`. Sin esta sentencia, las funciones dentro del paquete no se podrán utilizar a pesar de que se encuentre instalado.

```
library(ISLR)
library(MASS)
library(tree)
library(class)
library(e1071)
library(mlbench)
library(pROC)
library(caret)
library(psych)
```

Con esto ya podemos acceder a la información y funcionalidades de cada paquete previamente instalado.

### 3. Bases de datos

A continuación se presentan una serie de bases de datos disponibles en paquetes que serán utilizados para aplicar los métodos de aprendizajes estudiados durante el curso.

#### 3.1 Default Data

El conjunto de datos *Default*, proveniente del paquete *ISLR* es un conjunto de datos sintético que se centra en el comportamiento crediticio, analizando variables clave como el saldo pendiente, los ingresos anuales y el estatus de estudiante del titular. La base de datos consta de 10.000 observaciones organizadas en 4 variables descritas a continuación:

- “default”: Es una variable de tipo factor con 2 niveles (No,Yes) que indica si el cliente incumplió su deuda.
- “student”: Es una variable de tipo factor con 2 niveles (No,Yes) que indica si el cliente es o no estudiante.
- “balance”: Indica el saldo promedio que el cliente tiene en su tarjeta de crédito luego de realizar su pago mensual.
- “income”: Indica el ingreso del cliente.

Estos datos fueron creados para la ilustración de los métodos de clasificación supervisada y no supervisada en Tibshirani, et al (2013).

```
datos2<-Default #Asignamos la base de datos a una variable
head(datos2) #visualización de las 6 primeras filas de la base de datos
```

```
## default student balance income
## 1      No      No  729.5265 44361.625
## 2      No     Yes  817.1804 12106.135
## 3      No      No 1073.5492 31767.139
## 4      No      No  529.2506 35704.494
## 5      No      No  785.6559 38463.496
## 6      No     Yes  919.5885  7491.559
```

```
str(datos2)
```

```
## 'data.frame': 10000 obs. of 4 variables:
## $ default: Factor w/ 2 levels "No","Yes": 1 1 1 1 1 1 1 1 1 1 ...
## $ student: Factor w/ 2 levels "No","Yes": 1 2 1 1 1 2 1 2 1 1 ...
## $ balance: num 730 817 1074 529 786 ...
## $ income : num 44362 12106 31767 35704 38463 ...
```

```
summary(datos2) # Estadísticas descriptivas de las variables de la base de datos
```

```
## default student balance income
## No :9667 No :7056 Min. : 0.0 Min. : 772
## Yes: 333 Yes:2944 1st Qu.: 481.7 1st Qu.:21340
## Median : 823.6 Median :34553
## Mean : 835.4 Mean :33517
## 3rd Qu.:1166.3 3rd Qu.:43808
## Max. :2654.3 Max. :73554
```

```
describe(datos2)
```

```
##      vars      n      mean      sd      median      trimmed      mad      min
## default*    1 10000      1.03     0.18       1.00       1.00       0.00     1.00
## student*    2 10000      1.29     0.46       1.00       1.24       0.00     1.00
## balance     3 10000    835.37    483.71     823.64     823.73    507.52     0.00
## income      4 10000 33516.98 13336.64 34552.64 33305.57 16350.86 771.97
##           max      range skew kurtosis      se
## default*    2.00      1.00 5.20     25.06     0.00
## student*    2.00      1.00 0.90     -1.19     0.00
## balance    2654.32 2654.32 0.25     -0.36     4.84
## income    73554.23 72782.27 0.07     -0.90    133.37
```

## 3.2 PimaIndiansDiabetes

El conjunto de datos *PimaIndiansDiabetes* se encuentra disponible en la librería *mlbench* y está compuesto por una serie de medidas clínicas específicas sobre mujeres de al menos 21 años de edad, de ascendencia india Pima, que viven cerca de Phoenix, Arizona, EE. UU. La base de datos consta de 768 observaciones organizadas en 9 variables detalladas a continuación:

- “pregnant”’: Número de embarazos
- “glucose”’: Concentración de glucosa en plasma (prueba de tolerancia a la glucosa)
- “pressure”’: Presión arterial diastólica (mm Hg)
- “triceps”’: Grosor del pliegue cutáneo del tríceps (mm)
- “insulin”’: Insulina sérica a las 2 horas (mu U/ml)
- “mass”’: índice de masa corporal
- “pedigree”’: Función del pedigrí de diabetes
- “age”’: Edad en años
- “diabetes”’: Variable categórica con dos categorías (pos,neg) que indica si el paciente resulta positivo a negativo a un test de diabetes.

La fuente original de estos datos es el UCI Machine Learning Repository (Blake y Merz, 1998); posteriormente, a finales de los años 90, Friedrich Leisch realizó la conversión de los archivos al formato compatible con el lenguaje R.

```
data("PimaIndiansDiabetes") # con esto cargamos primero la base de datos
datos1<-PimaIndiansDiabetes # asigamos la base de datos a una variable
head(datos1) #visualización de las 6 primeras filas de la base de datos
```

```
##    pregnant glucose pressure triceps insulin mass pedigree age diabetes
## 1         6     148       72      35        0 33.6    0.627  50      pos
## 2         1      85       66      29        0 26.6    0.351  31      neg
## 3         8     183       64       0        0 23.3    0.672  32      pos
## 4         1      89       66      23       94 28.1    0.167  21      neg
## 5         0     137       40      35      168 43.1    2.288  33      pos
## 6         5     116       74       0        0 25.6    0.201  30      neg
```

```
str(datos1)
```

```
## 'data.frame': 768 obs. of 9 variables:
## $ pregnant: num 6 1 8 1 0 5 3 10 2 8 ...
## $ glucose : num 148 85 183 89 137 116 78 115 197 125 ...
## $ pressure: num 72 66 64 66 40 74 50 0 70 96 ...
## $ triceps : num 35 29 0 23 35 0 32 0 45 0 ...
## $ insulin : num 0 0 0 94 168 0 88 0 543 0 ...
## $ mass : num 33.6 26.6 23.3 28.1 43.1 25.6 31 35.3 30.5 0 ...
## $ pedigree: num 0.627 0.351 0.672 0.167 2.288 ...
## $ age : num 50 31 32 21 33 30 26 29 53 54 ...
## $ diabetes: Factor w/ 2 levels "neg","pos": 2 1 2 1 2 1 2 1 2 2 ...
```

```
summary(datos1) # Estadísticas descriptivas de las variables de la base de datos
```

```
##      pregnant      glucose      pressure      triceps
## Min.   : 0.000   Min.   : 0.0   Min.   : 0.00   Min.   : 0.00
## 1st Qu.: 1.000   1st Qu.: 99.0   1st Qu.: 62.00   1st Qu.: 0.00
## Median : 3.000   Median :117.0   Median : 72.00   Median :23.00
## Mean   : 3.845   Mean   :120.9   Mean   : 69.11   Mean   :20.54
## 3rd Qu.: 6.000   3rd Qu.:140.2   3rd Qu.: 80.00   3rd Qu.:32.00
## Max.   :17.000   Max.   :199.0   Max.   :122.00   Max.   :99.00
##      insulin      mass      pedigree      age      diabetes
## Min.   : 0.0   Min.   : 0.00   Min.   :0.0780   Min.   :21.00   neg:500
## 1st Qu.: 0.0   1st Qu.:27.30   1st Qu.:0.2437   1st Qu.:24.00   pos:268
## Median : 30.5   Median :32.00   Median :0.3725   Median :29.00
## Mean   : 79.8   Mean   :31.99   Mean   :0.4719   Mean   :33.24
## 3rd Qu.:127.2   3rd Qu.:36.60   3rd Qu.:0.6262   3rd Qu.:41.00
## Max.   :846.0   Max.   :67.10   Max.   :2.4200   Max.   :81.00
```

```
describe(datos1)
```

```
##      vars  n  mean    sd median trimmed  mad  min  max range skew
## pregnant  1 768  3.85  3.37  3.00   3.46  2.97  0.00 17.00 17.00  0.90
## glucose   2 768 120.89 31.97 117.00 119.38 29.65  0.00 199.00 199.00  0.17
## pressure  3 768  69.11 19.36  72.00  71.36 11.86  0.00 122.00 122.00 -1.84
## triceps   4 768  20.54 15.95  23.00  19.94 17.79  0.00  99.00  99.00  0.11
## insulin   5 768  79.80 115.24  30.50  56.75 45.22  0.00 846.00 846.00  2.26
## mass      6 768  31.99  7.88  32.00  31.96  6.82  0.00  67.10  67.10 -0.43
## pedigree  7 768   0.47  0.33   0.37   0.42  0.25  0.08   2.42   2.34  1.91
## age       8 768  33.24 11.76  29.00  31.54 10.38 21.00  81.00  60.00  1.13
## diabetes* 9 768   1.35  0.48   1.00   1.31  0.00  1.00   2.00   1.00  0.63
##      kurtosis  se
## pregnant    0.14 0.12
## glucose     0.62 1.15
## pressure    5.12 0.70
## triceps     -0.53 0.58
## insulin     7.13 4.16
## mass        3.24 0.28
## pedigree    5.53 0.01
## age         0.62 0.42
## diabetes*   -1.60 0.02
```

**Nota:** A diferencia de la librería ISLR, en este caso es necesario usar previamente la sentencia `data("PimaIndiansDiabetes")` debido a que las bases de datos disponibles en la librería `mlbench` no se cargan automáticamente en el `workspace`.

### 3.3 Smarket data

El conjunto de datos *Smarket*, proveniente del paquete *ISLR* es un conjunto de datos que registra los rendimientos diarios del índice bursátil S&P 500 durante un periodo de cinco años (desde inicios de 2001 hasta finales de 2005). La base de datos consta de 1250 observaciones organizadas en 9 variables económicas descritas a continuación:

- “Year”’: Año en que se observó el registro.
- “Lag1”’: Rentabilidad porcentual del día anterior.
- “Lag2”’: Rentabilidad porcentual de los 2 días anteriores.
- “Lag3”’: Rentabilidad porcentual de los 3 días anteriores.
- “Lag4”’: Rentabilidad porcentual de los 4 días anteriores.
- “Lag5”’: Rentabilidad porcentual de los 5 días anteriores.
- “Volume”’: Volumen de acciones negociadas (número de acciones diarias negociadas en miles de millones).
- “Today”’: Rentabilidad porcentual del día de hoy.
- “Direction”’: Es una variable tipo factor con 2 niveles (Down,Up) que indica si el mercado tuvo una rentabilidad positiva o negativa en un día determinado.

La información disponible proviene de la plataforma Yahoo Finance y fue sintetizada y arreglada por Tibshirani, et al (2013).

```
datos3<-Smarket
head(datos3) #visualización de las 6 primeras filas de la base de datos
```

|      | Year | Lag1   | Lag2   | Lag3   | Lag4   | Lag5   | Volume | Today  | Direction |
|------|------|--------|--------|--------|--------|--------|--------|--------|-----------|
| ## 1 | 2001 | 0.381  | -0.192 | -2.624 | -1.055 | 5.010  | 1.1913 | 0.959  | Up        |
| ## 2 | 2001 | 0.959  | 0.381  | -0.192 | -2.624 | -1.055 | 1.2965 | 1.032  | Up        |
| ## 3 | 2001 | 1.032  | 0.959  | 0.381  | -0.192 | -2.624 | 1.4112 | -0.623 | Down      |
| ## 4 | 2001 | -0.623 | 1.032  | 0.959  | 0.381  | -0.192 | 1.2760 | 0.614  | Up        |
| ## 5 | 2001 | 0.614  | -0.623 | 1.032  | 0.959  | 0.381  | 1.2057 | 0.213  | Up        |
| ## 6 | 2001 | 0.213  | 0.614  | -0.623 | 1.032  | 0.959  | 1.3491 | 1.392  | Up        |

```
str(datos3)
```

```
## 'data.frame':    1250 obs. of  9 variables:
## $ Year      : num  2001 2001 2001 2001 2001 ...
## $ Lag1     : num  0.381 0.959 1.032 -0.623 0.614 ...
## $ Lag2     : num  -0.192 0.381 0.959 1.032 -0.623 ...
## $ Lag3     : num  -2.624 -0.192 0.381 0.959 1.032 ...
## $ Lag4     : num  -1.055 -2.624 -0.192 0.381 0.959 ...
## $ Lag5     : num   5.01 -1.055 -2.624 -0.192 0.381 ...
## $ Volume   : num   1.19 1.3 1.41 1.28 1.21 ...
## $ Today    : num   0.959 1.032 -0.623 0.614 0.213 ...
## $ Direction: Factor w/ 2 levels "Down","Up": 2 2 1 2 2 2 1 2 2 2 ...
```

```
summary(datos3) # Estadísticas descriptivas de las variables de la base de datos
```

```
##      Year      Lag1      Lag2      Lag3
## Min.   :2001   Min.   :-4.922000   Min.   :-4.922000   Min.   :-4.922000
## 1st Qu.:2002   1st Qu.: -0.639500   1st Qu.: -0.639500   1st Qu.: -0.640000
## Median :2003   Median : 0.039000   Median : 0.039000   Median : 0.038500
## Mean   :2003   Mean   : 0.003834   Mean   : 0.003919   Mean   : 0.001716
## 3rd Qu.:2004   3rd Qu.: 0.596750   3rd Qu.: 0.596750   3rd Qu.: 0.596750
## Max.   :2005   Max.   : 5.733000   Max.   : 5.733000   Max.   : 5.733000
##      Lag4      Lag5      Volume      Today
## Min.   :-4.922000   Min.   :-4.922000   Min.   :0.3561   Min.   :-4.922000
## 1st Qu.: -0.640000   1st Qu.: -0.640000   1st Qu.:1.2574   1st Qu.: -0.639500
## Median : 0.038500   Median : 0.038500   Median :1.4229   Median : 0.038500
## Mean   : 0.001636   Mean   : 0.00561    Mean   :1.4783   Mean   : 0.003138
## 3rd Qu.: 0.596750   3rd Qu.: 0.59700    3rd Qu.:1.6417   3rd Qu.: 0.596750
## Max.   : 5.733000   Max.   : 5.73300    Max.   :3.1525   Max.   : 5.733000
## Direction
## Down:602
## Up :648
##
##
##
##
```

```
describe(datos3)
```

```
##      vars    n   mean   sd median trimmed  mad    min    max range
## Year      1 1250 2003.02 1.41 2003.00 2003.02 1.48 2001.00 2005.00 4.00
## Lag1      2 1250    0.00 1.14    0.04    0.00 0.91   -4.92    5.73 10.65
## Lag2      3 1250    0.00 1.14    0.04    0.00 0.91   -4.92    5.73 10.65
## Lag3      4 1250    0.00 1.14    0.04    0.00 0.91   -4.92    5.73 10.65
## Lag4      5 1250    0.00 1.14    0.04    0.00 0.91   -4.92    5.73 10.65
## Lag5      6 1250    0.01 1.15    0.04    0.00 0.92   -4.92    5.73 10.65
## Volume     7 1250    1.48 0.36    1.42    1.45 0.28    0.36    3.15  2.80
## Today      8 1250    0.00 1.14    0.04    0.00 0.91   -4.92    5.73 10.65
## Direction* 9 1250    1.52 0.50    2.00    1.52 0.00    1.00    2.00  1.00
##
##      skew kurtosis    se
## Year   -0.01    -1.29 0.04
## Lag1    0.20     2.38 0.03
## Lag2    0.20     2.38 0.03
## Lag3    0.19     2.36 0.03
## Lag4    0.19     2.36 0.03
## Lag5    0.25     2.48 0.03
## Volume  0.82     1.44 0.01
## Today   0.20     2.38 0.03
## Direction* -0.07    -2.00 0.01
```

### 3.4 Vehicle data

La base de datos *Vehicle* se encuentra disponible en la librería *mlbench* y está compuesta por un conjunto de características extraídas las siluetas de cuatro tipos de vehículos. La base está compuesta de 846 observaciones en 19 variables, todas numéricas y una nominal que define la clase de los objetos.

- Comp: Compacidad de la silueta
- Circ: Circularidad de la silueta
- D.Circ: Distancia de circularidad
- Rad.Ra: Razón de radios
- Pr.Axis.Ra: Razón de aspecto del eje principal
- Max.L.Ra: Razón de aspecto de la longitud máxima
- Scat.Ra: Razón de dispersión
- Elong: Elongación de la silueta
- Pr.Axis.Rect: Rectangularidad del eje principal
- Max.L.Rect: Rectangularidad de la longitud máxima
- Sc.Var.Maxis: Varianza escalada a lo largo del eje mayor
- Sc.Var.maxis: Varianza escalada a lo largo del eje menor
- Ra.Gyr: Radio de giro escalado
- Skew.Maxis: Asimetría respecto al eje mayor
- Skew.maxis: Asimetría respecto al eje menor
- Kurt.maxis: Curtosis respecto al eje menor
- Kurt.Maxis: Curtosis respecto al eje mayor
- Holl.Ra: Razón de cavidades
- Class: Variable categórica que indica el tipo de vehículo, el cual puede ser van, saab, bus u opel.

Los datos fueron generados originalmente por el Turing Institute en Glasgow (Escocia) en 1987 para un proyecto de investigación sobre reconocimiento de objetos.

```
data("Vehicle")
datos4<-Vehicle # asigamos la base de datos a una variable
head(datos4) #visualización de las 6 primeras filas de la base de datos
```

| ##   | Comp       | Circ         | D.Circ       | Rad.Ra | Pr.Axis.Ra | Max.L.Ra   | Scat.Ra    | Elong | Pr.Axis.Rect |
|------|------------|--------------|--------------|--------|------------|------------|------------|-------|--------------|
| ## 1 | 95         | 48           | 83           | 178    | 72         | 10         | 162        | 42    | 20           |
| ## 2 | 91         | 41           | 84           | 141    | 57         | 9          | 149        | 45    | 19           |
| ## 3 | 104        | 50           | 106          | 209    | 66         | 10         | 207        | 32    | 23           |
| ## 4 | 93         | 41           | 82           | 159    | 63         | 9          | 144        | 46    | 19           |
| ## 5 | 85         | 44           | 70           | 205    | 103        | 52         | 149        | 45    | 19           |
| ## 6 | 107        | 57           | 106          | 172    | 50         | 6          | 255        | 26    | 28           |
| ##   | Max.L.Rect | Sc.Var.Maxis | Sc.Var.maxis | Ra.Gyr | Skew.Maxis | Skew.maxis | Kurt.maxis |       |              |
| ## 1 | 159        | 176          | 379          | 184    | 70         | 6          | 16         |       |              |
| ## 2 | 143        | 170          | 330          | 158    | 72         | 9          | 14         |       |              |
| ## 3 | 158        | 223          | 635          | 220    | 73         | 14         | 9          |       |              |
| ## 4 | 143        | 160          | 309          | 127    | 63         | 6          | 10         |       |              |
| ## 5 | 144        | 241          | 325          | 188    | 127        | 9          | 11         |       |              |
| ## 6 | 169        | 280          | 957          | 264    | 85         | 5          | 9          |       |              |
| ##   | Kurt.Maxis | Holl.Ra      | Class        |        |            |            |            |       |              |



```
## 1      187      197   van
## 2      189      199   van
## 3      188      196  saab
## 4      199      207   van
## 5      180      183   bus
## 6      181      183   bus
```

```
str(datos4)
```

```
## 'data.frame':      846 obs. of  19 variables:
## $ Comp      : num  95 91 104 93 85 107 97 90 86 93 ...
## $ Circ      : num  48 41 50 41 44 57 43 43 34 44 ...
## $ D.Circ    : num  83 84 106 82 70 106 73 66 62 98 ...
## $ Rad.Ra    : num  178 141 209 159 205 172 173 157 140 197 ...
## $ Pr.Axis.Ra : num  72 57 66 63 103 50 65 65 61 62 ...
## $ Max.L.Ra   : num  10 9 10 9 52 6 6 9 7 11 ...
## $ Scat.Ra    : num  162 149 207 144 149 255 153 137 122 183 ...
## $ Elong      : num  42 45 32 46 45 26 42 48 54 36 ...
## $ Pr.Axis.Rect : num  20 19 23 19 19 28 19 18 17 22 ...
## $ Max.L.Rect : num  159 143 158 143 144 169 143 146 127 146 ...
## $ Sc.Var.Maxis : num  176 170 223 160 241 280 176 162 141 202 ...
## $ Sc.Var.maxis : num  379 330 635 309 325 957 361 281 223 505 ...
## $ Ra.Gyr     : num  184 158 220 127 188 264 172 164 112 152 ...
## $ Skew.Maxis : num  70 72 73 63 127 85 66 67 64 64 ...
## $ Skew.maxis : num  6 9 14 6 9 5 13 3 2 4 ...
## $ Kurt.maxis : num  16 14 9 10 11 9 1 3 14 14 ...
## $ Kurt.Maxis : num  187 189 188 199 180 181 200 193 200 195 ...
## $ Holl.Ra    : num  197 199 196 207 183 183 204 202 208 204 ...
## $ Class      : Factor w/ 4 levels "bus","opel","saab",...: 4 4 3 4 1 1 1 4 4 3 ...
```

```
summary(datos4) # Estadísticas descriptivas de las variables de la base de datos
```

```
##           Comp           Circ           D.Circ           Rad.Ra
## Min.      : 73.00   Min.      :33.00   Min.      : 40.00   Min.      :104.0
## 1st Qu.: 87.00   1st Qu.:40.00   1st Qu.: 70.00   1st Qu.:141.0
## Median : 93.00   Median :44.00   Median : 80.00   Median :167.0
## Mean      : 93.68   Mean      :44.86   Mean      : 82.09   Mean      :168.9
## 3rd Qu.:100.00   3rd Qu.:49.00   3rd Qu.: 98.00   3rd Qu.:195.0
## Max.      :119.00   Max.      :59.00   Max.      :112.00   Max.      :333.0
## Pr.Axis.Ra   Max.L.Ra   Scat.Ra   Elong
## Min.      : 47.00   Min.      : 2.000   Min.      :112.0   Min.      :26.00
## 1st Qu.: 57.00   1st Qu.: 7.000   1st Qu.:146.2   1st Qu.:33.00
## Median : 61.00   Median : 8.000   Median :157.0   Median :43.00
## Mean      : 61.69   Mean      : 8.567   Mean      :168.8   Mean      :40.93
## 3rd Qu.: 65.00   3rd Qu.:10.000   3rd Qu.:198.0   3rd Qu.:46.00
## Max.      :138.00   Max.      :55.000   Max.      :265.0   Max.      :61.00
## Pr.Axis.Rect   Max.L.Rect   Sc.Var.Maxis   Sc.Var.maxis   Ra.Gyr
## Min.      :17.00   Min.      :118   Min.      :130.0   Min.      : 184.0   Min.      :109.0
## 1st Qu.:19.00   1st Qu.:137   1st Qu.:167.0   1st Qu.: 318.2   1st Qu.:149.0
## Median :20.00   Median :146   Median :178.5   Median : 364.0   Median :173.0
## Mean      :20.58   Mean      :148   Mean      :188.6   Mean      : 439.9   Mean      :174.7
## 3rd Qu.:23.00   3rd Qu.:159   3rd Qu.:217.0   3rd Qu.: 587.0   3rd Qu.:198.0
## Max.      :29.00   Max.      :188   Max.      :320.0   Max.      :1018.0   Max.      :268.0
```

```
##      Skew.Maxis      Skew.maxis      Kurt.maxis      Kurt.Maxis
## Min.   : 59.00    Min.   : 0.000    Min.   : 0.0    Min.   :176.0
## 1st Qu.: 67.00    1st Qu.: 2.000    1st Qu.: 5.0    1st Qu.:184.0
## Median : 71.50    Median : 6.000    Median :11.0    Median :188.0
## Mean   : 72.46    Mean   : 6.377    Mean   :12.6    Mean   :188.9
## 3rd Qu.: 75.00    3rd Qu.: 9.000    3rd Qu.:19.0    3rd Qu.:193.0
## Max.   :135.00    Max.   :22.000    Max.   :41.0    Max.   :206.0
##      Holl.Ra      Class
## Min.   :181.0    bus :218
## 1st Qu.:190.2    opel:212
## Median :197.0    saab:217
## Mean   :195.6    van :199
## 3rd Qu.:201.0
## Max.   :211.0
```

```
describe(datos4)
```

```
##      vars  n  mean    sd median trimmed  mad min  max range skew
## Comp      1 846 93.68  8.23  93.0   93.33   8.90 73  119   46  0.38
## Circ      2 846 44.86  6.17  44.0  44.67   7.41 33   59   26  0.26
## D.Circ     3 846 82.09 15.77  80.0  82.07  17.79 40  112   72  0.11
## Rad.Ra     4 846 168.94 33.47 167.0 168.07  40.03 104 333  229  0.39
## Pr.Axis.Ra 5 846 61.69  7.89  61.0  61.14   5.93 47  138   91  3.81
## Max.L.Ra   6 846  8.57  4.60   8.0   8.17   2.97  2   55   53  6.75
## Scat.Ra    7 846 168.84 33.24 157.0 166.92  29.65 112 265  153  0.60
## Elong      8 846 40.93  7.81  43.0  40.73   8.90 26   61   35  0.05
## Pr.Axis.Rect 9 846 20.58  2.59  20.0  20.35   2.97 17   29   12  0.77
## Max.L.Rect 10 846 148.00 14.52 146.0 147.56  16.31 118 188   70  0.26
## Sc.Var.Maxis 11 846 188.63 31.39 178.5 187.13  28.91 130 320  190  0.65
## Sc.Var.maxis 12 846 439.91 176.69 364.0 424.58 140.11 184 1018 834  0.83
## Ra.Gyr     13 846 174.70 32.55 173.0 173.79  36.32 109 268  159  0.28
## Skew.Maxis 14 846 72.46  7.49  71.5  71.79   6.67 59  135   76  2.07
## Skew.maxis 15 846  6.38  4.92   6.0   5.91   5.93  0   22   22  0.77
## Kurt.maxis 16 846 12.60  8.93  11.0  11.83   8.90  0   41   41  0.69
## Kurt.Maxis 17 846 188.93  6.16 188.0 188.73   5.93 176 206   30  0.25
## Holl.Ra    18 846 195.63  7.44 197.0 195.75   7.41 181 211   30 -0.23
## Class*     19 846  2.47  1.11   2.0   2.46   1.48  1    4    3  0.03
##      kurtosis  se
## Comp      -0.55 0.28
## Circ      -0.93 0.21
## D.Circ     -0.98 0.54
## Rad.Ra      0.29 1.15
## Pr.Axis.Ra 29.58 0.27
## Max.L.Ra   57.88 0.16
## Scat.Ra    -0.62 1.14
## Elong      -0.87 0.27
## Pr.Axis.Rect -0.40 0.09
## Max.L.Rect -0.78 0.50
## Sc.Var.Maxis  0.10 1.08
## Sc.Var.maxis -0.23 6.07
## Ra.Gyr     -0.50 1.12
## Skew.Maxis 11.26 0.26
## Skew.maxis  0.07 0.17
## Kurt.maxis -0.15 0.31
```

```
## Kurt.Maxis      -0.60 0.21
## Holl.Ra         -0.82 0.26
## Class*          -1.35 0.04
```

## 4. Bibliografia

- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2013) An Introduction to Statistical Learning with applications in R, <https://www.statlearning.com>, Springer-Verlag, New York
- Siebert P (1987). “Vehicle Recognition Using Rule Based Methods.” Turing Institute Research Memorandum TIRM-87-018
- Blake CL, Merz CJ (1998). “UCI Repository of Machine Learning Databases.” University of California, Irvine, Department of Information and Computer Science. Formerly available from ‘<http://www.ics.uci.edu/~mlearn/MLRepository.html>’.