

EPG4001 Aprendizaje Supervisado

Clase 1: Conceptos Fundamentales de Aprendizaje Supervisado

Jorge Luis Bazán


Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



- 1 Introducción
- 2 Conceptos Fundamentales
 - Definiciones
 - Ejemplos
- 3 El Problema de Regresión
 - Definiciones
 - Ejemplo: k-NN
 - Ejemplo: Regresión Lineal
- 4 El Problema de Clasificación
 - Definiciones
 - Ejemplo: Regresión Lineal
 - Ejemplo: k-NN

1. Introducción



2. Conceptos Fundamentales

¿Qué es el Aprendizaje Supervisado?

2. Conceptos Fundamentales

2.1 Definiciones

- Suponga que tiene una variable objetivo, denotada por Y , junto con otras variables que representan ciertas características de la población de estudio, denotada por $\mathbf{X}$.
- El objetivo principal en aprendizaje supervisado es conocer el valor de Y_0 , para el conjunto de características $\mathbf{X}_0$.
- Si la variable Y es continua, el problema anterior **en Aprendizaje Supervisado** se conoce como regresión o predicción.
- Si la variable Y es categórica, el problema en cuestión **en Aprendizaje Supervisado** se conoce como clasificación.
- Es natural pensar que al tener diferente naturaleza la variable Y , los métodos para resolver el problema cambien.

Algunos ejemplos prácticos:

- Predecir si un paciente, hospitalizado por un infarto, tendrá un segundo infarto. La predicción puede basarse en medidas demográficas, dietéticas y clínicas de ese paciente.
- Predecir el precio de una acción dentro de 6 meses, basándose en medidas de rendimiento de la empresa y en datos económicos.
- Identificar los números de un código postal escrito a mano, a partir de una imagen digitalizada.
- Identificar los factores de riesgo del cáncer de próstata, a partir de variables clínicas y demográficas.

- Una forma de obtener respuesta a las preguntas anteriores se trata del **aprendizaje a partir de datos**.
- Esto quiere decir que disponemos de un conjunto de datos de entrenamiento, en el que conocemos tanto el resultado como las características.
- Con estos datos construimos un modelo de predicción, o aprendiz, que nos permitirá predecir el resultado de nuevos objetos no vistos.
- Un buen aprendiz es aquel que predice con exactitud dicho resultado.
- Este aprendizaje se llama **supervisado** por la presencia de la variable de resultado para guiar el proceso de aprendizaje.

- La ciencia del aprendizaje desempeña un papel fundamental en los campos de la estadística, la minería de datos y la inteligencia artificial, y se cruza con áreas de la ingeniería y otras disciplinas.
- La mezcla de áreas provoca que varias palabras que signifiquen lo mismo:
 X : Entrada = Características = Regresores = Predictores = V. Independientes.
 Y : Salida = Respuesta = V. Dependiente.
- Utilizaremos las anteriores indistintamente.

2. Conceptos Fundamentales

2.2 Ejemplos

Ejemplo: En un estudio para intentar predecir si un correo electrónico era "spam", consideraron la información de 4601 mensajes de correo electrónico. Cada correo, de los 4601, era clasificado como mail/spam.

El objetivo es diseñar un detector automático de spam que pudiera filtrar el spam antes de atascar los buzones de los usuarios.

Como una estrategia de análisis se registraron las frecuencias relativas de 57 de las palabras y signos de palabras y signos de puntuación más frecuentes en los mensajes de correo electrónico.

Por ejemplo, la siguiente tabla muestra algunas de las palabras junto a sus frecuencias relativas (porcentual):

	george	you	your	hp	free	hpl	!	our	re	edu	remove
spam	0.00	2.26	1.38	0.02	0.52	0.01	0.51	0.51	0.13	0.01	0.28
email	1.27	1.27	0.44	0.90	0.07	0.43	0.11	0.18	0.42	0.29	0.01

¿Cuál será un clasificador, que discrimine, entre email/spam?

Existen muchas alternativas:

- if (george<0.1 & hp>0.5) then *email* else *spam*.
- if (you>2 & your>1) then *spam* else *email*.

¿Cuál será el mejor clasificador, que discrimine, entre email/spam?

Tenemos la necesidad de definir técnicas que sean optimas en algún sentido.

Desde una perspectiva general, las diferentes técnicas de predicción y/o clasificación surgen de resolver el problema

$$\min \mathbb{E}[(Y - \hat{Y})^2 \mid \mathbf{X}] \Rightarrow \hat{Y} = \mathbb{E}[Y \mid \mathbf{X}] \text{ es el óptimo}$$

Por ejemplo,

- En modelos lineales $\mathbb{E}[Y \mid \mathbf{X}] = \mathbf{X}\beta$.
- En modelos lineales generalizados $\mu = \mathbb{E}[Y \mid \mathbf{X}]$, $g(\mu) = \mathbf{X}\beta$.
- En clasificación, $\mathbb{E}[Y \mid \mathbf{X}] = \mathbb{P}[Y = 1 \mid \mathbf{X}]$, cuando $Rec(Y) = \{0, 1\}$.

Muchos de los algoritmos que veremos se pueden utilizar tanto para regresión como clasificación, es por ello que veremos los dos problemas de forma conjunta.


Tendencias ahora



Las 10 más populares en España hoy



Originales de Netflix



3. El problema de Regresión

El problema de Regresión

3. El problema de Regresión

3.1 Definiciones

- La variable de interés es numérica (continua o discreta) es la principal característica. **Aquí usamos la idea Estadística antes que la idea de Aprendizaje Supervisado.**
- El modelo de pronóstico es de la forma

$$\hat{y} = f(\mathbf{x})$$

- Desde el punto de vista de análisis $f(\mathbf{x})$ podría ser una forma paramétrica o semi-paramétrica o bien completamente no paramétrica.
- Dos ejemplos característicos son la regresión lineal (modelo paramétrico) y el k-vecino más cercano (no-paramétrico).

- Suponga que $\mathbf{x} = (x_1, x_2, \dots, x_p)$ es un vector de p características.
- Asuma que dispone de n observaciones de la forma $(\mathbf{x}_i, y_i)$, $i = 1, \dots, n$, para entrenar al modelo.
- En el modelo de regresión lineal

$$f(\mathbf{x}_i) = \beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta} = \sum_{j=0}^p \beta_j x_{ji}, \quad \text{con } x_{0i} = 1, \quad i = 1, \dots, n.$$

Se puede probar que

$$\hat{\boldsymbol{\beta}} = (\hat{\beta}_0, \dots, \hat{\beta}_p) = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

donde $\mathbf{X} = (\mathbf{1} | \mathbf{x}_1 | \dots | \mathbf{x}_p)$ es la matriz de diseño e $\mathbf{Y} = (y_1, \dots, y_n)$ el vector de respuesta.

- Los detalles los revisaremos la próxima clase.

- Como contraparte del modelo de regresión lineal, el método del k -vecino más cercano, es un método no-paramétrico, que permite estimar Y_0 a partir de los k -vecinos más cercanos de $\mathbf{x}_0$.
- Para cada $\mathbf{x}$ se encuentra el conjunto $N_k(\mathbf{x})$ formado por los k vecinos de $\mathbf{x}$ y el conjunto de índices $N_k^* = \{i : \mathbf{x}_i \in N_k(\mathbf{x})\}$, luego

$$\hat{Y}_k(\mathbf{x}) = \frac{1}{k} \sum_{j \in N_k^*} Y_j$$

- Es decir, el estimador de Y_0 corresponde al promedio simple de valores observados de Y , donde para escoger los valores observados se busca la cercanía en las covariables.
- Cuando k es muy grande el valor de $\hat{Y}$ es el promedio de los datos observados.
- Una extensión natural del k -NN es el método de Nadaraya-Watson, donde el promedio simple es reemplazado por un promedio ponderado.

3. El problema de Regresión

3.2 Ejemplo: k-NN

Ejemplo: Considere la siguiente muestra

y	13	3	0	6	5	6	14	6	5	3
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 1-vecinos.
- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 2-vecinos.
- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 3-vecinos

Solución: Sea $\mathbf{x} = (5, 2)$, luego debemos calcular las distancias de los puntos observados a $\mathbf{x}$.

	1	2	3	4	5	6	7	8	9	10
y	13	3	0	6	5	6	14	6	5	3
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4
$d^2(\mathbf{x}_i, \mathbf{x})$	32	1	32	53	29	65	52	16	17	5

- $N_1^* = \{2\}$ entonces $\hat{Y} = 3$.
- $N_2^* = \{2, 10\}$ entonces $\hat{Y} = \frac{3+3}{2} = 3$.
- $N_3^* = \{2, 10, 6\}$ entonces $\hat{Y} = \frac{3+3+6}{3} = 4$.

Obs.: Los resultados dependen tanto de la cantidad de vecinos, así como también de la distancia utilizada

3. El problema de Regresión


3.3 Ejemplo: Regresión lineal.

Ejemplo: La información obtenida a partir de una muestra de tamaño 12 sobre la relación existente entre la inversión realizada y el rendimiento obtenido en cientos de miles de Euros para la explotación agrícola es la siguiente:

Inv. (X)	11	14	16	15	16	18	20	21	14	20	19	11
Rend. (Y)	2	3	5	6	5	3	7	10	6	10	5	6

Suponga que para tomar una cierta decisión de debe estimar el valor del Rendimiento (Y) para una inversión $x = 12$ y $x = 17$.

Inversión vs. Rendimiento




Suponga que aplicamos 1-NN, 6-NN, y los métodos de regresión:

$$f_1(x) = \beta_0 + \beta_1 x; \quad \wedge \quad f_2(x) = \beta_0 + \beta_1 x + \beta_2 x^2$$

Los resultados una, vez aplicado los diferentes modelos, son:

Inversión	Pred.Lineal	Pred.Cuadratico	Pred.1NN	Pred.6NN
12.00	3.74	4.16	4.00	4.71
17.00	6.01	5.19	4.33	5.56

Inversión vs. Rendimiento



Dentro de los modelos de regresión lineal, ¿cuál es más apropiado?

Dentro de los modelos de k-NN, ¿cómo elegir k?

4. El problema de Clasificación

El problema de Clasificación

4. El problema de Clasificación

4.1 Definiciones

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.
- Denote estas características por $\mathcal{G}$ al grupo de las K clases. Es decir, $\mathcal{G} = \{1, 2, 3, \dots, K\}$.
- El problema de Clasificación consiste en asignar a Y_0 , dado un conjunto de covariables $\mathbf{X}$, un valor de $\mathcal{G}$.
- Para tal fin se deben definir alguna medida de error.
- Tanto la regresión lineal, como el k-NN pueden ser adaptados para ser utilizados en el contexto de clasificación.

4. El problema de Clasificación

4.2 Ejemplo: Regresión Lineal

Suponga que Y tiene K grupos:

- **Regresión Lineal:** Sea $\hat{f}_k(\mathbf{x}) = \hat{\beta}_{k0} + \hat{\beta}_k^\top \mathbf{x}$, la regresión ajustada para el grupo $k = 1, \dots, K$.

Si $\hat{f}_k(\mathbf{x}) = \hat{f}_l(\mathbf{x})$, entonces el conjunto (hiperplano afín)

$$\left\{ \mathbf{x} : \left(\hat{\beta}_{k0} - \hat{\beta}_{l0} \right) + \left(\hat{\beta}_k - \hat{\beta}_l \right)^\top \mathbf{x} = 0 \right\}$$

representa el límite de decisión entre la clase k y l .

Suponga que $K = 3$, y que X_1, X_2 son dos covariables, luego $\mathbf{x} = (X_1, X_2)$ y $\tilde{\mathbf{x}} = (X_1, X_2, X_1^2, X_2^2, X_1 \cdot X_2)$ son dos clasificadores diferentes.




Figura 1: A la izquierda el clasificador $\mathbf{x}$ y la derecha el clasificador $\tilde{\mathbf{x}}$. Fuente Hastie et al. (2008)

4. El problema de Clasificación

4.3 Ejemplo: k-NN

Una alternativa no-paramétrica

- **k-NN**: La búsqueda de los vecinos es idéntica al caso de regresión, mientras que la clasificación se realiza utilizando la moda de Y relativa al grupo de vecinos.

Ejemplo: Considere la siguiente muestra

y	a	a	a	a	a	b	b	b	b	b
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 1-vecinos.
- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 2-vecinos.
- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 3-vecinos

Solución: Sea $\mathbf{x} = (5, 2)$, luego debemos calcular las distancias de los puntos observados a $\mathbf{x}$.

	1	2	3	4	5	6	7	8	9	10
y	a	a	a	a	a	b	b	b	b	b
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4
$d^2(\mathbf{x}_i, \mathbf{x})$	32	1	32	53	29	65	52	16	17	5

- $N_1^* = \{2\}$ entonces $\hat{Y} = a$.
- $N_2^* = \{2, 10\}$ entonces $\hat{Y} = \text{moda}\{a, b\} = b$, se agrega un vecino.
- $N_3^* = \{2, 10, 6\}$ entonces $\hat{Y} = \text{moda}\{a, b, b\} = b$.

Obs.: Los resultados dependen tanto de la cantidad de vecinos, así como también de la distancia utilizada.

Julian J. Faraway (2016) *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*, Boca Raton: Chapman Hall/CRC.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.

¿Alguna consulta?