

EPG4001 Aprendizaje Supervisado

Clase 3: Regresión Logística

Jorge Luis Bazán

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



- 1 Regresión Logística
 - Definiciones
 - Formulación del Modelo
 - Matriz de confusión
 - Curva ROC

- 2 Modelo Lineal Generalizado
 - Definición
 - Familia Exponencial

1 Regresión Logística

- Definiciones
- Formulación del Modelo
- Matriz de confusión
- Curva ROC

2 Modelo Lineal Generalizado

- Definición
- Familia Exponencial

1. Regresión Logística

1.1 Definiciones

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.

1. Regresión Logística

1.1 Definiciones

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.
- Denote estas características por $\mathcal{G}$ al grupo de las K clases. Es decir, $\mathcal{G} = \{1, 2, 3, \dots, K\}$.

1. Regresión Logística

1.1 Definiciones

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.
- Denote estas características por $\mathcal{G}$ al grupo de las K clases. Es decir, $\mathcal{G} = \{1, 2, 3, \dots, K\}$.
- Utilizar la Regresión Lineal para clasificar es una buena alternativa, sin embargo, ajustar un modelo continuo a datos categóricos no es lo más adecuado.

1. Regresión Logística

1.1 Definiciones

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.
- Denote estas características por $\mathcal{G}$ al grupo de las K clases. Es decir, $\mathcal{G} = \{1, 2, 3, \dots, K\}$.
- Utilizar la Regresión Lineal para clasificar es una buena alternativa, sin embargo, ajustar un modelo continuo a datos categóricos no es lo más adecuado.
- Para la variable aleatoria dicotómica Y_k ,

$$\mathbb{E}(Y_k \mid \mathbf{X} = \mathbf{x}) = \mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}).$$

1. Regresión Logística

1.1 Definiciones

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.
- Denote estas características por $\mathcal{G}$ al grupo de las K clases. Es decir, $\mathcal{G} = \{1, 2, 3, \dots, K\}$.
- Utilizar la Regresión Lineal para clasificar es una buena alternativa, sin embargo, ajustar un modelo continuo a datos categóricos no es lo más adecuado.

- Para la variable aleatoria dicotómica Y_k ,

$$\mathbb{E}(Y_k \mid \mathbf{X} = \mathbf{x}) = \mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}).$$

- La Regresión Lineal pertenece a una clase de métodos que modelan las funciones discriminantes $\delta_k(\mathbf{x})$ para cada clase, y luego clasifican $\mathbf{x}$ en la clase con el mayor valor de su función discriminante.

1. Regresión Logística

1.1 Definiciones

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.
- Denote estas características por $\mathcal{G}$ al grupo de las K clases. Es decir, $\mathcal{G} = \{1, 2, 3, \dots, K\}$.
- Utilizar la Regresión Lineal para clasificar es una buena alternativa, sin embargo, ajustar un modelo continuo a datos categóricos no es lo más adecuado.

- Para la variable aleatoria dicotómica Y_k ,

$$\mathbb{E}(Y_k \mid \mathbf{X} = \mathbf{x}) = \mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}).$$

- La Regresión Lineal pertenece a una clase de métodos que modelan las funciones discriminantes $\delta_k(\mathbf{x})$ para cada clase, y luego clasifican $\mathbf{x}$ en la clase con el mayor valor de su función discriminante.
- Existen muchas otras funciones discriminantes, tales como la Regresión Logística.

1. Regresión Logística

1.2 Formulación del modelo

- La Regresión Logística tiene por objetivo modelar el logaritmo natural del cociente entre las probabilidades a posteriori de pertenecer a cada grupo.

1. Regresión Logística

1.2 Formulación del modelo

- La Regresión Logística tiene por objetivo modelar el logaritmo natural del cociente entre las probabilidades a posteriori de pertenecer a cada grupo.
- Este cociente de probabilidades se conoce como log-odd o logit, los cuales se modelan de forma lineal en las covariables.

1. Regresión Logística

1.2 Formulación del modelo

- La Regresión Logística tiene por objetivo modelar el logaritmo natural del cociente entre las probabilidades a posteriori de pertenecer a cada grupo.
- Este cociente de probabilidades se conoce como log-odd o logit, los cuales se modelan de forma lineal en las covariables.
- La forma del modelo es:

$$\ln \left(\frac{\mathbb{P}(G = k | \mathbf{X} = \mathbf{x})}{\mathbb{P}(G = K | \mathbf{X} = \mathbf{x})} \right) = \beta_{k0} + \boldsymbol{\beta}_k^\top \mathbf{x}, \quad k = 1, 2, \dots, K - 1$$

Despejado se tiene que

$$\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = \frac{\exp(\beta_{k0} + \boldsymbol{\beta}_k^\top \mathbf{x})}{1 + \sum_{l=1}^K \exp(\beta_{l0} + \boldsymbol{\beta}_l^\top \mathbf{x})}, \quad k = 1, \dots, K - 1,$$

Despejado se tiene que

$$\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = \frac{\exp(\beta_{k0} + \boldsymbol{\beta}_k^\top \mathbf{x})}{1 + \sum_{l=1}^K \exp(\beta_{l0} + \boldsymbol{\beta}_l^\top \mathbf{x})}, \quad k = 1, \dots, K - 1,$$

$$\mathbb{P}(G = K | \mathbf{X} = \mathbf{x}) = \frac{1}{1 + \sum_{l=1}^K \exp(\beta_{l0} + \boldsymbol{\beta}_l^\top \mathbf{x})}$$

Despejado se tiene que

$$\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = \frac{\exp(\beta_{k0} + \boldsymbol{\beta}_k^\top \mathbf{x})}{1 + \sum_{l=1}^K \exp(\beta_{l0} + \boldsymbol{\beta}_l^\top \mathbf{x})}, \quad k = 1, \dots, K - 1,$$

$$\mathbb{P}(G = K | \mathbf{X} = \mathbf{x}) = \frac{1}{1 + \sum_{l=1}^K \exp(\beta_{l0} + \boldsymbol{\beta}_l^\top \mathbf{x})}$$

Obs.: Para poder estimar los parámetros del modelo, se necesita asociar un modelo de probabilidad a los datos. Esto lo veremos desde un punto de vista general, denominado GLM

Notación: $\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = p_k(\mathbf{x} | \boldsymbol{\beta})$, donde $\boldsymbol{\beta}$ representa el vector de parámetros.

Notación: $\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = p_k(\mathbf{x} | \boldsymbol{\beta})$, donde $\boldsymbol{\beta}$ representa el vector de parámetros.

$\boldsymbol{\beta}$ se estima vía máxima verosimilitud, donde

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N \ln\{p_{g_i}(\mathbf{x}_i | \boldsymbol{\beta})\}$$

es la log-verosimilitud.

Notación: $\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = p_k(\mathbf{x} | \boldsymbol{\beta})$, donde $\boldsymbol{\beta}$ representa el vector de parámetros.

$\boldsymbol{\beta}$ se estima vía máxima verosimilitud, donde

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N \ln\{p_{g_i}(\mathbf{x}_i | \boldsymbol{\beta})\}$$

es la log-verosimilitud.

Por ejemplo para el caso $K = 2$:

Notación: $\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = p_k(\mathbf{x} | \boldsymbol{\beta})$, donde $\boldsymbol{\beta}$ representa el vector de parámetros.

$\boldsymbol{\beta}$ se estima vía máxima verosimilitud, donde

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N \ln\{p_{g_i}(\mathbf{x}_i | \boldsymbol{\beta})\}$$

es la log-verosimilitud.

Por ejemplo para el caso $K = 2$:

Considere $y_i = 1$ para $g_i = 1$ y $y_i = 0$ para $g_i = 2$. Además,

$$p_1(\mathbf{x} | \boldsymbol{\beta}) = p(\mathbf{x} | \boldsymbol{\beta}) \quad \wedge \quad p_2(\mathbf{x} | \boldsymbol{\beta}) = 1 - p(\mathbf{x} | \boldsymbol{\beta})$$

La log-verosimilitud puede ser escrita como:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N \left[y_i \boldsymbol{\beta}^\top \mathbf{x}_i - \ln \left(1 + \exp(\boldsymbol{\beta}^\top \mathbf{x}_i) \right) \right],$$

La log-verosimilitud puede ser escrita como:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N \left[y_i \boldsymbol{\beta}^\top \mathbf{x}_i - \ln \left(1 + \exp(\boldsymbol{\beta}^\top \mathbf{x}_i) \right) \right],$$

La cual puede ser maximizada, encontrando las raíces de la ecuación gradiente igual a cero. Es decir, resolver:

$$U(\boldsymbol{\beta}) = \nabla \ell(\boldsymbol{\beta}) = \mathbf{0}$$

La log-verosimilitud puede ser escrita como:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N \left[y_i \boldsymbol{\beta}^\top \mathbf{x}_i - \ln \left(1 + \exp(\boldsymbol{\beta}^\top \mathbf{x}_i) \right) \right],$$

La cual puede ser maximizada, encontrando las raíces de la ecuación gradiente igual a cero. Es decir, resolver:

$$U(\boldsymbol{\beta}) = \nabla \ell(\boldsymbol{\beta}) = \mathbf{0}$$

Obs.: Veremos una extensión general que no solo permite realizar dicha estimación, sino que también permite realizar la inferencia sobre los parámetros y modelo, e incluir la regresión lineal y logística en una sola metodología

En resumen, para el modelo de Regresión Logística con dos respuestas (Llamdo tambien regresion binaria) tenemos que:

$$Y_i \sim \text{Bernoulli}(p_i), \quad i = 1, \dots, n$$
$$p_i = F(\boldsymbol{\eta}_i) = F(\mathbf{x}_i^T \boldsymbol{\beta}), \quad i = 1, \dots, n$$

En resumen, para el modelo de Regresión Logística con dos respuestas (Llamdo tambien regresion binaria) tenemos que:

$$Y_i \sim \text{Bernoulli}(p_i), \quad i = 1, \dots, n$$
$$p_i = F(\boldsymbol{\eta}_i) = F(\mathbf{x}_i^T \boldsymbol{\beta}), \quad i = 1, \dots, n$$

En donde:

- Y_i es una variable binaria tal que $Y_i = 1$ ocurre con probabilidad $p_i \in (0, 1)$.

En resumen, para el modelo de Regresión Logística con dos respuestas (Llamdo tambien regresion binaria) tenemos que:

$$Y_i \sim \text{Bernoulli}(p_i), \quad i = 1, \dots, n$$
$$p_i = F(\boldsymbol{\eta}_i) = F(\mathbf{x}_i^T \boldsymbol{\beta}), \quad i = 1, \dots, n$$

En donde:

- Y_i es una variable binaria tal que $Y_i = 1$ ocurre con probabilidad $p_i \in (0, 1)$.
- $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ik})^T$ es un vector con las variables explicativas, donde $x_{i1} = 1$ representa el intercepto.

En resumen, para el modelo de Regresión Logística con dos respuestas (Llamdo tambien regresion binaria) tenemos que:

$$Y_i \sim \text{Bernoulli}(p_i), \quad i = 1, \dots, n$$
$$p_i = F(\boldsymbol{\eta}_i) = F(\mathbf{x}_i^T \boldsymbol{\beta}), \quad i = 1, \dots, n$$

En donde:

- Y_i es una variable binaria tal que $Y_i = 1$ ocurre con probabilidad $p_i \in (0, 1)$.
- $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ik})^T$ es un vector con las variables explicativas, donde $x_{i1} = 1$ representa el intercepto.
- $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_k)^T$ es un vector de coeficientes de regresión, siendo β_1 el intercepto o coeficiente lineal y $\beta_2, \dots, \beta_k$ los coeficientes asociados a las variables $x_{i2}, \dots, x_{ik}$.

En resumen, para el modelo de Regresión Logística con dos respuestas (Llamdo tambien regresion binaria) tenemos que:

$$Y_i \sim \text{Bernoulli}(p_i), \quad i = 1, \dots, n$$
$$p_i = F(\boldsymbol{\eta}_i) = F(\mathbf{x}_i^T \boldsymbol{\beta}), \quad i = 1, \dots, n$$

En donde:

- Y_i es una variable binaria tal que $Y_i = 1$ ocurre con probabilidad $p_i \in (0, 1)$.
- $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ik})^T$ es un vector con las variables explicativas, donde $x_{i1} = 1$ representa el intercepto.
- $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_k)^T$ es un vector de coeficientes de regresión, siendo β_1 el intercepto o coeficiente lineal y $\beta_2, \dots, \beta_k$ los coeficientes asociados a las variables $x_{i2}, \dots, x_{ik}$.
- $F(\cdot)$ denota una función de distribución acumulada (FDA) con soporte en la recta, donde la función inversa $F^{-1}(\cdot)$ se denomina función de enlace.

En resumen, para el modelo de Regresión Logística con dos respuestas (Llamdo tambien regresion binaria) tenemos que:

$$Y_i \sim \text{Bernoulli}(p_i), \quad i = 1, \dots, n$$
$$p_i = F(\boldsymbol{\eta}_i) = F(\mathbf{x}_i^T \boldsymbol{\beta}), \quad i = 1, \dots, n$$

En donde:

- Y_i es una variable binaria tal que $Y_i = 1$ ocurre con probabilidad $p_i \in (0, 1)$.
- $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ik})^T$ es un vector con las variables explicativas, donde $x_{i1} = 1$ representa el intercepto.
- $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_k)^T$ es un vector de coeficientes de regresión, siendo β_1 el intercepto o coeficiente lineal y $\beta_2, \dots, \beta_k$ los coeficientes asociados a las variables $x_{i2}, \dots, x_{ik}$.
- $F(\cdot)$ denota una función de distribución acumulada (FDA) con soporte en la recta, donde la función inversa $F^{-1}(\cdot)$ se denomina función de enlace.
- $\boldsymbol{\eta}_i = \mathbf{x}_i^T \boldsymbol{\beta} = \beta_1 + \beta_2 x_{i2} + \dots + \beta_k x_{ik}$ es el i -ésimo predictor lineal.

1. Regresión Logística

1.3 Matriz de Confusión

		Estimado por el modelo	
			
Realidad		Verdadero positivo	Falso negativo
		Falso positivo	Verdadero negativo

1. Regresión Logística

1.3 Matriz de Confusión

		Estimado por el modelo	
			
Realidad		Verdadero positivo	Falso negativo
		Falso positivo	Verdadero negativo

- VP: Verdadero Positivo,
- VN: Verdadero Negativo,
- FP: Falso Positivo (Error Tipo I),
- FN: Falso Negativo (Error Tipo II).

La matriz de confusión permite calcular algunas métricas de desempeño que aportan información sobre la capacidad predictiva o discriminatoria del modelo

		Estimado por el modelo	
			
Realidad		Verdadero positivo	Falso negativo
		Falso positivo	Verdadero negativo

La matriz de confusión permite calcular algunas métricas de desempeño que aportan información sobre la capacidad predictiva o discriminatoria del modelo

		Estimado por el modelo	
			
Realidad		Verdadero positivo	Falso negativo
		Falso positivo	Verdadero negativo

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

$$\text{Especificidad} = \frac{VN}{VN + FP}$$

- Una sensibilidad alta indica que el modelo maneja correctamente los casos positivos reales

- Una sensibilidad alta indica que el modelo maneja correctamente los casos positivos reales
- Una especificidad alta indica que el modelo maneja correctamente los casos negativos reales.

- Una sensibilidad alta indica que el modelo maneja correctamente los casos positivos reales
- Una especificidad alta indica que el modelo maneja correctamente los casos negativos reales.
- Si bien estas métricas hablan de la capacidad de discriminación del modelo, es necesario combinarlas con otras para establecer un mejor rendimiento.

- Una sensibilidad alta indica que el modelo maneja correctamente los casos positivos reales
- Una especificidad alta indica que el modelo maneja correctamente los casos negativos reales.
- Si bien estas métricas hablan de la capacidad de discriminación del modelo, es necesario combinarlas con otras para establecer un mejor rendimiento.
- Cuando tenemos un dataset con desequilibrio, suele ocurrir que obtenemos una baja sensibilidad en la clase Minoritaria.

1. Regresión Lineal

1.4 Curva ROC

- La curva Receiver Operating Characteristic (ROC) es una representación gráfica de la especificidad frente a la sensibilidad de un sistema clasificador binario a medida que varía el umbral de discriminación.

1. Regresión Lineal

1.4 Curva ROC

- La curva Receiver Operating Characteristic (ROC) es una representación gráfica de la especificidad frente a la sensibilidad de un sistema clasificador binario a medida que varía el umbral de discriminación.
- Esta curva está conformada por todos los posible puntos de corte (probabilidades) que permiten discriminar entre las dos clases existentes. Para cada punto de corte, se establece la matriz de confusión respectiva y se calculan los valores de sensibilidad y especificidad asociados a ese punto.

1. Regresión Lineal



1.4 Curva ROC

- La curva Receiver Operating Characteristic (ROC) es una representación gráfica de la especificidad frente a la sensibilidad de un sistema clasificador binario a medida que varía el umbral de discriminación.
- Esta curva está conformada por todos los posibles puntos de corte (probabilidades) que permiten discriminar entre las dos clases existentes. Para cada punto de corte, se establece la matriz de confusión respectiva y se calculan los valores de sensibilidad y especificidad asociados a ese punto.
- La curva ROC es una herramienta para comparar la capacidad discriminatoria de los modelos/algoritmos de clasificación binaria.

1. Regresión Lineal

1.4 Curva ROC

- La curva Receiver Operating Characteristic (ROC) es una representación gráfica de la especificidad frente a la sensibilidad de un sistema clasificador binario a medida que varía el umbral de discriminación.
- Esta curva está conformada por todos los posibles puntos de corte (probabilidades) que permiten discriminar entre las dos clases existentes. Para cada punto de corte, se establece la matriz de confusión respectiva y se calculan los valores de sensibilidad y especificidad asociados a ese punto.
- La curva ROC es una herramienta para comparar la capacidad discriminatoria de los modelos/algoritmos de clasificación binaria.
- El modelo con mayor área bajo la curva (AUC) o aquel que minimice la distancia de la curva al punto (0,1) en los ejes (1 – Especificidad, Sensibilidad) es mejor.



- Hasta el momento hemos presentado la regresión lineal con variable continua y la regresión binaria con variable categórica como dos modelos de regresión (usando nombres en el area de Estadística) como si fueran dos cosas diferentes.
- Si lo vemos desde la perspectiva de uso diremos que el primero es para hacer prediction y el segundo para clasificación.
- A continuación vamos a traer conceptos de Estadística para mostrar que ambos modelos y otros mas pueden ser vistos como modelos de regresión en una clase mas general. Esta clase general se llama Modelo Lineal Generalizado

- 1 Regresión Logística
 - Definiciones
 - Formulación del Modelo
 - Matriz de confusión
 - Curva ROC

- 2 Modelo Lineal Generalizado
 - Definición
 - Familia Exponencial

2. Modelo Lineal Generalizado

2.1 Definición

- John Nelder y Robert Wedderburn (1972) formularon modelos lineales generalizados como una forma de unificar varios modelos estadísticos; como la regresión lineal, la regresión logística y la regresión de Poisson.

2. Modelo Lineal Generalizado

2.1 Definición

- John Nelder y Robert Wedderburn (1972) formularon modelos lineales generalizados como una forma de unificar varios modelos estadísticos; como la regresión lineal, la regresión logística y la regresión de Poisson.
- El objetivo en un GLM es ajustar la media de las variables aleatorias, a través de covariables conocidas.

2. Modelo Lineal Generalizado

2.1 Definición

- John Nelder y Robert Wedderburn (1972) formularon modelos lineales generalizados como una forma de unificar varios modelos estadísticos; como la regresión lineal, la regresión logística y la regresión de Poisson.
- El objetivo en un GLM es ajustar la media de las variables aleatorias, a través de covariables conocidas.

Definición (GLM)

Un Modelo Lineal Generalizado, es una extensión del modelo lineal general que utiliza como función de enlace (relación no lineal) el parámetro natural de una distribución de la familia exponencial, el cual a su vez se modela de forma lineal a través de los datos.

2. Modelo Lineal Generalizado

2.2 Familia Exponencial

Definición (Familia Exponencial)

Suponga que $Y \sim f(y|\theta)$ con $\dim(\theta) = 1$. Se dirá que la densidad $f(y|\theta)$ pertenece a la familia exponencial uniparamétrica si y solo si:

$$f(y|\theta) = \exp \{a(y)b(\theta) + c(\theta) + d(y)\}$$

2. Modelo Lineal Generalizado

2.2 Familia Exponencial

Definición (Familia Exponencial)

Suponga que $Y \sim f(y|\theta)$ con $\dim(\theta) = 1$. Se dirá que la densidad $f(y|\theta)$ pertenece a la familia exponencial uniparamétrica si y solo si:

$$f(y|\theta) = \exp \{a(y)b(\theta) + c(\theta) + d(y)\}$$

Observaciones:

- Si $a(y) = y$ la distribución se dirá canónica o estándar.
- $\eta = b(\theta)$ es llamado parámetro natural.
- Si hay otros parámetros, estos se denominan parámetros **molestos** (nuisance) y se tratan como si fueran conocidos.

- **Binomial:** Suponga que $Y \sim \text{bin}(n, p)$

$$\begin{aligned} f(y|p) &= \binom{n}{y} p^y (1-p)^{n-y} \\ &= \exp \left\{ y \ln(p) + (n-y) \ln(1-p) + \ln \binom{n}{y} \right\} \\ &= \exp \left\{ y \ln \left(\frac{p}{1-p} \right) + n \ln(1-p) + \ln \binom{n}{y} \right\} \end{aligned}$$

- **Binomial:** Suponga que $Y \sim \text{bin}(n, p)$

$$\begin{aligned}f(y|p) &= \binom{n}{y} p^y (1-p)^{n-y} \\&= \exp \left\{ y \ln(p) + (n-y) \ln(1-p) + \ln \binom{n}{y} \right\} \\&= \exp \left\{ y \ln \left(\frac{p}{1-p} \right) + n \ln(1-p) + \ln \binom{n}{y} \right\}\end{aligned}$$

$$\begin{aligned}a(y) &= y & c(p) &= n \ln(1-p) \\b(p) &= \ln \left(\frac{p}{1-p} \right) = \eta & d(y) &= \ln \binom{n}{y}\end{aligned}$$

- La Bernoulli es el caso particular de la binomial con $n = 1$, luego también se tiene que

$$\eta = \ln \left(\frac{p}{1-p} \right)$$

- Suponga que las variables aleatorias $Y_1, \dots, Y_n$ son independientes desde $f(y|\theta_i)$, donde $f(y|\theta_i)$ pertenece a la familia exponencial.

- Suponga que las variables aleatorias $Y_1, \dots, Y_n$ son independientes desde $f(y|\theta_i)$, donde $f(y|\theta_i)$ pertenece a la familia exponencial.
- Asuma que

$$\mathbb{E}[Y_i] = \mu_i, \quad i = 1, \dots, n$$

- Suponga que las variables aleatorias $Y_1, \dots, Y_n$ son independientes desde $f(y|\theta_i)$, donde $f(y|\theta_i)$ pertenece a la familia exponencial.
- Asuma que

$$\mathbb{E}[Y_i] = \mu_i, \quad i = 1, \dots, n$$

- Sea $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ la información disponible con la que se quiere ajustar cada Y_i de modo que:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} = \eta(\theta_i)$$

- Suponga que las variables aleatorias $Y_1, \dots, Y_n$ son independientes desde $f(y|\theta_i)$, donde $f(y|\theta_i)$ pertenece a la familia exponencial.
- Asuma que

$$\mathbb{E}[Y_i] = \mu_i, \quad i = 1, \dots, n$$

- Sea $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ la información disponible con la que se quiere ajustar cada Y_i de modo que:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} = \eta(\theta_i)$$

- La función g se denomina función de enlace. Mientras que η se denomina parámetro natural.

- Suponga que las variables aleatorias $Y_1, \dots, Y_n$ son independientes desde $f(y|\theta_i)$, donde $f(y|\theta_i)$ pertenece a la familia exponencial.
- Asuma que

$$\mathbb{E}[Y_i] = \mu_i, \quad i = 1, \dots, n$$


- Sea $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ la información disponible con la que se quiere ajustar cada Y_i de modo que:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} = \eta(\theta_i)$$

- La función g se denomina función de enlace. Mientras que η se denomina parámetro natural.
- En general g puede ser cualquier función monótona y diferenciable.

Algunas funciones de enlace para más utilizadas para una respuesta binomial son la Logit, Probit y cLogLog.

Funciones de Enlace



i) La transformación logística

$$\xi_i = \log \{ \pi_i / (1 - \pi_i) \} = \text{logit } \pi_i$$

ii) La transformación probit,

$$\xi_i = \Phi^{-1}(\pi_i)$$

donde $\Phi(\cdot)$ es la cdf de una distribución normal estándar por lo que ξ_i es la solución de

$$\int_{-\infty}^{\xi_i} \phi(u) du = \pi_i$$

donde $\phi(u)$ es la fdp de una normal estándar

$$\phi(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u^2\right),$$

iii) La transformación Cauchy

$$\xi_i = \tan \left\{ \pi \left(\pi_i - \frac{1}{2} \right) \right\}$$

iv) La transformación loglog,

$$\xi_i = \log(\log(\pi_i))$$

v) La transformación log-log complementaria,

$$\xi_i = \log [-\log (1 - \pi_i)] .$$

Todas estas transformaciones producen curvas sigmoidales que mapean una probabilidad de un intervalo $(0, 1)$ a la línea real $(-\infty, +\infty)$.

Las funciones logística y probit son simétricas alrededor de $\pi_i = 0,5$ y son bastante similares entre sí, sin embargo la función log-log complementaria es asimétrica. En principio, cualquiera de estas funciones puede usarse como función de enlace en un modelo lineal generalizado.

La facilidad de cálculo, la interpretación como el logaritmo de las probabilidades a favor de un éxito, y el hecho de que proporciona un enlace canónico, favorecen el uso de la transformación logística en aplicaciones prácticas.

Históricamente, sin embargo, la transformación probit se ha utilizado más ampliamente en bioensayos, mientras que la transformación log-log complementaria se usa principalmente en análisis de sobrevivencia.

Existen muchos resultados “amigables” cuando la distribución pertenece a la familia exponencial, entre ellos:

$$\begin{aligned}\mathbb{E}[a(Y)] &= -\frac{c'(\theta)}{b'(\theta)} \\ \mathbb{V}[a(Y)] &= \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{[b'(\theta)]^3}\end{aligned}$$

Existen muchos resultados “amigables” cuando la distribución pertenece a la familia exponencial, entre ellos:

$$\begin{aligned}\mathbb{E}[a(Y)] &= -\frac{c'(\theta)}{b'(\theta)} \\ \mathbb{V}[a(Y)] &= \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{[b'(\theta)]^3}\end{aligned}$$

Aunque lo más importante, en términos de ajuste es:

$$\ell(\theta) = \ln(f(y|\theta)) = a(y)b(\theta) + c(\theta) + d(y).$$

Existen muchos resultados “amigables” cuando la distribución pertenece a la familia exponencial, entre ellos:

$$\begin{aligned}\mathbb{E}[a(Y)] &= -\frac{c'(\theta)}{b'(\theta)} \\ \mathbb{V}[a(Y)] &= \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{[b'(\theta)]^3}\end{aligned}$$

Aunque lo más importante, en términos de ajuste es:

$$\ell(\theta) = \ln(f(y|\theta)) = a(y)b(\theta) + c(\theta) + d(y).$$

Cuya derivada se conoce como estadístico Score:

$$U(\theta) = \frac{d}{d\theta}\ell(\theta) = a(Y)b'(\theta) + c'(\theta)$$

Existen muchos resultados “amigables” cuando la distribución pertenece a la familia exponencial, entre ellos:

$$\begin{aligned}\mathbb{E}[a(Y)] &= -\frac{c'(\theta)}{b'(\theta)} \\ \mathbb{V}[a(Y)] &= \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{[b'(\theta)]^3}\end{aligned}$$

Aunque lo más importante, en términos de ajuste es:

$$\ell(\theta) = \ln(f(y|\theta)) = a(y)b(\theta) + c(\theta) + d(y).$$

Cuya derivada se conoce como estadístico Score:

$$U(\theta) = \frac{d}{d\theta}\ell(\theta) = a(Y)b'(\theta) + c'(\theta)$$

La información de Fisher queda como

$$\mathcal{J} = \mathbb{V}[U] = \mathbb{E}[U^2] = -\mathbb{E}[U'] = [b'(\theta)]^2 \mathbb{V}[a(Y)] = \frac{b''(\theta)c'(\theta)}{b'(\theta)} - c''(\theta)$$

2. Modelo Lineal Generalizado

2.3 Estimación

Asumiendo una muestra independiente, $Y_1, \dots, Y_n$, desde una familia exponencial, entonces la log-verosimilitud esta dada por

$$\ell_i = \ell_i(\boldsymbol{\beta}) = y_i b(\theta_i) + c(\theta_i) + d(y_i) \quad \implies \quad \ell = \ell(\boldsymbol{\beta}) = \sum_{i=1}^n \ell_i(\boldsymbol{\beta})$$

2. Modelo Lineal Generalizado

2.3 Estimación

Asumiendo una muestra independiente, $Y_1, \dots, Y_n$, desde una familia exponencial, entonces la log-verosimilitud esta dada por

$$\ell_i = \ell_i(\boldsymbol{\beta}) = y_i b(\theta_i) + c(\theta_i) + d(y_i) \implies \ell = \ell(\boldsymbol{\beta}) = \sum_{i=1}^n \ell_i(\boldsymbol{\beta})$$

De este modo para estimar $\boldsymbol{\beta}$ se debe resolver el sistema

$$U_j = \sum_{i=1}^n \frac{\partial}{\partial \beta_j} \ell_i(\boldsymbol{\beta}) = \sum_{i=1}^n \frac{\partial \ell_i}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \beta_j} = \sum_{i=1}^n \frac{(y_i - \mu_i)}{\mathbb{V}[Y_i]} \frac{\partial \mu_i}{\partial \eta_i} x_{ij}$$

Por otro lado,

$$\mathcal{J}_{jk} = \mathbb{E}[U_j U_k] = \sum_{i=1}^n \frac{x_{ij} x_{ik}}{\mathbb{V}[Y_i]} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \implies \mathcal{J} = \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

Así, el método de Fisher-Scoring queda

$$\boldsymbol{\beta}_{m+1} = \boldsymbol{\beta}_m + \mathcal{J}_m^{-1} \mathbf{U}_m \iff \mathcal{J}_m \boldsymbol{\beta}_{m+1} = \mathcal{J}_m \boldsymbol{\beta}_m + \mathbf{U}_m$$

El algoritmo se detiene cuando $\|\boldsymbol{\beta}_{m+1} - \boldsymbol{\beta}_m\| < \epsilon$ o $\|\mathbf{U}(\boldsymbol{\beta}_{m+1})\| < \epsilon$.

2. Modelo Lineal Generalizado

2.4 Bondad de Ajuste

- Una forma de evaluar la idoneidad de un modelo es compararlo con un modelo más general con el máximo número de parámetros que se pueden estimar.

2. Modelo Lineal Generalizado

2.4 Bondad de Ajuste

- Una forma de evaluar la idoneidad de un modelo es compararlo con un modelo más general con el máximo número de parámetros que se pueden estimar.
- Este modelo se denomina **modelo saturado** o **full model**.

2. Modelo Lineal Generalizado

2.4 Bondad de Ajuste

- Una forma de evaluar la idoneidad de un modelo es compararlo con un modelo más general con el máximo número de parámetros que se pueden estimar.
- Este modelo se denomina **modelo saturado** o **full model**.
- Es un GLM con la misma distribución y la misma función de enlace que el modelo de interés.

2. Modelo Lineal Generalizado

2.4 Bondad de Ajuste

- Una forma de evaluar la idoneidad de un modelo es compararlo con un modelo más general con el máximo número de parámetros que se pueden estimar.
- Este modelo se denomina **modelo saturado** o **full model**.
- Es un GLM con la misma distribución y la misma función de enlace que el modelo de interés.
- Si el tamaño muestral es n , entonces el modelo saturado estima a lo más n parámetros.

Se define la Deviance como:

$$D = -2 \left(\ell(\hat{\beta}) - \ell(\hat{\beta}_{\text{máx}}) \right)$$

donde $\hat{\beta}$ es el estimador máximo verosímil de β y $\hat{\beta}_{\text{máx}}$ es el estimador bajo el modelo saturado.

Se define la Deviance como:

$$D = -2 \left(\ell(\hat{\beta}) - \ell(\hat{\beta}_{\text{máx}}) \right)$$

donde $\hat{\beta}$ es el estimador máximo verosímil de β y $\hat{\beta}_{\text{máx}}$ es el estimador bajo el modelo saturado.

Se puede probar que

$$D \sim \chi^2_{n-p, \nu}$$

Se define la Deviance como:

$$D = -2 \left(\ell(\hat{\beta}) - \ell(\hat{\beta}_{\text{máx}}) \right)$$

donde $\hat{\beta}$ es el estimador máximo verosímil de β y $\hat{\beta}_{\text{máx}}$ es el estimador bajo el modelo saturado.

Se puede probar que $D \sim \chi^2_{n-p, \nu}$

donde ν es una constante positiva cercana de 0 si el modelo de interés se ajusta a los datos casi tan bueno como el modelo saturado.

Se define la Deviance como:

$$D = -2 \left(\ell(\hat{\beta}) - \ell(\hat{\beta}_{\text{máx}}) \right)$$

donde $\hat{\beta}$ es el estimador máximo verosímil de β y $\hat{\beta}_{\text{máx}}$ es el estimador bajo el modelo saturado.

Se puede probar que $D \sim \chi^2_{n-p, \nu}$

donde ν es una constante positiva cercana de 0 si el modelo de interés se ajusta a los datos casi tan bueno como el modelo saturado.

La Deviance constituye la base de la mayoría de las pruebas de hipótesis de los modelos lineales generalizados, y juega un rol fundamental en la selección de modelos, donde para el caso de la regresión logística esta dada por:

$$D = -2 \sum_{i=1}^n \hat{p}_i \logit(\hat{p}_i) + \ln(1 - \hat{p}_i)$$

2. Modelo Lineal Generalizado

2.5 Inferencia

- Por lo general se utiliza el test de Wald para la significancia de cada variable. Es decir, utilizando que

$$(\hat{\beta} - \beta)^\top \mathcal{J}(\hat{\beta} - \beta) \sim \chi_p^2 \quad \text{cuando } n \longrightarrow +\infty$$

Es posible, probar la hipótesis $H_0 : \beta = \mathbf{0}$

2. Modelo Lineal Generalizado

2.5 Inferencia

- Por lo general se utiliza el test de Wald para la significancia de cada variable. Es decir, utilizando que

$$(\hat{\beta} - \beta)^\top \mathcal{J}(\hat{\beta} - \beta) \sim \chi_p^2 \quad \text{cuando} \quad n \rightarrow +\infty$$

Es posible, probar la hipótesis $H_0 : \beta = \mathbf{0}$

- En el caso de modelos anidados se utiliza la variación de la Deviance para construir un test de hipótesis:

$$H_0 : \beta = \beta_0 \quad (M_0) \quad \text{vs.} \quad H_1 : \beta = \beta_1 \quad (M_1)$$

donde β_0 tiene q parámetros y β_1 tiene p parámetros, tal que $q < p < n$.

$$\Delta D = D_0 - D_1 = -2 \left(\ell(\hat{\beta}_0) - \ell(\hat{\beta}_1) \right) \sim \chi_{p-q}^2$$


o bien el cociente (cuando existe parámetro de dispersión).

$$F = \frac{(D_0 - D_1)/(p - q)}{D_1/(n - p)} \sim F_{p-q, n-p}$$

Obs: Por lo general, se realiza el ANOVA con varios modelos anidados.

2. Modelo Lineal Generalizado

2.6 Residuos



- En el modelo lineal general, los residuos $y_i - \hat{\mu}_i$ son la base fundamental del diagnóstico. Estos residuos se denominan **residuos de respuesta**. Sin embargo, son insuficientes para diagnosticar un GLM.

- En el modelo lineal general, los residuos $y_i - \hat{\mu}_i$ son la base fundamental del diagnóstico. Estos residuos se denominan **residuos de respuesta**. Sin embargo, son insuficientes para diagnosticar un GLM.
- La forma más directa de manejar la variación no constante en la familia exponencial es dividir el efecto de la variación no constante. Definiendo:

$$r_P = \frac{y - \hat{\mu}}{\sqrt{V(\hat{\mu})}}, \quad \text{residuos de Pearson}$$

$$r_D = \text{sgn}(y - \hat{\mu}) \sqrt{d(y, \hat{\mu})}, \quad \text{residuos de Deviance}$$

donde $V(\cdot)$ es la función de varianza.

- En el modelo lineal general, los residuos $y_i - \hat{\mu}_i$ son la base fundamental del diagnóstico. Estos residuos se denominan **residuos de respuesta**. Sin embargo, son insuficientes para diagnosticar un GLM.
- La forma más directa de manejar la variación no constante en la familia exponencial es dividir el efecto de la variación no constante. Definiendo:

$$r_P = \frac{y - \hat{\mu}}{\sqrt{V(\hat{\mu})}}, \quad \text{residuos de Pearson}$$

$$r_D = \text{sgn}(y - \hat{\mu}) \sqrt{d(y, \hat{\mu})}, \quad \text{residuos de Deviance}$$

donde $V(\cdot)$ es la función de varianza.

- Estos residuos deberían cumplir con las mismas propiedades de los residuos en el caso normal.

2. Modelo Lineal Generalizado

2.8 Funciones de enlace

Algunas de las funciones de enlace usadas en los GLMs son las siguientes:

Distribución	Función de enlace	Otras funciones de enlace comunes	Tipo de datos
Normal	$\eta = \mu$ (Identidad)	Log, Inversa	Variables continuas.
Binomial	$\eta = \ln\left(\frac{P}{1 - P}\right)$ (Logit)	Probit, Clog-log	Datos con múltiples categorías.
Poisson	$\eta = \ln(\mu)$ (Logarítmica)	Identidad, raíz cuadrada	Datos de conteo.
Exponencial	$\eta = \frac{1}{\mu}$ (Inversa)	Identidad, Log	Tiempos de espera o mediciones positivas.
Gamma	$\eta = \frac{1}{\mu}$ (Inversa)	Identidad, Log	Variables continuas positivas asimétricas.

Cuadro 1: Funciones de enlace usadas en los GLMs

2. Modelo Lineal Generalizado

2.7 Aplicación: Regresión Logística

- Como aplicación considere la data *faraway::wgs* donde la variable respuesta es *chd* y la variable explicativa es *cigs*.

2. Modelo Lineal Generalizado

2.7 Aplicación: Regresión Logística

- Como aplicación considere la data *faraway::wcgs* donde la variable respuesta es *chd* y la variable explicativa es *cigs*.
- En este caso el modelo

$$\text{logit}(p) = \beta_0 + \beta_1 * x \quad \implies \quad p = \frac{e^{\beta_0 + \beta_1 * x}}{1 + e^{\beta_0 + \beta_1 * x}}$$

Se interpreta como $P[Y = 1|x] = p$, donde $x : \text{cigs}$, e $y : \text{chd}$.

2. Modelo Lineal Generalizado

2.7 Aplicación: Regresión Logística

- Como aplicación considere la data *faraway::wcgs* donde la variable respuesta es *chd* y la variable explicativa es *cigs*.
- En este caso el modelo

$$\text{logit}(p) = \beta_0 + \beta_1 * x \implies p = \frac{e^{\beta_0 + \beta_1 * x}}{1 + e^{\beta_0 + \beta_1 * x}}$$

Se interpreta como $P[Y = 1|x] = p$, donde $x : \text{cigs}$, e $y : \text{chd}$.

- Notar que

$$\text{odd} = e^{\hat{\beta}_0} \cdot e^{\hat{\beta}_1 x}$$

Obs.: el contexto general anteriormente detallado permite realizar las mismas pruebas que en el caso normal

- En la respuesta normal se tiene

$$\mathbb{E}[Y_i] = \mu_i = g(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

- En la respuesta normal se tiene

$$\mathbb{E}[Y_i] = \mu_i = g(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

- Su log-verosimilitud

$$\ell(\boldsymbol{\beta}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 - \frac{n}{2} \ln(2\pi\sigma^2)$$

Respuesta Normal

- En la respuesta normal se tiene

$$\mathbb{E}[Y_i] = \mu_i = g(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

- Su log-verosimilitud

$$\ell(\boldsymbol{\beta}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 - \frac{n}{2} \ln(2\pi\sigma^2)$$

- Su parámetro de dispersión $\phi = \sigma^2$.

- En la respuesta normal se tiene

$$\mathbb{E}[Y_i] = \mu_i = g(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

- Su log-verosimilitud

$$\ell(\boldsymbol{\beta}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 - \frac{n}{2} \ln(2\pi\sigma^2)$$

- Su parámetro de dispersión $\phi = \sigma^2$.
- La estimación se lleva a cabo por Fisher-Scoring.

Respuesta Normal: Deviance

- Para el modelo saturado $\hat{\mu}_i = y_i$, luego

$$\ell(\hat{\beta}_{\text{máx}}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 - \frac{n}{2} \ln(2\pi\sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2)$$

Respuesta Normal: Deviance

- Para el modelo saturado $\hat{\mu}_i = y_i$, luego

$$\ell(\hat{\boldsymbol{\beta}}_{\text{máx}}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 - \frac{n}{2} \ln(2\pi\sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2)$$

- Para el modelo de interés $\hat{\mu}_i = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$, luego

$$\begin{aligned} \ell(\hat{\boldsymbol{\beta}}) &= -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 - \frac{n}{2} \ln(2\pi\sigma^2) \\ &= -\frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) - \frac{n}{2} \ln(2\pi\sigma^2) \end{aligned}$$

Respuesta Normal

- La Deviance está dada por

$$D = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 = \frac{SCE}{\sigma^2} \sim \chi_{n-p-1}^2$$

aquí $\hat{y}_i = \hat{\mu}_i = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

Respuesta Normal

- La Deviance está dada por

$$D = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 = \frac{SCE}{\sigma^2} \sim \chi_{n-p-1}^2$$

aquí $\hat{y}_i = \hat{\mu}_i = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

- Notar que en este punto se puede obtener un estimador de σ^2 , como

$$S^2 = \frac{SCE}{n-p-1} = \frac{1}{n-p-1} \sum_{i=1}^n (y_i - \hat{\mu}_i)^2$$

- La Deviance escalada está dada por

$$D^* = \sigma^2 D = \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 = SCE.$$

- Al considerar dos modelos M_0 y M_1 (M_0 contenido en M_1), se plantean las hipótesis

$$H_0 : \beta = \beta_0 \quad \text{vs.} \quad H_1 : \beta = \beta_1$$

donde β_0 tiene q parámetros y β_1 tiene p parámetros, tal que $q < p < n$.

- Al considerar dos modelos M_0 y M_1 (M_0 contenido en M_1), se plantean las hipótesis

$$H_0 : \beta = \beta_0 \quad \text{vs.} \quad H_1 : \beta = \beta_1$$

donde β_0 tiene q parámetros y β_1 tiene p parámetros, tal que $q < p < n$.

- La diferencia de Deviance

$$\Delta D = D_0 - D_1 = \frac{SCE_0}{\sigma^2} - \frac{SCE_1}{\sigma^2} \sim \chi_{p-q}^2$$

- Al considerar dos modelos M_0 y M_1 (M_0 contenido en M_1), se plantean las hipótesis

$$H_0 : \beta = \beta_0 \quad \text{vs.} \quad H_1 : \beta = \beta_1$$

donde β_0 tiene q parámetros y β_1 tiene p parámetros, tal que $q < p < n$.

- La diferencia de Deviance

$$\Delta D = D_0 - D_1 = \frac{SCE_0}{\sigma^2} - \frac{SCE_1}{\sigma^2} \sim \chi^2_{p-q}$$

- Luego, se elimina σ^2 al realizar la proporción de cambio en la Deviance, es decir,

$$\frac{(D_0 - D_1)/(p - q)}{D_1/(n - p - 1)} = \frac{(SCE_0 - SCE_1)/(p - q)}{SCE_1/(n - p - 1)} = F \sim F_{(p-q, n-p-1)}$$

Si bien todos los resultados ya se tienen desde la normal tradicional, este enfoque permite utilizar otras funciones de enlace:

Si bien todos los resultados ya se tienen desde la normal tradicional, este enfoque permite utilizar otras funciones de enlace:

- $g(\mu) = \mu_i$ identidad
- $g(\mu) = \ln(\mu_i)$ logaritmo
- $g(\mu) = \frac{1}{\mu_i}$ inversa

Respuesta Normal

Si bien todos los resultados ya se tienen desde la normal tradicional, este enfoque permite utilizar otras funciones de enlace:

- $g(\mu) = \mu_i$ identidad
- $g(\mu) = \ln(\mu_i)$ logaritmo
- $g(\mu) = \frac{1}{\mu_i}$ inversa

Obs.: El enlace logaritmo permite modelar datos positivos a través de la distribución normal.

¿Alguna consulta?

Julian J. Faraway (2016) *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*, Boca Raton: Chapman Hall/CRC.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.