

EPG4001 - Aprendizaje Supervisado

Clase 4: Métricas de desempeño

Jorge Luis Bazán

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



1 Aprendizaje Supervisado

2 Métricas de Evaluación y Desempeño

- Sesgo, Varianza y Complejidad del Modelo
- La descomposición sesgo-varianza
- Función de Pérdida y Errores en caso Cualitativo
- Accuracy
- F1 Score

3 Validación Cruzada

- Selección de Modelos a partir de los Datos
- Validación cruzada Simple
- Validación cruzada K-Fold
- Validación cruzada Aleatoria

1 Aprendizaje Supervisado

2 Métricas de Evaluación y Desempeño

- Sesgo, Varianza y Complejidad del Modelo
- La descomposición sesgo-varianza
- Función de Pérdida y Errores en caso Cualitativo
- Accuracy
- F1 Score

3 Validación Cruzada

- Selección de Modelos a partir de los Datos
- Validación cruzada Simple
- Validación cruzada K-Fold
- Validación cruzada Aleatoria

1. Aprendizaje Supervisado.

- Anteriormente ya se revisaron los modelos de regresión logística y en general de la familia exponencial, modelos estadísticos.
- En el contexto del aprendizaje estadístico (*Statistical Learning*) el foco está más bien establecido en **predecir** valores de alguna variable dependiente u *output*
- Cuando se ajustan modelos a partir de un conjunto de datos donde este *output* se conoce se puede hablar de modelos de aprendizaje *supervisado*.
- El término *supervisado* hace alusión a que en el proceso durante el cual el algoritmo busca una función adecuada para predecir y esta búsqueda (estimación) es *guiada* por el conjunto de datos disponibles dentro de los cuales se tienen de forma explícita los valores de y .

- Lo anterior, en términos estadísticos equivale a encontrar una función $f(\cdot)$ que mediante un conjunto de covariables $\mathbf{x}$ prediga el valor de y mediante $f(\mathbf{x}_i) = \hat{y}_i$.
- Dado todo lo anterior resulta clave introducir la noción de **evaluación y desempeño** como una noción de discrepancia entre lo predicho y lo real, intuitivamente: $\approx \hat{y}_i - y_i$.
- Existen diversas formas, **criterios**, para cuantificar esta discrepancia entre lo predicho y lo observado.
- El aprendizaje supervisado finalmente es el proceso por el cual se logra estimar una estructura de predicción $f(\cdot)$ que logre minimizar alguno de estos **criterios** de discrepancia con disponibilidad de datos que permiten guiar este proceso.

1 Aprendizaje Supervisado

2 Métricas de Evaluación y Desempeño

- Sesgo, Varianza y Complejidad del Modelo
- La descomposición sesgo-varianza
- Función de Pérdida y Errores en caso Cualitativo
- Accuracy
- F1 Score

3 Validación Cruzada

- Selección de Modelos a partir de los Datos
- Validación cruzada Simple
- Validación cruzada K-Fold
- Validación cruzada Aleatoria

2. Métricas de Evaluación y Desempeño

- El rendimiento de **generalización** de un método de aprendizaje está relacionado con su capacidad de predicción en datos de prueba independientes.
- La evaluación de este rendimiento es muy importante en la práctica, ya que orienta la elección del método de aprendizaje y nos da una medida de la calidad del modelo finalmente elegido.
- Existen muchas formas de medir la calidad de desempeño de un modelo, aunque un punto común es la relación **Sesgo, Varianza y Complejidad del modelo**

2. Métricas de Evaluación y Desempeño.

2.1. Sesgo, Varianza y Complejidad del Modelo.

- Suponga que la respuesta Y es cuantitativa.
- Sea $\mathbf{X}$ la entrada y $\hat{f}(\mathbf{X})$ el modelo de predicción de Y , es decir, $\hat{Y} = \hat{f}(\mathbf{X})$. Asuma que $\hat{f}(\mathbf{X})$ ha sido estimada a partir de un conjunto de entrenamiento $\mathcal{T}$.
- Denotaremos por $L(Y, \hat{Y})$ a la función de pérdida. Típicamente,

$$L(Y, \hat{Y}) = (Y - \hat{Y})^2 \quad \text{Pérdida Cuadrática}$$

$$L(Y, \hat{Y}) = |Y - \hat{Y}| \quad \text{Pérdida Absoluta}$$

- El **error de entrenamiento** es la pérdida media en la muestra de entrenamiento:

$$\overline{\text{err}} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}(\mathbf{x}_i))$$

- El **error de prueba** o error de generalización, es el error de predicción sobre una muestra de prueba independiente:

$$\text{Err}_{\mathcal{T}} = \mathbb{E}[L(Y, \hat{f}(\mathbf{X})) | \mathcal{T}],$$

donde el conjunto de entrenamiento $\mathcal{T}$ es fijo, y el error de prueba se refiere al error para este conjunto de entrenamiento específico. Notar que $(\mathbf{X}, Y)$ no pertenecen al conjunto de entrenamiento.


- El **error de predicción esperado** (o error de prueba esperado):

$$\text{Err} = \mathbb{E}[L(Y, \hat{f}(\mathbf{X}))] = \mathbb{E}[\text{Err}_{\mathcal{T}}]$$

Esta cantidad promedia todo lo que es aleatorio, incluida la aleatoriedad del conjunto de entrenamiento que produjo $\hat{f}$.

- En general, nos gustaría conocer el error de prueba esperado de nuestro modelo estimado $\hat{f}$.

- Es natural pensar que la forma en que se utilizan los datos de entrenamiento afectan al error de prueba esperado.
- La **complejidad** de un modelo tiene que ver con el uso de los datos de entrenamiento.
- A medida que el modelo se hace más complejo, utiliza más los datos de entrenamiento y es capaz de adaptarse a estructuras subyacentes más complicadas.
- En consecuencia, al aumentar la complejidad, disminuye el sesgo pero aumenta la varianza.
- Existe una complejidad intermedia del modelo que proporciona un error de prueba mínimo.



Fuente Hastie et al. (2008). Rojo ($\text{Err}_{\mathcal{T}}$); Azul ($\overline{\text{err}}$)

2. Métricas de Evaluación y Desempeño

2.2. La descomposición sesgo-varianza

Asuma el modelo $Y = f(\mathbf{X}) + \varepsilon$ donde $\mathbb{E}[\varepsilon] = 0$ y $\mathbb{V}[\varepsilon] = \sigma_\varepsilon^2$.

Sea $\hat{f}$ el modelo ajustado y sea $\mathbf{X} = \mathbf{x}_0$, luego

$$\begin{aligned}\text{Err}(\mathbf{x}_0) &= \mathbb{E}[(Y - \hat{f}(\mathbf{x}_0))^2 | \mathbf{X} = \mathbf{x}_0] \\ &= \sigma_\varepsilon^2 + \mathbb{E} \left[\hat{f}(\mathbf{x}_0) - f(\mathbf{x}_0) \right]^2 + \mathbb{V}[\hat{f}(\mathbf{x}_0)] \\ &= \text{Error Irreducible} + \text{Bias}^2 + \text{Varianza}\end{aligned}$$

- El primer término no puede evitarse por muy bien que estimemos $\hat{f}(\mathbf{x}_0)$, a menos que σ_ε^2 tienda a 0.
- Notar que a medida que disminuye el sesgo aumenta la varianza y viceversa.

2. Métricas de Evaluación y Desempeño

2.3. Función de Pérdida y Errores en caso Cualitativo

- Suponga que Y tiene K categorías, etiquetadas $1, 2, \dots, K$.
- Típicamente se modelan las probabilidades

$$p_k(\mathbf{X}) = \mathbb{P}[Y = k | \mathbf{X}] \quad \Rightarrow \quad \hat{Y} = \operatorname{argmax}_k \hat{p}_k(\mathbf{X})$$

- Posibles funciones de pérdida son

$$L(Y, \hat{Y}) = \mathbb{I}_{\{Y \neq \hat{Y}\}} \quad \text{Pérdida 0-1}$$

$$\begin{aligned} L(Y, \hat{p}(\mathbf{X})) &= -2 \sum_{k=1}^K \mathbb{I}_{\{Y=k\}} \hat{p}_k(\mathbf{X}) \quad -2\text{likelihood} \quad \text{o Deviance} \\ &= -2 \log \hat{p}_Y(\mathbf{X}) \end{aligned}$$

- El test error

$$\text{Err}_{\mathcal{T}} = \mathbb{E}[L(Y, \hat{Y}) \mid \mathcal{T}]$$

es el error de clasificación poblacional del clasificador entrenado en $\mathcal{T}$, y Err es el error de clasificación esperado.

- El error de entrenamiento en la muestra, por ejemplo,

$$\overline{\text{err}} = -\frac{2}{n} \sum_{i=1}^n \hat{p}_{y_i}(\mathbf{x}_i)$$

la log-likelihood muestral del modelo.

2. Métricas de Evaluación y Desempeño

2.4. Accuracy

- Un indicador resumen usual sobre las predicciones correctas realizadas por el modelo es el **accuracy** (“*exactitud*”) y corresponde simplemente a la proporción de predicciones correctas realizadas:

$$Ac = \frac{VP + VN}{n}$$

Donde VP : verdaderos positivos y VN : verdaderos negativos.

2. Métricas de Evaluación y Desempeño

2.5. F1 Score

- Ya vimos en los modelos de regresión logística que se pueden calcular la especificidad y sensibilidad al hacer predicción.
- Puede ocurrir sin embargo, que la data para el entrenamiento esté fuertemente desbalanceada, i.e. haya un exceso de 0 o 1. Esto puede llevar a altos valores de especificidad y bajos de sensibilidad, o viceversa.
- Para tales casos se propone como medida de desempeño el **F1-Score**, medida que penaliza el desbalanceo de casos

$$F1 = \frac{2VP}{2VP + FP + FN}$$

Donde VP : verdaderos positivos, FP : falsos positivos y FN : falsos negativos.

1 Aprendizaje Supervisado

2 Métricas de Evaluación y Desempeño

- Sesgo, Varianza y Complejidad del Modelo
- La descomposición sesgo-varianza
- Función de Pérdida y Errores en caso Cualitativo
- Accuracy
- F1 Score

3 Validación Cruzada

- Selección de Modelos a partir de los Datos
- Validación cruzada Simple
- Validación cruzada K-Fold
- Validación cruzada Aleatoria

3. Validación Cruzada


Objetivos a tener en cuenta:

- **Selección del modelo:** estimar el rendimiento de diferentes modelos para elegir el mejor.
- **Evaluación del modelo:** una vez elegido un modelo final, estimar su error de predicción (error de generalización) sobre nuevos datos.

Si nos encontramos en una situación de abundancia de datos, podemos separar la data en:

Entrenamiento Validación Test

- Los conjuntos de entrenamiento y Validación se usarán para la **Selección de Modelo**.
- El conjunto de Test se utiliza para evaluar el error de generalización del modelo final elegido (**Evaluación del modelo**).



- La validación cruzada es probablemente, el método más sencillo y más utilizado para estimar el error de predicción.
- Este método estima directamente el error esperado fuera de la muestra

$$\text{Err} = \mathbb{E}[L(Y, \hat{f}(\mathbf{X}))],$$

el error medio de generalización cuando el método $f()$ se aplica a una muestra de prueba independiente de la distribución conjunta de $\mathbf{X}$ e Y .

- Como se ha mencionado anteriormente, podríamos esperar que la validación cruzada estimara el error condicional, con el conjunto de entrenamiento $\mathcal{T}$ mantenido fijo. Sin embargo, la validación cruzada suele estimar bien sólo el error de predicción esperado.

3. Validación Cruzada

3.2. Validación cruzada Simple

- La validación cruce simple se emplea, por lo general, en un contexto de abundancia de datos, donde puede realizar la separación de la data en:

Entrenamiento - Validación - Test

- Así los conjuntos de entrenamiento y Validación se usarán para la Selección de Modelo, procediendo de la siguiente forma;
 - Se ajustan varios modelos con la muestra de entrenamiento,
 - Todos estos modelos se comparan con la muestra de validación,
 - De donde se escoge alguno, o bien se sigue buscando un nuevo modelo si el rendimiento en la muestra de validación es muy pobre.
- Esto podría convertirse en un procedimiento iterativo hasta tener un modelo con un rendimiento aceptable.
- Mientras que el conjunto de Test se utiliza solo para evaluar el error de generalización del modelo final elegido (Evaluación del modelo).

3. Validación Cruzada

3.3. Validación cruzada K-Fold

- Si tuviéramos suficientes datos, reserváramos un conjunto de validación y lo utilizaríamos para evaluar el rendimiento de nuestro modelo de predicción.
- Como los datos suelen ser escasos, esto no suele ser posible. Para suavizar el problema, la validación cruzada de K-Fold utiliza parte de los datos disponibles para ajustar el modelo y otra parte para probarlo.
- Dividimos los datos en K partes más o menos iguales; por ejemplo, $K=5$ ó $K=10$, son los valores más usados en la práctica.
- Se seleccionan $K-1$ partes para entrenar el modelo y la parte restante para cuantificar el error. El proceso se itera K veces, así cada parte es usada una vez para cuantificar el error.
- Finalmente se promedian los K errores del proceso anterior, esto permite obtener una medida global del error

Iter1	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Iter2	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Iter3	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Iter4	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Iter5	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5

Datos de validación

Datos de entrenamiento

- Para cada k se calcula $\overline{\text{err}}$, luego

$$CV(\hat{f}) = \frac{1}{k} \sum_{i=1}^k \overline{\text{err}}_i$$

- El caso particular en que $k = n$ se denomina **leave-one-out cross-validation**, en este caso

$$CV(\hat{f}) = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}^{-i}(\mathbf{x}_i))$$

- Para el caso de un modelo lineal, donde $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$ (con H la matriz de proyección $H = X(X^\top X)^{-1}X^\top$) y usando al función de pérdida cuadrática, se tiene que

$$CV(\hat{f}) = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_{ii}} \right)^2 \quad \Rightarrow \quad GCV(\hat{f}) = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - \text{tr}(\mathbf{H})/n} \right)^2$$

3. Validación Cruzada

3.4. Validación cruzada Aleatoria

Selección y Evaluación de Modelos: Bootstrap

- Para ajustar un cierto modelo, considere el conjunto de datos de entrenamiento

$$\mathbf{Z} = (z_1, z_2, \dots, z_N), \quad \text{donde } z_i = (x_i, y_i).$$

- La idea básica es extraer aleatoriamente conjuntos de datos con reemplazo de los datos de entrenamiento, cada muestra del mismo tamaño que el conjunto de entrenamiento original.
- En este contexto suponga que $\theta = S(\mathbf{Z})$ es alguna cantidad calculada de $\mathbf{Z}$, por ejemplo, un valor predicho.

¿Cómo aplicar el bootstrap para estimar el error de predicción?

Selección y Evaluación de Modelos: Bootstrap

- Si $\hat{f}^{*b}(x_i)$ es el valor predicho en x_i , a partir del modelo ajustado al b -ésimo conjunto de datos bootstrap, entonces la estimación del error es

$$\widehat{\text{Err}}_{boot} = \frac{1}{B} \frac{1}{N} \sum_{b=1}^B \sum_{i=1}^N L(y_i, \hat{f}^{*b}(x_i))$$

- Note que los conjuntos de datos bootstrap están actuando como las muestras de entrenamiento, mientras que el conjunto de entrenamiento original está actuando como la muestra de prueba, y estos dos muestras tienen observaciones en común.
- Por lo tanto, $\widehat{\text{Err}}_{boot}$ no proporciona una buena estimación en general.

- Por ejemplo, en un problema de clasificación de dos clases con el mismo número de observaciones en cada clase, y donde los predictores y las etiquetas de las clases son independientes, entonces la tasa de error real es de 0,5.
- Sin embargo,

$$\begin{aligned} P[\text{obs. } i \in \text{muestra bootstrap } b] &= 1 - \left(1 - \frac{1}{n}\right)^N \\ &\approx 1 - e^{-1} = 0,632 \end{aligned}$$

- Por lo tanto, la esperanza de $\widehat{\text{Err}}_{boot}$ es aproximadamente $0,184 = 0,5 * (1 - 0,632)$, muy por debajo de la tasa de error correcta 0,5.
- Utilizando la idea de la validación cruzada se puede definir un nuevo error.

- Se define el leave-one-out bootstrap como

$$\widehat{\text{Err}}^{(1)} = \frac{1}{N} \sum_{i=1}^N \frac{1}{|C^{(-i)}|} \sum_{b \in C^{(-i)}} L(y_i, \hat{f}^{*b}(x_i))$$

donde $C^{(-i)}$ es el conjunto de todas las muestras bootstrap que no contienen la observación i .

- Se debe escoger B suficientemente grande para que $|C^{(-i)}|$ sea diferente de 0.
- Notar que, el número medio de observaciones distintas en cada muestra de bootstrap es de aproximadamente $0,632N$.

- Se puede verificar que el estimador $\widehat{\text{Err}}^{(1)}$ presenta sesgo.
- El estimador “0,632” está diseñado para aliviar el sesgo mencionado, el cual se define como

$$\widehat{\text{Err}}^{(0,632)} = 0,368 * \overline{\text{err}} + 0,632 * \widehat{\text{Err}}^{(1)}$$

- El estimador de 0,632 funciona bien en situaciones de “ajuste ligero”, pero puede fallar en las de sobreajuste.
- También existe una versión mejorada del estimado “0,632”, denotado por $\widehat{\text{Err}}^{(0,632+)}$, el cual consiste en modificar el peso 0,632.

- La función *boot::cv.glm* permite hacer **k-Fold** provenientes de GLM.
- La librería *caret* permite hacer **k-Fold** en general.
- La librería *Metrics* contiene una serie de funciones para evaluar las métricas de la matriz de Confusión.

Ejemplo 4.1

Considere la base de datos **default** (James et al., 2021) que contiene la siguiente información de 1000 clientes de tarjetas de crédito: **default** (si cae o no en default, quiebra) (y), **balance** (x_1), **ingreso** (**income**) (x_2) y si es o no estudiante (x_3). Claramente $y, x_3 \in \{0, 1\}$.

El modelo entonces es, considerando $\mu_i = \pi_i$:

$$y_i \sim \text{Bernoulli}(\pi_i)$$

$$g(\mu) = g(\pi_i) = \text{logit}(\pi_i) = \eta_i$$

$$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta} = \beta_0 + \beta_1 \text{balance}_i + \beta_2 \text{income}_i + \beta_3 \text{student}_i$$

Considerando $L(Y, f)$ la devianza media para estimar el error de predicción, una división de la data en 70 % entrenamiento - 30 % Test, se obtienen los siguientes resultados

Ejemplo 4.1 — Resultados: Métricas de Clasificación

Cuadro 1: Métricas sobre el conjunto completo

Métrica	Valor
Accuracy	0.9732
Sensibilidad (Recall)	0.3153
Especificidad	0.9959
F1 Score	0.4393
AUC	0.9494

Ejemplo 4.1 — Resultados: Validación Cruzada

Cuadro 2: Estimación del error de predicción (Mean Deviance)

Método	Mean Deviance	SD
Hold-Out (70/30)	0.1579*	—
K-Fold ($K = 10$)	0.1579	—
Bootstrap estándar $\widehat{\text{Err}}_{boot}$	0.1576	0.0003
Bootstrap LOO $\widehat{\text{Err}}^{(1)}$	0.1583	—
Bootstrap $\widehat{\text{Err}}^{(0,632)}$	0.1579	—
<code>cv.glm</code> LOOCV (raw)	0.1580	—
<code>cv.glm</code> LOOCV (bias-corrected)	0.1576	—

* Accuracy = 0.973, F1 = 0.4255 en Hold-Out.

Ejemplo 4.2 — Resultados: Métricas de Ajuste

Cuadro 3: Métricas sobre el conjunto completo

Métrica	Valor
RMSE	1.6686
MAE	1.2520
R^2	0.8972

Ejemplo 4.2

La base **Advertising** contiene datos de 200 mercados diferentes sobre ventas ('sales'), gasto en publicidad, TV, Radio y Newspaper. Podemos proponer un modelo de regresión múltiple para predecir las ventas a partir de las otras covariables, este sería

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i$$

$$y_i = \beta_0 + \beta_1 \text{G.pub}_i + \beta_2 \text{G.tv}_i + \beta_3 \text{G.radio}_i + \beta_4 \text{G.news}_i + \varepsilon_i$$

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Considerando el RMSE como $L(Y, f)$ para estimar el error de predicción, una división de la data en 70 % entrenamiento - 30 % Test, se obtienen los siguientes resultados

Ejemplo 4.2 — Resultados: Validación Cruzada

Cuadro 4: Estimación del error de predicción

Método	RMSE	MAE	R^2
Hold-Out (70/30)	1.5236	1.2886	0.9223
K-Fold ($K = 10$)	1.6648	1.2687	0.9087
Bootstrap estándar $\widehat{\text{Err}}_{boot}$	1.6918	—	—
Bootstrap $\widehat{\text{Err}}^{(0,632)}$	1.7152	1.2856	0.8925

¿Alguna consulta?

- Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.
- Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani (2021) *An Introduction to Statistical Learning with Applications in R*, 2nd edition. Springer Series in Statistics.
- Julian J. Faraway (2016) *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*, Boca Raton: Chapman Hall/CRC.
- Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.