

EPG4001 - Aprendizaje Supervisado

Clase 5: Análisis Discriminante y Naive Bayes

Jorge Luis Bazán

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



1 Análisis Discriminante

- Naive Bayes
 - Estimación de densidad por Kernel
- Análisis Discriminante Lineal y Cuadrático

1 Análisis Discriminante


- Naive Bayes
 - Estimación de densidad por Kernel
- Análisis Discriminante Lineal y Cuadrático

1. Análisis Discriminante.

- Considere una variable respuesta (Y), la cual tiene como recorrido un conjunto de K características.
- Denotemos a $\mathcal{G}$ como el grupo de estas K características (clases). Es decir, $\mathcal{G} = \{1, 2, 3, \dots, K\}$.
- Tal como discutimos en el caso de la regresión Logística, necesitamos conocer la probabilidad posterior de una clase, $\mathbb{P}(G|X)$, para una clasificación óptima.
- Para la variable aleatoria categórica Y ,

$$\mathbb{E}(Y = k \mid \mathbf{X} = \mathbf{x}) = \mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}).$$

- Los métodos de análisis discriminante están basados en la maximización de la distribución a posteriori anterior.



Suponga que $f_k(\mathbf{x})$ es la densidad condicional de $\mathbf{X} \in \mathbb{R}^p$ dado la clase $G = k$, y que π_k es la probabilidad a priori de la clase k ($\pi_k = \mathbb{P}(G = k)$), tal que $\sum_{k=1}^K \pi_k = 1$.

Una aplicación del teorema de Bayes establece que

$$\mathbb{P}(G = k | \mathbf{X} = \mathbf{x}) = \frac{f_k(\mathbf{x})\pi_k}{\sum_{l=1}^K f_l(\mathbf{x})\pi_l},$$

- El método **Naive Bayes** asume que cada una de las densidades de clase son productos de densidades marginales, es decir, suponen que las entradas son condicionalmente independientes en cada clase
- **LDA** asume que $f_k(\mathbf{x})$ es la densidad de la distribución $\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$, es decir, las varianzas son iguales en cada Población.
- **QDA** asume que $f_k(\mathbf{x})$ es la densidad de la distribución $\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$, es decir, las varianzas son diferentes en cada Población.

1. Análisis Discriminante

1.1. Naive Bayes

- Es especialmente apropiado cuando la dimensión del espacio de características es alta (p grande).
- Supone que, dada una clase $G = k$, las características X_j son independientes, es decir:

$$\mathbb{P}(\mathbf{X}|G = k) = \mathbb{P}(X_1|G = k)\mathbb{P}(X_2|G = k)\dots\mathbb{P}(X_p|G = k)$$
$$f_k(\mathbf{X}) = \prod_{j=1}^p f_{kj}(X_j)$$

- Aunque la suposición anterior suele no ser cierta, simplifica enormemente la estimación.

- En un principio se utilizaron distribuciones Gaussianas Univariantes para representar las marginales f_{kj} .
- Una generalización consiste en estimar las densidades marginales f_{kj} por separado utilizando estimaciones de densidad de kernel unidimensionales.
- Si un componente X_j de $\mathbf{X}$ es discreto, se puede utilizar una estimación adecuada como Poisson o Multinomial. De este modo, se puede mezclar sin problemas los tipos de variables en un vector de características.

- Una estimación conveniente de π_k es $\hat{\pi}_k = \frac{n_k}{n}$, donde n_k es la cantidad de observaciones que pertenecen a la clase $G = k$, n es la cantidad total de observaciones.
- Si todos los X_j son continuos, al asumir que tienen una distribución marginal Gaussiana para cada clase $G = k$, entonces un estimador de f_k es

$$\hat{f}_k(\mathbf{x}) = \prod_{j=1}^p \frac{1}{\sqrt{2\pi S_{kj}^2}} \exp \left\{ -\frac{1}{2S_{kj}^2} (x_k - \bar{X}_{kj})^2 \right\}$$

donde $\bar{X}_{kj}$ y S_{kj}^2 son el promedio y varianza muestral de X_j restringida a la clase $G = k$.

- Si X_j es categórico con L estados posibles, entonces para cada clase ($G = k$) un estimador de f_{kj} es Multinom($\hat{p}_{k1}, \hat{p}_{k2}, \dots, \hat{p}_{kL}$), es decir,

$$\hat{f}_{kj}(\mathbf{x}) = \frac{n_k!}{x_{k1}! \cdots x_{kL}!} \hat{p}_{k1}^{x_{k1}} \hat{p}_{k2}^{x_{k2}} \cdots \hat{p}_{kL}^{x_{kL}}; \quad \sum_{i=1}^L x_{ki} = n_k$$

$$\hat{p}_{ki} = \frac{x_{ki}}{n_k} \quad (\text{EMV}); \quad \hat{p}_{ki} = \frac{x_{ki} + \alpha}{n_k + \alpha \cdot L} \quad (\text{Suavizado de Laplace})$$

donde, x_{ki} es la frecuencia de la categoría específica i observada para la clase k .

- Si el recorrido de X_j es el conjunto de los enteros, se puede utilizar la distribución de Poisson para estimar f_{kj} , es decir, $X_j \sim \text{Pois}(\lambda)$, donde el estimador MV es $\hat{\lambda} = \bar{X}_{kj}$; el promedio de los datos de la variable X_j en clase $G = k$.

Ejemplo

Considere la siguiente muestra

y	1	0	0	1	1	1	1	1	0	0
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

En este caso tenemos $n = 10$ observaciones, $K = 2$ grupos ($Y \in \{0, 1\}$) y $p = 2$ covariables.

Clasifiquemos la observación $\mathbf{x}^* = (x_1, x_2) = (4, 8)$ utilizando marginales Gaussianas.

Naive Bayes: Ejemplo

Consideremos el grupo $G = 1$ cuando $Y = 1$ y $G = 2$ cuando $Y = 0$.

Al separar las observaciones se tiene:

Grupo $G = 1$						
y	1	1	1	1	1	1
x_1	9	3	3	1	9	9
x_2	6	9	7	9	8	2

Grupo $G = 2$				
y	0	0	0	0
x_1	6	1	4	6
x_2	2	6	6	4

	$G = 1$		$G = 2$	
	x_1	x_2	x_1	x_2
Promedio	5.67	6.83	4.25	4.50
Desv. Estándar	3.72	2.64	2.36	1.91
$\hat{\pi}_j$	0.6		0.4	

$$f_1(4, 8) = \frac{1}{\sqrt{2\pi 3,72^2}} \exp \left\{ -\frac{1}{2 \cdot 3,72^2} (4 - 5,67)^2 \right\} \times$$

$$\frac{1}{\sqrt{2\pi 2,64^2}} \exp \left\{ -\frac{1}{2 \cdot 2,64^2} (8 - 6,83)^2 \right\} = 0,0133$$

$$f_2(4, 8) = \frac{1}{\sqrt{2\pi 2,36^2}} \exp \left\{ -\frac{1}{2 \cdot 2,36^2} (4 - 4,25)^2 \right\} \times$$

$$\frac{1}{\sqrt{2\pi 1,91^2}} \exp \left\{ -\frac{1}{2 \cdot 1,91^2} (8 - 4,50)^2 \right\} = 0,0066$$

Finalmente,

$$\mathbb{P}[G = 1 \mid \mathbf{X} = (4, 8)] = \frac{0,0133 \cdot 0,6}{0,0133 \cdot 0,6 + 0,0066 \cdot 0,4} = 0,7517$$

$$\mathbb{P}[G = 2 \mid \mathbf{X} = (4, 8)] = \frac{0,0066 \cdot 0,4}{0,0133 \cdot 0,6 + 0,0066 \cdot 0,4} = 0,2483$$

Por lo tanto, el punto $(4, 8)$ se clasifica como parte del grupo $G = 1$.

Notar que al utilizar la transformación logit (usando la clase K como referencia) se tiene:

$$\begin{aligned}\log \left(\frac{\mathbb{P}[G = k \mid X]}{\mathbb{P}[G = K \mid X]} \right) &= \log \left(\frac{\pi_k f_k(X)}{\pi_K f_K(X)} \right) = \log \left(\frac{\pi_k \prod_{l=1}^p f_{kl}(X_l)}{\pi_K \prod_{l=1}^p f_{Kl}(X_l)} \right) \\&= \log \left(\frac{\pi_k}{\pi_K} \right) + \sum_{l=1}^p \log \left(\frac{f_{kl}(X_l)}{f_{Kl}(X_l)} \right) \\&= \alpha_k + \sum_{l=1}^p g_{kl}(X_l)\end{aligned}$$

Esto tiene la forma de un modelo aditivo generalizado (GAM). Sin embargo, los modelos se ajustan de formas bastante diferentes.

1. Análisis Discriminante

1.1. Naive Bayes

- Sea X una variable aleatoria, tal que $Rec(X) \subset \mathbb{R}$, un estimador natural de la densidad de X en el punto x_0 es:

$$\hat{f}_X(x_0) = \frac{\#\{x_i : x_i \in V(x_0)\}}{\lambda n} = \frac{\#x_i \in (x_0 - \lambda/2; x_0 + \lambda/2]}{\lambda n}$$

donde $V(x_0)$ es una vecindad métrica de x_0 con ancho λ , y n la cantidad total de observaciones.

- Considere la función

$$K(x) = \begin{cases} 1; & -\frac{1}{2} \leq x < \frac{1}{2} \\ 0; & \text{otro caso} \end{cases} \Rightarrow \hat{f}_X(x_0) = \frac{1}{\lambda n} \sum_{i=1}^n K\left(\frac{x_0 - x_i}{\lambda}\right)$$

Este último es conocido como estimador de Kernel de caja de la densidad.

- La función K anterior puede ser extendida a cualquier función que cumpla con:

$$K(x) \geq 0 \quad \forall x \in \mathbb{R}; \quad K(x) = K(-x); \quad \int_{-\infty}^{\infty} K(x) dx = 1$$

Es decir, una función de densidad simétrica en el origen.

- Algunos ejemplos de Kernel son

Gaussiano $K(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in \mathbb{R}$

Triangular $K(x) = 1 - |x|, \quad -1 \leq x < 1$

Epanechnikov $K(x) = \frac{3(1 - x^2)}{4}, \quad -1 \leq x < 1$

1. Análisis Discriminante

1.2. Análisis Discriminante Lineal y Cuadrático

- Recordar que nuestro objetivo es maximizar $\mathbb{P}[G = k \mid \mathbf{X} = \mathbf{x}]$.
- Por el teorema de Bayes, se tiene

$$\mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}) = \frac{f_k(\mathbf{x})\pi_k}{\sum_{l=1}^K f_l(\mathbf{x})\pi_l},$$

- Los análisis discriminante lineal (LDA) y cuadrático (QDA) surgen al asumir que $f_k(\mathbf{x})$ es $\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$, y se diferencian según lo supuesto sobre $\boldsymbol{\Sigma}_k$:
 - LDA: matrices $\boldsymbol{\Sigma}_k$ son iguales entre grupos
 - QDA: matrices $\boldsymbol{\Sigma}_k$ difieren entre grupos
- La densidad de la distribución normal multivariada es

$$f_k(\mathbf{x}) = \frac{1}{(2\pi)^{p/2}|\boldsymbol{\Sigma}_k|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right\}$$

Para realizar la clasificación se calcula el cociente:

$$h(\mathbf{x}) = \log \left(\frac{\mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x})}{\mathbb{P}(G = l \mid \mathbf{X} = \mathbf{x})} \right) = \log \left(\frac{\pi_k}{\pi_l} \right) + \log \left(\frac{f_k(\mathbf{x})}{f_l(\mathbf{x})} \right)$$

Notar que

- Si $\mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}) = \mathbb{P}(G = l \mid \mathbf{X} = \mathbf{x})$ entonces $h(\mathbf{x}) = 0$ corresponde al límite de decisión.
- Si $\mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}) > \mathbb{P}(G = l \mid \mathbf{X} = \mathbf{x})$ entonces $h(\mathbf{x}) > 0$ y se clasifica en el grupo k por sobre el grupo l .
- Si $\mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}) < \mathbb{P}(G = l \mid \mathbf{X} = \mathbf{x})$ entonces $h(\mathbf{x}) < 0$ y se clasifica en el grupo l por sobre el grupo k .

Sea

$$\delta_k(\mathbf{x}) = \log(\pi_k) + \log(f_k(\mathbf{x})) \propto \log(\mathbb{P}(G = k \mid \mathbf{X} = \mathbf{x}))$$

En consecuencia

$$h(\mathbf{x}) = \delta_k(\mathbf{x}) - \delta_l(\mathbf{x}) \quad \Rightarrow \quad \hat{G}(\mathbf{x}) = \operatorname{argmax}_k \delta_k(\mathbf{x})$$

- Si $\Sigma_k = \Sigma$, entonces $\delta_k(\mathbf{x})$ es lineal en $\mathbf{x}$:

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \Sigma^{-1} \boldsymbol{\mu}_k + \log(\pi_k)$$

- Si Σ_k son diferentes, entonces $\delta_k(\mathbf{x})$ es cuadrática en $\mathbf{x}$:

$$\delta_k(\mathbf{x}) = -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) - \frac{1}{2} \log |\Sigma_k^{-1}| + \log(\pi_k)$$

Los parámetros podrían ser estimados usando los estimadores MV:

$$\begin{aligned}\hat{\pi}_k &= \frac{n_k}{n}, & \hat{\boldsymbol{\mu}}_k &= \frac{1}{n_k} \sum_{g_i=k} \mathbf{x}_i, \\ \hat{\boldsymbol{\Sigma}} &= \sum_{k=1}^K \sum_{g_i=k} \frac{(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)^\top}{n - K}, \\ \hat{\boldsymbol{\Sigma}}_k &= \sum_{g_i=k} \frac{(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)^\top}{n_k - 1},\end{aligned}$$

Notar que

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n - K} \sum_{k=1}^K (n_k - 1) \hat{\boldsymbol{\Sigma}}_k \quad (\text{Pooled})$$

LDA: Ejemplo

Consideremos nuevamente la muestra

y	1	0	0	1	1	1	1	1	0	0
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

Clasificar la observación $(x_1, x_2) = (4, 8)$ utilizando análisis discriminante lineal.

Considere el grupo $G = 1$ cuando $Y = 1$, y $G = 2$ cuando $Y = 0$.

Luego al separar la tabla se obtiene

Grupo $G = 1$						
y	1	1	1	1	1	1
x_1	9	3	3	1	9	9
x_2	6	9	7	9	8	2

Grupo $G = 2$				
y	0	0	0	0
x_1	6	1	4	6
x_2	2	6	6	4

$$\hat{\pi}_1 = 0,6; \quad \hat{\mu}_1 = (5,67, 6,83); \quad \hat{\Sigma}_1 = \begin{bmatrix} 13,87 & -6,27 \\ -6,27 & 6,97 \end{bmatrix}$$

$$\hat{\pi}_2 = 0,4; \quad \hat{\mu}_2 = (4,25, 4,50); \quad \hat{\Sigma}_2 = \begin{bmatrix} 5,58 & -3,50 \\ -3,50 & 3,67 \end{bmatrix}$$

$$\hat{\Sigma} = \begin{bmatrix} 10,76 & -5,23 \\ -5,23 & 5,73 \end{bmatrix} \Rightarrow \hat{\Sigma}^{-1} = \begin{bmatrix} 0,1670 & 0,1524 \\ 0,1524 & 0,3137 \end{bmatrix}$$

$$\begin{aligned}
\delta_1 = \delta_1(4, 8) &= \begin{bmatrix} 4 & 8 \end{bmatrix} \begin{bmatrix} 0,1670 & 0,1524 \\ 0,1524 & 0,3137 \end{bmatrix} \begin{bmatrix} 5,67 \\ 6,83 \end{bmatrix} \\
&\quad - \frac{1}{2} \begin{bmatrix} 5,67 & 6,83 \end{bmatrix} \begin{bmatrix} 0,1670 & 0,1524 \\ 0,1524 & 0,3137 \end{bmatrix} \begin{bmatrix} 5,67 \\ 6,83 \end{bmatrix} + \log(0,6) \\
&= 15,59
\end{aligned}$$

$$\begin{aligned}
\delta_2 = \delta_2(4, 8) &= \begin{bmatrix} 4 & 8 \end{bmatrix} \begin{bmatrix} 0,1670 & 0,1524 \\ 0,1524 & 0,3137 \end{bmatrix} \begin{bmatrix} 4, 25 \\ 4, 50 \end{bmatrix} \\
&\quad - \frac{1}{2} \begin{bmatrix} 4, 25 & 4, 50 \end{bmatrix} \begin{bmatrix} 0,1670 & 0,1524 \\ 0,1524 & 0,3137 \end{bmatrix} \begin{bmatrix} 4, 25 \\ 4, 50 \end{bmatrix} + \log(0,4) \\
&= 13,54
\end{aligned}$$

Por lo tanto, se clasifica como $G = 1$ (o bien $Y = 1$). Note que

$$\mathbb{P}[G = 1 \mid \mathbf{X} = (4, 8)] = \frac{e^{\delta_1}}{e^{\delta_1} + e^{\delta_2}} = 0,8859; \quad \mathbb{P}[G = 2 \mid \mathbf{X} = (4, 8)] = 0,1141$$

QDA: Ejemplo

Retomando la muestra de $n = 10$ y la observación $(x_1, x_2) = (4, 8)$:

Con $\hat{\Sigma}_1 = \begin{bmatrix} 13,87 & -6,27 \\ -6,27 & 6,97 \end{bmatrix}$, $\hat{\Sigma}_2 = \begin{bmatrix} 5,58 & -3,50 \\ -3,50 & 3,67 \end{bmatrix}$, la función discriminante cuadrática es:

$$\delta_k(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \hat{\boldsymbol{\mu}}_k)^\top \hat{\Sigma}_k^{-1}(\mathbf{x} - \hat{\boldsymbol{\mu}}_k) - \frac{1}{2} \log |\hat{\Sigma}_k| + \log(\hat{\pi}_k)$$

$$\delta_1(4, 8) = -2,656$$

$$\delta_2(4, 8) = -5,770$$

Como $\delta_1 > \delta_2$, la observación se clasifica en $G = 1$, igual que con LDA. Basados en estos valores verifique que las probabilidades de estar en el grupo 1 ($Y=1$) y grupo 2 ($Y=0$) son respectivamente 0.9575 y 0.0425.

Nota: en muestras pequeñas LDA y QDA pueden coincidir; la diferencia se aprecia en poblaciones con estructuras de covarianza distintas.

- James et al. (2021, §4.4) ilustran la diferencia mediante dos escenarios de datos simulados bivariados.
- **Escenario 1:** Ambas clases provienen de normales bivariadas con la **misma** matriz de covarianza ($\Sigma_1 = \Sigma_2$). La frontera de Bayes es lineal $\Rightarrow$ **LDA es óptimo**.
- **Escenario 2:** Las clases tienen **distintas** matrices de covarianza ($\Sigma_1 \neq \Sigma_2$). La frontera de Bayes es cuadrática $\Rightarrow$ **QDA es preferible**.
- La figura siguiente muestra la frontera LDA (línea discontinua, azul) y la frontera QDA (línea continua, roja) para ambos escenarios.

LDA vs QDA — Fronteras de decisión
(basado en James et al., ISL 2a ed.)





Figura 1: Fronteras de decisión LDA (discontinua, azul) y QDA (continua, roja).

LDA vs QDA: ¿Cuándo usar cada uno?

- Si $\Sigma_k \approx \Sigma$: **LDA** reduce la varianza al estimar un solo Σ , mejorando la precisión con muestras pequeñas.
- Si hay evidencia de covarianzas sustancialmente distintas entre clases: **QDA** modela mejor la frontera cuadrática real.
- **Regla práctica:** LDA suele preferirse cuando $n_k < 5p$; QDA puede ser conveniente con muestras grandes y p moderado (James et al., 2021).
- **Selección empírica:** compare el error de test (o validación cruzada K -fold) de ambos modelos y elija el de menor error de predicción.

Resumen: Métodos de Clasificación



Comparación métodos

	Naive Bayes	LDA	QDA
$f_k(\mathbf{x})$	$\prod_{j=1}^p f_{kj}(x_j)$	$\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$	$\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$
Covarianzas	No modela conjunta	$\boldsymbol{\Sigma}_k = \boldsymbol{\Sigma}$ (compartida)	$\boldsymbol{\Sigma}_k$ distintas
Frontera decisión	No lineal en general	Lineal en $\mathbf{x}$	Cuadrática en $\mathbf{x}$
n parámetros	$K \cdot p$ (marginales)	$Kp + \frac{p(p+1)}{2}$	$Kp + K \frac{p(p+1)}{2}$
Sesgo	Alto (indep. condicional)	Mayor	Menor
Varianza	Menor	Menor	Mayor

- En **R** naive-Bayes se puede estimar usando:
 - *e1071::naiveBayes*
 - *naivebayes::naive_bayes*
- En **R** LDA se puede estimar usando *MASS::lda*.
- En **R** QDA se puede estimar usando *MASS::qda*.

(Revisar material complementario)

¿Alguna consulta?

- Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.
- Efron, B. y Tibshirani, R.J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.
- Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.
- Wasserman, L. (2004). *All of Statistics. A Concise Course in Statistical Inference*. Springer. New York.