

EPG4001 Aprendizaje Supervisado

Clase 6: Árboles de decisión y Random Forest

Jorge Luis Bazán

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre, 2026



- 1 Árboles de Decisión
 - Árboles de Regresión
 - Algoritmo
 - Ajuste
 - Árboles de Clasificación
 - Funciones de pérdida
- 2 Random Forest
 - Definiciones
 - Algoritmo

1 Árboles de Decisión


- Árboles de Regresión
 - Algoritmo
 - Ajuste
- Árboles de Clasificación
 - Funciones de pérdida

2 Random Forest

- Definiciones
- Algoritmo

1. Árboles de Decisión

- Un **árbol de decisión** es un método de aprendizaje supervisado utilizado para tareas de clasificación y regresión.
- Su estructura representa una secuencia de decisiones que divide el conjunto de datos según los valores de las variables predictoras.
- Los principales componentes de un árbol son:
 - **Nodo raíz:** primer nodo del árbol que contiene todas las observaciones y donde inicia el proceso de partición.
 - **Nodo de decisión:** nodo interno donde se evalúa una condición sobre una variable para dividir los datos.
 - **Nodo hoja:** nodo terminal que entrega la predicción final (clase o valor estimado).
- El objetivo del árbol es generar particiones que permitan obtener grupos cada vez más homogéneos.



1. Árboles de Decisión

1.1 Árboles de Regresión

- Se conocen como árboles de Regresión para respuesta continua y como árboles de clasificación para respuesta categórica.

1. Árboles de Decisión

1.1 Árboles de Regresión

- Se conocen como árboles de Regresión para respuesta continua y como árboles de clasificación para respuesta categórica.
- Este método divide el espacio de las covariables en un conjunto de rectángulos y para cada uno de ellos se ajusta un modelo simple.

1. Árboles de Decisión

1.1 Árboles de Regresión

- Se conocen como árboles de Regresión para respuesta continua y como árboles de clasificación para respuesta categórica.
- Este método divide el espacio de las covariables en un conjunto de rectángulos y para cada uno de ellos se ajusta un modelo simple.
- El modelo más usado como ajuste es la constante.

1. Árboles de Decisión

1.1 Árboles de Regresión

- Se conocen como árboles de Regresión para respuesta continua y como árboles de clasificación para respuesta categórica.
- Este método divide el espacio de las covariables en un conjunto de rectángulos y para cada uno de ellos se ajusta un modelo simple.
- El modelo más usado como ajuste es la constante.
- Secuencialmente se escoge la covariable que divide en dos grupos la muestra.

1. Árboles de Decisión

1.1 Árboles de Regresión

- Se conocen como árboles de Regresión para respuesta continua y como árboles de clasificación para respuesta categórica.
- Este método divide el espacio de las covariables en un conjunto de rectángulos y para cada uno de ellos se ajusta un modelo simple.
- El modelo más usado como ajuste es la constante.
- Secuencialmente se escoge la covariable que divide en dos grupos la muestra.
- La covariable que es escogida es aquella que minimiza la función de pérdida adoptada (error cuadrático medio en el caso de regresión e índice de Gini o Deviance en el caso de clasificación).

1. Árboles de Decisión

1.1 Árboles de Regresión

- Se conocen como árboles de Regresión para respuesta continua y como árboles de clasificación para respuesta categórica.
- Este método divide el espacio de las covariables en un conjunto de rectángulos y para cada uno de ellos se ajusta un modelo simple.
- El modelo más usado como ajuste es la constante.
- Secuencialmente se escoge la covariable que divide en dos grupos la muestra.
- La covariable que es escogida es aquella que minimiza la función de pérdida adoptada (error cuadrático medio en el caso de regresión e índice de Gini o Deviance en el caso de clasificación).
- El algoritmo continúa hasta que alcanza una complejidad dada, la que es escogida de modo de no sobre-ajustar los datos.

Ejemplo: Considere la siguiente muestra

y	13	3	0	6	5	6	14	6	5	3
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

Ejemplo: Considere la siguiente muestra

y	13	3	0	6	5	6	14	6	5	3
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

- Considere la partición de la muestra en $x_1 < 4$ y $x_1 \geq 4$:

Ejemplo: Considere la siguiente muestra

y	13	3	0	6	5	6	14	6	5	3
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

- Considere la partición de la muestra en $x_1 < 4$ y $x_1 \geq 4$:

y	0	6	5	6
x_1	1	3	3	1
x_2	6	9	7	9

Cuadro 1: $x_1 < 4$

y	13	3	14	6	5	3
x_1	9	6	9	9	4	6
x_2	6	2	8	2	6	4

Cuadro 2: $x_1 \geq 4$

Ejemplo: Considere la siguiente muestra

y	13	3	0	6	5	6	14	6	5	3
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

- Considere la partición de la muestra en $x_1 < 4$ y $x_1 \geq 4$:

y	0	6	5	6
x_1	1	3	3	1
x_2	6	9	7	9

Cuadro 1: $x_1 < 4$

y	13	3	14	6	5	3
x_1	9	6	9	9	4	6
x_2	6	2	8	2	6	4

Cuadro 2: $x_1 \geq 4$

Observar que

$$\bar{y}(x_1 < 4) = 4,24 \quad \wedge \quad \bar{y}(x_1 \geq 4) = 7,33$$

- Para la rama $x_1 \geq 4$, se realiza una nueva partición de la muestra en $x_2 < 5$ y $x_2 \geq 5$:

- Para la rama $x_1 \geq 4$, se realiza una nueva partición de la muestra en $x_2 < 5$ y $x_2 \geq 5$:

y	3	6	3
x_1	6	9	6
x_2	2	2	4

Cuadro 3: $x_1 \geq 4 \wedge x_2 < 5$

y	13	14	5
x_1	9	9	4
x_2	6	8	6

Cuadro 4: $x_1 \geq 4 \wedge x_2 \leq 5$

- Para la rama $x_1 \geq 4$, se realiza una nueva partición de la muestra en $x_2 < 5$ y $x_2 \geq 5$:

y	3	6	3
x_1	6	9	6
x_2	2	2	4

Cuadro 3: $x_1 \geq 4 \wedge x_2 < 5$

y	13	14	5
x_1	9	9	4
x_2	6	8	6

Cuadro 4: $x_1 \geq 4 \wedge x_2 \leq 5$

Observar que

$$\bar{y}(x_1 \geq 4 \wedge x_2 < 5) = 4,00 \quad \wedge \quad \bar{y}(x_1 \geq 4 \wedge x_2 \leq 5) = 10,67$$

- Para la rama $x_1 \geq 4$, se realiza una nueva partición de la muestra en $x_2 < 5$ y $x_2 \geq 5$:

y	3	6	3
x_1	6	9	6
x_2	2	2	4



Cuadro 3: $x_1 \geq 4 \wedge x_2 < 5$



y	13	14	5
x_1	9	9	4
x_2	6	8	6

Cuadro 4: $x_1 \geq 4 \wedge x_2 \leq 5$

Observar que

$$\bar{y}(x_1 \geq 4 \wedge x_2 < 5) = 4,00 \quad \wedge \quad \bar{y}(x_1 \geq 4 \wedge x_2 \leq 5) = 10,67$$





¿Como determinar la partición optima?

1. Árboles de Decisión

1.1.1 Árboles de Regresión: Algoritmo

- (i) Considere todas las particiones de la región de los predictores en dos regiones donde la división es paralela a uno de los ejes. Habrá como máximo $(n - 1)p$ que considerar.

1. Árboles de Decisión

1.1.1 Árboles de Regresión: Algoritmo

- (i) Considere todas las particiones de la región de los predictores en dos regiones donde la división es paralela a uno de los ejes. Habrá como máximo particiones $(n - 1)p$ que considerar.
- (ii) Para cada partición, tomamos la media de la respuesta en esa partición. Además, se calcula

$$RSS(particion) = RSS(part1) + RSS(part2)$$

Luego elegimos la partición que minimiza la suma residual de cuadrados (RSS). También conocida como RSE por sus siglas en inglés.

1. Árboles de Decisión

1.1.1 Árboles de Regresión: Algoritmo


- (i) Considere todas las particiones de la región de los predictores en dos regiones donde la división es paralela a uno de los ejes. Habrá como máximo particiones $(n - 1)p$ que considerar.
- (ii) Para cada partición, tomamos la media de la respuesta en esa partición. Además, se calcula

$$RSS(particion) = RSS(part1) + RSS(part2)$$

Luego elegimos la partición que minimiza la suma residual de cuadrados (RSS). También conocida como RSE por sus siglas en inglés.

- (iii) Se procede de forma recursiva hasta que se alcanza el criterio de parada, el cual puede estar establecido como una cantidad mínima de datos en un nodo o bien por la complejidad

Árbol optimo, obtenido en **R**, mediante la libreria *rpart*.



1. Árboles de Regresión

1.1.2 Árboles de Regresión: Ajuste

- La estrategia preferida es hacer crecer un árbol grande T_0 , deteniendo el proceso de división sólo cuando se alcanza un tamaño de nodo mínimo.

1. Árboles de Regresión

1.1.2 Árboles de Regresión: Ajuste

- La estrategia preferida es hacer crecer un árbol grande T_0 , deteniendo el proceso de división sólo cuando se alcanza un tamaño de nodo mínimo.
- El árbol grande se *poda* utilizando la poda de complejidad de costes.

1. Árboles de Regresión

1.1.2 Árboles de Regresión: Ajuste

- La estrategia preferida es hacer crecer un árbol grande T_0 , deteniendo el proceso de división sólo cuando se alcanza un tamaño de nodo mínimo.
- El árbol grande se *poda* utilizando la poda de complejidad de costes.

Definición

Definimos un subárbol $T \subset T_0$ como cualquier árbol que se puede obtener podando T_0 , es decir, colapsando cualquier número de sus nodos internos (no terminales).

- Indexamos los nodos terminales por m , con el nodo m representando la región R_m .

- Indexamos los nodos terminales por m , con el nodo m representando la región R_m .
- Sean $|T|$ el número de nodos terminales de T , $N_m = \#\{x_i \in R_m\}$,

$$\hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m} y_i; \quad Q_m(T) = \frac{1}{N_m} \sum_{x_i \in R_m} (y_i - \hat{c}_m)^2$$

- Indexamos los nodos terminales por m , con el nodo m representando la región R_m .
- Sean $|T|$ el número de nodos terminales de T , $N_m = \#\{x_i \in R_m\}$,

$$\hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m} y_i; \quad Q_m(T) = \frac{1}{N_m} \sum_{x_i \in R_m} (y_i - \hat{c}_m)^2$$

- Se define el criterio de complejidad de costes por

$$C_\alpha(T) = \sum_{m=1}^{|T|} N_m Q_m(T) + \alpha |T|$$

Así, el objetivo es encontrar α , el subárbol $T_\alpha \subset T_0$, que minimice $C_\alpha(T)$.

- El parámetro de ajuste, $\alpha \geq 0$, gobierna el compromiso entre el tamaño del árbol y su bondad de ajuste a los datos. Para $\alpha = 0$, la solución es el árbol completo T_0 .

- El parámetro de ajuste, $\alpha \geq 0$, gobierna el compromiso entre el tamaño del árbol y su bondad de ajuste a los datos. Para $\alpha = 0$, la solución es el árbol completo T_0 .
- Para cada α existe un único subárbol más pequeño T_α que minimiza $C_\alpha(T)$.

- El parámetro de ajuste, $\alpha \geq 0$, gobierna el compromiso entre el tamaño del árbol y su bondad de ajuste a los datos. Para $\alpha = 0$, la solución es el árbol completo T_0 .
- Para cada α existe un único subárbol más pequeño T_α que minimiza $C_\alpha(T)$.
- Para encontrar T_α se utiliza la poda del eslabón más débil.

- El parámetro de ajuste, $\alpha \geq 0$, gobierna el compromiso entre el tamaño del árbol y su bondad de ajuste a los datos. Para $\alpha = 0$, la solución es el árbol completo T_0 .
- Para cada α existe un único subárbol más pequeño T_α que minimiza $C_\alpha(T)$.
- Para encontrar T_α se utiliza la poda del eslabón más débil.
- Se colapsa, sucesivamente, el nodo interno que produce el menor incremento por nodo en $\sum_m N_m Q_m(T)$, hasta producir el árbol de un solo nodo (raíz).

- El parámetro de ajuste, $\alpha \geq 0$, gobierna el compromiso entre el tamaño del árbol y su bondad de ajuste a los datos. Para $\alpha = 0$, la solución es el árbol completo T_0 .
- Para cada α existe un único subárbol más pequeño T_α que minimiza $C_\alpha(T)$.
- Para encontrar T_α se utiliza la poda del eslabón más débil.
- Se colapsa, sucesivamente, el nodo interno que produce el menor incremento por nodo en $\sum_m N_m Q_m(T)$, hasta producir el árbol de un solo nodo (raíz).
- Esto da una secuencia (finita) de subárboles, y se puede demostrar que esta secuencia debe contener a T_α .

- El parámetro de ajuste, $\alpha \geq 0$, gobierna el compromiso entre el tamaño del árbol y su bondad de ajuste a los datos. Para $\alpha = 0$, la solución es el árbol completo T_0 .
- Para cada α existe un único subárbol más pequeño T_α que minimiza $C_\alpha(T)$.
- Para encontrar T_α se utiliza la poda del eslabón más débil.
- Se colapsa, sucesivamente, el nodo interno que produce el menor incremento por nodo en $\sum_m N_m Q_m(T)$, hasta producir el árbol de un solo nodo (raíz).
- Esto da una secuencia (finita) de subárboles, y se puede demostrar que esta secuencia debe contener a T_α .
- La estimación de α se consigue mediante una validación cruzada k -fold: elegimos el valor $\hat{\alpha}$ para minimizar la suma de cuadrados de la validación cruzada. El árbol final es $T_{\hat{\alpha}}$.

1. Árboles de Decisión

1.2 Árboles de Clasificación

- En este caso, al ser la variable respuesta categórica, no se puede usar la pérdida cuadrática para definir el árbol.

1. Árboles de Decisión

1.2 Árboles de Clasificación

- En este caso, al ser la variable respuesta categórica, no se puede usar la pérdida cuadrática para definir el árbol.
- En un nodo m , que representa una región R_m con N_m observaciones, sea

$$\hat{p}_{mk} = \frac{1}{N_m} \sum_{x_i \in R_m} \mathbb{I}(y_i = k)$$

la proporción de observaciones de la clase k en el nodo m .

1. Árboles de Decisión

1.2 Árboles de Clasificación

- En este caso, al ser la variable respuesta categórica, no se puede usar la pérdida cuadrática para definir el árbol.
- En un nodo m , que representa una región R_m con N_m observaciones, sea

$$\hat{p}_{mk} = \frac{1}{N_m} \sum_{x_i \in R_m} \mathbb{I}(y_i = k)$$

la proporción de observaciones de la clase k en el nodo m .

- Se clasifican las observaciones del nodo m en la clase

$$k(m) = \operatorname{argmax}_k \hat{p}_{mk}.$$

1. Árboles de Decisión

1.2.1 Árboles de Clasificación: Funciones de pérdida

- Las funciones de pérdidas utilizadas (también denominadas de la impureza del nodo) son


$$Q_m(T) = \frac{1}{N_m} \sum_{i \in R_m} \mathbb{I}(y_i \neq k(m)) = 1 - \hat{p}_{mk(m)}; \quad \text{Misclassification}$$

$$Q_m(T) = \sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'} = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk}); \quad \text{Índice de Gini}$$

$$Q_m(T) = - \sum_{k=1}^K \hat{p}_{mk} \ln(\hat{p}_{mk}); \quad \text{Deviance o Entropía cruzada}$$

donde, para dos clases, si p es la proporción en la segunda clase, estas tres medidas son

$$1 - \max\{p, 1 - p\}; \quad 2p(1 - p); \quad -p \ln(p) - (1 - p) \ln(1 - p).$$



- Se debe utilizar el índice de Gini o la entropía cruzada al hacer crecer el árbol.

- Se debe utilizar el índice de Gini o la entropía cruzada al hacer crecer el árbol.
- Para guiar la poda de complejidad de costes, se puede utilizar cualquiera de las tres medidas, pero generalmente el índice de clasificación errónea es el más utilizado.

- Se debe utilizar el índice de Gini o la entropía cruzada al hacer crecer el árbol.
- Para guiar la poda de complejidad de costes, se puede utilizar cualquiera de las tres medidas, pero generalmente el índice de clasificación errónea es el más utilizado.
- Si se codifica cada observación como 1 para la clase k y 0 en caso contrario, la varianza en el nodo de esta respuesta es $p_{mk}(1 - p_{mk})$. Luego, al sumar, se muestra el índice de Gini.

- 1 Árboles de Decisión
 - Árboles de Regresión
 - Algoritmo
 - Ajuste
 - Árboles de Clasificación
 - Funciones de pérdida
- 2 Random Forest
 - Definiciones
 - Algoritmo

2. Random Forest

2.1 Definiciones

- **Random Forest** es una técnica de clasificación supervisada que se basa en un conjunto de árboles de decisiones, seleccionando aleatoriamente submuestras (con reemplazo) para elaborar cada árbol.

2. Random Forest

2.1 Definiciones

- **Random Forest** es una técnica de clasificación supervisada que se basa en un conjunto de árboles de decisiones, seleccionando aleatoriamente submuestras (con reemplazo) para elaborar cada árbol.
- El punto clave del Random Forest es utilizar una serie de árboles de decisión (diferentes individuos y diferentes variables), con el fin de mejorar la tasa de clasificación correcta.

2. Random Forest

2.1 Definiciones

- **Random Forest** es una técnica de clasificación supervisada que se basa en un conjunto de árboles de decisiones, seleccionando aleatoriamente submuestras (con reemplazo) para elaborar cada árbol.
- El punto clave del Random Forest es utilizar una serie de árboles de decisión (diferentes individuos y diferentes variables), con el fin de mejorar la tasa de clasificación correcta.
- Random Forest incorpora la técnica de **bootstrap**, generando cada árbol a partir de una muestra aleatoria con reemplazo del conjunto original. Esto introduce variabilidad entre árboles y reduce la varianza del modelo final al combinar sus predicciones.


2. Random Forest

2.1 Definiciones

- **Random Forest** es una técnica de clasificación supervisada que se basa en un conjunto de árboles de decisiones, seleccionando aleatoriamente submuestras (con reemplazo) para elaborar cada árbol.
- El punto clave del Random Forest es utilizar una serie de árboles de decisión (diferentes individuos y diferentes variables), con el fin de mejorar la tasa de clasificación correcta.
- Random Forest incorpora la técnica de **bootstrap**, generando cada árbol a partir de una muestra aleatoria con reemplazo del conjunto original. Esto introduce variabilidad entre árboles y reduce la varianza del modelo final al combinar sus predicciones.
- Cada árbol individual genera una predicción de clase y la clase con más votos se convierte en la predicción del modelo.

El concepto es simple pero poderoso.

El concepto es simple pero poderoso.



Tally: Six 1s and Three 0s

Prediction: 1

2. Random Forest

2.2 Algoritmo

Cada árbol (dentro del bosque) se construye así:

2. Random Forest

2.2 Algoritmo

Cada árbol (dentro del bosque) se construye así:

- Usando el conjunto de entrenamiento de tamaño N . Se toma una aleatoria **con reemplazo**. Esta muestra será el conjunto de entrenamiento para construir el árbol i .

2. Random Forest

2.2 Algoritmo

Cada árbol (dentro del bosque) se construye así:

- Usando el conjunto de entrenamiento de tamaño N . Se toma una aleatoria **con reemplazo**. Esta muestra será el conjunto de entrenamiento para construir el árbol i .
- Si existen p variables de entrada, se especifica $M < p$ tal que para cada nodo, M variables se seleccionan aleatoriamente. La mejor división de estos M atributos es usado para ramificar el árbol. El valor M se mantiene constante durante la generación de todo el bosque.

2. Random Forest

2.2 Algoritmo


Cada árbol (dentro del bosque) se construye así:

- Usando el conjunto de entrenamiento de tamaño N . Se toma una aleatoria **con reemplazo**. Esta muestra será el conjunto de entrenamiento para construir el árbol i .
- Si existen p variables de entrada, se especifica $M < p$ tal que para cada nodo, M variables se seleccionan aleatoriamente. La mejor división de estos M atributos es usado para ramificar el árbol. El valor M se mantiene constante durante la generación de todo el bosque.
- Cada árbol crece hasta su máxima extensión posible, sin proceso de poda. Nuevas instancias se predicen a partir de la agregación de las predicciones de los árboles (i.e., mayoría de votos para clasificación, promedio para regresión)

Desafiliado	Min_En_D ia	Min_Internaci onales	Reclamos	Llamadas_Inte rnacionales	Plan_Intern acional
no	187.7	9.1	0	5	no
yes	116.9	7	0	10	no
no	265.1	10	1	3	no
no	156.6	3.1	3	9	no
no	119.1	4.9	2	1	no
no	119.1	2.9	2	12	no
yes	332.9	5.4	4	9	no
yes	129.1	12.7	4	6	no
no	128.8	2	1	2	no
no	123	3	2	8	no
no	128.8	11.2	1	2	no
yes	116.9	4	0	2	no
no	187.7	9	0	5	no

Muestra Aleatoria de
Individuos y Variables

Fuente: <http://apuntes-r.blogspot.com/2014/11/ejemplo-de-random-forest.html>



¿Alguna consulta?

Julian J. Faraway (2016) *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*, Boca Raton: Chapman Hall/CRC.

Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.

Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.