

EPG4001 - Aprendizaje Supervisado

Clase 7: SVM, KNN, Clases Desbalanceadas

Jorge Luis Bazán

Magíster en Inteligencia Artificial
Pontificia Universidad Católica de Chile

Segundo Bimestre 2026



- 1 Support Vector Machine (SVM)
 - Hiperplanos de separación óptimos
 - SVM Lineal para Clasificación
 - SVM No Lineal para Clasificación
- 2 Clasificación con Clases Desbalanceadas
 - Balance de Clases
 - Oversampling
 - Criterio híbrido
 - Probabilidad de Corte
- 3 KNN: Vecinos más cercanos

- 1 Support Vector Machine (SVM)
 - Hiperplanos de separación óptimos
 - SVM Lineal para Clasificación
 - SVM No Lineal para Clasificación
- 2 Clasificación con Clases Desbalanceadas
 - Balance de Clases
 - Oversampling
 - Criterio híbrido
 - Probabilidad de Corte
- 3 KNN: Vecinos más cercanos

1. Support Vector Machine (SVM)

- Una máquina de vectores de soporte o **SVM** es un método de separación de hiperplanos óptimos.
- Una SVM construye un hiperplano o conjunto de hiperplanos en un espacio de dimensionalidad muy alta (o incluso infinita) que puede ser utilizado en problemas de clasificación o regresión.
- El objetivo es trabajar en otro espacio donde las clases de una variable categórica están perfectamente separadas, y así pueden ser fácilmente clasificadas.

1. Support Vector Machine (SVM)

1.1. Hiperplanos de separación ótimos

Definición (Hiperplano)

Un hiperplano, desde el punto de vista matemático, corresponde a una combinación lineal de las coordenadas más un desfase. Es decir, un hiperplano se define como el conjunto


$$P = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{x}^\top \boldsymbol{\beta} + \beta_0 = 0\}, \quad \text{donde} \quad \|\boldsymbol{\beta}\| = 1,$$

Observaciones:

- Sea $f(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta} + \beta_0$, la cual representa la distancia con signo desde el punto $\mathbf{x}$ al hiperplano P .
- El hiperplano de separación óptima separa las dos clases y maximiza la distancia al punto más cercano de cualquiera de ellas.
- Al maximizar el margen entre las dos clases en los datos de entrenamiento, conduce a un mejor rendimiento de la clasificación en los datos de prueba.

Si M representa el margen entre la observación más cercana al hiperplano, entonces se plantea el problema de optimización

$$\max_{\beta, \beta_0} M \quad \text{sujeto a} \quad \|\beta\| = 1$$



Casos lineales Separable y No separable. Fuente: Hastie et al. (2008).

1. Support Vector Machine (SVM)

1.2. SVM Lineal para Clasificación

- Considere una muestra de entrenamiento de n observaciones. Asuma que $y_i \in \{-1, 1\}$.
- Asumiendo que las clases son separables, podemos encontrar una función $f(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta} + \beta_0$ con $y_i f(\mathbf{x}_i) > 0 \quad \forall i$.

- Así una regla de clasificación, inducida por f es

$$G(\mathbf{x}) = \text{sign}\{\mathbf{x}^\top \boldsymbol{\beta} + \beta_0\}$$

- Así, para encontrar los coeficientes $\boldsymbol{\beta}$ y β_0 , se resuelve el problema de optimización

$$\max_{\boldsymbol{\beta}, \beta_0} M \quad \text{sujeto a} \quad \|\boldsymbol{\beta}\| = 1 \quad \wedge \quad y_i [\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0] > M, \quad i = 1, \dots, n$$

- El conjunto de restricciones garantiza que todos los puntos están al menos a una distancia con signo M de la frontera de decisión definida por $\boldsymbol{\beta}$ y β_0 .

- Podemos deshacernos de la restricción $\|\boldsymbol{\beta}\| = 1$ sustituyendo las condiciones por

$$\frac{1}{\|\boldsymbol{\beta}\|} y_i [\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0] > M$$

con lo que se debe redefinir β_0 y fijar $M = \frac{1}{\|\boldsymbol{\beta}\|}$.

- Luego el problema anterior es equivalente a

$$\min_{\boldsymbol{\beta}, \beta_0} \frac{1}{2} \|\boldsymbol{\beta}\|^2 \quad \text{sueto a} \quad y_i [\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0] > 1, \quad i = 1, \dots, n$$

Tratándose de un problema de optimización convexo (problema cuadrático con restricciones de desigualdad lineales).

- La función de Lagrange (o problema primal), es

$$L_p(\boldsymbol{\beta}, \beta_0) = \frac{1}{2} \|\boldsymbol{\beta}\|^2 - \sum_{i=1}^n \alpha_i [y_i (\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0) - 1],$$

donde los α_i son los multiplicadores de Lagrange.

- Derivando e igualando a cero, se obtiene que

$$\boldsymbol{\beta} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad \wedge \quad \sum_{i=1}^n \alpha_i y_i = 0$$

- Reemplazando en L_P se tiene el problema dual

$$L_D(\boldsymbol{\alpha}) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_j \quad \text{sejeto a} \quad \alpha_i \geq 0$$

- El problema dual es un problema de optimización convexa más sencillo, cuya solución debe satisfacer las condiciones de Karush-Kuhn-Tucker (KKT). Desde estas condiciones se deduce que
 - ❶ Si $\alpha > 0$, entonces $y_i(\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0) - 1 = 0$, es decir, $\mathbf{x}_i$ se encuentra en el umbral.
 - ❷ Si $y_i(\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0) - 1 > 0$, es decir, $\mathbf{x}_i$ no se encuentra en el umbral, entonces $\alpha_i = 0$.

- Los valores α_i distintos de 0 se denominan valores de soporte, mientras que los $\mathbf{x}_i$ asociados se denominan vectores de soporte.
- Note que el vector solución $\boldsymbol{\beta}$ se define en términos de una combinación lineal de los puntos de soporte.
- Mientras que β_0 se obtiene resolviendo

$$\alpha_i \left[y_i (\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0) - 1 \right] = 0$$

para cualquiera de los puntos de soporte.

- Finalmente, la regla de clasificación para nuevas observaciones, $\mathbf{x}_0$, es

$$G(\mathbf{x}_0) = \text{sign} \left\{ \hat{f}(\mathbf{x}_0) \right\} = \text{sign} \left\{ \mathbf{x}_0^\top \hat{\boldsymbol{\beta}} + \hat{\beta}_0 \right\}$$

- Suponga ahora que las clases se solapan en el espacio de características.
- Para solucionar este problema se definen las variables de holgura: $\xi_1, \dots, \xi_n$.
- Además, la nueva restricción queda dada por

$$y_i[\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0] > (1 - \xi_i), \quad i = 1, \dots, n \quad \text{donde} \quad \xi_i > 0, \quad \sum \xi_i \leq \text{const.}$$

- Por lo tanto, el problema a optimizar es

$$\min_{\boldsymbol{\beta}, \beta_0} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{sujeto a} \quad \xi_i > 0 \quad \wedge \quad y_i[\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0] > 1 - \xi_i$$

- El parámetro C , reemplaza la constante en $\sum \xi_i \leq \text{const.}$, y se denomina parámetro de coste. Esta regularización es conocida como C-SVM.

- El problema nuevamente se resuelve utilizando multiplicadores de Lagrange para levantar las restricciones.
- Ahora, α_i representa el multiplicador asociado a la restricción

$$y_i[\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0] - (1 - \xi_i) > 0.$$

- Se agregan los multiplicadores asociados al signo de ξ_i , denotado por μ_i .
- En consecuencia el problema primal, queda como

$$L_p(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi}) = \frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i [y_i(\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0) - (1 - \xi)] - \sum_{i=1}^n \mu_i \xi_i.$$

- Derivando e igualando a 0, se obtiene

$$\boldsymbol{\beta} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad \wedge \quad \sum_{i=1}^n \alpha_i y_i = 0 \quad \wedge \quad \alpha_i = C - \mu_i$$

- Nuevamente, reemplazando en L_p , se obtiene el problema dual

$$L_D(\boldsymbol{\alpha}) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i \quad \text{sujeto a} \quad 0 \leq \alpha_i \leq C$$

- La única diferencia con el caso separable es la cota superior C de los multiplicadores de Lagrange α_i , observando que $C = \infty$ corresponde al caso separable.
- Manteniendo así el valor de $\hat{\beta}$ y la interpretación de los puntos de soporte.
- Entre los puntos de soporte, algunos estarán en el borde del margen ($\hat{\xi}_i = 0$), y por tanto, se caracterizarán por $0 < \hat{\alpha}_i < C$; los restantes ($\hat{\xi}_i > 0$) tienen $\hat{\alpha}_i = C$.
- Cualquiera de estos puntos de margen pueden utilizarse para resolver β_0 , y normalmente se utiliza una media de todas las soluciones por motivos de estabilidad numérica.

1. Support Vector Machine (SVM)

1.3. SVM No Lineal para Clasificación

- En ambos casos, separable y no separable, el problema dual (sujeto a algunas restricciones específicas) queda caracterizado por

$$L_D(\boldsymbol{\alpha}) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i$$

- Notar que L_D depende de las covariables a través del producto punto $\mathbf{x}_i^\top \mathbf{x}_j$, el cual proviene de la ecuación del hiperplano, lo que provoca que las fronteras de decisión sean rectas.
- Ahora bien, es posible generalizar este producto, de modo que las fronteras sean curvas, para ello se considera la transformación

$$\mathbf{z}_i = \mathbf{h}(\mathbf{x}_i) = (h_1(\mathbf{x}_i), h_2(\mathbf{x}_i), \dots, h_m(\mathbf{x}_i)).$$

- luego el hiperplano se escribe en términos de $\mathbf{z}_i$, es decir,

$$f(\mathbf{z}) = \mathbf{z}^\top \boldsymbol{\beta} + \beta_0 = \mathbf{h}(\mathbf{x})^\top \boldsymbol{\beta} + \beta_0 = \tilde{f}(\mathbf{x}).$$

- En consecuencia, el nuevo problema dual:

$$L_D(\boldsymbol{\alpha}) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \underbrace{h(\mathbf{x}_j^\top)}_{\mathbf{z}_j^\top} \underbrace{h(\mathbf{x}_j)}_{\mathbf{z}_j^\top}$$

depende de las covariables originales solo a través de productos internos que involucran a $h(\mathbf{x})$.

- En consecuencia, basta solo con especificar la función de kernel:

$$K(\mathbf{u}, \mathbf{v}) = \langle h(\mathbf{u}), h(\mathbf{v}) \rangle,$$

para la cual solo se requiere que sea una función simétrica y semi-definida positiva.

- Finalmente, la solución se puede escribir como

$$\tilde{f}(\mathbf{x}) = \sum_{i=1}^n \hat{\alpha}_i y_i K(\mathbf{x}, \mathbf{x}_i) + \hat{\beta}_0$$

- Las Tres opciones populares para K en la literatura SVM son

$$K(\mathbf{u}, \mathbf{v}) = (1 + \langle \mathbf{u}, \mathbf{v} \rangle)^d \quad \text{Polinomial}$$

$$K(\mathbf{u}, \mathbf{v}) = \exp\{-\gamma \|\mathbf{u} - \mathbf{v}\|^2\} \quad \text{Radial}$$

$$K(\mathbf{u}, \mathbf{v}) = \tanh\{\kappa_1 \langle \mathbf{u}, \mathbf{v} \rangle + \kappa_2\} \quad \text{Red neuronal}$$

- En **R** la función `e1071::svm` permite ajustar un SVM.

- 1 Support Vector Machine (SVM)
 - Hiperplanos de separación ótimos
 - SVM Lineal para Clasificación
 - SVM No Lineal para Clasificación
- 2 Clasificación con Clases Desbalanceadas
 - Balance de Clases
 - Oversampling
 - Criterio híbrido
 - Probabilidad de Corte
- 3 KNN: Vecinos más cercanos

2. Clasificación con Clases Desbalanceadas

- Las clases desbalanceadas se producen cuando una categoría representa más del 90 % de los datos.
- Notar que la clase minoritaria tendrá menos del 10 % de la muestra.
- En la mayoría de los casos prácticos la clase de minoritaria es la clase de interés. Ejemplos:
 - Detección de fraudes.
 - Enfermedades.
 - Fuga de clientes.
 - Detección de Spam.
- La mayoría de los métodos son computacionales y buscan mejorar alguna medida de desempeño.


Para tratar con bases desbalanceadas comúnmente se utilizan las siguientes técnicas:

- **Balancear la Data:** Consiste en aumentar o disminuir alguna de las clases para eliminar el desbalance, esto se realiza solo en la data de entrenamiento. Específicamente:
 - **Undersampling:** Consiste en eliminar datos de la clase mayoritaria.
 - **Oversampling:** Consiste en aumentar la clase minoritaria, el aumento puede ser incluso creando datos sintéticos considerando pequeñas perturbaciones de los datos originales
- **Probabilidad de cortes:** En los algoritmos que reportan la probabilidad, se puede modificar el punto de corte para mejorar una métrica específica.

2. Clasificación con Clases Desbalanceadas

2.1. 1

Existen varias estrategias para realizar undersampling, todas tienen el mismo objetivo, por ejemplo en la data spam existe una proporción 91,7 % (no spam)-8,3 % (si spam).



- **Undersampling aleatorio:** Selecciona al azar los elementos de la clase mayoritaria.

- **Condensed Nearest Neighbours (CNN):** Se basa en el k-NN y busca eliminar (condensar) aquellos datos que no aportan mayor información.

Dado un conjunto de datos $\mathbf{X} = (X_1, \dots, X_n)$ con sus respectivas etiquetas y_i , $i = 1, \dots, n$, se procede iterativamente hasta encontrar un nuevo conjunto de datos U , denominado prototipo.

- ❶ Se añade a $U = \{X_0\}$ un elemento de forma aleatoria.
- ❷ Por el 1-NN se elige el nuevo elemento de U considerando a un elemento de etiqueta diferente al existente.
- ❸ Los vecinos cercanos en $k = 1$ cuyas etiquetas coincidan son absorbidos o eliminados.

Este proceso se realiza para cada uno de los elementos de $\mathbf{X}$.

En el caso de querer solo reducir los elementos de una clase, se procede de la misma forma con la salvedad que todos los elementos de la clase que no se reduce quedan en el conjunto U desde el comienzo.

- **Tomek Links:** A diferencia del anterior, este método se basa en eliminar directamente. Busca corregir la subjetividad aleatoria del método anterior. Suponga que se conoce la distancia entre los datos X_i y X_j de distinta clase (denominada enlace de Tomek).

Los enlaces de Tomek deben cumplir:

- 1 El vecino más cercano de X_i es X_j y viceversa.
- 2 X_i y X_j deben pertenecer a clases diferentes.

La instancia de la clase mayoritaria será eliminada si no existe un vecino más cercano entre X_i y X_j .

Pretende eliminar o limpiar las regiones en las que las instancias de distinta clase están más cerca.


- **Edited Nearest Neighbours (ENN)**: Es un método de limpieza similar a Tomek Links, pero basado en 3-NN. Opera de la siguiente forma:
 - 1 Se escoge X_j que pertenece a la clase mayoritaria
 - 2 Se determinan los 3-vecinos más próximos
 - 3 Si la clase de los vecinos más próximos (al menos 2) difiere de la clase de X_j , este elemento será eliminado.

Este proceso puede repetirse varias veces sobre el conjunto de datos (iterativamente) lo que se denomina **Repeated Edited Nearest Neighbours**.

2. Clasificación con Clases Desbalanceadas

2.1.1. Oversampling

Existen varias estrategias para realizar oversampling, todas tienen el mismo objetivo, por ejemplo,



- **Oversampling aleatorio:** Selecciona al azar los elementos de la clase minoritaria hasta balancear los datos.

- **SMOTE:** (Synthetic Minority Oversampling Technique) Se basa en la réplica de la clase minoritaria tomando cada caso e introduciendo nuevos ejemplos sobre las líneas de unión de sus k -vecinos.

Es decir, utilizando los k -vecinos de X_j se crean k nuevos registros denotados por $S_1^j, \dots, S_k^j$.

El procedimiento es el siguiente:


- 1 Se obtienen los k -vecinos de $\mathbf{X}_{min}$ (clase minoritaria)
- 2 Se calculan los datos sintéticos mediante

$$S_i^j = X_j + \lambda(X_i^j - X_j), \quad \lambda \sim (0, 1), \quad i = 1, \dots, k.$$

2. Clasificación con Clases Desbalanceadas

2.1.2. Criterio híbrido

Alternativamente es posible combinar las técnicas de undersampling y oversamplig.



Clasificación con Clases Desbalanceadas: Híbridas


- Se busca eliminar la información duplicada de la clase mayoritaria y exacerbar la información de la clase minoritaria.
- Las técnicas más utilizadas son:
 - SMOTE - Tomek Links
 - SMOTE - ENN
- En R se pueden utilizar las librerías *caret*, *unbalance*.

2. Clasificación con Clases Desbalanceadas

2.2. Probabilidad de Corte

- Los algoritmos de clasificación, basados en la probabilidad de cada clase, suelen clasificar la clase con la probabilidad más alta, donde en el caso de dos clases, esto equivale a clasificar aquella con probabilidad mayor a 0,5.
- Este punto corte proviene desde un criterio de optimización como minimizar la tasa de clasificación errónea, Sin embargo, es posible modificar este punto de corte para mejorar una métrica específica.
- La probabilidad de corte óptima puede ser encontrada tomando en cuenta métricas que tengan como objetivo la clase positiva y clase negativa, tales como:
 - ① Igualar la sensibilidad y la especificidad
 - ② Maximizar el F-beta-score, para algún beta fijo apropiado.
- En cada caso, se calcula la matriz de confusión para valores de probabilidad variando de 0 a 1.

Por ejemplo, la figura muestra que la probabilidad de corte es 0.039 con el primer criterio y 0.051 con el segundo criterio para $\beta=0.5$.



En resumen, se debe fijar el criterio y la probabilidad de corte se encuentra realizando muchas veces la clasificación.

- 1 Support Vector Machine (SVM)
 - Hiperplanos de separación óptimos
 - SVM Lineal para Clasificación
 - SVM No Lineal para Clasificación
- 2 Clasificación con Clases Desbalanceadas
 - Balance de Clases
 - Oversampling
 - Criterio híbrido
 - Probabilidad de Corte
- 3 KNN: Vecinos más cercanos

3. KNN: Vecinos más cercanos

- Hasta ahora hemos trabajado con métodos **paramétricos** (regresión logística, LDA, SVM), que asumen una forma funcional específica para $f(\mathbf{x})$.
- Los **métodos de vecinos más cercanos** (*nearest-neighbor methods*) representan el extremo opuesto: no asumen ninguna forma para la frontera de decisión.
- La idea central: para predecir en un punto de consulta $\mathbf{x}_0$, usar las observaciones del **conjunto de entrenamiento** $\mathcal{T}$ que sean más cercanas a $\mathbf{x}_0$ en el espacio de covariables.
- Estrategia especialmente útil cuando la frontera de decisión es irregular o cuando cada clase tiene muchos posibles prototipos (Hastie et al., 2008).
- El único parámetro a elegir es k (número de vecinos), que controla el trade-off sesgo-varianza.

Sea $\mathcal{T} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ el **conjunto de entrenamiento**, con $\mathbf{x}_i \in \mathbb{R}^p$ e $y_i \in \mathcal{G} = \{1, \dots, K\}$.

Definición (k -Vecinos más Cercanos)

Dado un punto de consulta $\mathbf{x}_0$, sea $\mathcal{N}_k(\mathbf{x}_0)$ la vecindad definida por los k puntos de $\mathcal{T}$ más cercanos. Entonces:

- Para **regresión**: $\hat{Y}(\mathbf{x}_0) = \frac{1}{k} \sum_{\mathbf{x}_i \in \mathcal{N}_k(\mathbf{x}_0)} y_i$
- Para **clasificación**: $\hat{G}(\mathbf{x}_0) = \operatorname{argmax}_{g \in \mathcal{G}} \frac{1}{k} \sum_{\mathbf{x}_i \in \mathcal{N}_k(\mathbf{x}_0)} \mathbb{1}(y_i = g)$


es decir, la clase más frecuente (moda) entre los k vecinos.

Observación

La cercanía requiere una métrica; por defecto, distancia euclidiana $d(i) = \|\mathbf{x}_i - \mathbf{x}_0\|$. Cuando los predictores tienen escalas distintas se recomienda estandarizarlos usando los parámetros de $\mathcal{T}$ (Hastie et al., 2008).

3. KNN: Vecinos más cercanos

Fronteras de decisión según k




Clasificador 15-NN sobre datos de dos clases. La frontera es irregular y responde a agrupaciones locales de cada clase. Fuente: Figura 2.2, Hastie et al. (2008).

3. KNN: Vecinos más cercanos

Selección de k : sesgo-varianza

- k **pequeño** ($k = 1$): cada $\mathbf{x}_i \in \mathcal{T}$ es su propio prototipo $\Rightarrow$ **alta varianza, bajo sesgo**. Frontera irregular (teselado de Voronoi).
- k **grande**: promedia más observaciones de $\mathcal{T} \Rightarrow$ **baja varianza, mayor sesgo**. Frontera más suave, cercana al clasificador lineal.



Error de entrenamiento ($\mathcal{T}$), prueba ($\mathcal{T}^*$) y VC 10-fold vs. k . Fuente: Figura 13.4, Hastie et al. (2008).

Observación

El k óptimo se selecciona por validación cruzada sobre $\mathcal{T}$ y se evalúa en $\mathcal{T}^*$.

3. KNN: Vecinos más cercanos

Propiedades y consideraciones prácticas

- **Basado en memoria:** no hay fase de entrenamiento explícita; el modelo es el conjunto $\mathcal{T}$. El costo se incurre al predecir.
- **Consistencia asintótica** (Hastie et al., 2008): si $N, k \rightarrow \infty$ con $k/N \rightarrow 0$:

$$\hat{f}(\mathbf{x}_0) = \text{Ave}(y_i \mid \mathbf{x}_i \in \mathcal{N}_k(\mathbf{x}_0)) \longrightarrow \mathbb{E}(Y \mid X = \mathbf{x}_0).$$

k -NN aproxima universalmente la esperanza condicional.

- **Maldición de la dimensionalidad:** en dimensiones altas los vecinos de $\mathbf{x}_0$ en $\mathcal{T}$ pueden estar muy alejados, degradando el rendimiento.
- **Resultado de Cover y Hart (1967):** el error del clasificador 1-NN es asintóticamente a lo sumo el *doble* del error de Bayes.
- En **R**: `class::knn(train= $\mathcal{T}$ , test= $\mathcal{T}^*$ , cl, k).`

Ejemplo: Considere la siguiente muestra

y	a	a	a	a	a	b	b	b	b	b
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4

- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 1-vecinos.
- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 2-vecinos.
- Estimar Y para $x_1 = 5$, $x_2 = 2$, usando 3-vecinos

Solución: Sea $\mathbf{x} = (5, 2)$, luego debemos calcular las distancias de los puntos observados a $\mathbf{x}$.

	1	2	3	4	5	6	7	8	9	10
y	a	a	a	a	a	b	b	b	b	b
x_1	9	6	1	3	3	1	9	9	4	6
x_2	6	2	6	9	7	9	8	2	6	4
$d^2(\mathbf{x}_i, \mathbf{x})$	32	1	32	53	29	65	52	16	17	5

- $N_1^* = \{2\}$ entonces $\hat{Y} = a$.
- $N_2^* = \{2, 10\}$ entonces $\hat{Y} = \text{moda}\{a, b\} = b$, se agrega un vecino.
- $N_3^* = \{2, 10, 6\}$ entonces $\hat{Y} = \text{moda}\{a, b, b\} = b$.

Obs.: Los resultados dependen tanto de la cantidad de vecinos, así como también de la distancia utilizada.

¿Alguna consulta?

- Christopher M. Bishop (2006) *Pattern Recognition and Machine Learning*. New York: Springer.
- Efron, B. y Tibshirani, R.J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.
- Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. Springer Series in Statistics.
- Wasserman, L. (2004). *All of Statistics. A Concise Course in Statistical Inference*. Springer. New York.