

Complemento: Análisis diagnóstico en Regresión

Jorge Luis Bazán

02-06-2026

Contents

1. Introducción	1
2. Propuesta de modelo	4
3. Selección del modelo: método Stepwise y AIC	7
4. Análisis de diagnóstico	8
5. Influencia de la exclusión de puntos	10
6. Especificación final	21
7. Conclusiones	21
8. REFERENCIAS	21

1. Introducción

En este documento realizamos un análisis usando un modelo lineal para los datos referentes a la producción de gasolina en una refinería (Wood, 1973). En el archivo `reg4.dat` se encuentran los datos de una determinada refinería, con tres variables observadas durante el proceso y una cuarta variable que es una combinación de las tres primeras. La respuesta es el número de octanos del producto obtenido. El octanaje es la propiedad que determina el límite máximo al que la gasolina, junto con el aire, puede ser comprimida en la cámara de combustión del vehículo sin quemarse antes de recibir la chispa de las bujías. Las mejores gasolinas tienen un octanaje alto. En grandes refinerías, el aumento de un octano en la producción de gasolina puede representar un aumento de algunos millones de dólares en el costo final de producción. Use el método stepwise para seleccionar las variables explicativas significativas. Realice un análisis de diagnóstico con el modelo seleccionado. Comente.

1.1 Propósito del análisis

La producción de gasolina se mide en octanos. Las mejores gasolinas tienen un octanaje alto. En grandes refinerías, el aumento de un octano en la producción de gasolina puede representar un aumento de algunos millones de dólares en el costo final de producción. Durante el proceso de producción se consideran tres variables y una cuarta que es combinación de las tres primeras.

Se propone encontrar el mejor modelo para predecir la producción de gasolina, considerando una selección de cuatro variables.

1.2 Datos

El archivo `reg4.dat` (<http://www.ime.usp.br/~giapaula/reg4.dat>) contiene las siguientes variables correspondientes a la producción de gasolina de una refinería, mediante 82 observaciones. Wood, F. (1973).

Octano es la producción de gasolina medida en número de octanos; `x1`, `x2` y `x3` representan compuestos y `conb` es el logaritmo de las condiciones del proceso. La Tabla 1 presenta los datos.

El código siguiente lee los datos directamente del archivo local `dados/reg4.dat`, manteniendo los mismos nombres de variables usados en el análisis.

```
REG4.DAT <- read.table(  
  "reg4.dat",  
  col.names = c("x1", "x2", "x3", "conb", "octano")  
)  
  
REG4.DAT$obser <- seq_len(nrow(REG4.DAT))  
REG4.DAT <- REG4.DAT[, c("obser", "x1", "x2", "x3", "conb", "octano")]  
  
head(REG4.DAT)
```

```
##   obser    x1    x2 x3 conb octano  
## 1      1 55.33 1.72 54 1.66 92.19  
## 2      2 59.13 1.20 53 1.58 92.74  
## 3      3 57.39 1.42 55 1.62 91.88  
## 4      4 56.43 1.78 55 1.66 92.80  
## 5      5 55.98 1.58 54 1.63 92.56  
## 6      6 56.16 2.12 56 1.68 92.61
```

```
tabela1_esquerda <- REG4.DAT[1:41, ]  
tabela1_direita <- REG4.DAT[42:82, ]  
  
names(tabela1_esquerda) <- c("obser", "x1", "x2", "x3", "conb", "octano")  
names(tabela1_direita) <- c("obser ", "x1 ", "x2 ", "x3 ", "conb ", "octano ")  
  
tabela1 <- cbind(tabela1_esquerda, tabela1_direita)  
  
knitr::kable(  
  tabela1,  
  digits = 2,  
  caption = "Datos correspondientes a la producción de gasolina durante 82 días (Wood, 1973)."  
)
```

Tabla 1: Datos correspondientes a la producción de gasolina durante 82 días (Wood, 1973).

obser	x1	x2	x3	conb	octano	obser	x1	x2	x3	conb	octano
1	55.33	1.72	54	1.66	92.19	42	71.31	3.44	55	1.60	90.51
2	59.13	1.20	53	1.58	92.74	43	72.30	4.02	55	1.67	90.24
3	57.39	1.42	55	1.62	91.88	44	68.81	6.88	55	1.70	91.01
4	56.43	1.78	55	1.66	92.80	45	66.61	2.31	52	1.78	91.90
5	55.98	1.58	54	1.63	92.56	46	63.66	2.99	52	1.81	91.92
6	56.16	2.12	56	1.68	92.61	47	63.85	0.24	50	1.81	92.16

obser	x1	x2	x3	conb	octano	obser	x1	x2	x3	conb	octano
7	54.85	1.17	54	1.58	92.33	48	67.25	0.00	53	1.73	91.36
8	52.83	1.50	58	1.55	92.22	49	67.19	0.00	52	1.87	92.16
9	54.52	0.87	57	1.55	91.56	50	62.34	0.00	48	2.01	92.68
10	54.12	0.88	57	1.58	92.17	51	62.98	0.00	47	1.95	92.88
11	51.72	0.00	56	1.60	92.75	52	69.89	0.00	55	1.89	92.59
12	51.29	0.00	58	1.60	92.89	53	73.13	0.00	57	1.82	91.35
13	53.22	1.31	58	1.55	92.79	54	65.09	1.01	57	1.46	90.29
14	54.76	1.67	58	1.63	92.55	55	64.71	0.61	55	1.39	90.71
15	53.34	1.81	59	1.60	92.42	56	64.05	1.64	57	1.34	90.41
16	54.84	2.87	60	1.55	92.43	57	63.97	2.80	60	1.42	90.43
17	54.03	1.19	60	1.58	92.77	58	70.48	4.64	60	1.58	89.87
18	51.44	0.42	59	1.61	92.60	59	71.11	3.56	60	1.41	89.98
19	53.54	1.39	59	1.51	92.30	60	69.05	2.51	60	1.55	90.00
20	57.88	1.28	62	1.56	92.30	61	71.99	1.28	55	1.55	89.66
21	60.93	1.22	62	1.54	92.48	62	72.03	1.28	56	1.60	90.08
22	59.59	1.13	61	1.57	91.61	63	69.90	2.19	56	1.67	90.67
23	61.42	1.45	62	1.41	91.30	64	72.16	0.51	56	1.55	90.59
24	56.60	2.10	62	1.55	91.37	65	70.97	0.09	55	1.46	91.06
25	59.94	2.29	61	1.66	91.25	66	70.55	0.05	52	1.26	90.69
26	58.30	3.11	62	1.30	90.76	67	69.73	0.05	54	1.29	91.11
27	58.25	3.10	63	1.20	90.90	68	69.93	0.05	55	1.36	90.32
28	55.53	2.88	64	1.21	90.43	69	70.60	0.00	55	1.42	90.36
29	59.79	1.48	62	1.31	90.83	70	75.54	0.00	55	1.67	90.57
30	57.51	0.87	60	1.30	92.18	71	49.14	0.00	40	2.17	94.17
31	62.82	0.88	59	1.40	91.73	72	49.10	0.00	42	2.32	94.39
32	62.57	0.42	60	1.45	91.10	73	44.66	4.99	42	2.14	93.42
33	60.23	0.12	59	1.54	91.74	74	44.64	3.73	44	2.08	94.65
34	65.08	0.10	60	1.69	91.46	75	4.23	10.76	41	2.17	97.61
35	65.58	0.05	59	1.75	91.44	76	5.53	7.99	40	1.99	97.08
36	65.64	0.05	60	1.75	91.56	77	17.11	5.06	47	1.61	95.12
37	65.28	0.42	60	1.78	91.90	78	67.60	1.84	55	1.65	91.86
38	65.03	0.65	59	1.78	91.61	79	64.81	2.24	54	1.70	91.61
39	67.84	0.49	54	1.72	92.09	80	63.13	1.60	52	1.65	92.17
40	73.74	0.00	54	1.73	90.64	81	63.48	3.46	52	1.48	91.56
41	72.66	0.00	55	1.72	91.09	82	62.25	3.56	50	1.50	92.16

1.3 Análisis descriptivo

Se considera conveniente realizar un análisis de regresión teniendo en cuenta: variable respuesta: octano; variables independientes: x1, x2, x3 y conb. Se usa el método stepwise para seleccionar las variables explicativas significativas.

Para establecer un modelo más adecuado, se realizó un análisis descriptivo de las variables, cuyos resultados se presentan en la Tabla 2.

```

dados_num <- REG4.DAT[, c("x1", "x2", "x3", "conb", "octano")]

descricao <- psych::describe(dados_num)

estatisticas <- data.frame(
  Variable = rownames(descricao),
  N = descricao$N,

```

```

Min = descricao$min,
Mean = descricao$mean,
Median = descricao$median,
Max = descricao$max,
`Std Dev.` = descricao$sd,
Skewness = descricao$skew,
Kurtosis = descricao$kurtosis,
CV = 100 * descricao$sd / descricao$mean,
check.names = FALSE
)

estadisticas[-1] <- round(estadisticas[-1], 2)

knitr::kable(
  estadisticas,
  caption = "Estadísticas descriptivas de las variables"
)

```

Tabla 2: Estadísticas descriptivas de las variables

Variable	N	Min	Mean	Median	Max	Std Dev.	Skewness	Kurtosis	CV
x1	82	4.23	60.17	62.70	75.54	12.44	-2.54	8.57	20.67
x2	82	0.00	1.66	1.28	10.76	1.90	2.12	6.15	114.37
x3	82	40.00	55.46	56.00	64.00	5.38	-1.14	1.15	9.70
conb	82	1.20	1.63	1.60	2.32	0.22	0.73	0.89	13.50
octano	82	89.66	91.85	91.74	97.61	1.40	1.57	4.09	1.53

Se tiene:

La variable x1 va de 4.23 a 60.17 octanos, con media 60.17 próxima a la mediana 62.70. Presenta asimetría positiva y curtosis positiva. La variabilidad es 12.44.

La variable x2 va de 0.00 a 10.76 octanos, con media 1.66 que se aleja de la mediana 1.28. Presenta asimetría positiva y curtosis positiva. La variabilidad es 1.90

La variable x3 va de 40.00 a 64.00 octanos, con media 55.46 próxima a la mediana 56.00. Presenta asimetría positiva y curtosis positiva. La variabilidad es 5.38.

La variable conb va de 1.20 a 2.32 octanos, con media 1.63 próxima a la mediana 1.60. Presenta asimetría positiva y curtosis positiva. La variabilidad es 0.22.

La variable octano va de 89.66 a 97.61 octanos, con media 91.85 próxima a la mediana 91.74. Presenta asimetría positiva y curtosis positiva. La variabilidad es 1.90.

Además, podemos notar que las variables explicativas tienen un coeficiente de variación alto.

En la Figura 1 se muestra la relación de la variable octano con las demás. La relación entre x1 y x3 parece ser inversa. La relación con x2 y conb parece ser directa. Sin embargo, se observa una gran concentración de puntos en valores bajos de octano y solamente tres puntos en valores altos. También se observa que conb se relaciona inversamente con x1 y x3, y directamente con x2.

2. Propuesta de modelo

2.1 Especificación del tipo de modelo a analizar

Entonces se puede formular el siguiente modelo:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \varepsilon_i, \quad i = 1, \dots, 82.$$

O, vectorialmente

$$Y_i = x_i^\top \beta + \varepsilon_i.$$

donde Y_i es la cantidad de octano en la observación i , $\beta = (\beta_0, \beta_1, \beta_2, \beta_3, \beta_4)^\top$ es el vector de coeficientes de regresión, $x_i^\top = (1, x_{i1}, x_{i2}, x_{i3}, x_{i4})$ es el vector de predictores (nótese que $x_{i4} = \text{comb}_i$, $i = 1, \dots, 82$) y ε_i es un error aleatorio.

Vamos a asumir que

$$\varepsilon_i \sim N(0, \sigma^2), \quad i = 1, \dots, 82.$$

Nótese que:

$$\mu_i = E(Y_i) = E(x_i^\top \beta + \varepsilon_i) = x_i^\top \beta + E(\varepsilon_i) = x_i^\top \beta;$$

$$\text{Var}(Y_i) = \text{Var}(x_i^\top \beta + \varepsilon_i) = \text{Var}(\varepsilon_i) = \sigma^2.$$

Por lo tanto,

$$Y_i \sim N(x_i^\top \beta, \sigma^2).$$

En resumen,

Componente aleatorio: $Y_1, \dots, Y_{82}$, supuesto independiente con $Y_i \sim N(\mu_i, \sigma^2)$;

Componente sistemático: $\eta_i = x_i^\top \beta$;

Función de enlace: $\mu_i = \eta_i$ (función de enlace identidad).

```
psych::pairs.panels(
  dados_num,
  method = "pearson",
  hist.col = "#d9ecf2",
  density = TRUE,
  ellipses = FALSE,
  lm = TRUE,
  stars = TRUE,
  pch = 19,
  col = grDevices::adjustcolor("#1f77b4", alpha.f = 0.65),
  main = "Diagrama de dispersión múltiple de las variables"
)
```

2.2 Estimación del modelo completo

Se usa la siguiente rutina en R:

Diagrama de dispersión múltiple de las variables




Figura 1: Diagrama de dispersión múltiple de las variables

```
datos_modelo <- REG4.DAT[, c("x1", "x2", "x3", "conb", "octano")]
head(datos_modelo)
```

```
##      x1    x2 x3 conb octano
## 1 55.33 1.72 54 1.66  92.19
## 2 59.13 1.20 53 1.58  92.74
## 3 57.39 1.42 55 1.62  91.88
## 4 56.43 1.78 55 1.66  92.80
## 5 55.98 1.58 54 1.63  92.56
## 6 56.16 2.12 56 1.68  92.61
```

```
fit.model <- lm(octano ~ x1 + x2 + x3 + conb, data = datos_modelo)
summary(fit.model)
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.00391 -0.28823 -0.04065  0.31516  0.98129
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 95.893414   1.219426  78.638 < 2e-16 ***
## x1          -0.092893   0.005235 -17.745 < 2e-16 ***
## x2          -0.127348   0.032149  -3.961 0.000165 ***
## x3          -0.025803   0.013928  -1.853 0.067775 .
## conb         1.961301   0.323624   6.060 4.69e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4415 on 77 degrees of freedom
## Multiple R-squared:  0.9056, Adjusted R-squared:  0.9007
## F-statistic: 184.7 on 4 and 77 DF,  p-value: < 2.2e-16
```

Los resultados indican que la variable x3 no posee un coeficiente significativo en el modelo.

3. Selección del modelo: método Stepwise y AIC

Este método ayuda a encontrar un subconjunto parsimonioso de variables explicativas para incluir en la regresión múltiple, usando mínimos cuadrados. Se usa el método stepwise AIC, que es un método de selección de Akaike orientado a encontrar un modelo bien ajustado con un número reducido de parámetros.

Se usa la siguiente rutina en R:

```
library(MASS)
stepAIC(fit.model)
```

```
## Start:  AIC=-129.24
## octano ~ x1 + x2 + x3 + conb
```

```
##
##           Df Sum of Sq      RSS       AIC
## <none>                 15.009 -129.243
## - x3      1         0.669 15.678 -127.668
## - x2      1         3.058 18.067 -116.035
## - conb    1         7.159 22.168 -99.262
## - x1      1        61.380 76.388   2.187

##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo)
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##    95.89341    -0.09289    -0.12735    -0.02580     1.96130
```

Los resultados indican que el mejor modelo es aquel que usa todas las variables, aunque el modelo que elimina x_3 también puede ser considerado.

El modelo ajustado está dado por:

$$\widehat{\text{octano}} = 95.8541 - 0.0928x_1 - 0.1270x_2 - 0.02539x_3 + 1.968 \text{ conb}.$$

Por cada aumento de una unidad en la variable x_1 , el número medio de octanos del combustible disminuye 0.093 unidades;

Por cada aumento de una unidad en la variable x_2 , el número medio de octanos del combustible disminuye 0.127 unidades;

Por cada aumento de una unidad en la variable x_3 , el número medio de octanos del combustible disminuye 0.025 unidades;

Por cada aumento de una unidad en la variable conb , el número medio de octanos del combustible aumenta en 1.968 unidades.

4. Análisis de diagnóstico

4.1 Sensibilidad del modelo

En esta sección se usa la función `influencePlot()` del paquete `car` para identificar puntos de apalancamiento, influyentes y extremos (aberrantes), usando residuos studentizados, valores de apalancamiento y distancia de Cook después de ajustar un modelo lineal.

Un punto de apalancamiento es una observación con una combinación inusual de las variables explicativas. Aparece a la derecha en el gráfico porque tiene un valor alto de apalancamiento (**Hat**). Un punto extremo, o aberrante, es una observación con una respuesta distante de la prevista por el modelo; aparece con un residuo studentizado alto en valor absoluto, es decir, muy por encima o muy por debajo de la línea horizontal central. Un punto influyente es aquel cuya presencia altera de forma relevante el ajuste del modelo; en el gráfico esto se indica principalmente por el tamaño de la burbuja, proporcional a la distancia de Cook (**CookD**).

En la salida de `influencePlot()`, la columna **StudRes** representa el residuo studentizado, **Hat** representa el apalancamiento y **CookD** representa la distancia de Cook. Así, los puntos a la derecha son candidatos a puntos de apalancamiento; los puntos muy por encima o por debajo son candidatos a aberrantes; los puntos con burbujas grandes son candidatos a influyentes. Las etiquetas indican las observaciones más relevantes según estos criterios.

Se identificaron los puntos 44, 75 y 77 como puntos de apalancamiento e influyentes. Otros puntos como 66, 72, 71, 73 y 82 presentan uno de los dos problemas. No hay mayores discrepancias en relación con los residuos studentizados. No hay puntos extremos. Los puntos 75, 76 y 77 son muy influyentes, pues sus valores ajustados difieren significativamente de los demás. En general, existe homogeneidad de las varianzas de los residuos.

Los puntos 75, 76 y 77 tienen un valor muy pequeño para la variable x_1 , bastante por debajo de la media. En cambio, presentan un valor muy alto para la variable x_2 .

Los puntos 66, 71 y 72 tienen un valor de x_2 cercano a cero. Los puntos 82 y 44 tienen un valor alto para x_2 .

```
car::influencePlot(
  fit.model,
  id = list(n = 6),
  xlab = "Valores de apalancamiento",
  ylab = "Residuos studentizados",
  main = "Diagnóstico: apalancamiento, influencia y puntos aberrantes"
)
```




Figura 2: Diagnóstico del modelo lineal con `car::influencePlot()`

##	StudRes	Hat	CookD
## 21	2.3330162	0.04000125	0.04288502

```
## 44  1.2046246 0.21562769 0.07931928
## 52  2.1525465 0.05836716 0.05485264
## 54 -1.9134052 0.02251023 0.01629881
## 61 -2.3813702 0.03293021 0.03641194
## 71 -0.9457174 0.16162322 0.03453133
## 72 -1.0176380 0.17142402 0.04283071
## 73 -1.9703016 0.11636623 0.09855789
## 75  0.7987419 0.36495997 0.07367730
## 76 -0.4053830 0.27636455 0.01269003
## 77 -1.2338661 0.20327813 0.07716375
## 82  2.0608910 0.08893248 0.07956285
```

4.2 Análisis de envelopes

Para este análisis, se usa la función `qqPlot()` del paquete `car`, con envelope simulado para los residuos studentizados bajo la hipótesis de normalidad.

El envelope es una banda de referencia simulada para el gráfico cuantil-cuantil de los residuos. Muestra la región donde se espera que caigan los residuos si el supuesto de normalidad es razonable. Cuando la mayor parte de los puntos queda dentro del envelope y no hay un patrón sistemático de alejamiento, no hay evidencia fuerte contra la normalidad. Puntos aislados fuera de la banda pueden indicar observaciones atípicas; muchos puntos fuera de la banda, especialmente en las colas, sugieren asimetría, colas pesadas u otra violación del supuesto de normalidad.

```
set.seed(123)

car::qqPlot(
  fit.model,
  distribution = "norm",
  simulate = TRUE,
  envelope = TRUE,
  reps = 1000,
  id = list(n = 6),
  xlab = "Cuantiles de la N(0,1)",
  ylab = "Residuos studentizados",
  main = "Envelope normal simulado"
)
```

```
## [1] 21 52 54 61 73 82
```

Como se muestra en la Figura 3, la mayor parte de los residuos studentizados permanece dentro del envelope simulado. Por lo tanto, no hay indicios de alejamientos serios del supuesto de normalidad, aunque algunos puntos en las colas merecen atención por estar más próximos a los límites de la banda.

Análisis eliminando puntos.

5. Influencia de la exclusión de puntos

5.1 Influencia de la exclusión individual de puntos atípicos

Para realizar el análisis de regresión eliminando puntos, se puede usar en R el siguiente comando:




Figura 3: Envelope normal de los residuos studentizados con `car::qqPlot()`

```
lm(octano ~ x1 + x2 + x3 + conb, data = datos_modelo, subset = -c(44))
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo,
##     subset = -c(44))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##   96.16217   -0.09512   -0.14650   -0.02659    1.92051
```

Este comando realiza el análisis de regresión sin la observación número 44.

```
lm(octano ~ x1 + x2 + x3 + conb, data = datos_modelo, subset = -c(44))
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo,
##     subset = -c(44))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##   96.16217   -0.09512   -0.14650   -0.02659    1.92051
```

Los demás análisis de regresión, excluyendo un punto cada vez, aparecen en la Tabla 3.

```
lm(octano ~ x1 + x2 + x3 + conb, data = datos_modelo, subset = -c(75))
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo,
##     subset = -c(75))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##   95.92341   -0.09193   -0.13703   -0.02614    1.92536
```

```
lm(octano ~ x1 + x2 + x3 + conb, data = datos_modelo, subset = -c(76))
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo,
##     subset = -c(76))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##   95.99698   -0.09359   -0.12598   -0.02662    1.95147
```

```
lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -c(77))
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = dados_modelo,
##     subset = -c(77))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##   96.34466    -0.09522    -0.12987    -0.02853     1.87009
```

```
lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -c(73))
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = dados_modelo,
##     subset = -c(73))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##   95.90549    -0.09222    -0.11820    -0.02879     2.02830
```

```
lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -c(61))
```

```
##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = dados_modelo,
##     subset = -c(61))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##   96.03462    -0.09137    -0.12433    -0.02857     1.91712
```

```
modelos_exclusao <- list(
  "Todos los puntos" = fit.model,
  "Sin punto 44" = lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -44),
  "Sin punto 75" = lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -75),
  "Sin punto 76" = lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -76),
  "Sin punto 77" = lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -77),
  "Sin punto 73" = lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -73),
  "Sin punto 61" = lm(octano ~ x1 + x2 + x3 + conb, data = dados_modelo, subset = -61)
)
```

```
extrair_estimativas <- function(modelo) {
  resumo <- summary(modelo)
  c(
    "$\\beta_0$ (Intercepto)" = coef(modelo)[["(Intercept)"]],
    "$\\beta_1$ (Coeficiente $x_1$)" = coef(modelo)[["x1"]],
    "$\\beta_2$ (Coeficiente $x_2$)" = coef(modelo)[["x2"]],
    "$\\beta_3$ (Coeficiente $x_3$)" = coef(modelo)[["x3"]],
    "$\\beta_4$ (Coeficiente `conb`)" = coef(modelo)[["conb"]],
  )
}
```

```

    "$\\sigma$ (Error estándar)" = sigma(modelo),
    "$R^2$" = resumo$r.squared
  )
}

matriz_tabela3 <- sapply(modelos_exclusao, extrair_estimativas)
tabela3 <- data.frame(
  Estimación = rownames(matriz_tabela3),
  round(matriz_tabela3, 3),
  check.names = FALSE
)

knitr::kable(
  tabela3,
  escape = FALSE,
  row.names = FALSE,
  caption = "Estimaciones de algunas cantidades con todos los puntos y cuando se excluyen observaciones"
)

```

Tabla 3: Estimaciones de algunas cantidades con todos los puntos y cuando se excluyen observaciones.

Estimación	Todos los puntos	Sin punto 44	Sin punto 75	Sin punto 76	Sin punto 77	Sin punto 73	Sin punto 61
β_0 (Intercepto)	95.893	96.162	95.923	95.997	96.345	95.905	96.035
β_1 (Coeficiente x_1)	-0.093	-0.095	-0.092	-0.094	-0.095	-0.092	-0.091
β_2 (Coeficiente x_2)	-0.127	-0.146	-0.137	-0.126	-0.130	-0.118	-0.124
β_3 (Coeficiente x_3)	-0.026	-0.027	-0.026	-0.027	-0.029	-0.029	-0.029
β_4 (Coeficiente conb)	1.961	1.921	1.925	1.951	1.870	2.028	1.917
σ (Error estándar)	0.441	0.440	0.443	0.444	0.440	0.433	0.429
R^2	0.906	0.907	0.881	0.886	0.901	0.909	0.909

Como se puede observar, la exclusión de una de las observaciones, o puntos, altera de forma diferente los coeficientes estimados, excepto el intercepto.

La Tabla 4 presenta el porcentaje de cambio en la estimación como consecuencia de eliminar un determinado punto u observación. Es decir,

$$p_{ij} = \frac{\beta_{ij} - \beta_i}{\beta_i} \times 100, \quad i = 0, \dots, 4, \quad j \in \{44, 75, 76, 77, 73, 61\}.$$

donde β_i es la estimación del coeficiente i con todos los puntos y β_{ij} es la estimación retirando el punto j .

```

linhas_tabela4 <- rownames(matriz_tabela3)[rownames(matriz_tabela3) != "$R^2$"]
estimativas_completas <- matriz_tabela3[linhas_tabela4, "Todos los puntos"]

matriz_tabela4 <- apply(
  matriz_tabela3[linhas_tabela4, -1, drop = FALSE],
  2,
  function(estimativas_reduzidas) {
    100 * (estimativas_reduzidas - estimativas_completas) / estimativas_completas
  }
)

```

```

)

tabela4 <- data.frame(
  Estimación = linhas_tabela4,
  round(matriz_tabela4, 2),
  check.names = FALSE
)

names(tabela4) <- c(
  "Estimación",
  "Sin 44",
  "Sin 75",
  "Sin 76",
  "Sin 77",
  "Sin 73",
  "Sin 61"
)

knitr::kable(
  tabela4,
  escape = FALSE,
  row.names = FALSE,
  caption = "Porcentaje de cambio de las estimaciones de algunas cantidades cuando se remueven observaciones."
)

```

Tabla 4: Porcentaje de cambio de las estimaciones de algunas cantidades cuando se remueven observaciones.

Estimación	Sin 44	Sin 75	Sin 76	Sin 77	Sin 73	Sin 61
β_0 (Intercepto)	0.28	0.03	0.11	0.47	0.01	0.15
β_1 (Coeficiente x_1)	2.40	-1.03	0.75	2.51	-0.73	-1.64
β_2 (Coeficiente x_2)	15.04	7.60	-1.07	1.98	-7.18	-2.37
β_3 (Coeficiente x_3)	3.07	1.30	3.16	10.57	11.59	10.73
β_4 (Coeficiente conb)	-2.08	-1.83	-0.50	-4.65	3.42	-2.25
σ (Error estándar)	-0.29	0.24	0.55	-0.34	-1.82	-2.90

El punto 44 tiene un valor de cambio alto en x_2 ; los puntos 77 y 76 tienen un valor de x_1 muy bajo, al igual que el punto 75. Los puntos 77 y 73 producen cambios bastante altos en las estimaciones de x_3 , así como en las estimaciones de conb .

Sin embargo, el error estándar no queda muy alto con la remoción de las observaciones.

5.2 Influencia de la exclusión de los puntos atípicos 77, 76 y 75

Como estrategia, vamos a excluir los puntos 77, 76 y 75 en ese orden, considerando que son puntos atípicos y muy influyentes para determinar la recta de regresión.

Las Figuras 4 a 6 muestran el efecto de excluir sucesivamente los puntos 77, 76 y 75. Después de estas exclusiones, los valores de apalancamiento y distancia de Cook quedan menos extremos. Sin embargo, como se muestra en los resultados del análisis de regresión, el R^2 cae a 0.829 (-17.10 %). También se observa que el punto 44 ya no es tan problemático, pero el punto 73 pasa a destacarse como observación influyente y de apalancamiento.

```
fit.sem77 <- lm(
  octano ~ x1 + x2 + x3 + conb,
  data = datos_modelo,
  subset = -c(77)
)

diag.sem77 <- car::influencePlot(
  fit.sem77,
  id = list(n = 6),
  xlab = "Valores de apalancamiento",
  ylab = "Residuos studentizados",
  main = "Diagnóstico sin el punto 77"
)
```




Figura 4: Diagnóstico después de excluir el punto 77

```
fit.sem76.77 <- lm(
  octano ~ x1 + x2 + x3 + conb,
  data = datos_modelo,
  subset = -c(76, 77)
)

diag.sem76.77 <- car::influencePlot(
```



```

fit.sem76.77,
id = list(n = 6),
xlab = "Valores de apalancamiento",
ylab = "Residuos studentizados",
main = "Diagnóstico sin los puntos 76 y 77"
)

```




Figura 5: Diagnóstico después de excluir los puntos 76 y 77

```

fit.sem75.76.77 <- lm(
  octano ~ x1 + x2 + x3 + conb,
  data = datos_modelo,
  subset = -c(75, 76, 77)
)

diag.sem75.76.77 <- car::influencePlot(
  fit.sem75.76.77,
  id = list(n = 6),
  xlab = "Valores de apalancamiento",
  ylab = "Residuos studentizados",
  main = "Diagnóstico sin los puntos 75, 76 y 77"
)

```




Figura 6: Diagnóstico después de excluir los puntos 75, 76 y 77

```

resumo_diagnostico <- rbind(
  cbind(Escenario = "Sin el punto 77", Observacion = rownames(diag.sem77), diag.sem77),
  cbind(Escenario = "Sin los puntos 76 y 77", Observacion = rownames(diag.sem76.77), diag.sem76.77),
  cbind(Escenario = "Sin los puntos 75, 76 y 77", Observacion = rownames(diag.sem75.76.77), diag.sem75.76.77)
)

resumo_diagnostico[, c("StudRes", "Hat", "CookD")] <-
  round(resumo_diagnostico[, c("StudRes", "Hat", "CookD")], 3)

knitr::kable(
  resumo_diagnostico,
  row.names = FALSE,
  caption = "Puntos destacados por `car::influencePlot()` después de las exclusiones sucesivas"
)

```

Tabla 5: Puntos destacados por `car::influencePlot()` después de las exclusiones sucesivas

Escenario	Observacion	StudRes	Hat	CookD
Sin el punto 77	21	2.351	0.040	0.044
Sin el punto 77	28	-1.656	0.083	0.048
Sin el punto 77	44	1.294	0.219	0.093
Sin el punto 77	52	2.252	0.062	0.064
Sin el punto 77	54	-1.942	0.023	0.017
Sin el punto 77	61	-2.363	0.033	0.036
Sin el punto 77	66	0.487	0.163	0.009
Sin el punto 77	71	-1.026	0.165	0.041
Sin el punto 77	72	-1.049	0.172	0.046
Sin el punto 77	73	-2.045	0.118	0.108
Sin el punto 77	75	0.518	0.402	0.036
Sin el punto 77	76	-0.778	0.332	0.060
Sin el punto 77	82	2.009	0.091	0.078
Sin los puntos 76 y 77	21	2.363	0.040	0.044
Sin los puntos 76 y 77	44	1.288	0.219	0.092
Sin los puntos 76 y 77	52	2.314	0.067	0.073
Sin los puntos 76 y 77	54	-1.934	0.023	0.017
Sin los puntos 76 y 77	61	-2.329	0.035	0.037
Sin los puntos 76 y 77	66	0.474	0.163	0.009
Sin los puntos 76 y 77	71	-1.121	0.175	0.053
Sin los puntos 76 y 77	72	-1.116	0.178	0.054
Sin los puntos 76 y 77	73	-2.207	0.141	0.153
Sin los puntos 76 y 77	75	0.130	0.567	0.004
Sin los puntos 76 y 77	82	1.950	0.095	0.077
Sin los puntos 75, 76 y 77	21	2.345	0.041	0.044
Sin los puntos 75, 76 y 77	44	1.325	0.243	0.112
Sin los puntos 75, 76 y 77	52	2.296	0.076	0.082
Sin los puntos 75, 76 y 77	54	-1.928	0.024	0.018
Sin los puntos 75, 76 y 77	61	-2.330	0.040	0.042
Sin los puntos 75, 76 y 77	66	0.460	0.172	0.009
Sin los puntos 75, 76 y 77	71	-1.106	0.192	0.058
Sin los puntos 75, 76 y 77	72	-1.101	0.193	0.058
Sin los puntos 75, 76 y 77	73	-2.307	0.253	0.341

Escenario	Observacion	StudRes	Hat	CookD
Sin los puntos 75, 76 y 77	74	0.931	0.179	0.038
Sin los puntos 75, 76 y 77	82	1.966	0.107	0.089

La Figura 4 muestra que, después de excluir el punto 77, los puntos 75 y 76 continúan con valores de apalancamiento elevados. El punto 73 también aparece con distancia de Cook relativamente alta, indicando sensibilidad del ajuste a esa observación.

En la Figura 5, después de excluir 76 y 77, el punto 75 pasa a ser el punto de mayor apalancamiento. Esto refuerza que los tres puntos forman un grupo atípico respecto al patrón de las variables explicativas, especialmente por sus valores bajos de x_1 .

En la Figura 6, al excluir 75, 76 y 77, ya no hay un punto con apalancamiento tan extremo como antes. Sin embargo, el punto 73 pasa a tener mayor distancia de Cook y residuo studentizado negativo, siendo el principal candidato a observación influyente remanente. Aun así, la influencia es mucho menor que la estructura observada inicialmente con los puntos 75, 76 y 77.

El análisis de regresión también se presenta sin considerar estos tres puntos.

```
fit2.modelo <- lm(octano ~ x1 + x2 + x3 + conb,
                  data = datos_modelo,
                  subset = -c(75, 76, 77))
summary(fit2.modelo)

##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo,
##     subset = -c(75, 76, 77))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.98491 -0.29910 -0.05123  0.33220  0.99025
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  96.594566   1.365307  70.749  < 2e-16 ***
## x1           -0.096585   0.006987 -13.823  < 2e-16 ***
## x2           -0.129682   0.036217  -3.581  0.00061 ***
## x3           -0.030406   0.014562  -2.088  0.04023 *
## conb         1.833462   0.337225   5.437 6.67e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4441 on 74 degrees of freedom
## Multiple R-squared:  0.8288, Adjusted R-squared:  0.8195
## F-statistic: 89.53 on 4 and 74 DF,  p-value: < 2.2e-16
```

5.3 Reestudio de la selección de variables, sin los puntos 75, 76 y 77

Ahora vamos a rehacer el procedimiento de selección de variables, sin considerar los puntos 75, 76 y 77.

```
stepAIC(fit2.model)
```

```
## Start:  AIC=-123.43
## octano ~ x1 + x2 + x3 + conb
##
##           Df Sum of Sq    RSS    AIC
## <none>                 14.593 -123.425
## - x3      1      0.860 15.453 -120.902
## - x2      1      2.528 17.121 -112.802
## - conb    1      5.829 20.422  -98.874
## - x1      1     37.682 52.275  -24.622

##
## Call:
## lm(formula = octano ~ x1 + x2 + x3 + conb, data = datos_modelo,
##     subset = -c(75, 76, 77))
##
## Coefficients:
## (Intercept)          x1          x2          x3          conb
##    96.59457    -0.09659    -0.12968    -0.03041     1.83346
```

Residual standard error: 0.443724

Los estudios indican que, también en este caso, no es necesario remover ninguna variable del modelo.

6. Especificación final

En la estimación final se consideran todos los puntos, excepto 75, 76 y 77. El mejor modelo especificado considera todas las variables. Los puntos 44 y 73 pueden ser excluidos en este análisis, pero los cambios producidos en las estimaciones al excluirlas no son significativos. El modelo final estimado está dado por:

$$\widehat{\text{octano}} = 95.56 - 0.0966x_1 - 0.129x_2 - 0.030x_3 + 1.8404 \text{ conb} \quad (R^2 = 0.829, EE = 0.44).$$

7. Conclusiones

Se identificó que todas las variables son útiles en el modelo especificado.

Se identificó que los puntos 75, 76 y 77 son atípicos en el modelo, pues tienen valores de x_1 muy bajos y son influyentes y de apalancamiento. Otros puntos, como 73 y 44, pueden ser eliminados; sin embargo, no son determinantes para la recta de regresión.

8. REFERENCIAS

Wood, F. (1973). The Use of Individual Effects and Residuals in Fitting equations to Data. *Tecnometrics*. 15(4), 677-693.

Para citar este documento use:

Bazán, J. L. (2010). Un ejemplo de modelo lineal: el problema de selección del mejor modelo para predecir el octanaje en la producción de gasolina. Maestría en Estadística. Cursos Modelos Lineales. Pontificia Universidad Católica del Perú. Versión en español.