

Pontificia Universidad Católica de Chile

EPG4001 Aprendizaje Supervisado

Material Complementario Adicional

MIAApSupClase5A.pdf

Jorge Luis Bazán
jlbazan@uc.cl

Librerías

Las librerías a utilizar para los procedimientos son las siguientes:

```
library(ISLR)           # Base de datos Default
library(MASS)           # lda(), qda()
library(e1071)          # naiveBayes()
library(pROC)           # Curvas ROC y AUC
library(caret)          # trainControl(), train(), confusionMatrix()
library(tidyverse)      # Manipulación y visualización
library(knitr)          # Tablas con kable()
library(Metrics)        # F1, precision, recall
library(boot)           # cv.glm()
```


1. Base de Datos: Default

La base `Default` contiene información de **10,000 clientes** de tarjetas de crédito. La variable respuesta es `default` (impago: **Yes / No**) en función de tres predictores: `balance` (saldo promedio), `income` (ingreso anual) y `student` (si es o no estudiante).


```
data(Default)
head(Default)
```

```
##   default student   balance   income
## 1      No      No  729.5265 44361.625
## 2      No     Yes  817.1804 12106.135
## 3      No      No 1073.5492 31767.139
## 4      No      No  529.2506 35704.494
## 5      No      No  785.6559 38463.496
## 6      No     Yes  919.5885  7491.559
```

```
hist(Default$income)
```



```
hist(Default$balance)
```



```
cor(Default$income, Default$balance)
```

```
## [1] -0.1522434
```

Las variables de balance e income no son normales y además Student es una variable categórica.

```
Default <- Default %>%  
  mutate(default_bin = ifelse(default == "Yes", 1, 0))  
glimpse(Default)
```

```
## Rows: 10,000  
## Columns: 5  
## $ default      <fct> No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, No~  
## $ student      <fct> No, Yes, No, No, No, Yes, No, Yes, No, No, Yes, Yes, No, N~  
## $ balance      <dbl> 729.5265, 817.1804, 1073.5492, 529.2506, 785.6559, 919.588~  
## $ income       <dbl> 44361.625, 12106.135, 31767.139, 35704.494, 38463.496, 749~  
## $ default_bin  <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
```

```
Default %>%  
  count(default) %>%  
  mutate(proporcion = round(n / sum(n), 3)) %>%  
  kable(caption = "Distribución de la variable respuesta Default",  
        booktabs = TRUE)
```

Cuadro 1: Distribución de la variable respuesta Default

default	n	proporcion
No	9667	0.967
Yes	333	0.033

Los datos presentan un marcado desbalance: solo el 3.3% de los clientes incurre en impago. Esto tendrá efecto en las métricas de desempeño, especialmente en la sensibilidad.

```
ggplot(Default, aes(x = balance, y = income, color = default)) +
  geom_point(alpha = 0.3, size = 0.6) +
  scale_color_manual(values = c("steelblue", "tomato")) +
  labs(x = "Balance", y = "Income", color = "Default") +
  theme_minimal(base_size = 11)
```



Figura 1: Balance vs Income según Default

Se observa que los clientes con impago tienden a concentrarse en valores altos de **balance**.

2. Ajuste de los Modelos de Clasificación

Se ajustan los cuatro clasificadores sobre el conjunto completo de datos utilizando los tres predictores disponibles: `balance`, `income` y `student`.

2.1. Regresión Logística

El modelo logístico (Clase 3) modela directamente la probabilidad posterior:

$$\log \frac{P(G = 1 | \mathbf{x})}{P(G = 0 | \mathbf{x})} = \beta_0 + \beta_1 \text{balance} + \beta_2 \text{income} + \beta_3 \text{student}$$

```
mod_logit <- glm(default ~ balance + income + student,
                  data = Default,
                  family = binomial(link = "logit"))
summary(mod_logit)

##
## Call:
## glm(formula = default ~ balance + income + student, family = binomial(link = "logit"),
##      data = Default)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.087e+01  4.923e-01 -22.080  < 2e-16 ***
## balance      5.737e-03  2.319e-04  24.738  < 2e-16 ***
## income       3.033e-06  8.203e-06   0.370  0.71152
## studentYes  -6.468e-01  2.363e-01  -2.738  0.00619 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 1571.5  on 9996  degrees of freedom
## AIC: 1579.5
##
## Number of Fisher Scoring iterations: 8
```

2.2. Naive Bayes

Naive Bayes (Clase 5) estima la probabilidad posterior vía teorema de Bayes asumiendo independencia condicional de los predictores dado el grupo:

$$P(G = k | \mathbf{x}) \propto \pi_k \prod_{j=1}^p f_{kj}(x_j)$$

```
mod_nb <- naiveBayes(default ~ balance + income + student,
                      data = Default)
```

2.3. Análisis Discriminante Lineal (LDA)

LDA (Clase 5) asume densidad Gaussiana multivariada con matriz de covarianza común Σ para todos los grupos, dando lugar a fronteras de decisión lineales:

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k^\top \Sigma^{-1} \hat{\mu}_k + \log(\hat{\pi}_k)$$

```
mod_lda <- lda(default ~ balance + income + student,  
               data = Default)
```

2.4. Análisis Discriminante Cuadrático (QDA)

QDA (Clase 5) permite matrices de covarianza distintas por grupo (Σ_k), produciendo fronteras cuadráticas y mayor flexibilidad:

$$\delta_k(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \hat{\mu}_k)^\top \Sigma_k^{-1}(\mathbf{x} - \hat{\mu}_k) - \frac{1}{2} \log |\Sigma_k| + \log(\hat{\pi}_k)$$

```
mod_qda <- qda(default ~ balance + income + student,  
               data = Default)
```

3. Métricas de Desempeño en Muestra Completa

Se obtienen las probabilidades predichas por cada modelo y se clasifican con umbral 0.5 para calcular las métricas de desempeño sobre la muestra completa.

```
y      <- Default$default
y_bin  <- Default$default_bin

# Probabilidades predichas
pi_logit <- fitted(mod_logit)
pi_nb    <- predict(mod_nb, newdata = Default, type = "raw")[, "Yes"]
pi_lda   <- predict(mod_lda, newdata = Default)$posterior[, "Yes"]
pi_qda   <- predict(mod_qda, newdata = Default)$posterior[, "Yes"]

# Función auxiliar de clasificación con umbral 0.5
clf <- function(p) factor(ifelse(p >= 0.5, "Yes", "No"), levels = c("No", "Yes"))

y_logit <- clf(pi_logit)
y_nb    <- clf(pi_nb)
y_lda   <- clf(pi_lda)
y_qda   <- clf(pi_qda)
```

3.1. Matrices de Confusión

```
cm_logit <- confusionMatrix(y_logit, y, positive = "Yes")

# Matriz de confusión - Regresión Logística:
cm_logit$table

##           Reference
## Prediction  No  Yes
##          No 9627 228
##          Yes  40 105

kable(cm_logit$table,
      caption = "Matriz de Confusión - Regresión Logística (umbral 0.5)",
      booktabs = TRUE)
```

Cuadro 2: Matriz de Confusión — Regresión Logística (umbral 0.5)

	No	Yes
No	9627	228
Yes	40	105

```
cm_nb <- confusionMatrix(y_nb, y, positive = "Yes")

# Matriz de confusión - Naive Bayes:
cm_nb$table
```



```
##           Reference
## Prediction  No  Yes
##           No 9615 241
##           Yes  52  92
```

```
kable(cm_nb$table,
      caption = "Matriz de Confusión - Naive Bayes (umbral 0.5)",
      booktabs = TRUE)
```

Cuadro 3: Matriz de Confusión — Naive Bayes (umbral 0.5)

	No	Yes
No	9615	241
Yes	52	92

```
cm_lda <- confusionMatrix(y_lda, y, positive = "Yes")
```

```
# Matriz de confusión - LDA:
cm_lda$table
```

```
##           Reference
## Prediction  No  Yes
##           No 9645 254
##           Yes  22  79
```

```
kable(cm_lda$table,
      caption = "Matriz de Confusión - LDA (umbral 0.5)",
      booktabs = TRUE)
```

Cuadro 4: Matriz de Confusión — LDA (umbral 0.5)

	No	Yes
No	9645	254
Yes	22	79

```
cm_qda <- confusionMatrix(y_qda, y, positive = "Yes")
```

```
# Matriz de confusión - QDA:
cm_qda$table
```

```
##           Reference
## Prediction  No  Yes
##           No 9636 239
##           Yes  31  94
```

```
kable(cm_qda$table,
      caption = "Matriz de Confusión - QDA (umbral 0.5)",
      booktabs = TRUE)
```

Cuadro 5: Matriz de Confusión — QDA (umbral 0.5)

	No	Yes
No	9636	239
Yes	31	94

3.2. Métricas Resumen

Se calculan Accuracy, Sensibilidad, Especificidad y F1 Score para cada método. El F1 Score pondera la precisión y la exhaustividad:

$$F_1 = \frac{2 VP}{2 VP + FP + FN}$$

```
# Función auxiliar para extraer métricas de un confusionMatrix
extraer_metricas <- function(cm, nombre) {
  VP <- cm$table[2, 2]; FP <- cm$table[2, 1]; FN <- cm$table[1, 2]
  data.frame(
    Método      = nombre,
    Accuracy    = round(cm$overall["Accuracy"],      4),
    Sensibilidad = round(cm$byClass["Sensitivity"],   4),
    Especificidad = round(cm$byClass["Specificity"],  4),
    F1          = round(2*VP / (2*VP + FP + FN),      4)
  )
}

tab_metricas <- bind_rows(
  extraer_metricas(cm_logit, "Reg. Logística"),
  extraer_metricas(cm_nb,   "Naive Bayes"),
  extraer_metricas(cm_lda,  "LDA"),
  extraer_metricas(cm_qda,  "QDA")
)

kable(tab_metricas, row.names = FALSE, booktabs = TRUE,
      caption = "Métricas de desempeño en muestra completa (umbral 0.5)")
```

Cuadro 6: Métricas de desempeño en muestra completa (umbral 0.5)

Método	Accuracy	Sensibilidad	Especificidad	F1
Reg. Logística	0.9732	0.3153	0.9959	0.4393
Naive Bayes	0.9707	0.2763	0.9946	0.3857
LDA	0.9724	0.2372	0.9977	0.3641
QDA	0.9730	0.2823	0.9968	0.4105

3.3. Log-Loss (Devianza Media)

La pérdida logarítmica (devianza media) cuantifica qué tan calibradas están las probabilidades predichas:

$$\text{Log-Loss} = -\frac{2}{n} \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]$$

```

log_loss <- function(y, p) {
  -2 * mean(y * log(p + 1e-15) + (1 - y) * log(1 - p + 1e-15))
}

tab_logloss <- data.frame(
  Método = c("Reg. Logística", "Naive Bayes", "LDA", "QDA"),
  LogLoss = round(c(log_loss(y_bin, pi_logit),
                      log_loss(y_bin, pi_nb),
                      log_loss(y_bin, pi_lda),
                      log_loss(y_bin, pi_qda)), 4)
)

kable(tab_logloss, row.names = FALSE, booktabs = TRUE,
      caption = "Log-Loss (Devianza Media) en muestra completa")

```

Cuadro 7: Log-Loss (Devianza Media) en muestra completa

Método	LogLoss
Reg. Logística	0.1572
Naive Bayes	0.1674
LDA	0.1595
QDA	0.1593

Valores menores de Log-Loss indican probabilidades predichas más calibradas respecto a los resultados observados.

4. Curvas ROC Comparativas

Las curvas ROC permiten evaluar el desempeño de cada clasificador a todos los umbrales posibles. El AUC (Área Bajo la Curva) resume en un único valor la capacidad discriminante del modelo.

```
roc_logit <- roc(y_bin, pi_logit, quiet = TRUE)
roc_nb    <- roc(y_bin, pi_nb,    quiet = TRUE)
roc_lda   <- roc(y_bin, pi_lda,   quiet = TRUE)
roc_qda   <- roc(y_bin, pi_qda,   quiet = TRUE)

plot(roc_logit, col = "tomato", lwd = 2,
     main = "Curvas ROC -- Clasificadores sobre Default")
plot(roc_nb, col = "steelblue", lwd = 2, add = TRUE)
plot(roc_lda, col = "darkgreen", lwd = 2, add = TRUE)
plot(roc_qda, col = "purple", lwd = 2, add = TRUE)
abline(a = 0, b = 1, lty = 2, col = "gray60")

legend("bottomright",
      legend = c(
        paste0("Reg. Logística (AUC = ", round(pROC::auc(roc_logit), 3), ")"),
        paste0("Naive Bayes (AUC = ", round(pROC::auc(roc_nb), 3), ")"),
        paste0("LDA (AUC = ", round(pROC::auc(roc_lda), 3), ")"),
        paste0("QDA (AUC = ", round(pROC::auc(roc_qda), 3), ")")
      ),
      col = c("tomato", "steelblue", "darkgreen", "purple"),
      lwd = 2, cex = 0.85)

tab_auc <- data.frame(
  Método = c("Reg. Logística", "Naive Bayes", "LDA", "QDA"),
  AUC     = round(c(pROC::auc(roc_logit), pROC::auc(roc_nb),
                    pROC::auc(roc_lda), pROC::auc(roc_qda)), 4)
)

kable(tab_auc, row.names = FALSE, booktabs = TRUE,
      caption = "AUC por clasificador")
```

Cuadro 8: AUC por clasificador

Método	AUC
Reg. Logística	0.9496
Naive Bayes	0.9437
LDA	0.9495
QDA	0.9492

Note que la métrica AUC se ve similar entre los diferentes métodos usados y no muestra una preferencia clara por el método logístico como las métricas F1 o log-loss. Eso sucede como se muestra en de la Cruz et al (2025), AUC no es una buena métrica con datos desbalanceados como es el caso aquí.




Figura 2: Curvas ROC — Comparación de los cuatro clasificadores

5. Validación Cruzada

Se estima el error de predicción fuera de muestra mediante tres métodos de validación cruzada vistos en la Clase 4, aplicados a los cuatro clasificadores.

5.1. Hold-Out 70/30

Se divide aleatoriamente el conjunto en 70 % entrenamiento y 30 % prueba.

```
set.seed(123)
n <- nrow(Default)
idx <- sample(1:n, size = floor(0.7 * n))
train_d <- Default[idx, ]
test_d <- Default[-idx, ]
```

Se ajusta cada modelo con `train_d` y se evalúa con `test_d`:

```
# Regresión Logística
mod_h_logit <- glm(default ~ balance + income + student,
                  data = train_d, family = binomial())
pi_h_logit <- predict(mod_h_logit, newdata = test_d, type = "response")

# Naive Bayes
mod_h_nb <- naiveBayes(default ~ balance + income + student, data = train_d)
pi_h_nb <- predict(mod_h_nb, newdata = test_d, type = "raw")[, "Yes"]

# LDA
mod_h_lda <- lda(default ~ balance + income + student, data = train_d)
pi_h_lda <- predict(mod_h_lda, newdata = test_d)$posterior[, "Yes"]

# QDA
mod_h_qda <- qda(default ~ balance + income + student, data = train_d)
pi_h_qda <- predict(mod_h_qda, newdata = test_d)$posterior[, "Yes"]

y_test <- test_d$default
y_test_bin <- test_d$default_bin

# Función auxiliar para hold-out
metricas_holdout <- function(pi_hat, y_obs, y_bin, nombre) {
  y_pred <- clf(pi_hat)
  cm <- confusionMatrix(y_pred, y_obs, positive = "Yes")
  VP <- cm$table[2,2]; FP <- cm$table[2,1]; FN <- cm$table[1,2]
  data.frame(
    Método = nombre,
    Accuracy = round(cm$overall["Accuracy"], 4),
    Sensibilidad = round(cm$byClass["Sensitivity"], 4),
    Especificidad = round(cm$byClass["Specificity"], 4),
    F1 = round(2*VP/(2*VP+FP+FN), 4),
    AUC = round(as.numeric(pROC::auc(pROC::roc(y_bin, pi_hat, quiet=TRUE))), 4),
    LogLoss = round(log_loss(y_bin, pi_hat), 4)
  )
}
```

```

tab_holdout <- bind_rows(
  metricas_holdout(pi_h_logit, y_test, y_test_bin, "Reg. Logística"),
  metricas_holdout(pi_h_nb, y_test, y_test_bin, "Naive Bayes"),
  metricas_holdout(pi_h_lda, y_test, y_test_bin, "LDA"),
  metricas_holdout(pi_h_qda, y_test, y_test_bin, "QDA")
)

kable(tab_holdout, row.names = FALSE, booktabs = TRUE,
      caption = "Métricas Hold-Out 70/30 - conjunto de prueba (30\\%)")

```

Cuadro 9: Métricas Hold-Out 70/30 — conjunto de prueba (30 %)

Método	Accuracy	Sensibilidad	Especificidad	F1	AUC	LogLoss
Reg. Logística	0.9730	0.30	0.9962	0.4255	0.9490	0.1590
Naive Bayes	0.9697	0.29	0.9931	0.3893	0.9424	0.1682
LDA	0.9720	0.24	0.9972	0.3636	0.9486	0.1610
QDA	0.9723	0.27	0.9966	0.3942	0.9475	0.1621

5.2. Validación Cruzada K-Fold ($K = 10$)

Se emplea la librería `caret` con $K = 10$ pliegues. Se define una función de resumen personalizada que incluye AUC, Sensibilidad, Especificidad y Log-Loss medio:

```

custom_summary <- function(data, lev = NULL, model = NULL) {
  tcs <- twoClassSummary(data, lev, model)
  p <- data$Yes
  y_kf <- as.numeric(data$obs == "Yes")
  mdev <- -2 * mean(y_kf * log(p + 1e-15) + (1 - y_kf) * log(1 - p + 1e-15))
  c(tcs, LogLoss = mdev)
}

ctrl_kf <- trainControl(
  method = "cv",
  number = 10,
  classProbs = TRUE,
  summaryFunction = custom_summary,
  savePredictions = "final"
)

```

Se ajusta cada clasificador con `caret::train()` usando el mismo `trainControl`:

```

set.seed(123)
kf_logit <- train(default ~ balance + income + student,
  data = Default,
  method = "glm",
  family = binomial(),
  trControl = ctrl_kf,
  metric = "ROC")

cat("K-Fold (Logística) - AUC:", round(kf_logit$results$ROC, 4), "\n")

```

```
## K-Fold (Logística) - AUC: 0.9494
```

```
cat("K-Fold (Logística) - Sens:", round(kf_logit$results$Sens, 4), "\n")
```

```
## K-Fold (Logística) - Sens: 0.9958
```

```
cat("K-Fold (Logística) - Spec:", round(kf_logit$results$Spec, 4), "\n")
```

```
## K-Fold (Logística) - Spec: 0.3217
```

```
cat("K-Fold (Logística) - LogLoss:", round(kf_logit$results$LogLoss, 4), "\n")
```

```
## K-Fold (Logística) - LogLoss: 0.1579
```

```
set.seed(123)
kf_nb <- train(default ~ balance + income + student,
               data      = Default,
               method    = "naive_bayes",
               trControl = ctrl_kf,
               metric    = "ROC")
```

```
best_nb <- kf_nb$results[which.max(kf_nb$results$ROC), ]
cat("K-Fold (Naive Bayes) - AUC:", round(best_nb$ROC, 4), "\n")
```

```
## K-Fold (Naive Bayes) - AUC: 0.9427
```

```
cat("K-Fold (Naive Bayes) - Sens:", round(best_nb$Sens, 4), "\n")
```

```
## K-Fold (Naive Bayes) - Sens: 0.9939
```

```
cat("K-Fold (Naive Bayes) - Spec:", round(best_nb$Spec, 4), "\n")
```

```
## K-Fold (Naive Bayes) - Spec: 0.2826
```

```
cat("K-Fold (Naive Bayes) - LogLoss:", round(best_nb$LogLoss, 4), "\n")
```

```
## K-Fold (Naive Bayes) - LogLoss: 0.1697
```

```
set.seed(123)
kf_lda <- train(default ~ balance + income + student,
               data      = Default,
               method    = "lda",
               trControl = ctrl_kf,
               metric    = "ROC")
```

```
cat("K-Fold (LDA) - AUC:", round(kf_lda$results$ROC, 4), "\n")
```

```
## K-Fold (LDA) - AUC: 0.9492
```



```
cat("K-Fold (LDA) - Sens:", round(kf_lda$results$Sens, 4), "\n")
```

```
## K-Fold (LDA) - Sens: 0.9977
```

```
cat("K-Fold (LDA) - Spec:", round(kf_lda$results$Spec, 4), "\n")
```

```
## K-Fold (LDA) - Spec: 0.2406
```

```
cat("K-Fold (LDA) - LogLoss:", round(kf_lda$results$LogLoss, 4), "\n")
```

```
## K-Fold (LDA) - LogLoss: 0.1599
```

```
set.seed(123)
kf_qda <- train(default ~ balance + income + student,
  data      = Default,
  method    = "qda",
  trControl = ctrl_kf,
  metric    = "ROC")
```

```
cat("K-Fold (QDA) - AUC:", round(kf_qda$results$ROC, 4), "\n")
```

```
## K-Fold (QDA) - AUC: 0.9485
```

```
cat("K-Fold (QDA) - Sens:", round(kf_qda$results$Sens, 4), "\n")
```

```
## K-Fold (QDA) - Sens: 0.9968
```

```
cat("K-Fold (QDA) - Spec:", round(kf_qda$results$Spec, 4), "\n")
```

```
## K-Fold (QDA) - Spec: 0.2735
```

```
cat("K-Fold (QDA) - LogLoss:", round(kf_qda$results$LogLoss, 4), "\n")
```

```
## K-Fold (QDA) - LogLoss: 0.1606
```

```
tab_kfold <- data.frame(
  Método      = c("Reg. Logística", "Naive Bayes", "LDA", "QDA"),
  AUC         = round(c(kf_logit$results$ROC,
    best_nb$ROC,
    kf_lda$results$ROC,
    kf_qda$results$ROC), 4),
  Sensibilidad = round(c(kf_logit$results$Sens,
    best_nb$Sens,
    kf_lda$results$Sens,
    kf_qda$results$Sens), 4),
  Especificidad = round(c(kf_logit$results$Spec,
    best_nb$Spec,
    kf_lda$results$Spec,
```

```

    kf_qda$results$Spec), 4),
LogLoss      = round(c(kf_logit$results$LogLoss,
    best_nb$LogLoss,
    kf_lda$results$LogLoss,
    kf_qda$results$LogLoss), 4)
)

kable(tab_kfold, row.names = FALSE, booktabs = TRUE,
      caption = "Validación Cruzada K-Fold (K = 10) - promedios por clasificador")

```

Cuadro 10: Validación Cruzada K-Fold (K = 10) — promedios por clasificador

Método	AUC	Sensibilidad	Especificidad	LogLoss
Reg. Logística	0.9494	0.9958	0.3217	0.1579
Naive Bayes	0.9427	0.9939	0.2826	0.1697
LDA	0.9492	0.9977	0.2406	0.1599
QDA	0.9485	0.9968	0.2735	0.1606

5.3. Bootstrap 0.632

El estimador Bootstrap 0.632 corrige el sesgo del bootstrap estándar ponderando el error aparente con el error out-of-bag:

$$\widehat{\text{Err}}^{(0.632)} = 0,368 \cdot \overline{\text{err}} + 0,632 \cdot \widehat{\text{Err}}^{(1)}$$

Se emplea `method = "boot632"` en `trainControl` de `caret` con $B = 200$ muestras:

```

ctrl_boot632 <- trainControl(
  method      = "boot632",
  number      = 200,
  classProbs  = TRUE,
  summaryFunction = custom_summary,
  savePredictions = "final"
)

set.seed(42)
bt_logit <- train(default ~ balance + income + student,
  data      = Default,
  method    = "glm",
  family    = binomial(),
  trControl = ctrl_boot632,
  metric    = "ROC")

cat("Boot632 (Logística) - AUC:", round(bt_logit$results$ROC, 4), "\n")

## Boot632 (Logística) - AUC: 0.949

cat("Boot632 (Logística) - Sens:", round(bt_logit$results$Sens, 4), "\n")

```

```
## Boot632 (Logística) - Sens: 0.9959
```

```
cat("Boot632 (Logística) - Spec:", round(bt_logit$results$Spec, 4), "\n")
```

```
## Boot632 (Logística) - Spec: 0.3142
```

```
cat("Boot632 (Logística) - LogLoss:", round(bt_logit$results$LogLoss, 4), "\n")
```

```
## Boot632 (Logística) - LogLoss: 0.1582
```

```
set.seed(42)
bt_nb <- train(default ~ balance + income + student,
               data      = Default,
               method    = "naive_bayes",
               trControl = ctrl_boot632,
               metric     = "ROC")
```

```
best_bt_nb <- bt_nb$results[which.max(bt_nb$results$ROC), ]
cat("Boot632 (Naive Bayes) - AUC:", round(best_bt_nb$ROC, 4), "\n")
```

```
## Boot632 (Naive Bayes) - AUC: 0.9423
```

```
cat("Boot632 (Naive Bayes) - Sens:", round(best_bt_nb$Sens, 4), "\n")
```

```
## Boot632 (Naive Bayes) - Sens: 0.994
```

```
cat("Boot632 (Naive Bayes) - Spec:", round(best_bt_nb$Spec, 4), "\n")
```

```
## Boot632 (Naive Bayes) - Spec: 0.2752
```

```
cat("Boot632 (Naive Bayes) - LogLoss:", round(best_bt_nb$LogLoss, 4), "\n")
```

```
## Boot632 (Naive Bayes) - LogLoss: 0.17
```

```
set.seed(42)
bt_lda <- train(default ~ balance + income + student,
                data      = Default,
                method    = "lda",
                trControl = ctrl_boot632,
                metric     = "ROC")
```

```
cat("Boot632 (LDA) - AUC:", round(bt_lda$results$ROC, 4), "\n")
```

```
## Boot632 (LDA) - AUC: 0.949
```

```
cat("Boot632 (LDA) - Sens:", round(bt_lda$results$Sens, 4), "\n")
```

```
## Boot632 (LDA) - Sens: 0.9977
```

```
cat("Boot632 (LDA) - Spec:", round(bt_lda$results$Spec, 4), "\n")
```

```
## Boot632 (LDA) - Spec: 0.2381
```

```
cat("Boot632 (LDA) - LogLoss:", round(bt_lda$results$LogLoss, 4), "\n")
```

```
## Boot632 (LDA) - LogLoss: 0.1603
```

```
set.seed(42)
bt_qda <- train(default ~ balance + income + student,
  data      = Default,
  method    = "qda",
  trControl = ctrl_boot632,
  metric    = "ROC")
```

```
cat("Boot632 (QDA) - AUC:", round(bt_qda$results$ROC, 4), "\n")
```

```
## Boot632 (QDA) - AUC: 0.9483
```

```
cat("Boot632 (QDA) - Sens:", round(bt_qda$results$Sens, 4), "\n")
```

```
## Boot632 (QDA) - Sens: 0.9969
```

```
cat("Boot632 (QDA) - Spec:", round(bt_qda$results$Spec, 4), "\n")
```

```
## Boot632 (QDA) - Spec: 0.2744
```

```
cat("Boot632 (QDA) - LogLoss:", round(bt_qda$results$LogLoss, 4), "\n")
```

```
## Boot632 (QDA) - LogLoss: 0.161
```

```
tab_boot632 <- data.frame(
  Método      = c("Reg. Logística", "Naive Bayes", "LDA", "QDA"),
  AUC         = round(c(bt_logit$results$ROC,
    best_bt_nb$ROC,
    bt_lda$results$ROC,
    bt_qda$results$ROC), 4),
  Sensibilidad = round(c(bt_logit$results$Sens,
    best_bt_nb$Sens,
    bt_lda$results$Sens,
    bt_qda$results$Sens), 4),
  Especificidad = round(c(bt_logit$results$Spec,
    best_bt_nb$Spec,
    bt_lda$results$Spec,
    bt_qda$results$Spec), 4),
  LogLoss     = round(c(bt_logit$results$LogLoss,
    best_bt_nb$LogLoss,
    bt_lda$results$LogLoss,
```

```
        bt_qda$results$LogLoss), 4)
)

kable(tab_boot632, row.names = FALSE, booktabs = TRUE,
      caption = "Bootstrap 0.632 (B = 200) - promedios por clasificador")
```

Cuadro 11: Bootstrap 0.632 (B = 200) — promedios por clasificador

Método	AUC	Sensibilidad	Especificidad	LogLoss
Reg. Logística	0.9490	0.9959	0.3142	0.1582
Naive Bayes	0.9423	0.9940	0.2752	0.1700
LDA	0.9490	0.9977	0.2381	0.1603
QDA	0.9483	0.9969	0.2744	0.1610

6. Tabla Resumen Comparativa

Se consolida el AUC y el Log-Loss estimados por cada método de validación cruzada, facilitando la comparación final entre los cuatro clasificadores.

```
tab_auc_cv <- data.frame(
  Método = c("Reg. Logística", "Naive Bayes", "LDA", "QDA"),
  Muestra.Completa = round(c(pROC::auc(roc_logit), pROC::auc(roc_nb),
                             pROC::auc(roc_lda), pROC::auc(roc_qda)), 4),
  Hold.Out.30 = tab_holdout$AUC,
  K.Fold.10 = tab_kfold$AUC,
  Boot.632 = tab_boot632$AUC
)

kable(tab_auc_cv, row.names = FALSE, booktabs = TRUE,
      caption = "AUC por clasificador y método de validación")
```

Cuadro 12: AUC por clasificador y método de validación

Método	Muestra.Completa	Hold.Out.30	K.Fold.10	Boot.632
Reg. Logística	0.9496	0.9490	0.9494	0.9490
Naive Bayes	0.9437	0.9424	0.9427	0.9423
LDA	0.9495	0.9486	0.9492	0.9490
QDA	0.9492	0.9475	0.9485	0.9483

```
tab_ll_cv <- data.frame(
  Método = c("Reg. Logística", "Naive Bayes", "LDA", "QDA"),
  Muestra.Completa = tab_logloss$LogLoss,
  Hold.Out.30 = tab_holdout$LogLoss,
  K.Fold.10 = tab_kfold$LogLoss,
  Boot.632 = tab_boot632$LogLoss
)

kable(tab_ll_cv, row.names = FALSE, booktabs = TRUE,
      caption = "Log-Loss por clasificador y método de validación")
```

Cuadro 13: Log-Loss por clasificador y método de validación

Método	Muestra.Completa	Hold.Out.30	K.Fold.10	Boot.632
Reg. Logística	0.1572	0.1590	0.1579	0.1582
Naive Bayes	0.1674	0.1682	0.1697	0.1700
LDA	0.1595	0.1610	0.1599	0.1603
QDA	0.1593	0.1621	0.1606	0.1610

Los resultados permiten observar:

1. La **Regresión Logística** y el **LDA** suelen obtener AUC similares en este conjunto, ambos con probabilidades bien calibradas (Log-Loss bajo), lo que es esperable dado que la frontera de decisión real en Default es aproximadamente lineal en **balance**. Eso ocurre también porque hay datos desbalanceados. Así esta métrica no se muestra adecuada.

2. **Naive Bayes** puede presentar diferencias en Log-Loss respecto a los modelos discriminativos, ya que su supuesto de independencia condicional puede ser violado cuando **balance** e **income** están correlacionados.
3. **QDA** gana flexibilidad al no asumir covarianzas iguales entre grupos, aunque con $n = 10\,000$ observaciones el costo en varianza es manejable.
4. Las estimaciones de muestra completa son optimistas (sesgo hacia abajo). Los métodos de validación cruzada producen estimaciones más realistas del error de predicción fuera de muestra.
5. Para este conjunto de datos el mejor modelo fue la logística porque los otros métodos requieren comportamiento normal de las covariables y continuidad, aspecto que no se cumple en estos datos.

7. Ejercicio Propuesto

Ejercicio Considere la base de datos **Smarket** de ISLR2, que contiene 1250 observaciones diarias del mercado bursátil estadounidense entre 2001 y 2005. La variable respuesta es **Direction** (Up / Down) en función de los retornos porcentuales rezagados **Lag1**, **Lag2** y el volumen **Volume**.

Utilizando como conjunto de entrenamiento los años 2001–2004 y como conjunto de prueba el año 2005:

- a) Ajuste los cuatro clasificadores (Regresión Logística, Naive Bayes, LDA y QDA) usando **Lag1**, **Lag2** y **Volume** como predictores. Para cada modelo reporte la matriz de confusión y calcule Accuracy, Sensibilidad, Especificidad, F1 Score y AUC.
- b) Grafique las cuatro curvas ROC en un mismo panel e identifique visualmente cuál clasificador tiene mejor capacidad discriminante.
- c) Estime el error de predicción de los cuatro modelos mediante validación cruzada K-Fold con $K = 10$ sobre el conjunto de entrenamiento. Reporte AUC y Log-Loss.
- d) Repita la estimación del literal (c) utilizando Bootstrap 0.632 con $B = 200$ muestras. ¿Las conclusiones cambian respecto al K-Fold?
- e) Elabore una tabla resumen comparativa (similar a la Sección 6 de este material) e indique cuál clasificador recomendaría para este problema y por qué.

Referencias

- [James et al.(2021)] Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani (2021) *An Introduction to Statistical Learning with Applications in R*, 2nd edition. Springer Series in Statistics.
- [Hastie et al.(2008)] Trevor Hastie, Robert Tibshirani and Jerome Friedman (2008) *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Series in Statistics.