

Pontificia Universidad Católica de Chile

Aprendizaje Supervisado

Material complementario

Clase1MIApSu.pdf

Dr. Jorge Luis Bazán
jlbazan@uc.cl

1. Introducción

El lenguaje R es ampliamente utilizado en análisis estadístico y ciencia de datos, pues permite organizar, visualizar y procesar grandes conjuntos de datos de manera eficiente mediante herramientas intuitivas y reproducibles. El uso de software especializado facilita la aplicación de métodos estadísticos complejos, reduciendo errores y mejorando la precisión de los resultados, al mismo tiempo que promueve la reproducibilidad y la comunicación clara de los análisis, aspectos fundamentales en la investigación moderna.

Además, existe el entorno RStudio el cual es un entorno de desarrollo integrado diseñado para trabajar con el lenguaje R y se complementa con una amplia variedad de paquetes que extienden sus funcionalidades, permitiendo realizar desde manipulación de datos hasta modelamiento estadístico avanzado y visualización gráfica. Estos paquetes incluyen conjuntos de datos de ejemplo que facilitan el aprendizaje y la experimentación, y también permiten importar información desde múltiples fuentes externas, como archivos CSV, Excel o bases de datos así como también generar reportes estadísticos en formatos como Látex o HTML, lo que hace posible trabajar tanto con datos propios como con datos disponibles dentro del ecosistema del software.

2.Instalación de paquetes

Un paquete en RStudio es un conjunto organizado de funciones, datos y documentación que extiende las capacidades básicas del software. Estos paquetes permiten realizar tareas específicas como visualización, modelamiento o manipulación de datos sin tener que programar todo desde cero, facilitando así el trabajo y haciendo más eficiente el análisis estadístico. La instalación de paquetes se puede realizar a través de la sentencia `install.package(Nombredelpaquete)`

Algunos de los paquetes más utilizados en el curso son los siguientes:

```
install.packages("ISLR") #contiene bases de datos a trabajar
install.packages("MASS") #contiene herramientas estadísticas para análisis de regresión
install.packages("tree") #contiene herramientas estadísticas para métodos supervisados
install.packages("class") #contiene herramientas estadísticas para métodos supervisados
install.packages("e1071") #contiene herramientas estadísticas para métodos supervisados
install.packages("mlbench") #contiene bases de datos a trabajar
install.packages("pROC") #contiene herramientas para métodos supervisados y visualización
install.packages("caret") #contiene herramientas estadísticas para métodos supervisados
```

Una vez instalados los paquetes, estos deben ser llamados para poder acceder a todas las funciones y documentación que poseen mediante el comando `library(Nombredelpaquete)`. Sin esta sentencia, las funciones dentro del paquete no se podrán utilizar a pesar de que se encuentre instalado.

```
library(ISLR)
library(MASS)
library(tree)
library(class)
library(e1071)
library(mlbench)
library(pROC)
library(caret)
```

Con esto ya podemos acceder a la información y funcionalidades de cada paquete previamente instalado.

3. Bases de datos

A continuación se presentan una serie de bases de datos disponibles en paquetes que serán utilizados para aplicar los métodos de aprendizajes estudiados durante el curso.

3.1 Default Data

El conjunto de datos *Default*, proveniente del paquete *ISLR* es un conjunto de datos sintético que se centra en el comportamiento crediticio, analizando variables clave como el saldo pendiente, los ingresos anuales y el estatus de estudiante del titular. La base de datos consta de 10.000 observaciones organizadas en 4 variables descritas a continuación:

- “default”: Es una variable de tipo factor con 2 niveles (No,Yes) que indica si el cliente incumplió su deuda.
- “student”: Es una variable de tipo factor con 2 niveles (No,Yes) que indica si el cliente es o no estudiante.
- “balance”: Indica el saldo promedio que el cliente tiene en su tarjeta de crédito luego de realizar su pago mensual.
- “income”: Indica el ingreso del cliente.

Estos datos fueron creados para la ilustración de los métodos de clasificación supervisada y no supervisada en Tibshirani, et al (2013).

```
datos2<-Default #Asignamos la base de datos a una variable
head(datos2) #visualización de las 10 primeras filas de la base de datos
```

```
## default student balance income
## 1      No      No 729.5265 44361.625
## 2      No     Yes 817.1804 12106.135
## 3      No      No 1073.5492 31767.139
## 4      No      No 529.2506 35704.494
## 5      No      No 785.6559 38463.496
## 6      No     Yes 919.5885 7491.559
```

```
summary(datos2) # Estadísticas descriptivas de las variables de la base de datos
```

```
## default student balance income
## No :9667 No :7056 Min. : 0.0 Min. : 772
## Yes: 333 Yes:2944 1st Qu.: 481.7 1st Qu.:21340
## Median : 823.6 Median :34553
## Mean : 835.4 Mean :33517
## 3rd Qu.:1166.3 3rd Qu.:43808
## Max. :2654.3 Max. :73554
```

3.2 PimaIndiansDiabetes

El conjunto de datos *PimaIndiansDiabetes* se encuentra disponible en la librería *mlbench* y está compuesto por una serie de medidas clínicas específicas sobre mujeres de al menos 21 años de edad, de ascendencia india Pima, que viven cerca de Phoenix, Arizona, EE. UU. La base de datos consta de 768 variables organizadas en 9 variables detalladas a continuación:

- “pregnant”: Número de embarazos
- “glucose”: Concentración de glucosa en plasma (prueba de tolerancia a la glucosa)
- “pressure”: Presión arterial diastólica (mm Hg)
- “triceps”: Grosor del pliegue cutáneo del tríceps (mm)
- “insulin”: Insulina sérica a las 2 horas (μ U/ml)
- “mass”: índice de masa corporal
- “pedigree”: Función del pedigrí de diabetes
- “age”: Edad en años
- “diabetes”: Variable categórica con dos categorías (pos,neg) que indica si el paciente resulta positivo a negativo a un test de diabetes.

La fuente original de estos datos es el UCI Machine Learning Repository (Blake y Merz, 1998); posteriormente, a finales de los años 90, Friedrich Leisch realizó la conversión de los archivos al formato compatible con el lenguaje R.

```
data("PimaIndiansDiabetes") # con esto cargamos primero la base de datos
datos1<-PimaIndiansDiabetes # asignamos la base de datos a una variable

head(datos1) #visualización de las 10 primeras filas de la base de datos
```

```
##   pregnant glucose pressure triceps insulin mass pedigree age diabetes
## 1         6     148       72      35        0  33.6   0.627  50      pos
## 2         1      85       66      29        0  26.6   0.351  31      neg
## 3         8     183       64       0        0  23.3   0.672  32      pos
## 4         1      89       66      23       94  28.1   0.167  21      neg
## 5         0     137       40      35      168  43.1   2.288  33      pos
## 6         5     116       74       0        0  25.6   0.201  30      neg
```

```
summary(datos1) # Estadísticas descriptivas de las variables de la base de datos
```

```
##      pregnant      glucose      pressure      triceps
##  Min.   : 0.000   Min.    : 0.0   Min.    : 0.00   Min.    : 0.00
## 1st Qu.: 1.000   1st Qu.: 99.0   1st Qu.: 62.00   1st Qu.: 0.00
##  Median : 3.000   Median :117.0   Median : 72.00   Median :23.00
##  Mean   : 3.845   Mean    :120.9   Mean    : 69.11   Mean    :20.54
## 3rd Qu.: 6.000   3rd Qu.:140.2   3rd Qu.: 80.00   3rd Qu.:32.00
##  Max.   :17.000   Max.    :199.0   Max.    :122.00   Max.    :99.00
##      insulin      mass      pedigree      age      diabetes
##  Min.    : 0.0   Min.    : 0.00   Min.   :0.0780   Min.   :21.00   neg:500
## 1st Qu.: 0.0   1st Qu.:27.30   1st Qu.:0.2437   1st Qu.:24.00   pos:268
##  Median : 30.5   Median :32.00   Median :0.3725   Median :29.00
##  Mean    : 79.8   Mean    :31.99   Mean    :0.4719   Mean    :33.24
## 3rd Qu.:127.2   3rd Qu.:36.60   3rd Qu.:0.6262   3rd Qu.:41.00
##  Max.    :846.0   Max.    :67.10   Max.    :2.4200   Max.    :81.00
```

Nota: A diferencia de la librería ISLR, en este caso es necesario usar previamente la sentencia `data("PimaIndiansDiabetes")` debido a que las bases de datos disponibles en la librería `mlbench` no se cargan automáticamente en el workspace.

3.3 Smarket data

El conjunto de datos *Smarket*, proveniente del paquete *ISLR* es un conjunto de datos que registra los rendimientos diarios del índice bursátil S&P 500 durante un periodo de cinco años (desde inicios de 2001 hasta finales de 2005). La base de datos consta de 1250 observaciones organizadas en 9 variables económicas descritas a continuación:

- “Year”: Año en que se observó el registro.
- “Lag1”: Rentabilidad porcentual del día anterior.
- “Lag2”: Rentabilidad porcentual de los 2 días anteriores.
- “Lag3”: Rentabilidad porcentual de los 3 días anteriores.
- “Lag4”: Rentabilidad porcentual de los 4 días anteriores.
- “Lag5”: Rentabilidad porcentual de los 5 días anteriores.
- “Volume”: Volumen de acciones negociadas (número de acciones diarias negociadas en miles de millones).
- “Today”: Rentabilidad porcentual del día de hoy.
- “Direction”: Es una variable tipo factor con 2 niveles (Down,Up) que indica si el mercado tuvo una rentabilidad positiva o negativa en un día determinado.

La información disponible proviene de la plataforma Yahoo Finance y fue sintetizada y arreglada por Tibshirani, et al (2013).

```
datos3<-Smarket
```

```
head(datos3) #visualización de las 10 primeras filas de la base de datos
```

```
##   Year  Lag1  Lag2  Lag3  Lag4  Lag5 Volume  Today Direction
## 1 2001  0.381 -0.192 -2.624 -1.055  5.010 1.1913  0.959      Up
## 2 2001  0.959  0.381 -0.192 -2.624 -1.055 1.2965  1.032      Up
## 3 2001  1.032  0.959  0.381 -0.192 -2.624 1.4112 -0.623     Down
## 4 2001 -0.623  1.032  0.959  0.381 -0.192 1.2760  0.614      Up
## 5 2001  0.614 -0.623  1.032  0.959  0.381 1.2057  0.213      Up
## 6 2001  0.213  0.614 -0.623  1.032  0.959 1.3491  1.392      Up
```

```
summary(datos3) # Estadísticas descriptivas de las variables de la base de datos
```

```
##      Year      Lag1      Lag2      Lag3
## Min.   :2001   Min.   :-4.922000   Min.   :-4.922000   Min.   :-4.922000
## 1st Qu.:2002   1st Qu.: -0.639500   1st Qu.: -0.639500   1st Qu.: -0.640000
## Median :2003   Median :  0.039000   Median :  0.039000   Median :  0.038500
## Mean   :2003   Mean   :  0.003834   Mean   :  0.003919   Mean   :  0.001716
## 3rd Qu.:2004   3rd Qu.:  0.596750   3rd Qu.:  0.596750   3rd Qu.:  0.596750
## Max.   :2005   Max.    :  5.733000   Max.    :  5.733000   Max.    :  5.733000
##      Lag4      Lag5      Volume      Today
## Min.   :-4.922000   Min.   :-4.92200   Min.    :0.3561   Min.    :-4.922000
## 1st Qu.: -0.640000   1st Qu.: -0.64000   1st Qu.:1.2574   1st Qu.: -0.639500
## Median :  0.038500   Median :  0.03850   Median :1.4229   Median :  0.038500
## Mean   :  0.001636   Mean    :  0.00561   Mean    :1.4783   Mean    :  0.003138
```

```
## 3rd Qu.: 0.596750 3rd Qu.: 0.59700 3rd Qu.:1.6417 3rd Qu.: 0.596750
## Max. : 5.733000 Max. : 5.73300 Max. :3.1525 Max. : 5.733000
## Direction
## Down:602
## Up :648
##
##
##
##
```

3.4 Vehicle data

La base de datos *Vehicle* se encuentra disponible en la librería *mlbench* y está compuesta por un conjunto de características extraídas las siluetas de cuatro tipos de vehículos. La base está compuesta de 846 observaciones en 19 variables, todas numéricas y una nominal que define la clase de los objetos.

- Comp: Compacidad de la silueta
- Circ: Circularidad de la silueta
- D.Circ: Distancia de circularidad
- Rad.Ra: Razón de radios
- Pr.Axis.Ra: Razón de aspecto del eje principal
- Max.L.Ra: Razón de aspecto de la longitud máxima
- Scat.Ra: Razón de dispersión
- Elong: Elongación de la silueta
- Pr.Axis.Rect: Rectangularidad del eje principal
- Max.L.Rect: Rectangularidad de la longitud máxima
- Sc.Var.Maxis: Varianza escalada a lo largo del eje mayor
- Sc.Var.maxis: Varianza escalada a lo largo del eje menor
- Ra.Gyr: Radio de giro escalado
- Skew.Maxis: Asimetría respecto al eje mayor
- Skew.maxis: Asimetría respecto al eje menor
- Kurt.maxis: Curtosis respecto al eje menor
- Kurt.Maxis: Curtosis respecto al eje mayor
- Holl.Ra: Razón de cavidades
- Class: Variable categórica que indica el tipo de vehículo, el cual puede ser van, saab, bus u opel.

Los datos fueron generados originalmente por el Turing Institute en Glasgow (Escocia) en 1987 para un proyecto de investigación sobre reconocimiento de objetos.

```
data("Vehicle")
datos4<-Vehicle # asigamos la base de datos a una variable
head(datos4) #visualización de las 10 primeras filas de la base de datos
```

```
##      Comp Circ D.Circ Rad.Ra Pr.Axis.Ra Max.L.Ra Scat.Ra Elong Pr.Axis.Rect
## 1    95   48   83   178         72    10   162   42          20
## 2    91   41   84   141         57     9   149   45          19
## 3   104   50  106   209         66    10   207   32          23
## 4    93   41   82   159         63     9   144   46          19
## 5    85   44   70   205        103    52   149   45          19
## 6   107   57  106   172         50     6   255   26          28
##      Max.L.Rect Sc.Var.Maxis Sc.Var.maxis Ra.Gyr Skew.Maxis Skew.maxis Kurt.maxis
## 1          159          176          379   184          70           6          16
## 2          143          170          330   158          72           9          14
## 3          158          223          635   220          73          14           9
## 4          143          160          309   127          63           6          10
## 5          144          241          325   188         127           9          11
## 6          169          280          957   264          85           5           9
##      Kurt.Maxis Holl.Ra Class
## 1          187       197   van
## 2          189       199   van
## 3          188       196  saab
## 4          199       207   van
## 5          180       183   bus
## 6          181       183   bus
```

```
summary(datos4) # Estadísticas descriptivas de las variables de la base de datos
```

```
##           Comp           Circ           D.Circ           Rad.Ra
## Min.      : 73.00   Min.      :33.00   Min.      : 40.00   Min.      :104.0
## 1st Qu.: 87.00   1st Qu.:40.00   1st Qu.: 70.00   1st Qu.:141.0
## Median : 93.00   Median :44.00   Median : 80.00   Median :167.0
## Mean     : 93.68   Mean     :44.86   Mean     : 82.09   Mean     :168.9
## 3rd Qu.:100.00   3rd Qu.:49.00   3rd Qu.: 98.00   3rd Qu.:195.0
## Max.     :119.00   Max.     :59.00   Max.     :112.00   Max.     :333.0
##      Pr.Axis.Ra      Max.L.Ra      Scat.Ra      Elong
## Min.      : 47.00   Min.      : 2.000   Min.      :112.0   Min.      :26.00
## 1st Qu.: 57.00   1st Qu.: 7.000   1st Qu.:146.2   1st Qu.:33.00
## Median : 61.00   Median : 8.000   Median :157.0   Median :43.00
## Mean     : 61.69   Mean     : 8.567   Mean     :168.8   Mean     :40.93
## 3rd Qu.: 65.00   3rd Qu.:10.000   3rd Qu.:198.0   3rd Qu.:46.00
## Max.     :138.00   Max.     :55.000   Max.     :265.0   Max.     :61.00
##      Pr.Axis.Rect      Max.L.Rect      Sc.Var.Maxis      Sc.Var.maxis      Ra.Gyr
## Min.      :17.00   Min.      :118   Min.      :130.0   Min.      : 184.0   Min.      :109.0
## 1st Qu.:19.00   1st Qu.:137   1st Qu.:167.0   1st Qu.: 318.2   1st Qu.:149.0
## Median :20.00   Median :146   Median :178.5   Median : 364.0   Median :173.0
## Mean     :20.58   Mean     :148   Mean     :188.6   Mean     : 439.9   Mean     :174.7
## 3rd Qu.:23.00   3rd Qu.:159   3rd Qu.:217.0   3rd Qu.: 587.0   3rd Qu.:198.0
## Max.     :29.00   Max.     :188   Max.     :320.0   Max.     :1018.0   Max.     :268.0
##      Skew.Maxis      Skew.maxis      Kurt.maxis      Kurt.Maxis
## Min.      : 59.00   Min.      : 0.000   Min.      : 0.0   Min.      :176.0
## 1st Qu.: 67.00   1st Qu.: 2.000   1st Qu.: 5.0   1st Qu.:184.0
```

```
## Median : 71.50    Median : 6.000    Median :11.0    Median :188.0
## Mean   : 72.46    Mean   : 6.377    Mean   :12.6    Mean   :188.9
## 3rd Qu.: 75.00    3rd Qu.: 9.000    3rd Qu.:19.0    3rd Qu.:193.0
## Max.   :135.00    Max.   :22.000    Max.   :41.0    Max.   :206.0
##      Holl.Ra      Class
## Min.   :181.0    bus :218
## 1st Qu.:190.2    opel:212
## Median :197.0    saab:217
## Mean   :195.6    van :199
## 3rd Qu.:201.0
## Max.   :211.0
```

4. Bibliografia

- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2013) An Introduction to Statistical Learning with applications in R, <https://www.statlearning.com>, Springer-Verlag, New York
- Siebert P (1987). “Vehicle Recognition Using Rule Based Methods.” Turing Institute Research Memorandum TIRM-87-018
- Blake CL, Merz CJ (1998). “UCI Repository of Machine Learning Databases.” University of California, Irvine, Department of Information and Computer Science. Formerly available from ‘<http://www.ics.uci.edu/~mlearn/MLRepository.html>’.