

Pontificia Universidad Católica de Chile

EPG4001 Aprendizaje Supervisado

Material complementario

Clase3MIAApSu.pdf

Dr. Jorge Luis Bazán
jlbazan@uc.cl

1. Carga de librerías

Las librerías a utilizar para los procedimientos son las siguientes

```
library(ISLR)
library(MASS)
library(pROC)
library(caret)
```

2. Gráfica funciones de enlace sección 2.2

El objetivo es visualizar el comportamiento de las distintas funciones de enlace para el modelo lineal generalizado cuya respuesta es binaria. Primero definimos los rangos entre los que se moverá la función

```
# Valores del eje x
x <- seq(-5, 5, length = 500)
```

Luego definimos las funciones Logit, Probit y CLogLog

```
# Funciones de enlace inversas
logit    <- plogis(x)           # Logit
probit   <- pnorm(x)            # Probit
cloglog  <- 1 - exp(-exp(x))    # Complementary log-log
```

Luego realizamos el gráfico respectivo


```
#graficamos la funcion logit primero
plot(x, logit,
     type="l",
     lwd=2,
     col="black",
     ylim=c(0,1),
     xlab="",
     ylab="p",
     main="Funciones de Enlace")

#Agregamos las funciones probit y cloglog
lines(x, probit, col="#E95A74", lwd=2)
lines(x, cloglog, col="dodgerblue", lwd=2)

# agregamos líneas punteadas que indican la probabilidad 0.5.
abline(v=0, lty=2)
abline(h=0.5, lty=2)

# Leyenda
legend("bottomright",
     legend=c("Logit", "Probit", "CLogLog"),
     col=c("black", "#E95A74", "dodgerblue"),
     lwd=2,
     bty="o",
     cex=1.2)
```

Funciones de Enlace



Es importante notar que cada función de enlace tiene su particularidad para datos binarios. Se observa que tanto la función de enlace Logit como la Probit resultan ser simétricas y centradas en el punto (0,0.5), con la diferencia de que la función de enlace Logit presenta colas un poco más pesadas que la función Probit. Por otro lado, la función de enlace CLogLog presenta una asimetría que permite que la función alcance valores positivos más rápidamente que las mencionadas anteriormente.

3. Aplicación sección 2.7

Realizaremos una regresión logística para modelar la variable *chd* en función de *cigs*. Primero cargamos los datos

```
library(faraway)
data<-wcgs
head(data)
```

```
##   age height weight sdp dbp chol behave cigs dibep chd  typechd timechd  arcus
## 1  49     73   150 110  76  225    A2   25    A  no     none    1664 absent
## 2  42     70   160 154  84  177    A2   20    A  no     none    3071 present
## 3  42     69   160 110  78  181    B3    0    B  no     none    3071 absent
## 4  41     68   152 124  78  132    B4   20    B  no     none    3064 absent
## 5  59     70   150 144  86  255    B3   20    B yes infdeath 1885 present
## 6  44     72   204 150  90  182    B4    0    B  no     none    3102 absent
```

```
table(data$chd)
```

```
##
##   no  yes
## 2897 257
```

3.1 Regresión Logística simple

Los resultados mediante la función *glm()* son los siguientes

```
modelo<-glm(chd~cigs,family = binomial(link = "logit"),data = data)
```

Luego analizamos los resultados de la estimación con la siguiente sentencia

```
summary(modelo)
```

```
##
## Call:
## glm(formula = chd ~ cigs, family = binomial(link = "logit"),
##      data = data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -2.742160    0.092111 -29.770 < 2e-16 ***
## cigs         0.023220    0.004042   5.744 9.22e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1781.2  on 3153  degrees of freedom
## Residual deviance: 1750.0  on 3152  degrees of freedom
## AIC: 1754
##
## Number of Fisher Scoring iterations: 5
```

Se observan los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ los cuales son -2.742160 y 0.0232220 respectivamente.

Notar que en este caso el modelo de regresión logística indica que la variable *cigs* tiene un efecto estadísticamente significativo sobre la probabilidad de que ocurra *chd*, con un valor $p = 9,22 \times 10^{-9} \approx 0$, lo que permite rechazar la hipótesis nula al 5 %.

El modelo de regresión logística quedaría expresado de la siguiente forma

$$P(\text{chd} = \text{Yes} \mid \text{cigs}) = \frac{e^{-2,742160 - 0,023220 \cdot \text{cigs}}}{1 + e^{-2,742160 - 0,023220 \cdot \text{cigs}}} \quad (1)$$

3.2 Cálculo de Odds

El odd representa una razón de probabilidades, es decir, nos indica que tanto aumenta o disminuye la probabilidad de ocurrencia de nuestra variable respuesta cuando aumentamos en una unidad la variable explicativa.

$$\text{odd} = e^{\hat{\beta}_0} \cdot e^{\hat{\beta}_1 \cdot x} \quad (2)$$

En este caso, si *x* aumenta en una unidad

$$\text{odd}(x+1) = e^{\beta_0 + \beta_1(x+1)} \quad (3)$$

$$= e^{\beta_0 + \beta_1 x + \beta_1} \quad (4)$$

$$= e^{\beta_0 + \beta_1 x} e^{\beta_1} \quad (5)$$

$$= \text{odd}(x)e^{\beta_1} \quad (6)$$

Por tanto

$$\frac{\text{odd}(x+1)}{\text{odd}(x)} = e^{\beta_1} \quad (7)$$

Si el valor es mayor a 1, entonces el riesgo de que ocurra el evento es mayor, si es menor a 1, entonces el riesgo de que ocurra el evento es menor.

```
exp(coef(modelo)) #extrae la exponencial de los coeficientes
```

```
## (Intercept)          cigs
##  0.06443106    1.02349149
```

```
as.numeric(exp(coef(modelo)[2])) #pasamos a numerico para solo tener el valor
```

```
## [1] 1.023491
```

Esto indica que, por cada unidad de aumento en la variable *cigs* el riesgo de que ocurra la variable *chd* es 0.02349149 veces mayor.

4. Regresión Logística en Default data

El objetivo es predecir el cumplimiento o incumplimiento de la deuda de los clientes en función de las variables explicativas

```
datos1<-Default #Asignamos la base de datos a una variable
head(datos1) #visualización de las 10 primeras filas de la base de datos
```

##	default	student	balance	income
## 1	No	No	729.5265	44361.625
## 2	No	Yes	817.1804	12106.135
## 3	No	No	1073.5492	31767.139
## 4	No	No	529.2506	35704.494
## 5	No	No	785.6559	38463.496
## 6	No	Yes	919.5885	7491.559

```
summary(datos1) # Estadísticas descriptivas de las variables de la base de datos
```

##	default	student	balance	income
##	No :9667	No :7056	Min. : 0.0	Min. : 772
##	Yes: 333	Yes:2944	1st Qu.: 481.7	1st Qu.:21340
##			Median : 823.6	Median :34553
##			Mean : 835.4	Mean :33517
##			3rd Qu.:1166.3	3rd Qu.:43808
##			Max. :2654.3	Max. :73554

4.1 Regresión logística simple

Estudiaremos el cumplimiento o incumplimiento de la deuda de los clientes (default) en función del ingreso de los clientes (income), utilizando la función *glm()*

```
modelo_1<-glm(default~income,family=binomial(link="logit"),data = datos1)
```

Luego analizamos los resultados de la estimación con la siguiente sentencia

```
summary(modelo_1)
```

```
##
## Call:
## glm(formula = default ~ income, family = binomial(link = "logit"),
##      data = datos1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -3.094e+00  1.463e-01 -21.156  <2e-16 ***
## income      -8.353e-06  4.207e-06  -1.985   0.0471 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 2916.7  on 9998  degrees of freedom
## AIC: 2920.7
##
## Number of Fisher Scoring iterations: 6
```

Notar que en este caso el modelo de regresión logística indica que la variable income tiene un efecto estadísticamente significativo sobre la probabilidad de que ocurra el evento de interés (variable default), con un valor p de 0.0471, lo que permite rechazar la hipótesis nula al 5%.

El modelo de regresión logística quedaría expresado de la siguiente forma

$$P(\text{default} = \text{Yes} \mid \text{income}) = \frac{e^{-3,094-0,00000835 \cdot \text{income}}}{1 + e^{-3,094-0,00000835 \cdot \text{income}}} \quad (8)$$

En esta línea, si por ejemplo quisieramos realizar una predicción de incumplimiento o cumplimiento de deuda para clientes con un ingreso de \$40{,}000, reemplazando en nuestro modelo el resultado sería el siguiente

$$\hat{P}(\text{default} = \text{Yes} \mid \text{income}) = \frac{e^{-3,094-0,00000835 \cdot 40000}}{1 + e^{-3,094-0,00000835 \cdot 40000}} = \frac{e^{-3,428}}{1 + e^{-3,428}} = 0,0314 \quad (9)$$

Lo que nos indica que para un ingreso de \$40{,}000, la probabilidad estimada de default es aproximadamente 3.14%,

4.2 Regresión logística múltiple

Estudiaremos el cumplimiento o incumplimiento de la deuda de los clientes (*default*) en función del ingreso de los clientes (*income*), saldo promedio en su tarjeta de crédito (*balance*) y condición de estudiante (*student*), utilizando la función *glm()*

```
modelo_2<-glm(default~income+student+balance,family=binomial(link="logit"),data=datos1)
```

Luego analizamos los resultados de la estimación con la siguiente sentencia

```
summary(modelo_2)
```

```
##
## Call:
## glm(formula = default ~ income + student + balance, family = binomial(link = "logit"),
##      data = datos1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.087e+01  4.923e-01 -22.080  < 2e-16 ***
## income      3.033e-06  8.203e-06   0.370  0.71152
## studentYes  -6.468e-01  2.363e-01  -2.738  0.00619 **
## balance      5.737e-03  2.319e-04  24.738  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 1571.5  on 9996  degrees of freedom
## AIC: 1579.5
##
## Number of Fisher Scoring iterations: 8
```

Es posible observar que la variable *balance* es altamente significativa ($p < 2 \times 10^{-16}$). Este resultado sugiere que *balance* es una variable altamente explicativa para el modelo.

Por otro lado, la variable *studentYes* también resulta significativa al 1 % ($p = 0,00619$).

Adicionalmente, al incluir el resto de covariables se observa que la variable *income* no es estadísticamente significativa ($p = 0,7115$), por lo que no existe evidencia suficiente para afirmar que el ingreso tenga un efecto sobre la probabilidad de *default*.

También queda en evidencia que tanto la devianza residual como el AIC en este caso disminuyen considerablemente con respecto al modelo con la variable *income* como único predictor, lo cual indica una mejora sustancial en la predicción de la probabilidad de incumplimiento de la deuda.

$$P(\text{default} = \text{Yes} \mid \vec{X}) = \frac{e^{-10,87-0,6468 \cdot \text{studentYes}+0,005737 \cdot \text{balance}+0,000003033 \cdot \text{income}}}{1 + e^{-10,87-0,6468 \cdot \text{studentYes}+0,005737 \cdot \text{balance}+0,000003033 \cdot \text{income}}} \quad (10)$$

4.2.1 Curva ROC

Para el modelo con todas las covariables como predictores, realizamos el cálculo de la curva ROC para buscar el punto de corte óptimo que maximice la sensibilidad y especificidad. Para esto ocupamos funciones de la librería *pROC*

```


pred_m2 <- predict(modelo_2, type="response") #realiza predicciones utilizando la información de las vari
roc_m2 <- roc(datos1$default, pred_m2) #crea un objeto roc con todos los posibles puntos de corte para

## Setting levels: control = No, case = Yes

## Setting direction: controls < cases

plot(roc_m2, print.auc=T, print.thres = "best", main = "Curva ROC para el Modelo Logístico", col = "blue",
     xlab="1-Especificidad", ylab="Sensibilidad") #grafica la curva ROC

```



De la gráfica es posible observar que aquel punto de corte óptimo que maximiza la curva es el 0.031 con un AUC de 0.950, lo cual indica una buena clasificación y capacidad predictiva del modelo.

4.2.2 Matriz de confusión

Ya determinado el punto de corte óptimo, podemos ver la matriz de confusión asociada, a través de las siguientes sentencias

```

pred_op <- ifelse(pred_m2 > 0.031, "Yes", "No") #aquí reemplazamos el 0.031
#encontrado en la curva roc

pred_op <- factor(pred_op, levels = c("No", "Yes")) #llevamos a los mismos
#nombres de la variable objetivo

```

```
real <- factor(datos1$default, levels = c("No", "Yes")) #guardamos los valores
#reales en un factor

table(Predicho = pred_op, Real = real) #generamos la matriz de confusión
```

```
##          Real
## Predicho  No  Yes
##        No 8318  32
##        Yes 1349 301
```

Recordemos que la matriz de confusión está compuesta por las siguientes celdas, considerando Yes como clase positiva:

	Estimado (No)	Estimado (Yes)
Real (No)	Verdadero negativo	Falso negativo
Real (Yes)	Falso positivo	Verdadero positivo

Y las formulas para sensibilidad y especificidad son las siguientes

$$\begin{aligned} \text{Sensibilidad} &= \frac{VP}{VP + FN} \\ \text{Especificidad} &= \frac{VN}{VN + FP} \end{aligned} \quad (11)$$

Luego, con los resultados de la tabla tenemos que

```
mconf<-table(Predicho = pred_op, Real = real) #guardamos la tabla
sens<-mconf[2,2]/(mconf[2,2]+mconf[1,2]);sens #calculo de sensibilidad
```

```
## [1] 0.9039039
```

```
esp<- mconf[1,1]/(mconf[1,1]+mconf[2,1]);esp #calculo de especificidad
```

```
## [1] 0.8604531
```

$$\begin{aligned} \text{Sensibilidad} &= \frac{301}{301 + 32} = 0,9039 \\ \text{Especificidad} &= \frac{8318}{8318 + 301} = 0,8605 \end{aligned} \quad (12)$$

El modelo presenta una alta sensibilidad (0.9039), lo que indica una gran capacidad para identificar correctamente los casos de default. Asimismo, muestra una especificidad de 0.8605, evidenciando un buen desempeño al clasificar correctamente los casos de no default, aunque con cierta proporción de falsos positivos.

Por otro lado, es posible visualizar los mismos resultados a través de la función *confusionMatrix* de la librería *caret*.

```
confusionMatrix(pred_op, real, positive = "Yes")
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  No  Yes
##           No 8318  32
##           Yes 1349 301
##
##           Accuracy : 0.8619
##           95% CI : (0.855, 0.8686)
##           No Information Rate : 0.9667
##           P-Value [Acc > NIR] : 1
##
##           Kappa : 0.2627
##
##           Mcnemar's Test P-Value : <2e-16
##
##           Sensitivity : 0.9039
##           Specificity : 0.8605
##           Pos Pred Value : 0.1824
##           Neg Pred Value : 0.9962
##           Prevalence : 0.0333
##           Detection Rate : 0.0301
##           Detection Prevalence : 0.1650
##           Balanced Accuracy : 0.8822
##
##           'Positive' Class : Yes
##
```

5. Bibliografia

- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2013) An Introduction to Statistical Learning with applications in R, <https://www.statlearning.com>, Springer-Verlag, New York
- Siebert P (1987). "Vehicle Recognition Using Rule Based Methods." Turing Institute Research Memorandum TIRM-87-018
- Blake CL, Merz CJ (1998). "UCI Repository of Machine Learning Databases." University of California, Irvine, Department of Information and Computer Science. Formerly available from '<http://www.ics.uci.edu/~mlearn/MLRepository.html>'. -https://rpubs.com/joaquin_ar/229736