

Pontificia Universidad Católica de Chile

EPG4001 Aprendizaje Supervisado

Material complementario

Clase6MIAApSu.pdf

Dr. Jorge Luis Bazán
jlbazan@uc.cl

1. Carga de librerías

Las librerías a utilizar para los procedimientos son las siguientes

```
library(ISLR)
library(MASS)
library(pROC)
library(caret)
library(tree)
library(rpart)
library(rpart.plot)
library(randomForest)
```

2. Ejemplo sección 1.1

Este ejemplo corresponde a un árbol de regresión con dos variables predictoras x_1 y x_2 . La muestra a considerar es la siguiente

```
y <- c(13,3,0,6,5,6,14,6,5,3)
x1 <- c(9,6,1,3,3,1,9,9,4,6)
x2 <- c(6,2,6,9,7,9,8,2,6,4)
```

```
datos <- data.frame(y,x1,x2)
```

```
datos
```

```
##      y x1 x2
## 1  13  9  6
## 2   3  6  2
## 3   0  1  6
## 4   6  3  9
## 5   5  3  7
## 6   6  1  9
## 7  14  9  8
## 8   6  9  2
## 9   5  4  6
## 10  3  6  4
```

Dividimos la muestra considerando los siguientes nodos $x_1 < 4$ y $x_1 \geq 4$

```
nodo1 <- subset(datos, x1 < 4)
nodo2 <- subset(datos, x1 >= 4)
```

```
nodo1
```

```
##      y x1 x2
## 3  0  1  6
## 4  6  3  9
## 5  5  3  7
## 6  6  1  9
```

```
nodo2
```

```
##      y x1 x2
## 1  13  9  6
## 2   3  6  2
## 7  14  9  8
## 8   6  9  2
## 9   5  4  6
## 10  3  6  4
```

Calculamos las medias de cada región:

```
mean(nodo1$y)
```

```
## [1] 4.25
```

```
mean(nodo2$y)
```

```
## [1] 7.333333
```

Por lo tanto,

$$\bar{y}(x_1 < 4) = 4,25 \text{ y } \bar{y}(x_1 \geq 4) = 7,33.$$

Luego, realizamos la siguiente partición de la rama $x_1 \geq 4$ en función de la variable x_2 , la que sería $x_2 < 5$ y $x_2 \geq 5$

```
nodo3 <- subset(datos, x1 >= 4 & x2 < 5)
nodo4 <- subset(datos, x1 >= 4 & x2 >= 5)
```

```
nodo3
```

```
##      y x1 x2
## 2   3  6  2
## 8   6  9  2
## 10  3  6  4
```

```
nodo4
```

```
##      y x1 x2
## 1  13  9  6
## 7  14  9  8
## 9   5  4  6
```

Calculamos las medias:

```
mean(nodo3$y)
```

```
## [1] 4
```

```
mean(nodo4$y)
```


```
## [1] 10.66667
```

Obteniendo

$$\bar{y}(x_1 \geq 4 \text{ y } x_2 < 5) = 4,00 \quad \bar{y}(x_1 \geq 4 \text{ y } x_2 \leq 5) = 10,67.$$

Luego las gráficas asociadas a este problema son las siguientes

```
# =====  
# Gráfico 1: Regiones  
# =====  
  
plot(NULL,  
      xlim=c(0,10),  
      ylim=c(0,10),  
      xlab=expression(x[1]),  
      ylab=expression(x[2]),  
      asp=1)  
  
# Región verde:  $x_1 < 4$   
rect(0,0,4,10,col="green",border="black")  
  
# Región azul:  $x_1 \geq 4$  y  $x_2 < 5$   
rect(4,0,10,5,col="blue",border="black")  
  
# Región roja:  $x_1 \geq 4$  y  $x_2 \geq 5$   
rect(4,5,10,10,col="red",border="black")  
  
abline(v=4,lwd=2)  
abline(h=5,lwd=2)  
  
points(x1,x2,pch=19)  
text(x1,x2,labels=y,pos=3)
```



Las tres regiones corresponden a:

- Verde: $x_1 < 4$
- Azul: $x_1 \geq 4$ y $x_2 < 5$
- Roja: $x_1 \geq 4$ y $x_2 \geq 5$

3. Gráfica funciones de funciones de pérdida sección 1.2.1

El objetivo es visualizar el comportamiento de las distintas funciones de pérdida para los árboles de clasificación. Primero definimos los rangos entre los que se moverá la función

```
# Valores del eje x
p <- seq(0, 1, length = 500)
```

Luego definimos las funciones Misclassification, Gini y Devianza/entropía


```
Misclassification <- 1-pmax(p,1-p)
Gini <- 2*p*(1-p)
Deviance <- (-p*log(p) - (1-p)*log(1-p)) * (0.5/log(2)) #escalada a un máximo en 0.5 para que sea consi.
```

Luego realizamos el gráfico respectivo

```
#Grafica general de Misclassification
plot(p,Misclassification,
     type="l",
     col="red",
     lwd=2,
     ylim=c(0,0.5),
     xlab="p",
     ylab=expression(Q[m]))
```

```
#agregamos funciones gini y devianza
lines(p,Gini,col="green",lwd=2)
lines(p,Deviance,col="blue",lwd=2)

#agregamos la leyenda
legend("bottom",
      legend=c("Misclassification","Gini","Deviance"),
      col=c("red","green","blue"),
      lwd=2)
```



4. Árbol de Clasificación

Utilizaremos la base de datos **PimaIndiansDiabetes** del paquete **mlbench**. Esta base contiene información clínica de 768 pacientes y una variable respuesta binaria a predecir que indica la presencia (**pos**) o ausencia (**neg**) de diabetes. Primero cargamos la base de datos

```
data("PimaIndiansDiabetes")
datos <- PimaIndiansDiabetes
head(datos)
```

```
##   pregnant glucose pressure triceps insulin mass pedigree age diabetes
## 1         6    148      72     35        0 33.6   0.627  50      pos
## 2         1     85     66     29        0 26.6   0.351  31      neg
## 3         8    183     64      0        0 23.3   0.672  32      pos
## 4         1     89     66     23       94 28.1   0.167  21      neg
## 5         0    137     40     35      168 43.1   2.288  33      pos
## 6         5    116     74      0        0 25.6   0.201  30      neg
```

Luego hacemos la separación en 80% entrenamiento y 20% test de la base de datos

Algunos comentarios son los siguiente:

- Es posible observar, que el nodo correspondiente a los individuos que cumplen la condición $\text{glucose} < 104$, tiene la clase **neg** (no diabético) como clase predicha e indica que aproximadamente el 76 % de las observaciones pertenecen a la categoría negativa, mientras que sólo el 24 % corresponde a pacientes diabéticos. Además, este nodo contiene cerca del 77 % de las observaciones de entrenamiento. Por lo tanto, pacientes con niveles relativamente bajos de glucosa presentan una baja probabilidad de padecer diabetes, lo que confirma la relevancia de esta variable para la clasificación.
- Por otro lado, en el nodo $\text{glucose} \geq 144$ y $\text{mass} \geq 30$, La clase predicha es **pos** (diabético). Aproximadamente el 81 % de los individuos pertenecen a la categoría positiva, mientras que sólo el 19 % corresponde a pacientes sin diabetes. Este nodo agrupa cerca del 18 % de las observaciones. Este resultado sugiere que pacientes con niveles elevados de glucosa y un índice de masa corporal alto presentan una alta probabilidad de padecer diabetes, lo que coincide con el conocimiento médico existente sobre los principales factores de riesgo asociados a esta enfermedad. Retar y permiten identificar perfiles de riesgo asociados a la diabetes.

4.2 Predicción sobre el conjunto de prueba

Ahora, realizamos la predicción sobre el conjunto de test y visualizamos las métricas de desempeño respectivas

```
pred_tree <- predict(tree_class,newdata = test,type = "class")

cm_tree <- confusionMatrix(pred_tree,test$diabetes,positive = "pos")
cm_tree
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction neg pos
##      neg  79  20
##      pos  23  32
##
##           Accuracy : 0.7208
##           95% CI : (0.6429, 0.79)
##      No Information Rate : 0.6623
##      P-Value [Acc > NIR] : 0.07215
##
##           Kappa : 0.3845
##
##  Mcnemar's Test P-Value : 0.76037
##
##           Sensitivity : 0.6154
##           Specificity : 0.7745
##           Pos Pred Value : 0.5818
##           Neg Pred Value : 0.7980
##           Prevalence : 0.3377
##           Detection Rate : 0.2078
##      Detection Prevalence : 0.3571
##           Balanced Accuracy : 0.6949
##
##           'Positive' Class : pos
##
```


Agrrupando las métricas de desempeño y calculando el F1-Score, tenemos los siguientes resultados

```
acc_tree <- cm_tree$overall["Accuracy"]

sens_tree <- cm_tree$byClass["Sensitivity"]

spec_tree <- cm_tree$byClass["Specificity"]

prec_tree <- cm_tree$byClass["Pos Pred Value"]

f1_tree <- 2*(prec_tree*sens_tree)/(prec_tree+sens_tree);f1_tree
```

```
## Pos Pred Value
##      0.5981308
```

Métrica	Valor
Accuracy	0.7208
Sensibilidad	0.6154
Especificidad	0.7745
Precisión	0.5818
F1-score	0.5981

- El árbol de clasificación obtuvo una **exactitud (Accuracy) de 0.7208**, lo que indica que aproximadamente el **72.08 %** de las observaciones del conjunto de prueba fueron clasificadas correctamente. Este resultado sugiere un desempeño razonablemente bueno, considerando la complejidad inherente al problema de detección de diabetes.
- La **sensibilidad (Sensitivity) fue de 0.6154**, indicando que el modelo identifica correctamente alrededor del **61.54 %** de los pacientes que realmente presentan diabetes. En otras palabras, existe una proporción no despreciable de pacientes diabéticos que son clasificados erróneamente como no diabéticos.
- Por otra parte, la **especificidad (Specificity) alcanzó un valor de 0.7745**, lo que significa que el modelo clasifica correctamente el **77.45 %** de los pacientes que no presentan diabetes. Este resultado es superior a la sensibilidad, sugiriendo que el árbol tiene una mayor capacidad para identificar pacientes sanos que pacientes diabéticos.
- La **precisión (Precision) fue de 0.5818**, indicando que, entre todos los pacientes clasificados como diabéticos por el modelo, aproximadamente el **58.18 %** efectivamente padecen la enfermedad. Esto evidencia la presencia de falsos positivos en las predicciones.
- Finalmente, el **F1-score fue de 0.5981**, valor que resume el equilibrio entre precisión y sensibilidad. Dado que este indicador es cercano a 0.60, se concluye que el modelo posee una capacidad moderada para detectar pacientes diabéticos, aunque existe margen de mejora en la identificación de casos positivos.

En conjunto, los resultados muestran que el árbol de clasificación presenta un desempeño aceptable y logra una buena capacidad general de

5. Árbol de Regresión

Para ilustrar un problema de regresión se utiliza la variable *glucose* como respuesta.


5.1 Ajuste del árbol

Consideremos la misma separación de entrenamiento y testeo utilizada anteriormente, entonces en este caso el ajuste es el siguiente

```
tree_reg <- rpart(glucose ~ pregnant + pressure + triceps +  
  insulin + mass + pedigree + age, data = train, method = "anova")
```

Luego, la visualización es la siguiente

```
rpart.plot(tree_reg, type = 2, fallen.leaves = TRUE)
```



5.2 Predicción sobre el conjunto de test

Se utiliza el mismo comando que en la sección anterior con la diferencia de que en este caso la respuesta es numérica, por ende las métricas de desempeño a considerar son distintas.

```
pred_reg <- predict(tree_reg, newdata = test)
```

Ahora calculamos las métricas de desempeño

```
RMSE <- sqrt(mean((test$glucose - pred_reg)^2));RMSE
```

```
## [1] 30.23109
```

```
MAE <- mean(abs(test$glucose - pred_reg));MAE
```

```
## [1] 23.46694
```

```
R2 <- cor(test$glucose,pred_reg)^2;R2
```

```
## [1] 0.1793169
```

Métrica	Valor
RMSE	30.23
MAE	23.47
R^2	0.1793

Interpretación de las métricas de regresión

- El árbol de regresión obtuvo un **RMSE de 30.23**, lo que indica que, en promedio, las predicciones difieren de los valores reales de glucosa en aproximadamente 30 unidades. Debido a que esta métrica penaliza con mayor intensidad los errores grandes, el resultado sugiere que existen algunas observaciones para las cuales el árbol presenta errores de predicción considerables.
- Por otra parte, el **Error medio absoluto de 23.47**, lo que significa que el error absoluto promedio de las predicciones es de aproximadamente 23.5 unidades de glucosa. Como el MAE es menos sensible a valores extremos que el RMSE, la diferencia entre ambas métricas sugiere la presencia de algunos errores relativamente grandes en ciertas observaciones.
- El coeficiente de determinación $R^2 = 0,1793$ indica que el modelo explica aproximadamente el **17.93 %** de la variabilidad observada en los niveles de glucosa. Este valor es relativamente bajo, por lo que la capacidad explicativa del árbol resulta limitada.
- En conjunto, los resultados muestran que el árbol de regresión logra capturar parte de la relación entre las variables clínicas y los niveles de glucosa, pero aún existe una proporción importante de variabilidad que no es explicada por el modelo. Esto sugiere que la estructura del árbol es relativamente simple para describir completamente el comportamiento de la variable respuesta o que existen otros factores relevantes no considerados en el análisis.

6. Random Forest


La variable respuesta utilizada corresponde nuevamente a *diabetes*

6.1 Ajuste del modelo

```
rf <- randomForest(diabetes ~ .,data = train,ntree = 500,importance = TRUE)
```

En primer lugar, visualizamos la importancia de las variables

```
varImpPlot(rf)
```



- La medida **Mean Decrease Accuracy** cuantifica cuánto disminuye la exactitud del modelo cuando se altera aleatoriamente una variable. Valores más altos indican que la variable es más importante para la capacidad predictiva del modelo. Por otra parte, **Mean Decrease Gini** mide la contribución de cada variable a la reducción de la impureza de los nodos a lo largo de todos los árboles del bosque.
- Se observa que la variable **glucose** es, por amplio margen, la más importante según ambas medidas. Esto indica que los niveles de glucosa constituyen el principal factor para distinguir entre pacientes diabéticos y no diabéticos. Este resultado es consistente con el conocimiento médico, ya que la glucosa sanguínea es uno de los indicadores más relevantes en el diagnóstico de diabetes.
- La segunda variable más importante es **mass** (índice de masa corporal), lo que sugiere que el sobrepeso y la obesidad tienen una influencia significativa en la presencia de la enfermedad. Posteriormente aparecen variables como **age** y **pedigree**, las cuales también aportan información relevante para la clasificación, aunque en menor medida.
- variables como **pressure** y **triceps** presentan los menores niveles de importancia, indicando que su contribución al desempeño predictivo del modelo es relativamente reducida.

En términos generales, los resultados muestran que el modelo basa principalmente sus decisiones en variables relacionadas con factores metabólicos y antecedentes de riesgo, destacando especialmente la glucosa y el índice de masa corporal como los predictores más influyentes para la detección de diabetes.

6.2 Predicciones sobre el conjunto de test

Realizamos la predicción en el conjunto de test y determinamos la matriz de confusión respectiva.

```
pred_rf <- predict(rf,newdata = test)

cm_rf <- confusionMatrix(pred_rf,test$diabetes,positive = "pos")

cm_rf
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction neg pos
##      neg  90  20
##      pos  12  32
##
##              Accuracy : 0.7922
##              95% CI : (0.7195, 0.8533)
##      No Information Rate : 0.6623
##      P-Value [Acc > NIR] : 0.0002837
##
##              Kappa : 0.5172
##
##  Mcnemar's Test P-Value : 0.2159249
##
##              Sensitivity : 0.6154
##              Specificity : 0.8824
##              Pos Pred Value : 0.7273
##              Neg Pred Value : 0.8182
##              Prevalence : 0.3377
##              Detection Rate : 0.2078
##      Detection Prevalence : 0.2857
##              Balanced Accuracy : 0.7489
##
##              'Positive' Class : pos
##
```

Luego ordenamos los resultados y calculamos el F1-Score

```
acc_rf <- cm_rf$overall["Accuracy"]

sens_rf <- cm_rf$byClass["Sensitivity"]

spec_rf <- cm_rf$byClass["Specificity"]

prec_rf <- cm_rf$byClass["Pos Pred Value"]

f1_rf <- 2*(prec_rf*sens_rf)/(prec_rf+sens_rf)
```

Métrica	Valor
Accuracy	0.7922
Sensibilidad	0.6154
Especificidad	0.8824
Precisión	0.7273
F1-score	0.6667

- El modelo Random Forest obtuvo una **Accuracy de 0.7922**, lo que indica que aproximadamente el **79.22 %** de las observaciones del conjunto de prueba fueron clasificadas correctamente. Este resultado representa una mejora respecto al árbol de clasificación individual, sugiriendo que la combinación de múltiples árboles permite obtener predicciones más robustas y precisas.
- La **sensibilidad fue de 0.6154**, indicando que el modelo identifica correctamente el **61.54 %** de los pacientes que realmente presentan diabetes. Este valor coincide con el obtenido por el árbol de clasificación, por lo que la capacidad para detectar casos positivos no experimenta una mejora significativa.
- Por otra parte, la **especificidad alcanzó un valor de 0.8824**, lo que significa que el modelo clasifica correctamente el **88.24 %** de los pacientes que no presentan diabetes. Este resultado es considerablemente superior al obtenido por el árbol individual, evidenciando una reducción importante de los falsos positivos.
- La **precisión fue de 0.7273**, indicando que aproximadamente el **72.73 %** de los pacientes clasificados como diabéticos efectivamente padecen la enfermedad. Este valor es superior al observado en el árbol de clasificación, lo que refleja una mayor confiabilidad de las predicciones positivas.
- Finalmente, el **F1-score fue de 0.6667**, valor que resume el equilibrio entre precisión y sensibilidad. El incremento respecto al árbol individual indica que Random Forest logra un mejor compromiso entre la detección de pacientes diabéticos y la reducción de errores de clasificación.

En términos generales, los resultados muestran que Random Forest supera al árbol de clasificación en la mayoría de las métricas consideradas. La principal mejora se observa en la especificidad y en la precisión, lo que permite identificar con mayor exactitud a los pacientes sin diabetes y reducir la cantidad de diagnósticos positivos incorrectos.

6.3 Comparación entre árbol y random forest

Los resultados para la predicción de *glucose* en términos de métricas para ambos métodos fueron los siguientes

Métrica	Árbol	Random Forest
Accuracy	0.7208	0.7922
Sensibilidad	0.6154	0.6154
Especificidad	0.7745	0.8824
Precisión	0.5818	0.7273
F1-score	0.5981	0.6667

- Se observa que **Random Forest supera al árbol de clasificación en la mayoría de las métricas evaluadas**. En particular, la exactitud (**Accuracy**) aumenta de 0.7208 a 0.7922, lo que representa una mejora cercana a 7 puntos porcentuales en la proporción de observaciones clasificadas correctamente.
- La **sensibilidad** se mantiene constante en ambos modelos (0.6154), indicando que la capacidad para identificar correctamente a los pacientes con diabetes no experimenta cambios significativos. Esto sugiere que ambos métodos detectan una proporción similar de casos positivos.

- La **especificidad** aumenta considerablemente desde 0.7745 hasta 0.8824. Esto implica que Random Forest logra identificar con mayor precisión a los pacientes que no presentan diabetes, reduciendo la cantidad de falsos positivos respecto al árbol individual.
- La **precisión** mejora de 0.5818 a 0.7273, indicando que las predicciones positivas realizadas por Random Forest son más confiables. En otras palabras, cuando el modelo clasifica a un paciente como diabético, la probabilidad de que dicha clasificación sea correcta es significativamente mayor.
- Finalmente, el **F1-score** aumenta de 0.5981 a 0.6667. Dado que esta métrica combina precisión y sensibilidad, el incremento observado refleja un mejor equilibrio entre la detección de pacientes diabéticos y la reducción de errores de clasificación.

En conjunto, los resultados muestran que Random Forest proporciona un desempeño superior al árbol de clasificación individual. La principal mejora se observa en la reducción de falsos positivos y en el aumento de la confiabilidad de las predicciones, mientras que la capacidad para detectar pacientes diabéticos se mantiene prácticamente constante.

7. Bibliografía

- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2013) An Introduction to Statistical Learning with applications in R, <https://www.statlearning.com>, Springer-Verlag, New York
- Siebert P (1987). "Vehicle Recognition Using Rule Based Methods." Turing Institute Research Memorandum TIRM-87-018
- Blake CL, Merz CJ (1998). "UCI Repository of Machine Learning Databases." University of California, Irvine, Department of Information and Computer Science. Formerly available from 'http://www.ics.uci.edu/~mlearn/MLRepository.html'. -https://rpubs.com/joaquin_ar/229736