

Pontificia Universidad Católica de Chile

EPG4001 Aprendizaje Supervisado

Material Complementario

Clase4MIAApSup.pdf

Jorge Luis Bazán
jlbazan@uc.cl

El presente es un documento complementario al material de la Clase 2 referente a regresión lineal, destinado a exponer la aplicación de los contenidos vistos en el software R.

Al final del documento encontrará algunos ejercicios propuestos para practicar.

1. Librerías

Las librerías a utilizar para los procedimientos son las siguientes

```
library(MASS)
library(car)
```

```
## Loading required package: carData
```

```
## Registered S3 method overwritten by 'car':
##   method           from
##   na.action.merMod lme4
```

```
##
## Attaching package: 'car'
```

```
## The following objects are masked from 'package:faraway':
##
##   logit, vif
```

```
library(nortest)
library(tseries)
```

```
## Registered S3 method overwritten by 'quantmod':
##   method           from
##   as.zoo.data.frame zoo
```

```
library(lmtest)
```

```
## Loading required package: zoo
```

```
##
## Attaching package: 'zoo'
```

```
## The following objects are masked from 'package:base':
##
##   as.Date, as.Date.numeric
```

```
library(caret)
library(faraway)
library(mlbench)
```

2. Ejemplo 1.1: Data inversión/rendimiento

La información obtenida corresponde a una muestra de tamaño 12 sobre la relación existente entre la inversión realizada y el rendimiento obtenido, en cientos de miles de Euros para la explotación agrícola.

Cargando la data:

```
data.inversion <- data.frame(  
  inversion = c(  
    11, 14, 16, 15, 16, 18,  
    20, 21, 14, 20, 19, 11  
  ),  
  
  rendimiento = c(  
    2, 3, 5, 6, 5, 3,  
    7, 10, 6, 10, 5, 6  
  )  
)  
#data.inversion  
head(data.inversion)
```

```
##   inversion rendimiento  
## 1         11           2  
## 2         14           3  
## 3         16           5  
## 4         15           6  
## 5         16           5  
## 6         18           3
```

2.1 Ajuste de modelo

Mediante la función base `lm()` ajustamos la regresión lineal y almacenamos en un objeto `m1`, éste contendrá todos los resultados involucrados en el análisis.

```
m1<-lm(rendimiento~inversion,data=data.inversion)
```

2.2 Resultados

Podemos obtener la tabla ANOVA con las sumas de cuadrados y el test F con `anova()` y el valor de los coeficientes, su significancia y R^2 mediante `summary()`:

```
# Tabla ANOVA  
anova(m1)
```

```
## Analysis of Variance Table  
##  
## Response: rendimiento  
##           Df Sum Sq Mean Sq F value Pr(>F)  
## inversion  1 26.230 26.2300   6.181 0.0322 *  
## Residuals 10 42.437  4.2437  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Resumen coeficientes, SE y significancia:
summary(m1)
```

```
##
## Call:
## lm(formula = rendimiento ~ inversion, data = data.inversion)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.4581 -1.3816 -0.4581  1.5595  2.7076
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -1.6823     3.0152  -0.558  0.5892
## inversion      0.4522     0.1819   2.486  0.0322 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.06 on 10 degrees of freedom
## Multiple R-squared:  0.382, Adjusted R-squared:  0.3202
## F-statistic: 6.181 on 1 and 10 DF,  p-value: 0.0322
```

A partir de la tabla ANOVA vemos que el modelo sugiere explicar de manera significativa la variabilidad del rendimiento (Y), a partir del test F ($F_c(1,10) = 6,181, p = 0,0322$) para un nivel de significancia del $\alpha = 0,05$. Al contemplar este solo la variable inversion (X) lo anterior es equivalente a señalar a que esta variable predice de manera significativa el rendimiento ($\beta_1 = 0,452, p = 0,0322$). En este caso al tratarse de una regresión simple notará que la significancia del coeficiente β_1 y el test F es la misma, esto ocurre solo cuando el modelo presenta una variable explicativa. Por otro lado el modelo explicaría el 32 % de la variabilidad del rendimiento ($R_{ajust} = 0,3202$).

Graficando valores predichos con bandas de confianza:

```
# Grid of values for prediction
newdata <- data.frame(
  inversion = seq(
    min(data.inversion$inversion),
    max(data.inversion$inversion),
    length.out = 200
  )
)
# Confidence intervals
pred90 <- predict(
  m1,
  newdata,
  interval = "confidence",
  level = 0.90
)

pred95 <- predict(
  m1,
  newdata,
  interval = "confidence",
  level = 0.95
)
```

```

)

pred99 <- predict(
  m1,
  newdata,
  interval = "confidence",
  level = 0.99
)

# Plot data
plot(
  rendimiento ~ inversion,
  data = data.inversion,
  pch = 16,
  xlab = "Inversión",
  ylab = "Rendimiento",
  main = "Predicted Values with Confidence Bands"
)

grid()

# 99% confidence band
lines(newdata$inversion, pred99[, "lwr"],
      lty = 2, col = "red")
lines(newdata$inversion, pred99[, "upr"],
      lty = 2, col = "red")

# 95% confidence band
lines(newdata$inversion, pred95[, "lwr"],
      lty = 2, col = "blue")
lines(newdata$inversion, pred95[, "upr"],
      lty = 2, col = "blue")

# 90% confidence band
lines(newdata$inversion, pred90[, "lwr"],
      lty = 2, col = "darkgreen")
lines(newdata$inversion, pred90[, "upr"],
      lty = 2, col = "darkgreen")

# Fitted regression line
lines(
  newdata$inversion,
  pred95[, "fit"],
  lwd = 2,
  col = "black"
)

# Legend
legend(
  "topleft",
  legend = c(
    "Fitted line",
    "90% CI",


```

```

    "95% CI",
    "99% CI"
  ),
  col = c(
    "black",
    "darkgreen",
    "blue",
    "red"
  ),
  lty = c(1, 2, 2, 2),
  lwd = c(2, 1, 1, 1),
)

```

Predicted Values with Confidence Bands



3. Selección de modelos

Cargamos los datos de temperatura global de la base *globalwarm* disponible en la librería *faraway*:

```

data(globwarm)  #disponible de librería faraway
head(globwarm)

```

```


##      nhtemp  wusa  jasper westgreen chesapeake tornetrask urals  mongolia  tasman
## 1000     NA -0.66 -0.03      0.03     -0.66      0.33 -1.49      0.83  -0.12
## 1001     NA -0.63 -0.07      0.09     -0.67      0.21 -1.44      0.96  -0.17
## 1002     NA -0.60 -0.11      0.18     -0.67      0.13 -1.39      0.99  -0.22
## 1003     NA -0.55 -0.14      0.30     -0.68      0.08 -1.34      0.95  -0.26
## 1004     NA -0.51 -0.15      0.41     -0.68      0.06 -1.30      0.87  -0.31
## 1005     NA -0.47 -0.15      0.52     -0.68      0.07 -1.25      0.77  -0.37

```

```
##      year
## 1000 1000
## 1001 1001
## 1002 1002
## 1003 1003
## 1004 1004
## 1005 1005
```

Graficando la serie:

```
# Mantenemos solo observaciones desde el año 1880
globwarm2 <- subset(globwarm, year >= 1880)
plot(
  globwarm2$year,
  globwarm2$nhtemp,
  type = "l",
  lwd = 2,
  xlim=c(1880,2000),
  xlab = "Year",
  ylab = "Temperature",
  main = "Northern Hemisphere Temperature"
)
abline(h=0,col="red")
grid()
```



3.1 Ajuste de modelos

A continuación ajustamos los diferentes modelos que consideran polinomios de distintos grados:

$$M_1 : \quad y = \beta_0 + \beta_1 t + \varepsilon_t$$

```
mod.lin <- lm(
  nhtemp ~ year,
  data = globwarm2
)
```

$$M_2 : \quad y = \beta_0 + \beta_1 t + \beta_2 t^2 + \varepsilon_t$$

```
mod.quad <- lm(
  nhtemp ~ year + I(year^2),
  data = globwarm2
)
```

$$M_3 : \quad y = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3 + \varepsilon_t$$

```
mod.cubic <- lm(
  nhtemp ~ year + I(year^2) + I(year^3),
  data = globwarm2
)
```

Resúmenes del ajuste de los modelos:

```
summary(mod.lin)
```

```
##
## Call:
## lm(formula = nhtemp ~ year, data = globwarm2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.37118 -0.10026  0.01147  0.10836  0.43997
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.057e+01  7.506e-01  -14.09  <2e-16 ***
## year         5.402e-03  3.869e-04   13.96  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1486 on 119 degrees of freedom
## Multiple R-squared:  0.621, Adjusted R-squared:  0.6178
## F-statistic: 195 on 1 and 119 DF, p-value: < 2.2e-16
```

```
summary(mod.quad)
```



```
##
## Call:
## lm(formula = nhtemp ~ year + I(year^2), data = globwarm2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.37373 -0.10383  0.02615  0.09553  0.36789
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.159e+02  4.533e+01   2.557  0.01181 *
## year        -1.250e-01  4.674e-02  -2.675  0.00852 **
## I(year^2)     3.362e-05  1.205e-05   2.791  0.00613 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1446 on 118 degrees of freedom
## Multiple R-squared:  0.6445, Adjusted R-squared:  0.6385
## F-statistic: 107 on 2 and 118 DF, p-value: < 2.2e-16
```

```
summary(mod.cubic)
```

```
##
## Call:
## lm(formula = nhtemp ~ year + I(year^2) + I(year^3), data = globwarm2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.36139 -0.09319  0.02493  0.10404  0.34207
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2.665e+03  2.867e+03  -0.929   0.355
## year         4.177e+00  4.435e+00   0.942   0.348
## I(year^2)    -2.184e-03  2.286e-03  -0.955   0.341
## I(year^3)     3.811e-07  3.929e-07   0.970   0.334
##
## Residual standard error: 0.1446 on 117 degrees of freedom
## Multiple R-squared:  0.6473, Adjusted R-squared:  0.6383
## F-statistic: 71.58 on 3 and 117 DF, p-value: < 2.2e-16
```

Comparando podemos ver que los modelos M_2 y M_3 tienen mayor R^2 , para este último ninguna de las componentes muestra ser significativa ($p > 0,05$) mientras que para el segundo todas resultan serlo ($p < 0,05$) aunque el coeficiente que acompaña la componente cuadrática es casi 0 ($\beta_2 = 0,0000336, p = 0,006$).

Comparando los modelos en términos de predicción gráficamente:

```
plot(
  globwarm2$year,
  globwarm2$nhtemp,
  type = "l",
  lwd = 2,
  xlim = c(1880, 2000),
```

```

    xlab = "Year",
    ylab = "Temperature",
    main = "Northern Hemisphere Temperature"
)

abline(h = 0, col = "red")
grid()

# Add fitted lines
lines(
  globwarm2$year,
  predict(mod.lin),
  col = "blue",
  lwd = 2
)


lines(
  globwarm2$year,
  predict(mod.quad),
  col = "darkgreen",
  lwd = 2
)

lines(
  globwarm2$year,
  predict(mod.cubic),
  col = "purple",
  lwd = 2
)

# Legend
legend(
  "topleft",
  legend = c(
    "Observed",
    "Linear",
    "Quadratic",
    "Cubic"
  ),
  col = c(
    "black",
    "blue",
    "darkgreen",
    "purple"
  ),
  lwd = 2,
)

```

Northern Hemisphere Temperature



3.2 Comparación de modelos

Podemos comparar también los modelos en términos de sumas de cuadrados con la función base `anova()`:

```
anova(mod.lin, mod.quad, mod.cubic)
```

```
## Analysis of Variance Table
##
## Model 1: nhtemp ~ year
## Model 2: nhtemp ~ year + I(year^2)
## Model 3: nhtemp ~ year + I(year^2) + I(year^3)
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      119 2.6292
## 2      118 2.4663   1  0.162830 7.7865 0.006148 **
## 3      117 2.4467   1  0.019676 0.9409 0.334042
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Vemos que hay diferencia significativa entre el primer y segundo modelo ($F = 7,78, p = 0,006$), más no con el tercero ($F = 0,94, p = 0,33$). Comparando ahora en términos de AIC, BIC y R^2 :

```
data.frame(
  Model = c("M1", "M2", "M3"),
  AIC = c(AIC(mod.lin), AIC(mod.quad), AIC(mod.cubic)),
  BIC = c(BIC(mod.lin), BIC(mod.quad), BIC(mod.cubic)),
  Adj_R2 = c(
```

```
summary(mod.lin)$adj.r.squared,
summary(mod.quad)$adj.r.squared,
summary(mod.cubic)$adj.r.squared
)
)
```

```
##      Model      AIC      BIC    Adj_R2
## 1      M1 -113.9400 -105.5527 0.6178326
## 2      M2 -119.6759 -108.4927 0.6384628
## 3      M3 -118.6451 -104.6661 0.6382817
```

Siguiendo el criterio AIC y BIC efectivamente el segundo modelo es el que mejor ajuste presenta al tener los valores más bajos, vemos también que el cambio en términos de explicabilidad (R^2) es importante entre el segundo y el primer modelo pero ya no entre el segundo y primero. Todos los criterios apuntan a que el segundo modelo es el que presenta mejor ajuste.

4. Verificación supuestos

Para esto utilizaremos la base de datos *PimaIndiansDiabetes* (librería *mlbench*) que consiste en información referente a mujeres de ascendencia India que viven en EE.UU (revisar material complementario 1).

Cargando los datos:

```
data("PimaIndiansDiabetes")
datos.pima<-PimaIndiansDiabetes
head(datos.pima)
```

```
##      pregnant glucose pressure triceps insulin mass pedigree age diabetes
## 1           6      148       72      35         0 33.6    0.627  50      pos
## 2           1       85       66      29         0 26.6    0.351  31      neg
## 3           8      183       64       0         0 23.3    0.672  32      pos
## 4           1       89       66      23        94 28.1    0.167  21      neg
## 5           0      137       40      35       168 43.1    2.288  33      pos
## 6           5      116       74       0         0 25.6    0.201  30      neg
```

Realizaremos un análisis de regresión para explorar si la edad (x_1), IMC (x_2) y el grosor del pliegue cutáneo del tríceps (x_3) aexplican o no la concentración de glucosa en plasma (y). Así, el modelo es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon, \quad \text{con } \varepsilon \sim N(0, \sigma^2)$$

Ajustando el modelo y explorando sus resultados:

```
m4<-lm(glucose~age+mass+triceps,data=datos.pima)
summary(m4)
```

```
##
## Call:
## lm(formula = glucose ~ age + mass + triceps, data = datos.pima)
##
```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -132.441  -19.076   -1.995   18.303   83.776
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 70.290238   5.405596  13.003  < 2e-16 ***
## age          0.696954   0.093545   7.450 2.52e-13 ***
## mass         0.852423   0.150726   5.655 2.20e-08 ***
## triceps      0.008069   0.074933   0.108  0.914
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30.15 on 764 degrees of freedom
## Multiple R-squared:  0.1143, Adjusted R-squared:  0.1108
## F-statistic: 32.85 on 3 and 764 DF,  p-value: < 2.2e-16
```

En principio podemos ver que la edad y el IMC resultan significativas para explicar el nivel de glucosa, chequeemos los supuestos del modelo para así verificar si esta inferencia es confiable o no:

4.1 VIF

Chequeando si hay o no problemas de multicolinealidad podemos obtener el VIF para cada variable mediante el comando `vif()` disponible en el paquete *car*:

```
vif(m4)
```

```
##      age      mass  triceps
## 1.021182 1.191552 1.205647
```

Dado que todos los valores son inferiores a 10 no habría problemas de colinealidad.

4.2 Chequeando homocedasticidad

Gráficamente se puede chequear con un gráfico entre los residuos y los valores ajustados:

```
m4<-lm(glucose~age+mass+triceps,data=datos.pima)
summary(m4)
```


```
##
## Call:
## lm(formula = glucose ~ age + mass + triceps, data = datos.pima)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -132.441  -19.076   -1.995   18.303   83.776
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 70.290238   5.405596  13.003  < 2e-16 ***
## age          0.696954   0.093545   7.450 2.52e-13 ***
```

```
## mass      0.852423  0.150726  5.655 2.20e-08 ***
## triceps   0.008069  0.074933  0.108  0.914
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30.15 on 764 degrees of freedom
## Multiple R-squared:  0.1143, Adjusted R-squared:  0.1108
## F-statistic: 32.85 on 3 and 764 DF,  p-value: < 2.2e-16
```

```
# Residuals vs fitted values plot
plot(
  fitted(m4),
  residuals(m4),
  pch = 16,
  xlab = "Fitted values",
  ylab = "Residuals",
  main = "Residuals vs Fitted Values"
)
# Reference line
abline(h = 0, col = "red", lwd = 2)

# Optional smooth trend
lines(
  lowess(fitted(m4), residuals(m4)),
  col = "blue",
  lwd = 2
)
grid()
```

Residuals vs Fitted Values



En general gráficamente no se observa un comportamiento sistemático de los residuos para la mayor

cantidad de puntos, si no más bien una nube aleatoria de puntos, lo cual es señal de que hay homocedasticidad. Sin embargo, para valores ajustados menores (cerca de $\hat{y}_i \approx 90$) se puede observar un pequeño grupo de puntos que presentan menor dispersión.

Podemos seguir explorando este supuesto con el test Breusch-Pagan mediante la función `bptest()` disponible en *lmtest*:

```
library(lmtest)
bptest(m4)

##
## studentized Breusch-Pagan test
##
## data: m4
## BP = 14.873, df = 3, p-value = 0.001928
```

Podemos ver según este test que se rechaza la hipótesis de homocedasticidad por lo que este supuesto no se estaría cumpliendo. En estos casos lo que falla es la estimación de los errores estándar de los estimadores $SE[\hat{\beta}_j]$ y por ende la inferencia asociada a ellos con los resultados obtenidos puede no ser cierta. En estos casos, tanto de homocedasticidad como de presencia de autocorrelación en los errores se pueden recalcular correctamente los errores estándar mediante las matrices de White o Newey-West.

4.3 Autocorrelación

La autocorrelación de orden 1 ($\text{lag}=1$) la podemos chequear mediante el test de Durbin-Watson, función también disponible en *lmtest*

```
library(lmtest)
dwtest(m4)

##
## Durbin-Watson test
##
## data: m4
## DW = 1.8367, p-value = 0.01167
## alternative hypothesis: true autocorrelation is greater than 0
```

Este test entonces también rechaza la hipótesis nula de no autocorrelación, con un 95% de confianza.

4.4 Normalidad de los errores

Para chequear la normalidad de los errores revisaremos varios tests:

4.4.1 Shapiro-Wilk

```
res <- residuals(m4)
shapiro.test(res)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data:  res  
## W = 0.97901, p-value = 4.764e-09
```

4.4.2 Kolmogorov-Smirnov

```
ks.test(  
  scale(res),  
  "pnorm"  
)
```

```
##  
## Asymptotic one-sample Kolmogorov-Smirnov test  
##  
## data:  scale(res)  
## D = 0.066259, p-value = 0.002357  
## alternative hypothesis: two-sided
```

4.4.3 Jarque-Bera

```
jarque.bera.test(res)
```

```
##  
## Jarque Bera Test  
##  
## data:  res  
## X-squared = 39.03, df = 2, p-value = 3.348e-09
```

4.4.4 Lilliefords

```
lillie.test(res)
```


```
##  
## Lilliefors (Kolmogorov-Smirnov) normality test  
##  
## data:  res  
## D = 0.066259, p-value = 1.727e-08
```

Para todos los tests se rechaza H_0 que supone normalidad de los errores, con un 95 % de confianza, así, no podemos asumir que este supuesto de normalidad se esté cumpliendo.

Podemos explorar esto gráficamente mediante un gráfico qqnorm que compara los cuantiles teóricos de la distribución normal versus los observados:

4.4.5 QQnorm plot

```
qqnorm(  
  residuals(m4),  
  pch = 16,  
  main = "Normal Q-Q Plot of Residuals"  
)  
  
qqline(  
  residuals(m4),  
  col = "red",  
  lwd = 2  
)  
grid()
```



Vemos efectivamente que para los cuantiles extremos hay un alejamiento de la normalidad, siendo esto más fuerte para los residuos más negativos.

5. Ejercicio propuesto

En una universidad se desea explorar si las variables género, años en la institución y tiempo desde el cual se obtuvo el último grado explican o no el salario de los docentes que trabajan en ella, para esto se dispone de la siguiente muestra:

```
datos.ej <- data.frame(  
  Salario = c(  
    36.35, 35.35, 28.2, 26.775, 33.696, 28.516, 24.9, 31.909,  
    31.85, 32.85, 27.025, 24.75, 28.2, 23.712, 25.748, 29.342,  
    31.114, 24.742, 22.906, 24.45, 19.175, 20.525, 27.959,  
    38.045, 24.832, 25.4, 24.8, 25.5, 26.182, 23.725, 21.6,  
    23.3, 23.713, 20.69, 22.45, 20.85, 18.304, 17.095, 16.7,  
    17.6, 18.075, 18, 20.999, 17.25, 16.5, 16.094, 16.15,  
    15.35, 16.244, 16.686, 15, 20.3  
  ),  
  
  Genero = c(  
    0,0,0,1,0,0,1,0,  
    0,0,0,0,0,0,0,0,  
    0,0,0,0,0,0,0,1,  
    0,0,0,1,0,0,1,0,  
    0,1,1,0,1,0,0,0,  
    0,0,0,1,0,0,1,1,  
    0,1,1,1  
  ),  
  
  Años = c(  
    25,13,10,7,19,16,0,16,  
    13,13,12,15,9,9,9,7,  
    13,11,10,6,16,8,7,8,  
    9,5,11,5,3,3,10,11,  
    9,4,6,1,8,4,4,4,  
    3,3,0,3,2,2,2,2,  
    1,1,1,0  
  ),  
  
  Tiempo = c(  
    35,22,23,27,30,21,32,18,  
    30,31,22,19,17,27,24,15,  
    20,14,15,21,23,31,13,24,  
    12,18,14,16,7,17,15,31,  
    14,33,29,9,14,4,5,4,  
    4,11,7,3,3,1,6,2,  
    1,1,1,2  
  )  
)  
head(datos.ej)
```

```
##   Salario Genero Años Tiempo  
## 1  36.350      0   25     35  
## 2  35.350      0   13     22  
## 3  28.200      0   10     23
```

## 4	26.775	1	7	27
## 5	33.696	0	19	30
## 6	28.516	0	16	21

Realice un completo análisis de regresión que responda las inquietudes del estudio, considere:

1. Plantear variables, modelo teórico y sus supuestos
2. Ajustar el modelo a los datos
3. Chequee si se verifican o no los supuestos relacionados
4. Responda a las inquietudes de la investigación en términos de las variables, ¿Cuál es la interpretación de los coeficientes estimados?
5. Muestre gráficamente para la variable años en la institución las predicciones realizadas por el modelo
6. Explore gráficamente los supuestos de homocedasticidad y normalidad de los errores

6. Bibliografía

- Julian J. Faraway (2016). *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*, Boca Raton: Chapman Hall/CRC.
- Krzanowski, W. (1998). *An Introduction to Statistical Modelling*. Arnold, New York.