



Pontificia Universidad Católica de Chile
Facultad de Matemáticas
EPG4001 - Aprendizaje Supervisado
Profesor: Jorge Luis Bazán
Fecha de entrega: 15/06/2026 a las 23:59 horas (vía canvas)
Instrucciones: Trabajo individual o en grupos de 2 personas.

EPG4001 - Aprendizaje Supervisado

Laboratorio 1

Objetivo: Aplicar e interpretar los métodos estudiados en las primeras tres clases del curso: k-NN, regresión lineal y regresión logística, utilizando R.

Formato de Entrega: El desarrollo del laboratorio puede ser en pares (grupos de a 2) y debe ser entregado mediante un script `.R` subido a canvas y enviado a los correos `fgomezs@estudiante.uc.cl` e `ibetan-court@estudiante.uc.cl` con fecha límite **lunes 15 de junio 23:59 hrs.** Parte de la evaluación consistirá en que el script ejecute sin errores. Las respuestas a cada pregunta deben incluirse como comentarios usando `#`.

Pregunta 1: (20 puntos, 5 c/u) Utilice el conjunto de datos `Smarket` disponible en la librería ISLR. Considere $Y = \text{Today}$ como variable de respuesta; todas las demás serán variables explicativas.

- Realizar un análisis descriptivo de las variables de la base de datos. Debe incluir indicadores y gráficas.
- Utilizando alguno de los criterios de selección de variables, determine el modelo lineal que mejor se ajusta a la variable respuesta. Indique el criterio utilizado y especifique los resultados e indicadores del modelo final.
- Considere ahora la variable $Y = \text{direction}$ como respuesta y las variables $\text{Lag}_1, \dots, \text{Lag}_5$ como predictores. Ajuste un modelo de regresión logística y determine el modelo que mejor ajusta a la variable respuesta. Indique el criterio utilizado.
- Calcule e interprete los odds ratio asociados al modelo resultante en el inciso anterior.

Problema 2: (20 puntos, 5 c/u) Respecto al conjunto de datos `Boston` disponible en la librería MASS conteste (considere $\alpha = 0.05$):

- Ajuste un modelo de regresión lineal múltiple para predecir el valor mediano de las viviendas (`medv`), considere todas las covariables disponibles. Presente la tabla ANOVA del modelo e interprete el estadístico F global. ¿Existen covariables significativas?
- Aplique un procedimiento de selección de variables `stepwise` con criterio AIC (función `step()`). Presente el modelo final seleccionado e interprete el coeficiente asociado a al menos dos variables, indicando el efecto marginal sobre `medv`.
- Verifique los supuestos de multicolinealidad y homocedasticidad del modelo seleccionado en b)
- Identifique observaciones influyentes usando `car::influencePlot()` y la distancia de Cook, señale cuáles observaciones resultan más problemáticas.

Problema 3: (20 puntos, 5 c/u) Utilice el conjunto de datos `PimaIndiansDiabetes` disponible en la librería `mlbench`. Considere como variable respuesta a `diabetes` (pos/neg), la cual indica si un paciente presenta diabetes o no.

- a) Ajuste un modelo de regresión logística con todas las variables. Presente la tabla de coeficientes e interprete el efecto de `glucose` y `mass` en términos de *odds* y *log-odds*. ¿Son ambas significativas?
- b) Evalúe la bondad de ajuste del modelo comparando la devianza nula y la residual. Calcule el porcentaje de devianza explicada por el modelo. ¿Considera que el modelo tiene un buen ajuste?
- c) Calcule la curva ROC utilizando el paquete `pROC` y reporte el AUC. Determine el punto de corte óptimo usando el índice de Youden (sensibilidad + especificidad -1). ¿Qué implica este punto de corte en el contexto de detección de diabetes?
- d) Con el punto de corte óptimo obtenido en c), construya la matriz de confusión. Reporte e interprete la sensibilidad, especificidad y *accuracy* del clasificador. ¿Preferiría maximizar la sensibilidad o la especificidad en este problema? Justifique.

– Santiago, 8 de junio 2026 –