



Introducción a Ciencia de Datos

¿Qué es la Ciencia de Datos?


Data Age: La Digitización del Mundo



The data-driven world will be **always on**,
always tracking, **always monitoring**, **always listening** and
always watching – **because it will be always learning.**






Data Age: La Digitización del Mundo



“Datósfera Global”: una medida de toda la nueva data que es capturada, creada y replicada en un cierto año en el planeta.

¿Dónde se generan y almacenan estos datos?



Actividad de discusión (10’):


❖ Instrucciones:

- Al iniciar la actividad, será dirigido a una Sesión de Grupos de Zoom con 2 de sus compañeros.
- Entre los 3, deben elegir una de sus industrias o área de trabajo, donde se generen constantemente datos, y estimar el volumen producido anualmente. Es decir, deben dimensionar su propia “Datósfera” profesional.
- Asuma o investigue (y explique) los supuestos que sean necesarios para hacer su estimación.

Actividad de discusión:

- ❖ ¿Cuál es el tamaño de su datósfera?
- ❖ ¿Aproximadamente qué volúmenes de datos se generan anualmente en su área de trabajo o investigación, y de dónde provienen?

Ej: Astronomía



Big Universe, Big Data: Machine Learning
and Image Analysis for Astronomy

Jan Kremer, Kristoffer Stensbo-Smidt, Fabian Gieseke, Kim
Steenstrup Pedersen, and Christian Igel

Department of Computer Science, University of Copenhagen,
Universitetsparken 5, 2100 Copenhagen Ø, Denmark

¿Qué es la Ciencia de Datos?

- ❖ Hay una falta de uniformidad o acuerdo universal respecto a la terminología básica:
 - “Big Data”
 - “Ciencia de Datos”
 - ¿Cómo se relacionan?
- ❖ ¿Es realmente distinto a la estadística o analítica, o sólo un nuevo nombre?
- ❖ ¿Es una nueva disciplina?

¿Qué es la Ciencia de Datos?

- ❖ Hay una falta de uniformidad o acuerdo universal respecto a la terminología básica:
 - “Big Data”
 - “Ciencia de Datos”
 - ¿Cómo se relacionan?
- ❖ ¿Es realmente distinto a la estadística o analítica, o sólo un nuevo nombre?
- ❖ ¿Es una nueva disciplina?

Big Data: definiciones sencillas


- ❖ Algunas propiedades fundamentales (VVV):
 - Gran volumen
 - Gran velocidad (ej: tiempo real)
 - Gran variedad: estructurada y no estructurada
 - Veracidad, valor....

- ❖ Es una definición relativa: “**es Big Data cuando no puede ser contenida en una sola unidad de cómputo**” (David Cranshaw, Google)

- ❖ ¿Es Ciencia de Datos lo mismo que trabajar con “Big Data”?

Ciencia de Datos: definiciones sencillas


- ❖ *“Es la ciencia de extraer información significativa de los datos”*
- ❖ Es el proceso de formular una pregunta cuantitativa, que puede ser respondida con datos,
 - Recolectando y limpiando los datos
 - Analizando los datos, y
 - Comunicando la respuesta a la pregunta a una audiencia relevante.



Ciencia y Ciencia de Datos

❖ ¿Qué entendemos por **ciencia**?

- ❖ Estudio sistemático de la estructura y comportamiento del mundo físico y natural, mediante la observación y experimentación.
- ❖ Foco: relaciones de **causalidad** → ¿Por qué?
- ❖ En la medida que abordamos problemas cada vez más complejos, la ciencia requiere un enfoque interdisciplinario para identificar las hipótesis, análisis y relaciones de causalidad correctas.



Ciencia de Datos: definiciones sencillas

“The combination of some data and an aching desire for an answer does not ensure that a reasonable answer can be extracted from a given body of data”

-John Tuke

Una intensa polémica causó el **informe Big Data**, que **reúne una serie de antecedentes del comportamiento en las redes sociales** a partir del estallido social.

El documento de 112 páginas generó diversas opiniones al **apuntar a diferentes figuras públicas como “influenciadores” de las manifestaciones**, entre las que se encuentran Mon Laferte, Ismael Serrano, Claudio Bravo, Gary Medel, las diputadas Vallejo y Cariola, además del K-Pop.

Tras las diversas críticas que ha recibido el escrito, **el Gobierno desmintió estar detrás de su autoría**. Según ***El Mercurio***, fue el **Ministerio de Defensa el primero que habría recibido el documento** para posteriormente traspasarlo a la Agencia Nacional de Inteligencia (ANI).

The screenshot shows the Science journal website. The header features the "Science" logo and navigation links: Home, News, Journals, Topics, Careers. Below this is a search bar and a list of journal categories: Science, Science Advances, Science Immunology, Science Robotics, Science Signaling, and Science Translational Medicine. The main content area displays a research article titled "Combining satellite imagery and machine learning to predict poverty" by Neal Jean, Marshall Burke, Michael Xie, W. Matthew Davis, David B. Lobell, and Stefano Ermon. The article is dated 19 Aug 2016 and is part of Volume 353, Issue 6301. The page also includes a "SHARE" section with social media icons, a "RESEARCH ARTICLE" label, and a "PRE" (Peer Reviewed) badge. On the right side, there is a sidebar with a "Science" logo, a "Table of Contents" link, and a list of "ARTICLE TOOLS" including Email, Print, Alerts, Citation tools, Download Powerpoint, Save to my folders, Request Permissions, and Share.

¿Qué es la Ciencia de Datos?

- ❖ Hay una falta de uniformidad o acuerdo universal respecto a la terminología básica:
 - “Big Data”
 - “Ciencia de Datos”
 - ¿Cómo se relacionan?
- ❖ ¿Es realmente distinto a la estadística o analítica, o sólo un nuevo nombre?
- ❖ ¿Es una nueva disciplina?

¿Qué es la Ciencia de Datos?

- ❖ Hay una falta de uniformidad o acuerdo universal respecto a la terminología básica:
 - “Big Data”
 - “Ciencia de Datos”
 - ¿Cómo se relacionan?
- ❖ ¿Es realmente distinto a la estadística o analítica, o sólo un nuevo nombre?
- ❖ ¿Es una disciplina propia?

Ciencia de Datos vs. Estadística



Journal of Computational and Graphical Statistics



ISSN: 1061-8600 (Print) 1537-2715 (Online) Journal homepage: <https://www.tandfonline.com/loi/ucgs20>

50 Years of Data Science

David Donoho

To cite this article: David Donoho (2017) 50 Years of Data Science, Journal of Computational and Graphical Statistics, 26:4, 745-766, DOI: [10.1080/10618600.2017.1384734](https://doi.org/10.1080/10618600.2017.1384734)

To link to this article: <https://doi.org/10.1080/10618600.2017.1384734>

- ❖ ¿Hay preguntas propias de la Ciencia de Datos que no requieren del contexto de ninguna otra disciplina?
- ❖ ¿Hay problemas profundos propios de la Ciencia de Datos?

- *Aren't we Data Science?*

Column of ASA President Marie Davidian in AmStat News, July 2013⁷

- *A grand debate: is data science just a “rebranding” of statistics?*

Martin Goodson, co-organizer of the Royal Statistical Society meeting May 19, 2015, on the relation of statistics and data science, in internet postings promoting that event.

- *Let us own Data Science.*

IMS Presidential address of Bin Yu, reprinted in IMS bulletin October 2014⁸

One does not need to look far to find blogs capitalizing on the befuddlement about this new state of affairs:

- *Why Do We Need Data Science When We've Had Statistics for Centuries?*

Irving Wladawsky-Berger

Wall Street Journal, CIO report, May 2, 2014

- *Data Science is statistics.*

When physicists do mathematics, they don't say they're doing number science. They're doing math. If you're analyzing data, you're doing statistics. You can call it data science or informatics or analytics or whatever, but it's still statistics. ...You may not like what some statisticians do. You may feel they don't share your values. They may embarrass you. But that shouldn't lead us to abandon the term “statistics.”

Karl Broman, Univ. Wisconsin⁹

¿Ciencia de Datos Geográfica?

¿Qué son los datos geoespaciales?

Son conjuntos de **datos** en los cuales cada registro tiene asociada una **ubicación** específica sobre la Tierra.

- Podemos aplicar muchas de las operaciones y análisis que usaríamos con datos no espaciales.
- Cada observación se puede poner en un mapa
- Podemos identificar **relaciones espaciales** y **relaciones causa/efecto** que pasarían desapercibidas en otro tipo de análisis.

¿Ciencia de Datos Geográfica?

Special Issue


Geographic Data Science

Alex Singleton , Daniel Arribas-Bel 

Department of Geography and Planning, University of Liverpool, Liverpool, L69 7ZT, U.K.

It is widely acknowledged that the emergence of “Big Data” is having a profound and often controversial impact on the production of knowledge. In this context, Data Science has developed as an interdisciplinary approach that turns such “Big Data” into information. This article argues for the positive role that Geography can have on Data Science when being applied to spatially explicit problems; and inversely, makes the case that there is much that Geography and Geographical Analysis could learn from Data Science. We propose a deeper integration through an ambitious research agenda, including systems engineering, new methodological development, and work toward addressing some acute challenges around epistemology. We argue that such issues must be resolved in order to realize a Geographic Data Science, and that such goal would be a desirable one.

Relaciones Espaciales




John Snow, 1854

Epidemia de cólera
en Londres

¿Cómo se transmite
el cólera?

Relaciones Espaciales



John Snow, 1854

Epidemia de cólera
en Londres Soho

¿Cómo se transmite
el cólera?

El proceso de Ciencia de Datos




Figure 2-2. The data science process

¿Qué es un Cientista de Datos?





Figure 1-1. Drew Conway's Venn diagram of data science




- Se requiere una combinación de competencias o conocimientos
 - Estadística y modelación matemática
 - Computación / programación
 - Visualización y comunicación
 - Conocimiento específico del campo de estudio.

¿Qué es un Cientista de Datos?



¿Qué es un Cientista de Datos?

- Una sola persona no puede ser un científico de datos “perfecto”, necesitamos **EQUIPOS**:



Hay distintos tipos de Cientista de Datos...

Type A Data Scientist: The A is for Analysis. This type is primarily concerned with making sense of data or working with it in a fairly static way. The Type A Data Scientist is very similar to a statistician (and may be one) but knows all the practical details of working with data that aren't taught in the statistics curriculum: data cleaning, methods for dealing with very large data sets, visualization, deep knowledge of a particular domain, writing well about data, and so on.

¿Academia?

Type B Data Scientist: The B is for Building. Type B Data Scientists share some statistical background with Type A, but they are also very strong coders and may be trained software engineers. The Type B Data Scientist is mainly interested in using data "in production." They build models which interact with users, often serving recommendations (products, people you may know, ads, movies, search results).

¿Industria?

¿Con qué perfil de cientista de datos se identifican?

¿Cuáles son los Desafíos de la Ciencia de Datos?

Harvard Data Science Review • Issue 2.3, Summer 2020

Ten Research Challenge Areas in Data Science

Jeannette M. Wing

Published on: Sep 30, 2020

DOI: 10.1162/99608f92.c6577b1f

Desafíos de la Ciencia de Datos


Comprender científicamente las formas de aprendizaje de máquina (especialmente, aprendizaje profundo).

- ¿Cuáles son las propiedades matemáticas de los algoritmos de aprendizaje profundo?
- ¿Qué tan robustos o frágiles son los modelos ante perturbaciones en las distribuciones de datos de entrada?
- ¿Cómo caracterizamos la incerteza de los resultados de un modelo?
- ¿Hasta cuándo es útil o beneficioso tener *más* data?

Desafíos de la Ciencia de Datos

Razonamiento causal e interpretación de modelos.

- El uso de métodos de ciencia de datos y aprendizaje de máquinas en distintos campos permite encontrar correlaciones antes ocultas en los datos.
- ¿Cómo encontramos una explicación causal a estas correlaciones?
 - ➔ Modelos híbridos: Scientific Machine Learning
 - ➔ Machine Learning para parametrizar modelos físicos o modelar residuos de modelos físicos



Desafíos de la Ciencia de Datos

Razonamiento causal e interpretación de modelos.

Integrating Physics-Based Modeling With Machine Learning: A Survey

JARED WILLARD* and XIAOWEI JIA*, University of Minnesota
SHAOMING XU, University of Minnesota
MICHAEL STEINBACH, University of Minnesota
VIPIN KUMAR, University of Minnesota




Fig. 4. Diagram of a hybrid physics-ML model. (Figure adapted from Karpatne et al. [128]). f_{PHY} represents the physics-based model which converts the input drivers D to simulated outputs Y_{PHY} , f_{HPD} represents the hybrid physics-ML model that combines D and Y_{PHY} as input to make final predictions.

➔ Modelos híbridos: Scientific Machine Learning




Fig. 3 | Linkages between physical models and machine learning. An abstraction of a part of a physical system—for example, an Earth system model—is depicted here. The model consists of submodels; each submodel has parameters and forcing variables as inputs and produces output, which can be input (forcing) to another sub-model. Data-driven learning approaches can be helpful in various instances, as indicated by the circled numbers. For example, the circle labelled 2 represents hybrid modelling. See the text for more detail. ML, machine learning.





Fig. 3. Machine Learning model f_{ML} trained to model the error made by Physics model f_{PHY} . Figure adapted from [82]

➔ Machine Learning para parametrizar modelos físicos o modelar residuos de modelos físicos


Desafíos de la Ciencia de Datos

Datos "preciosos", ruidosos o incompletos.

- Hay problemas muy relevantes que pueden ser abordados a partir de los datos, pero éstos pueden ser:
 - Muy caros de recolectar




LHC




Desafíos de la Ciencia de Datos

Datos "preciosos", ruidosos o incompletos.

- Hay problemas muy relevantes que pueden ser abordados a partir de los datos, pero éstos pueden ser:
 - Correspondientes a eventos raros o débiles (baja señal-ruido).



Global Reporting Geophysical Observatories in Chile | IRIS



Seismic Network and Routine Data Processing - Japan

Desafíos de la Ciencia de Datos

Múltiples y diversas fuentes de datos.

PERSPECTIVE

<https://doi.org/10.1038/s41586-019-0912-1>

Deep learning and process understanding for data-driven Earth system science

Markus Reichstein^{1,2*}, Gustau Camps-Valls³, Bjorn Stevens⁴, Martin Jung¹, Joachim Denzler^{2,5}, Nuno Carvalhais^{1,6} & Prabhat⁷




Fig. 1 | Big data challenges in the geoscientific context. Data size now exceeds 100 petabytes, and is growing quasi-exponentially (tapering of the figure to the right indicates decreasing data size.) The speed of change exceeds 5 petabytes a year; data are taken at frequencies of up to 10 Hz or more; reprocessing and versioning are common challenges. Data sources can be one- to four-dimensional, spatially integrated, from the organ level (such as leaves) to the global level. Earth has diverse observational systems, from remote sensing to in situ observation. The uncertainty of data can stem from observational errors or conceptual inconsistencies.

Desafíos de la Ciencia de Datos

Privacidad.

“La data anónima, no lo es”

Name	Age	Gender	Zip Code	Smoker	Diagnosis
Richard	64	Male	19146	Y	Heart disease
Susan	61	Female	19118	N	Arthritis
Matthew	67	Male	19104	Y	Lung cancer
Alice	63	Female	19146	N	Crohn's disease
Thomas	69	Male	19115	Y	Lung cancer
Rebecca	56	Female	19103	N	HIV
Tony	52	Male	19146	Y	Lyme disease
Mohammed	59	Male	19130	Y	Seasonal allergies
Lisa	55	Female	19146	N	Ulcerative colitis

Name	Age	Gender	Zip Code	Smoker	Diagnosis
*	60-70	Male	191**	Y	Heart disease
*	60-70	Female	191**	N	Arthritis
*	60-70	Male	191**	Y	Lung cancer
*	60-70	Female	191**	N	Crohn's disease
*	60-70	Male	191**	Y	Lung cancer
*	50-60	Female	191**	N	HIV
*	50-60	Male	191**	Y	Lyme disease
*	50-60	Male	191**	Y	Seasonal allergies
*	50-60	Female	191**	N	Ulcerative colitis

MICHAEL KEARNS
AND
AARON ROTH

THE ETHICAL ALGORITHM

The Science of Socially Aware Algorithm Design

Name	Age	Gender	Zip Code	Diagnosis
*	50-60	Female	191**	HIV
*	50-60	Female	191**	Lupus
*	50-60	Female	191**	Hip fracture
*	60-70	Male	191**	Pancreatic cancer
*	60-70	Male	191**	Ulcerative colitis
*	60-70	Male	191**	Flu-like symptoms

Desafíos de la Ciencia de Datos

Ética.


- ❖ Desarrollo de modelos: ¿la data de entrenamiento es unbiased?
¿Usamos predictores éticamente aceptables?
- ❖ Transparencia e interpretabilidad de modelos.
- ❖ Proceso de gobernanza para supervisar el proceso de data science y abordar áreas grises
 - ➔ Requiere expertise múltiples disciplinas

Saving Face: Investigating the Ethical Concerns of Facial Recognition Auditing

3 Jan 2020 • Inioluwa Deborah Raji • Timnit Gebru • Margaret Mitchell • Joy Buolamwini • Joonseok Lee • Emily Denton

[Edit social preview](#)

Although essential to revealing biased performance, well intentioned attempts at algorithmic auditing can have effects that may harm the very populations these measures are meant to protect. This concern is even more salient while auditing biometric systems such as facial recognition, where the data is sensitive and the technology is often used in ethically questionable manners. We demonstrate a set of five ethical concerns in the particular case of auditing commercial facial processing technology, highlighting additional design considerations and ethical tensions the auditor needs to be aware of so as not exacerbate or complement the harms propagated by the audited system. We go further to provide tangible illustrations of these concerns, and conclude by reflecting on what these concerns mean for the role of the algorithmic audit and the fundamental product limitations they reveal. [\(show less\)](#)



Herramientas Básicas para Ciencia de Datos

Reproducibilidad Científica

- ❖ Capacidad de reproducir procedimientos científicos (experimentos, análisis, resultados).
- ❖ Clave para el desarrollo, colaboración y transparencia científica y profesional.

The science 'reproducibility crisis' – and what can be done about it

March 15, 2017 5:48am EDT



Science and integrity is under the microscope. Shutterstock

Email
Twitter 75
Facebook 90
LinkedIn
Print

Reproducibility is the idea that an experiment can be repeated by another scientist and they will get the same result. It is important to show that the claims of any experiment are true and for them to be useful for any further research.

However, science appears to have an issue with reproducibility. A survey by Nature revealed that 52% of researchers believed there was a "significant reproducibility crisis" and 38% said there was a "slight crisis".

We asked three experts how they think the situation could be improved.

Open Research is the answer

Danny Kingsley, head of the Office of Scholarly Communication, University of Cambridge

The solution to the scientific reproducibility crisis is to move towards Open Research – the idea that scientific knowledge of all kinds should be openly shared as early as it is practical in the discovery process. We need to reward the publication of research outputs along the entire process, rather than just each journal article as it is published.



Story by James Somers

Like *The Atlantic*? Subscribe to [The Atlantic Daily](#), our free weekday email newsletter.

Enter your email

Sign up

THE SCIENTIFIC paper—the actual form of it—was one of the enabling inventions of modernity. Before it was developed in the 1600s, results were communicated privately in letters, ephemerally in lectures, or all at once in books. There was no public forum for *incremental* advances. By making room for reports of single experiments or minor technical advances, journals made the chaos of science accretive. Scientists from that point forward became like the social insects: They made their progress steadily, as a buzzing mass.

The earliest papers were in some ways more readable than papers are today. They were less specialized, more direct, shorter, and far less formal. Calculus had only just been invented. Entire data sets could fit in a table on a single page. What little “computation” contributed to the results was done by hand and could be verified in the same way.

The more sophisticated science becomes, the harder it is to communicate results. Papers today are longer than ever and full of jargon and symbols. They depend on chains of computer programs that generate data, and clean up data, and plot data, and run statistical models on data. These programs tend to be both so sloppily written and so central to the results that it's contributed to a replication crisis, or put another way, a failure of the paper to perform its most basic task: to report what you've actually discovered, clearly enough that someone else can discover it for themselves.

<https://theconversation.com/the-science-reproducibility-crisis-and-what-can-be-done-about-it-74198>

<https://www.theatlantic.com/science/archive/2018/04/the-scientific-paper-is-obsolete/556676/>

Reproducibilidad científica.

¿Cómo lo hacemos?

- ❖ Disponibilización de **datos**.
- ❖ Desarrollando procesos computacionales **transparentes**.
- ❖ Con suficiente **detalle** para reproducir todo el análisis.

- ❖ Usando modelos y herramientas eficientes de **reusabilidad**.
 - ❖ Paquete de código abierto
 - ❖ Software libre
 - ❖ “Notebooks” computacionales

Python

- Lenguaje interpretado de programación: los comandos o instrucciones se ejecutan paso por paso, sin compilación previa.
- Gran y activa comunidad de computación científica y ciencia de datos desarrollada en torno a Python.
- Facilidad para integrar códigos desarrollados en C, C++, FORTRAN, etc. (más eficientes para algunos algoritmos de cálculo)
- Integración de múltiples librerías con distintas funcionalidades y usos (numPy, sciPy, onadas, skict-learn, Etc).
- Menos eficiente que otros lenguaje para computación paralela y concurrencias.

SciPy

- ❖ Ecosistema de software de código abierto basado en Python para matemáticas, ciencia e ingeniería.



NumPy

Base N-dimensional
array package



SciPy library

Fundamental
library for scientific
computing



Matplotlib

Comprehensive 2-D
plotting

IP[y]:
IPython

IPython

Enhanced
interactive console



SymPy

Symbolic
mathematics



pandas

Data structures &
analysis

- ❖ La *librería* SciPy provee una colección de paquetes enfocados en distintos problemas o requerimientos propios de computación científica:
 - Integración (`scipy.integrate`)
 - Álgebra lineal (`scipy.linalg`)
 - Optimización (`scipy.optimize`)
 - Análisis de señales (`scipy.signal`)
 - Estadísticas (`scipy.stats`)
 - Interpolación (`scipy.interpolation`)

<https://numpy.org/>


Provee las estructuras, algoritmos y funciones para la mayoría de las aplicaciones científicas relacionadas con datos numéricos.

- **Arreglos** multi-dimensionales (**ndarray**): eficientes para almacenar y manipular data
- Funciones para realizar **operaciones matemáticas entre arreglos → evita iteraciones!**
 - Operaciones de algebra lineal, transformadas de Fourier, números aleatorios, etc.
- **Interoperable**: Herramientas para leer y escribir datos/arreglos al disco/archivos.
- **Eficiente**: basada en códigos en C bien optimizados




CASE STUDIES

FIRST IMAGE OF A BLACK HOLE



How NumPy, together with libraries like SciPy and Matplotlib that depend on NumPy, enabled the Event Horizon Telescope to produce the first ever image of a black hole

DETECTION OF GRAVITATIONAL WAVES



In 1916, Albert Einstein predicted gravitational waves; 100 years later their existence was confirmed by LIGO scientists using NumPy.


Pandas

<https://pandas.pydata.org/>

- Provee las estructuras y funciones de alto nivel para trabajar con datos estructurados y tablas en forma rápida, fácil y expresiva.
 - **DataFrame**: estructura de datos tabular, orientada a columnas, con etiquetas de filas y columnas.
 - **Series**: objeto tipo arreglo 1-D, con etiqueta.
- Combina la eficiencia de cálculo de NumPy, con capacidades de manipulación de datos típicas de hojas de cálculo (e.g. Excel) y bases de datos relacionales.
- Provee funcionalidades de indexación para reformatear (reshape) , seccionar (slice), agregar, filtrar, seleccionar subconjuntos de datos.




DataFrame



Each column in a DataFrame is a Series

Series



Geopandas

<https://geopandas.org/>



- Librería que facilita el trabajo con datos geoespaciales en Python.

- Extiende los tipos de datos usados por pandas para permitir manipulación y operaciones espaciales con datos geométricos.

- DataFrame → GeoDataframe
- Series → GeoSeries

- Se basa en otras librerías pre-existentes:

- **fiona** → acceso a formatos de datos geoespaciales
- **shapely** → operaciones geométricas

```
[27]: data.head()
```

```
[27]:
```

	GROUP	CLASS	geometry	area
0	64	32421	POLYGON ((379394.248 6689991.936, 379389.790 6...	76.027392
1	64	32421	POLYGON ((378980.811 6689359.377, 378983.401 6...	2652.054186
2	64	32421	POLYGON ((378804.766 6689256.471, 378817.107 6...	3185.649995
3	64	32421	POLYGON ((379229.695 6685025.111, 379233.366 6...	13075.165279
4	64	32421	POLYGON ((379825.199 6685096.247, 379829.651 6...	3980.682621

<https://matplotlib.org>

- ❖ Librería de Python más popular para producción de gráficos y visualizaciones estáticas, animadas e interactivas.
- ❖ Existen varios paquetes que extienden y construyen sobre las funcionalidades de Matplotlib, incluyendo algunas interfaces de ploteo de alto nivel:
 - ❖ **Seaborn**: interfaz para generación de gráficos estadísticos atractivos e informativos. Ayuda a explorar y entender la data.
 - ❖ **Cartopy**: paquete diseñado para el procesamiento de data geoespacial, para producir mapas y otros análisis espaciales




<https://scikit-learn.org/stable/>

- Construido sobre NumPy, SciPy y matplotlib.
- Provee herramientas simples y eficientes para análisis predictivo de datos.
 - Clasificación
 - Regresión
 - Clustering

Jupyter Notebooks

❖ Documentos de archivo único que incluyen:

- Código ejecutable
- Resultados del código
- Texto narrativo e imágenes



The Jupyter Notebook

The Jupyter Notebook is an open-source web application that allows you to create and share documents that contain live code, equations, visualizations and narrative text. Uses include: data cleaning and transformation, numerical simulation, statistical modeling, data visualization, machine learning, and much more.

Try it in your browser

Install the Notebook



Language of choice

Jupyter supports over 40 programming languages, including Python, R, Julia, and Scala.



Share notebooks

Notebooks can be shared with others using email, Dropbox, GitHub and the [Jupyter Notebook Viewer](#).



Interactive output

Your code can produce rich, interactive output: HTML, images, videos, LaTeX, and custom MIME types.



Big data integration

Leverage big data tools, such as Apache Spark, from Python, R and Scala. Explore that same data with pandas, scikit-learn, ggplot2, TensorFlow.