

Análisis Exploratorio y Visualización de Datos

Clase 4



MIA

Magíster en
Inteligencia Artificial

IMT3860 – Introducción a Data Science
Profesor: Alejandro Cataldo Cornejo
correo: aecatald@uc.cl

El proceso de Ciencia de Datos




Figure 2-2. The data science process

Análisis Exploratorio

Análisis Exploratorio de Datos

Preface

This book is based on an important principle:


It is important to understand what you CAN DO before you learn to measure how WELL you seem to have DONE it.

Learning first what you can do will help you to work more easily and effectively.

This book is about exploratory data analysis, about looking at data to see what it seems to say. It concentrates on simple arithmetic and easy-to-draw pictures. It regards whatever appearances we have recognized as partial descriptions, and tries to look beneath them for new insights. Its concern is with appearance, not with confirmation.

Exploratory data analysis" is an attitude, a state of flexibility, a willingness to look for those things that we believe are not there, as well as those we believe to be there.

John Tukey



Análisis Exploratorio de Datos

❖ No hay hipótesis ni modelos → **los estamos buscando**, la comprensión del problema cambia a medida que avanzamos.

❖ **Objetivos:**

- Ganar intuición sobre la data, identificar patrones
- Confirmar si las preguntas son adecuadas
- Comparar distribuciones
- Chequear los datos
- Identificar datos faltantes o outliers
- Resumir la data

Análisis Exploratorio de Datos

EDA	Estadístico	Gráfico
Una variable	Media Mediana Desviación estándar Varianza Percentiles Rango intercuartil (IQR=Q3-Q1) Distribución de probabilidad	Histograma FDA KDE Boxplot Choropleth
Numérica		
Categórica		Gráfico de pie ☹
Multi-variable	Coef. Pearson Matriz de correlación Regresión Agrupación (groupby, pivot)	Scatterplot Jointplot Pairplots Histograma múltiple Serie de tiempo Stacked area Heatmap Pairplots

Visualizaciones y Análisis Gráfico

- ❖ Las visualizaciones de datos pueden tener distintos fines:

Análisis exploratorio

- **Entender** los datos
- Evaluar la situación
- Determinar cómo seguir
- (Re)formular preguntas

Comunicación de resultados

- Presentar datos e ideas
- **Explicar** e informar resultados
- Entregar evidencia
- Influir y persuadir



Visualizaciones y Análisis Gráfico


- ❖ Las estadísticas de resumen no siempre muestran claramente las diferencias o similitudes entre datasets:



Anscombe's Quartet

Each dataset has the same summary statistics (mean, standard deviation, correlation), and the datasets are *clearly different*, and *visually distinct*.

	Dataset I		Dataset II		Dataset III		Dataset IV	
	x	y	x	y	x	y	x	y
	10	8.04	10	9.14	10	7.46	8	6.58
	8	6.95	8	8.14	8	6.77	8	5.76
	13	7.58	13	8.74	13	12.74	8	7.71
	9	8.81	9	8.77	9	7.11	8	8.84
	11	8.33	11	9.26	11	7.81	8	8.47
	14	9.96	14	8.1	14	8.84	8	7.04
	6	7.24	6	6.13	6	6.08	8	5.25
	4	4.26	4	3.1	4	5.39	19	12.5
	12	10.84	12	9.13	12	8.15	8	5.56
	7	4.82	7	7.26	7	6.42	8	7.91
	5	5.68	5	4.74	5	5.73	8	6.89
Sum:	99.00	82.51	99.00	82.51	99.00	82.51	99.00	82.51
Avg:	9.00	7.50	9.00	7.50	9.00	7.50	9.00	7.50
Std:	3.32	2.03	3.32	2.03	3.32	2.03	3.32	2.03



**Mismas estadísticas,
distintos gráficos**

Visualizaciones y Análisis Gráfico

- ❖ Las estadísticas de resumen no siempre muestran claramente las diferencias o similitudes entre datasets:




Fig 2. The Datasaurus Dozen. While different in appearance, each dataset has the same summary statistics (mean, standard deviation, and Pearson's correlation) to two decimal places.


Mismas estadísticas, distintos gráficos

Visualizaciones y Análisis Gráfico

- ❖ Las estadísticas de resumen no siempre muestran claramente las diferencias o similitudes entre datasets:

✗ Unstructured Quartet

Each dataset here also has the same summary statistics. However, they are not *clearly different* or *visually distinct*.



Mismos gráficos, distintas estadísticas

Análisis Exploratorio de Datos

EDA	Estadístico	Gráfico
Una variable	Media Mediana Desviación estándar Varianza Percentiles Rango intercuartil (IQR=Q3-Q1) Distribución de probabilidad	Histograma FDA KDE Boxplot Choroplet
Numérica		
Categórica		Gráfico de pie ☹
Multi-variable	Coef. Pearson Matriz de correlación Regresión Agrupación (groupby, pivot)	Scatterplot Jointplot Pairplots Histograma múltiple Serie de tiempo Stacked area Heatmap

pandas
numpy
scipy

sklearn

matplotlib
seaborn
geopandas

Estadísticas de Resumen

Estadísticas de Resumen

- ❖ **Media:** es la suma de todos los valores, dividida por el número de puntos.

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

- ❖ **Mediana:** es el valor medio de un conjunto de datos. Es inmune a valores extremos o outliers. Para calcularla, se ordenan los datos y se elige el valor que queda en la mitad.
- ❖ **Percentiles:** el percentil p , corresponde al valor que es mayor al $p\%$ de los datos.
- ❖ **Varianza:** promedio de la distancia cuadrática de los datos a la media. Es una medida de la dispersión de los datos.

$$\text{Var} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- ❖ **Desviación Estándar:** es la raíz cuadrada de la varianza. Está en la misma escala de unidades que los datos.

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Estadísticas de Resumen

- ❖ **Covarianza:** es una medida de cómo dos cantidades varían juntas. Es la media del producto entre las diferencias de los valores respecto a la media.

$$\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$


- Si x e y tienden a estar ambas arriba, o ambas abajo de la media, la covarianza es positiva.
- Esto quiere decir que hay una correlación positiva: cuando x es alta, y es alta.
- Por el contrario, si x es alta cuando y es baja, la covarianza es negativa y los datos están anticorrelacionados.

- ❖ **Coeficiente de Pearson (ρ):** para tener una medida más general y aplicable de la correlación entre dos variables, necesitamos que sea adimensional. Por lo tanto dividimos la covarianza por las desviaciones estándar de x e y .

$$\rho = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$

- Es la comparación de la variabilidad en los datos debido a una codependencia (covarianza), con la variabilidad inherente de cada variable (sus desviaciones estándar).
- Un valor 0 indica que no hay correlación, valor 1 indica alta correlación.

Estadísticas de Resumen



- ❖ **Coeficiente de Pearson (ρ):** para tener una medida más general y aplicable de la correlación entre dos variables, necesitamos que sea adimensional. Por lo tanto dividimos la covarianza por las desviaciones estándar de x e y .

$$\rho = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$

- Es la comparación de la variabilidad en los datos debido a una codependencia (covarianza), con la variabilidad inherente de cada variable (sus desviaciones estándar).
- Un valor 0 indica que no hay correlación, valor 1 indica alta correlación.

Regresión Lineal y No Lineal

- ❖ Existen muchas librerías y funciones en Python para realizar regresiones lineales (o no lineales) entre 2 o más variables, de acuerdo a la forma:

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i,$$

- ❖ Típicamente, estos modelos aplican un ajuste mediante minimización de mínimos cuadrados (OLS), de acuerdo a la fórmula general:


$$\hat{\beta} = \arg \min_{\beta} \|y - X\beta\|,$$

- ❖ El resultado, son los parámetros o estimadores β que minimizan el error total.

Regresión Lineal y No Lineal

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i,$$

$$\hat{\beta} = \arg \min_{\beta} \|y - X\beta\|,$$




❖ En Python:

- `scipy.stats.linregress`
- `statsmodels.ols`
 - Fit - predict

```
>>> import statsmodels.api as sm
>>> import numpy as np
>>> duncan_prestige = sm.datasets.get_rdataset("Duncan", "carData")
>>> Y = duncan_prestige.data['income']
>>> X = duncan_prestige.data['education']
>>> X = sm.add_constant(X)
>>> model = sm.OLS(Y,X)
>>> results = model.fit()
>>> results.params
const          10.603498
education       0.594859
dtype: float64
```

Análisis Gráfico

seaborn: statistical data visualization



Seaborn is a Python data visualization library based on [matplotlib](#). It provides a high-level interface for drawing attractive and informative statistical graphics.

For a brief introduction to the ideas behind the library, you can read the [introductory notes](#). Visit the [installation page](#) to see how you can download the package and get started with it. You can browse the [example gallery](#) to see what you can do with seaborn, and then check out the [tutorial](#) and [API reference](#) to find out how.

To see the code or report a bug, please visit the [GitHub repository](#). General support questions are most at home on [stackoverflow](#) or [discourse](#), which have dedicated channels for seaborn.


Dataset de Ejemplo: Pasajeros del Titanic

- ❖ El dataset **titanic.csv** contiene datos para 887 pasajeros del Titanic, cada uno de los cuales representa una fila.
- ❖ Las columnas indican atributos de la persona: si sobrevivió, edad, clase, sexo, tarifa pagada, etc.


```
1 titanic = sns.load_dataset('titanic');  
2 titanic.info();
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 891 entries, 0 to 890  
Data columns (total 15 columns):  
survived      891 non-null int64  
pclass        891 non-null int64  
sex           891 non-null object  
age           714 non-null float64  
sibsp         891 non-null int64  
parch         891 non-null int64  
fare          891 non-null float64  
embarked      889 non-null object  
class         891 non-null category  
who           891 non-null object  
adult_male    891 non-null bool  
deck          203 non-null category  
embark_town    889 non-null object  
alive         891 non-null object  
alone         891 non-null bool  
dtypes: bool(2), category(2), float64(2), int64(4), object(5)  
memory usage: 80.6+ KB
```

Variables categóricas: countplot




```
1 f, ax = plt.subplots(figsize=(7, 3));  
2 ax = sns.countplot(y="deck", data=titanic, color="c");  
3 ax.set_title('Titanic');  
4 ax.set_xlabel('N Pasajeros')  
5 ax.set_ylabel('Cubierta')
```



```
1 ax = sns.countplot(x="class", data=titanic)  
2 ax.set_title('Titanic');  
3 ax.set_ylabel('N Pasajeros');  
4 ax.set_xlabel('Clase');
```


Variables categóricas: relplot

```
1 sns.set(style="ticks", palette="muted")
2 sns.relplot(x="age", y="deck", col="class", data=titanic);
```




Histograma y Función de Densidad

```
1  # ¿Cuál es la distribución de edades de los pasajeros del Titanic?
2  import seaborn as sns
3  sns.set(color_codes=True)
4
5  f, ax = plt.subplots(1,1, figsize=(8, 3));
6  ax = sns.distplot(titanic.age, kde=False, bins=20)
7
8  ax.set(xlim=(0, 90));
9  ax.set_ylabel('N');
10 ax.set_xlabel('Edad');
```



Histograma y Función de Densidad


```
1 # ¿Cuál es la distribución de edades de los pasajeros del Titanic?
2 import seaborn as sns
3 sns.set(color_codes=True)
4
5 f, ax = plt.subplots(1,1, figsize=(8, 3));
6
7 sns.kdeplot(titanic.age, bw=0.6, label="bw: 0.6", shade=True, color="r", ax=ax);
8 sns.kdeplot(titanic.age, bw=2, label="bw: 2", shade=True, ax=ax);
9
10 ax.set(xlim=(0, 90));
11 ax.set_ylabel('N');
12 ax.set_xlabel('Edad');
```



Boxplot

Una Variable


```
: 1 # seaborn
2 ax = sns.boxplot(x='age', data=titanic)
3 ax.set_ylabel(None);
4 ax.set_xlabel('Edad', fontsize=14);
5 ax.set_title('Distribución de Edad de Pasajeros del Titanic', fontsize=14);
```



Boxplot


Dos variables: ¿la primera clase se componía de pasajeros más jóvenes o mayores?

```
: 1 ax = sns.boxplot(x='class', y='age', data=titanic)
  2 ax.set_ylabel('Edad');
  3 ax.set_xlabel('Clase', fontsize=14);
  4 ax.set_title('Distribución de Edad y Clase de Pasajeros del Titanic', fontsize=14);
```




Scatterplot / Jointplot : Relación entre 2 variables

```
1 sns.jointplot("fare", "age", data=titanic, s=40, edgecolor="w", linewidth=1);  
2 ax.set_ylabel('Tarifa');  
3 ax.set_xlabel('Edad', fontsize=14);  
4 ax.set_title('Relación entre Edad y Tarifa Pagada por Pasajeros del Titanic', fontsize=14);
```




Scatterplot / Jointplot : Relación entre 2 variables

```
1 sns.jointplot("fare", "age", data=titanic, s=40, edgecolor="w", linewidth=1);  
2 ax.set_ylabel('Tarifa');  
3 ax.set_xlabel('Edad', fontsize=14);  
4 ax.set_title('Relación entre Edad y Tarifa Pagada por Pasajeros del Titanic', fontsize=14);
```



Scatterplot y Distplot: Relación entre 2 o más variables

```
1 f, ax = plt.subplots(1,1, figsize=(10, 5))
2 sns.scatterplot(x="fare", y="age", hue="survived", size="sex", data=titanic, ax=ax);
3 ax.set_ylabel('Tarifa');
4 ax.set_xlabel('Edad', fontsize=14);
5 ax.set_title('Relación entre Edad, Tarifa Pagada, Sobrevivencia y Sexo', fontsize=14);
6 plt.show();
```




Pairplot: Análisis multivariable

```
1 titanic.columns
```

```
Index(['survived', 'pclass', 'sex', 'age', 'sibsp', 'parch', 'fare', 'class', 'deck'], dtype='object')
```


```
1 graficar = ['age', 'fare', 'survived', 'deck']
```

```
1 titanic_plot = titanic.loc[:,graficar]  
2 sns.pairplot(titanic_plot);
```



Pairplot: Análisis multivariable


```
: 1 titanic.columns  
  
: Index(['survived', 'pclass', 'sex', 'age', 'sibsp', 'parch', 'fare', 'class', 'deck'], dtype  
      ='object')  
  
: 1 graficar = ['age', 'fare', 'survived', 'deck']  
  
: 1 titanic_plot = titanic.loc[:,graficar]  
  2 sns.pairplot(titanic_plot,hue='deck');
```



Choropleths (Coropletas)


- ❖ Mapas que permiten visualizar un **atributo** (variable no – espacial)
- ❖ Los valores se codifican como un **mapa de colores**, donde cada color representa **uno o varios valores**.

Confirmed Cases of COVID-19 in the United States
cases per 100,000 population



Choropleths (Coropletas)

- ❖ Mapas que permiten visualizar un **atributo** (variable no – espacial)
- ❖ Los valores se codifican como un **mapa de colores**, donde cada color representa **uno o varios valores**.





EEUU, resultados de elecciones presidenciales 2012 por condado.

(Fuente: NY Times)

<https://www.nytimes.com/elections/2012/results/president>

Choropleths (Coropletas)


- ❖ Mapas que permiten visualizar un **atributo** (variable no – espacial)
- ❖ Los valores se codifican como un **mapa de colores**, donde cada color representa **uno o varios valores**.



Choropleths (Coropletas)

- ❖ En GeoPandas, usamos el método **plot** de un GeoDataFrame, especificando la variable o atributo a mapear:
- ❖ Por defecto, este comando genera una escala de colores continua, pero para el ojo humano es difícil reconocer cambios de color muy sutiles.
- ❖ Ej: mapa de PIB mundial

```
countries.plot(column='gdp_per_cap', legend=True)
```



Choropleths (Coropletas)


- ❖ Para crear choropleths efectivos, típicamente clasificamos los valores en conjuntos de grupos discretos.
- ❖ Para ello, se requiere definir 3 parámetros clave:
 - ❖ Número de clases (**k**) → cuántos colores usar
 - ❖ Algoritmo de clasificación (**scheme**) → cómo asignar colores a cada valor del atributo
 - ❖ Paleta de colores (**cmap**) → combinación de colores

```
locations.plot(column='variable', scheme='quantiles', k=7, cmap='viridis')
```

- ❖ Al agrupar muchos valores en pocos grupos, hay pérdida de información, pero hace los mapas más fáciles de interpretar.
- ❖ La definición del número de clases (**k**), es un trade-off:
 - ❖ Muy pocas clases (bajo **k**) → mapa no dice nada
 - ❖ Muchas clases (alto **k**) → mapa tiene más información de la que un humano puede procesar en forma significativa

Choropleths


- ❖ ¿Cuántos bins? → la literatura sugiere **entre 3 y 12 bins**.
- ❖ ¿Cómo asignamos cada valor de nuestra `variable` a uno de los k grupos?
- ❖ **Intervalos iguales** (`equal_intervals`): rango de valores se divide en segmentos iguales, y se asigna un color a cada bin.
 - ❖ bins de ancho uniforme
 - ❖ si la variable está distribuida de forma no-uniforme en el espacio de valores entonces gran parte de las observaciones se verán del mismo color.



```
locations.plot(column='variable', scheme='equal_interval', k=7, cmap='Purples')
```

Choropleths

- ❖ **Cuantiles** (`quantiles`): se hace un ranking de todos los valores y asigna la misma proporción a cada bin.
 - Ej: $k=7$ grupos, cada uno queda con $1/7$ de las observaciones.
 - Problema potencial: incluir valores muy disímiles en un mismo bin



```
locations.plot(column='variable', scheme='quantiles', k=7, cmap='viridis')
```

Choropleths

❖ ¿Qué combinación o paleta de colores?

- Se recomienda elegir una que esté alineada con el propósito del mapa y la naturaleza de los datos.

❖ **Datos categóricos** (no ordenados): usar paletas que no impliquen ningún gradiente o escala de color

❖ **Datos continuos** (graduados):

- Si el mínimo es un punto de inicio natural: usamos una **paleta secuencial**. Ej: población
- Si el punto de inicio está en el centro, usamos una **paleta divergente**, compuesta por dos paletas secuenciales que se mueven en direcciones opuestas. Ej: temperatura, alturas

Categories, non-ordered



```
locations.plot(column='variable',  
               categorical=True, cmap='Purples')
```

Graduated, sequential

```
locations.plot(column='variable',  
               k=5, cmap='RdPu')
```

Graduated, divergent

```
locations.plot(column='variable',  
               k=5, cmap='RdYlGn')
```




IMPORTANT: Align with your purpose

Para identificar paletas adecuadas a cada caso:

ColorBrewer
<https://colorbrewer2.org/>

Mapas de burbujas (bubble maps)

- ❖ Se usa el **tamaño de círculo** como la forma de codificación de una variable.
- ❖ El tamaño del círculo representa un valor numérico para una cierta área geográfica.
- ❖ Ayudan a resolver limitaciones de choropleths para áreas muy grandes.




continent

- Asia
- Europe
- Africa
- Americas
- Oceania


Ebola cases reported by month in West Africa 2014
Source: [HDX](#)

● June
● July
● Aug
● Sept
Aa



Visualizaciones NO EFECTIVAS


Figure 1 Mortality and disease burden (DALYs) in women aged 15–44 years by region and broad causes, 2004




* High-income countries are excluded from the regional groups.
Source: World Health Organization.¹

Visualizaciones NO EFECTIVAS

Coupons Maturing*
February 15, 2010-November 15, 2039



Visualizaciones NO EFECTIVAS



Visualizaciones NO EFECTIVAS




Figure 5.2 Mean prevalence rates of *Cryptosporidium* oocysts by animal species.

Visualizaciones **NO EFECTIVAS**

The Hindi belt scores low, while the south does better

Female labour force participation rate (%)

