

Argumento: ¿Por qué analizar la desigualdad educativa y su correlación con la migración en la RM?

Pregunta propuesta

¿Cómo varía la desigualdad educativa (ESCOLARIDAD) entre comunas de la Región Metropolitana, y existe correlación espacial con la concentración de población migrante?

1. Relevancia social y de política pública

La Región Metropolitana concentra más de 7 millones de habitantes (según los microdatos censales con los que trabajamos: 7,112,808 registros). Dentro de este territorio coexisten **52 comunas** con realidades socioeconómicas profundamente distintas.

La educación es uno de los indicadores más robustos de desarrollo humano y movilidad social. Al mismo tiempo, Chile ha experimentado un crecimiento sostenido de la inmigración en la última década, concentrándose fuertemente en la RM. Entender **dónde** se acumula la desigualdad educativa y si esta se relaciona con la distribución espacial de la población migrante tiene implicaciones directas para:

- **Planificación de servicios públicos** (escuelas, programas de integración).
- **Focalización de políticas sociales** (subsidios, capacitación laboral).
- **Comprensión de dinámicas urbanas** (segregación residencial, gentrificación).

Esto conecta directamente con lo visto en **Clase 1** sobre cómo la ciencia de datos busca responder preguntas que impactan en el mundo real, y el ejemplo de **John Snow (1854)** que usó análisis espacial para entender la epidemia de cólera en Londres — nosotros haríamos algo análogo: usar la dimensión geográfica para revelar patrones ocultos.

2. Conexión con los conceptos de clase

2.1 Análisis Exploratorio de Datos (Clase 2)

La pregunta requiere aplicar directamente las herramientas de **EDA** presentadas en clase:

Herramienta EDA	Aplicación en nuestra pregunta
Histogramas	Distribución de escolaridad por comuna (ya se usó <code>plt.hist</code> en el Taller con P09; aquí lo aplicamos a ESCOLARIDAD)

Estadísticas de resumen (media, mediana, desviación estándar)	Comparar escolaridad promedio entre comunas y detectar dispersión
Diagramas de caja (boxplots)	Visualizar la distribución de escolaridad por comuna, identificando outliers y asimetrías
Gráficos de dispersión	Relación entre % migrantes y escolaridad promedio por comuna
Coeficiente de Pearson (ρ)	Cuantificar la correlación entre concentración migrante y nivel educativo

2.2 Distribuciones de probabilidad (Clase 2)

La escolaridad en distintas comunas probablemente siga distribuciones con formas muy diferentes: - Comunas de altos ingresos → distribuciones concentradas en valores altos (poca varianza). - Comunas con mayor diversidad socioeconómica → distribuciones bimodales o con alta dispersión.

Esto permite discutir conceptos de **función de densidad**, **varianza** y **comparación de distribuciones**.

2.3 Testeo de hipótesis (Clase 2)

Podemos formular una **hipótesis nula** concreta:

H_0 : No existe diferencia significativa en la escolaridad promedio entre comunas con alta y baja proporción de población migrante.

Y evaluarla usando: - **Bootstrapping** para construir intervalos de confianza. - **Testeo de permutaciones** (A/B testing) para evaluar si la diferencia observada es estadísticamente significativa. - Cálculo de **valor p** para determinar si rechazamos **H_0** .

2.4 Ciencia de Datos Geográfica (Clase 1)

La dimensión **espacial** es lo que distingue esta pregunta de un análisis puramente tabular. Usando **GeoPandas** y el shapefile de zonas censales (ya cargado en el Taller), podemos:

- Generar **mapas coropléticos** de escolaridad promedio por zona censal.
- Generar **mapas coropléticos** de proporción de migrantes por zona.
- Comparar visualmente ambos mapas para detectar patrones de co-localización.

Esto conecta con la idea de **relaciones espaciales** de la Clase 1 y demuestra el valor de los datos geoespaciales.

3. Factibilidad con los datos disponibles

La pregunta es **completamente realizable** con el dataset `CensoRM.csv` que ya tenemos. Las variables clave son:

Variable	Descripción	Uso
<code>ESCOLARIDAD</code>	Años de escolaridad (0–22)	Variable dependiente principal
<code>P10</code>	Lugar de nacimiento (misma comuna, otra comuna, otro país)	Identificar migrantes internacionales
<code>P10PAIS</code> / <code>P10PAIS_GRUPO</code>	País de nacimiento	Clasificar origen migratorio
<code>P12</code>	Residencia habitual	Confirmar residencia actual
<code>P12A_LLEGADA</code>	Año de llegada al país	Temporalidad migratoria
<code>COMUNA</code>	Código de comuna	Agrupación geográfica
<code>P08</code>	Sexo	Control demográfico
<code>P09</code>	Edad	Control demográfico

No se requieren datos externos: todo está en el censo.

4. Métodos propuestos (paso a paso)

Paso 1: Preparación de datos

```
# Filtrar población relevante (ej: mayores de 25 años, para escolaridad completa)
censo_adultos = censo[censo['P09'] >= 25]

# Crear variable binaria de migrante internacional
censo_adultos['MIGRANTE'] = (censo['P10'] == 4).astype(int) # nacido en otro país
```

Paso 2: Estadísticas descriptivas por comuna

```
# Escolaridad promedio y % migrantes por comuna
stats_comuna = censo_adultos.groupby('COMUNA').agg(
    escolaridad_media=('ESCOLARIDAD', 'mean'),
    escolaridad_std=('ESCOLARIDAD', 'std'),
    pct_migrante=('MIGRANTE', 'mean'),
    poblacion=('PERSONAN', 'count')
)
```

Paso 3: Análisis de correlación

```
# Coeficiente de Pearson (Clase 2)
from scipy.stats import pearsonr
r, p_value = pearsonr(stats_comuna['escolaridad_media'], stats_comuna['pct_migrante'])

# Scatter plot
plt.scatter(stats_comuna['pct_migrante'], stats_comuna['escolaridad_media'])
plt.xlabel('% Población Migrante')
plt.ylabel('Escolaridad Promedio (años)')
```

Paso 4: Visualización espacial

```
# Merge con GeoDataFrame y generar mapa coroplético (como en el Taller)
zonas_censales = zonas_censales.merge(stats_zona, on='ID_ZONA_U')
zonas_censales.plot(column='escolaridad_media', legend=True, cmap='RdYlGn')
```

Paso 5: Testeo de hipótesis (opcional, avanzado)

```
# Bootstrap para intervalo de confianza de la correlación
bootstrap_corrs = []
for _ in range(10000):
    sample = stats_comuna.sample(frac=1, replace=True)
    r_boot, _ = pearsonr(sample['escolaridad_media'], sample['pct_migrante'])
    bootstrap_corrs.append(r_boot)
ci = np.percentile(bootstrap_corrs, [2.5, 97.5])
```

5. ¿Por qué esta pregunta es más atractiva que otras alternativas?

Criterio	Esta pregunta	Alternativa simple (ej: solo distribución etaria)
Variables involucradas	Múltiples (escolaridad, migración, geografía, edad)	Una sola (edad)
Métodos demostrados	EDA + correlación + mapas + hipótesis	Solo histograma
Relevancia social	Alta (desigualdad, migración, política pública)	Moderada
Complejidad adecuada	Suficiente para demostrar competencias sin ser inabordable	Demasiado básica
Visualización	Scatter + boxplots + mapas coropléticos	Un solo gráfico
Conexión con Clase 1 y 2	Usa conceptos de ambas clases	Solo herramientas básicas

6. Conclusión

Esta pregunta es atractiva porque:

1. **Es socialmente relevante:** aborda desigualdad educativa y migración, dos temas centrales en Chile.
2. **Integra múltiples conceptos del curso:** EDA, correlación de Pearson, distribuciones, bootstrapping, testeo de hipótesis, y análisis geoespacial.
3. **Es factible:** todos los datos necesarios ya están en el dataset del Taller.
4. **Permite visualizaciones impactantes:** mapas coropléticos que revelan segregación espacial.
5. **Conecta con el espíritu de la ciencia de datos** (Clase 1): extraer información significativa de los datos para responder preguntas que importan.

"Es la ciencia de extraer información significativa de los datos" — Definición de Ciencia de Datos, Clase 1.