

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



INF3812 – Deep Learning

Fundamentos de Deep Learning


Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación

Partamos el curso con una pregunta

En cuanto a lo técnico, ¿por qué estamos hablando de **Inteligencia Artificial** desde hace unos **pocos años**, siendo que es un área “**antigua**” de la computación?

Este es un curso conceptual-teórico-práctico




Este es un curso conceptual-teórico-práctico, pero no porque sí

- Es fundamental aprender bien los conceptos y teoría detrás de DL, si no, ...

- También es fundamental entender los elementos prácticos necesarios para que DL funcione, si no, ...

- En el fondo, ambos elementos son fundamentales.

- Así, salvo algunas excepciones, siempre consideraremos las implementaciones como parte fundamental de los contenidos del curso (pero no el código en sí).



Aunque los conceptos son independientes del framework, preferentemente usaremos PyTorch y Colab para los ejemplos



En cuanto a contenidos, el curso cubre los fundamentos de Deep Learning

Sesión	Fecha	Tema
1	04/08	Fundamentos de DL
2	11/08	Arquitecturas básicas de Redes Neuronales
3	18/08	Redes Convolucionales
4	25/08	Entrenamiento de Redes Neuronales
5	01/09	Evaluaciones 1
6	08/09	Redes Recurrentes
7	22/09	Modelos de lenguaje
8	29/09	Arquitectura Transformer
9	06/10	Evaluaciones 2


Evaluaciones: 2 Controles y 2 Tareas

- Tendremos 2 controles individuales (sesiones 5 y 9), donde cada uno vale 25% de la nota final.
- Tendremos 2 tareas grupales (hasta grupos de 3), donde cada una vale 25% de la nota final.
- Enunciados de las tareas se publicarán luego de las sesiones 4 y 8.
- Posterior a los controles en las sesiones 5 y 9, se realizarán sesiones de preguntas para las tareas.
- Entrega de las tareas será para el domingo subsiguiente a la publicación.


Sesión	Fecha	Tema
1	04/08	Fundamentos de DL
2	11/08	Arquitecturas básicas de Redes Neuronales
3	18/08	Redes Convolucionales
4	25/08	Entrenamiento de Redes Neuronales
5	01/09	Evaluaciones 1
6	08/09	Redes Recurrentes
7	22/09	Modelos de lenguaje
8	29/09	Arquitectura Transformer
9	06/10	Evaluaciones 2

Canvas es el medio oficial para todo

- Programación del curso está completamente basada en el programa, que está disponible en Canvas.
- Todo queda en Canvas (videos, slides, ejemplos, etc.).
- Teams se utilizará para las sesiones y comunicaciones sincrónicas.
- Fuera de clases, para dudas de materia, el medio oficial es el foro del curso. Para temas administrativos, el medio oficial es mi correo halobel@uc.cl.





Explosión digital (empezamos a usar computadores
en vez de papel para guardar datos)
≈ 1990



IA tradicional: buscaba máquinas
tan inteligentes como un humano
(en todo)

Machine Learning: máquinas especializadas que
aprenden **INDUCTIVAMENTE**, pueden superar a
los humanos en la(s) tarea(s) asignada(s)





Cat




Dog

¿



?



Cat







Dog


¿




?









Type	Level	Description
Location	I/B [†]	Geocoded position of the unit
SES	I B	Socioeconomic status
Aesthetic	I/B	Aesthetic perception index of the nearest geocoded image (individual) or averaged at the urban block level
Political	I/B	Proportion of a political choice in the Constitutional plebiscite or in the Chilean Presidential Elections (first round)
Land use	I/B	Proportion/ $M^{2\frac{1}{2}}$ of land use of the urban block according to a land use typology*
Demographic	I B	Sex, age, proportion of immigrants Age, proportion of immigrants/women










<https://youtu.be/KHMwq9pv7mg>

Todos los sistemas de Machine Learning presentan, a alto nivel, un esquema de funcionamiento similar



Buscamos, en el **espacio de hipótesis** del modelo, aquella con mejor rendimiento (**menor pérdida**) en los datos de **entrenamiento**, apoyándonos en el **sesgo inductivo** del modelo.


¿Cómo se ve esto matemáticamente?

Problema de optimización: búsqueda sobre el espacio de hipótesis

Parámetros: viven en el espacio de hipótesis del modelo

Función de pérdida: captura el rendimiento del modelo al cuantificar su error en los datos de entrenamiento

Etiqueta: valor a predecir (tarea)

$$\operatorname{argmin}_W J(X, Y; W) = \lambda \mathcal{R}(W) + \sum_i^N \mathcal{L}(f(x_i; W), y_i)$$






Datos de entrenamiento: incluyen los datos en sí y sus etiquetas.

Regularizador: función que induce sesgo inductivo en el modelo predictivo a través de sus parámetros

Modelo predictivo: función parametrizada, que mapea desde el espacio de los datos hacia el de las etiquetas

Buscamos, en el **espacio de hipótesis** del modelo, aquella con mejor rendimiento (**menor pérdida**) en los datos de **entrenamiento**, apoyándonos en el **sesgo inductivo** del modelo.

¿Qué aprenden los modelos tradicionales de Machine Learning?



En muchos *pipelines* tradicionales, la representación se diseña por separado y el modelo aprende principalmente la regla de predicción.

¿Qué podemos decir con respecto a esto?

Qué son las representaciones/*features* diseñadas (*handcrafted features* o *feature engineering*)

d1 : Mary loves Movies, Cinema and Art

d2 : John went to the Football game



d3 : Robert went for the Movie Delicatessen

Class 1 : Arts

Class 2 : Sports



Class : Arts

	Mary	Loves	Movies	Cinema	Art	John	Went	to	the	Delicatessen	Robert	Football	Game	and	for
d1	1	1	1	1	1									1	
d2						1	1	1	1			1	1		
d3			1				1		1		1				1



La clave para enfrentar esto se enfoca en pensar en las features y el modelo predictivo como un modelo/problema conjunto

- Técnicas tradicionales de ML usan características (*features*) hechas a mano para clasificar/predecir.
- Estas tienen que ver más con el conocimiento experto que tengamos (o no) del problema.
- Esto no es ideal por tres motivos:
 - i. Un experto es caro y nada asegura que su conocimiento sea óptimo
 - ii. Para datos no estructurados, no son evidentes las mejores características y/o especificaciones de modelo
 - iii. No siempre es evidente cómo combinar distintos tipos de datos para extraer información, ni las relaciones que hay entre ellos




Buscamos **mecanismos** de **aprendizaje** suficientemente poderosos y **generales**, que permitan capturar aspectos complejos y eventualmente desconocidos (para nosotros) de los datos, con el fin de resolver **tareas** con **alto rendimiento**




¿Cómo logramos entonces construir sistemas que cumplan con esto?

Partamos con un simple modelo conectivista,
también llamado **red neuronal artificial**




Partamos con un simple modelo conectivista,
también llamado **red neuronal artificial**




Dada la estructura de una red, el problema de aprendizaje está dado por la siguiente pregunta:
¿cómo podemos ajustar los parámetros de las neuronas (nodos, unidades) para que al ingresar un
vector de entrada obtengamos la salida deseada?

Ejemplo: cuando la red recibe una
imagen de un 4, su codificación de
salida debe indicar un 4.






Una **unidad neuronal** aplica una transformación lineal y, cuando corresponde, una activación



Una **unidad neuronal** aplica una transformación lineal y, cuando corresponde, una activación

Name	Plot	Equation
Identity		$f(x) = x$
Logistic (a.k.a Soft step)		$f(x) = \frac{1}{1 + e^{-x}}$
Tanh		$f(x) = \tanh(x) = \frac{2}{1 + e^{-2x}} - 1$
ArcTan		$f(x) = \tan^{-1}(x)$
Rectified Linear Unit (ReLU)		$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$





Un modelo neuronal de una capa permite estimar funciones de manera supervisada

- Estamos interesados en aproximar el mapeo $g(x) = y$, que dado un ejemplo x , entrega su etiqueta y .
- Si tenemos suficientes datos muestreados de este mapeo, pares (x_i, y_i) , es posible construir una función que nos indique cuán buena es en promedio la estimación de un modelo para el mapeo.
- Sea $f(x; w) = \sigma(\sum_{i=1}^m w_{(i)} x_{(i)}) = \sigma(w \cdot x)$, una función que modela la aplicación de un modelo parametrizado por un vector de pesos w , a un vector de características x . Buscamos que $g(x) \approx f(x; w)$.
- Sin suponer cosas raras sobre los datos, una posible **función de pérdida** (o costo, o error) puede quedar de la siguiente manera:


$$J(w) = \frac{1}{n} \sum_{i=1}^n (f(x_i; w) - y_i)^2$$

- ¿Qué representan los pesos w que minimizan esta función?

¿Cómo podemos entrenar un modelo neuronal de una capa?

- En modelos de una capa con una pérdida apropiada (casi todos), el objetivo es convexo respecto de los parámetros.

$$J(w) = \frac{1}{n} \sum_{i=1}^n (f(x_i; w) - y_i)^2$$






¿Cómo podemos entrenar un modelo neuronal de una capa?



- En modelos de una capa con una pérdida apropiada (casi todos), el objetivo es convexo respecto de los parámetros.

$$J(w) = \frac{1}{n} \sum_{i=1}^n (f(x_i; w) - y_i)^2$$


- En esos casos, el descenso de gradiente puede alcanzar un óptimo global bajo condiciones adecuadas.









Un modelo de una capa representa funciones afines o fronteras de decisión lineales



x_1	x_2	$x_1 \text{ XOR } x_2$
0	0	0
0	1	1
1	0	1
1	1	0


¿Cómo podemos extender este modelo para representar relaciones no lineales?




Al agregar una nueva capa, típicamente llamada **capa oculta** (en azul), podemos capturar **features intermedias** entre entrada y salida, que permiten separar más fácilmente los datos

MLP generaliza el modelo de una capa



- Un Multilayer Perceptron (MLP) combina transformaciones afines y activaciones no lineales en múltiples capas. También se conoce como red feedforward profunda.
- Puede representar funciones más complejas que un modelo de una capa.
- Bajo ciertas condiciones, un MLP puede aproximar cualquier función continua.



Nuevas capas aumentan poder discriminativo



Visualmente, representaremos los MLP utilizando capas



Sin glamour, ¿qué es en realidad un MLP?

Siempre es bueno pensar también en las redes neuronales como una composición de funciones:

- Modelo de 1 capa:

$$f = \sigma(W_1 x)$$


* $\sigma(z)$ = función de activación

- MLP de 2 capas:

$$f = \sigma(W_2 \sigma(W_1 x))$$


- MLP de 3 capas:


$$f = \sigma(W_3 \sigma(W_2 \sigma(W_1 x)))$$



Los datos, como siempre, son la perdición y la salvación


- Cerca de 2010, las técnicas tradicionales de *machine Learning*, incluyendo el MLP como recién lo vimos, estaban comenzando a mostrar signos de saturación.
- Modelos **no mostraban** mayores **beneficios** al usar **grandes volúmenes de datos**.
- Tampoco estaba claro cómo utilizar distintos tipos de datos simultáneamente.






¿Qué es Deep Learning?

- Área de la IA centrada en redes neuronales de múltiples capas, entrenadas para aprender representaciones y resolver tareas de manera conjunta.
- Sus capas pueden aprender representaciones (*features*) composicionales y jerárquicas, además de las necesarias para la tarea.
- Las unidades neuronales son diferenciables y se entrenan conjuntamente mediante una función objetivo común.
- Principal diferencia con redes neuronales previas: **ahora sí funcionan**.




¿Qué son las representaciones composicionales y jerárquicas?

- Las representaciones composicionales y jerárquicas son muy comunes en la naturaleza
- Se organizan desde niveles bajos a altos de abstracción.
- La composicionalidad es su principal característica.
- Permiten describir infinitas configuraciones a partir de un número acotado de elementos.
- Algunos ejemplos:
 - Sonidos -> fonemas -> sílabas -> palabras
 - Píxeles -> bordes -> partes -> objetos -> escenas
 - Caracteres -> palabras -> grupos -> cláusulas -> frases




Cómo funciona la composicionalidad jerárquica en Deep Learning

- En muchas arquitecturas, cada capa transforma su entrada en features que pueden alcanzar un mayor nivel de abstracción.
- Elementos de un nivel son compartidos para generar la transformación.
- Esto permite a las redes aprender a identificar una cantidad prácticamente infinita de patrones a partir de un número acotado de neuronas.



¿Se aprenden features con un nivel de abstracción progresivamente mayor?




¿Qué se aprende en los distintos niveles?

- Frecuentemente, las capas de bajo nivel (poca profundidad) detectan *features* genéricas y locales que funcionan como bloques de construcción: fonemas y bordes en reconocimiento de voz y visual, respectivamente.
- Las capas de alto nivel pueden detectar *features* especializadas y globales, que son más robustas a variaciones: independientes del que habla o del punto de vista, en reconocimiento de voz y visual, respectivamente.



ARTIFICIAL INTELLIGENCE

Artificial Intelligence captures the imagination of the world.



MACHINE LEARNING

Machine learning starts to gain traction.



DEEP LEARNING

Deep learning catapults the industry.



1950s

1960s

1970s

1980s

1990s

2000s

2010s



1958 Perceptron

1974 Backpropagation

Handwritten Recognition
1998




General Object
Detection
2008

No more funds
awkward silence (AI Winter)

1969
Perceptron criticized




1995
SVM reigns



2005
Human
Detection




2012
Deep Learning
Rises



¿Por qué las redes neuronales recién pudieron funcionar después de tanto tiempo?


Éxito se debe a tres elementos centrales







Distintos grupos mantuvieron y desarrollaron las bases técnicas de las redes neuronales durante décadas, incluso cuando el foco dominante estaba en otras técnicas.


Éxito se debe a tres elementos centrales





Datos para Reconocimiento Visual

Datos para Procesamiento
de Lenguaje Natural (NLP)





1.2M




OpenAI
CLIP

400M



5,000M

Éxito se debe a tres elementos centrales



Uso de aceleradores es una necesidad



- Cuando crecen los datos y los modelos, el cómputo en CPU se vuelve un cuello de botella.



Uso de aceleradores es una necesidad

- Cuando crecen los datos y los modelos, el cómputo en CPU se vuelve un cuello de botella.
- Los aceleradores y las arquitecturas paralelas o distribuidas hacen viable el entrenamiento a escala.





Generated Question	Answer
How many bears are laying on the ice?	"two"
What are the two animals laying on the ice?	"bears"
What are the bears doing?	"laying down"
Two bears are laying down on what?	"ice"
Where are the bears laying?	"on the ice"
Are the bears on the ice?	"yes"



A dog wearing a Superhero outfit with red cape flying through the sky

Material de referencia recomendado

- “Deep Learning”, de Goodfellow y colaboradores: <https://www.deeplearningbook.org/>
- “Dive into Deep Learning”, de Zhang y colaboradores: <https://d2l.ai/>

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



INF3812 – Deep Learning

Fundamentos de Deep Learning

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación