

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



INF3812 – Deep Learning


Arquitecturas neuronales fundamentales de Deep Learning



Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación

MLP: transformaciones lineales y seguidas de activaciones no lineales


- Un Multilayer Perceptron (MLP), combina múltiples perceptrones en múltiples capas. Es conocido también como Deep Feed Forward Network (DFF).
- A diferencia de un modelo de una neurona, puede representar fronteras de decisión no lineales.






Una **capa oculta** (en azul) transforma la entrada en una **representación intermedia** donde la separación puede ser más simple. Estas representaciones se aprenden junto con la tarea.

Más capas amplían la clase de funciones representables






Los MLP son aproximadores universales


- Bajo determinadas condiciones, una red con una capa oculta suficientemente ancha puede aproximar funciones continuas sobre dominios compactos con precisión arbitraria.
- El resultado no garantiza que esa red sea fácil de entrenar, eficiente en parámetros ni capaz de generalizar con pocos datos.





Veamos una pequeña “mostración” del teorema




Veamos una pequeña “mostración” del teorema




Veamos una pequeña “mostración” del teorema



$w = 1$





$w = 10$




$w = 100$


Veamos una pequeña “mostración” del teorema



$w = 100, b = 100$




$w = 100, b = 0$




$w = 100, b = -100$

Veamos una pequeña “mostración” del teorema



Veamos una pequeña “mostración” del teorema



MLP son teóricamente todopoderosos

- En resumen, dada una función continua, siempre es posible construir un MLP que la estime con precisión arbitraria, usando esta metodología.
- Sin embargo, la cantidad de neuronas por capa va a depender del problema, o sea, puede ser potencialmente muy grande.
- Esta metodología no es práctica y es distinta de entrenar un MLP, pero al menos nos da una idea de una cota superior para el tamaño de un MLP.
- Validemos a continuación lo todopoderoso de un MLP, viendo su rendimiento en la práctica...

El set de datos **MNIST** permite construir **clasificadores de dígitos** a partir de imágenes

- MNIST contiene imágenes de dígitos escritos a mano en escala de grises.
- Cada imagen muestra un solo dígito entre 0 y 9, con una resolución de $28 \times 28 = 784$ píxeles.
- El conjunto incluye 60.000 ejemplos de entrenamiento y 10.000 de prueba.
- ¿Qué arquitectura de MLP podríamos entrenar para resolver el problema?




Input Layer
784

Hidden Layer 1
128


Hidden Layer 2
64

Output Layer
10

Loss Layer



Para construir una función de pérdida adecuada, el primer paso es hacer que las salidas del MLP sean las probabilidades de que la entrada x corresponda a cada una de las $K = 10$ categorías posibles, $P(Y = k \mid X = x)$. Esto se logra utilizando la función de activación *softmax* luego de la capa de salida.



Como función de pérdida, podemos utilizar la función Cross Entropy, que penaliza adecuadamente las probabilidades incorrectamente asignadas


$$P(Y = k|X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

Queremos maximizar la log-verosimilitud o, como función de pérdida, minimizar la log-verosimilitud negativa de la clase correcta:


$$L_i = -\log P(Y = y_i|X = x_i)$$

en resumen: $L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$

Loss



Accuracy





El set de datos Fashion MNIST permite construir clasificadores de ropa a partir de imágenes

- Sucesor de MNIST con mayor dificultad (pero tampoco tanto más).
- Cada imagen muestra una sola prenda de una de diez categorías. Las imágenes son en escala de grises, con una resolución de 28x28 píxeles.
- El dataset consta de 60.000 ejemplos de entrenamiento y 10.000 de test.
- Veamos el rendimiento si entrenamos un MLP igual al que entrenamos para MNIST...

Label	Description	Examples
0	T-Shirt/Top	
1	Trouser	
2	Pullover	
3	Dress	
4	Coat	
5	Sandals	
6	Shirt	
7	Sneaker	
8	Bag	
9	Ankle boots	

Extreme Overfitting MLP on Fashion MNIST



Sesgo inductivo en imágenes


- Quizá los MLP no andan bien con imágenes, y aprenden patrones que no son muy generales (próxima semana veremos el porqué).
- Probemos suerte con otro dominio más estructurado...



Una aplicación típica de los MLP es en el procesamiento de datos tabulados

- Filas en una tabla pueden verse de manera natural como los vectores de entrada.
- Pero parece que acá tampoco le va muy bien...

id	name	rows	cols
3	kr-vs-kp	3196	36
24	mushroom	8124	22
31	credit-g	1000	20
38	sick	3772	29
44	spambase	4601	57
179	adult	48842	14
715	fri_c3_1000_25	1000	25
718	fri_c4_1000_100	1000	100
720	abalone	4177	8



Tipos y escalas heterogéneas

1. Heterogeneidad de tipos y escalas

- Los datos tabulares suelen combinar variables numéricas y categóricas con unidades, escalas y cardinalidades distintas.
- Además, pueden contener valores faltantes y categorías raras.
- Estas diferencias requieren representaciones y preprocesamiento explícitos.

Una aplicación típica de los MLP es en el procesamiento de datos tabulados

2. Distribución y correlación en los datos

- **Columnas** en datos tabulados presentan generalmente una **alta correlación**, por lo que basta un subconjunto pequeño de variables para poder hacer la predicción.
- Existe habitualmente un **alto desbalance** en las **clases** a predecir.
- Todo esto es campo fértil para el sobreajuste.




The image shows a printed table with multiple columns and rows of numerical data. The numbers are arranged in a grid, with some rows and columns highlighted in blue. The text is slightly blurred, emphasizing the density and structure of the data.

¿Cómo se relaciona esto con el Teorema de Aproximación Universal?

- MLP no tienen restricción en lo que pueden aprender, por lo que les sale más fácil usar correlaciones entre el ruido en los datos y la etiqueta.
- Gran parte del arte de Deep Learning es utilizar arquitecturas que **sesguen el aprendizaje** de la red neuronal en base a la estructura de los datos, de modo que aprendan **representaciones útiles**.

Veamos cómo enfrentar al menos algunos de los desafíos de los datos tabulados y los MLP


- El primer problema (discordancia) se relaciona con la incapacidad de los MLPs de trabajar con datos que no sean numéricos (continuos) y bien distribuidos.
- Datos categóricos son un buen ejemplo de un tipo de dato complejo de manejar con MLPs
- En vez de adaptar los MLPs para que funcionen con datos categóricos, buscaremos **aprender transformaciones** que muevan los datos categóricos a un espacio numérico.
- Este tipo de transformación se conoce como **embedding**, y es de los aspectos más importante y generales de Deep Learning.




Un embedding es un vector aprendido

- Un embedding asigna cada elemento discreto a un vector continuo que se aprende para una tarea.
- La cercanía entre vectores puede capturar similitudes útiles para el predictor.
- No necesariamente reduce dimensionalidad: su dimensión es definida previamente por parte del experto.
- Aquí nos concentraremos en embeddings de variables categóricas.


En datos tabulados tendremos *embeddings* categóricos,
que actúan solamente al inicio del procesamiento




Embeddings + variables numéricas




¿Cómo implementar un embedding categórico?



One-hot × matriz equivale a seleccionar una fila



Embeddings y MLP se entrenan conjuntamente



Caso histórico: Entity Embeddings (2016)


Entity Embeddings of Categorical Variables

C. Guo y F. Berkhahn (2016)

Objetivo es predecir ventas diarias de cada tienda de la cadena Rossman

- 2.5 años de datos para 1115 tiendas.
- 1.017.210 registros, divididos en 90% para entrenamiento y 10% para test.
- No se utilizó *feature engineering*.
- Compara el rendimiento de redes neuronales basadas en *embeddings* categóricos, vs otros modelos de ML: XGBoost, Random Forest, KNN.

feature	data type	number of values	EE dimension
store	nominal	1115	10
day of week	ordinal	7	6
day	ordinal	31	10
month	ordinal	12	6
year	ordinal	3 (2013-2015)	2
promotion	binary	2	1
state	nominal	12	6





$$MAPE = \left\langle \left| \frac{Sales - Sales_{predict}}{Sales} \right| \right\rangle$$

method	MAPE	MAPE (with EE)
KNN	0.315	0.099
random forest	0.167	0.089
gradient boosted trees	0.122	0.071
neural network	0.070	0.070

TABLE III. Comparison of different methods on the Kaggle Rossmann dataset with 10% shuffled data used for testing and 200,000 random samples from the remaining 90% for training.

method	MAPE	MAPE (with EE)
KNN	0.290	0.116
random forest	0.158	0.108
gradient boosted trees	0.152	0.115
neural network	0.101	0.093

TABLE IV. Same as Table IV except the data is not shuffled and the test data is the latest 10% of the data. This result shows the models generalization ability based on what they have learned from the training data.









FIG. 2. Distance in the store embedding space versus distance in the metric space for 10000 random pair of stores.




Una técnica que permite enfrentar el segundo problema (distribución y correlación) es **Dropout**

- La observación principal de **Dropout** es que, haga lo que se haga, las capas densas de un MLP son altamente propensas a sobreajustarse.
- Para evitar esto, **Dropout** “apaga” aleatoriamente neuronas en estas capas durante el entrenamiento, con una probabilidad previamente definida, p.ej., 0,5.
- El efecto neto es que las neuronas no pueden “confiar” en las otras, por lo que aprenden representaciones más robustas.




Regularization: **Dropout**

“randomly set some neurons to zero in the forward pass”



(a) Standard Neural Net




(b) After applying dropout.

[Srivastava et al., 2014]


Waaaait a second...

How could this possibly be a good idea?



Waaaaait a second...

How could this possibly be a good idea?




Forces the network to have a redundant representation.



Waaaaait a second...

How could this possibly be a good idea?




Another interpretation:

Dropout is training a large ensemble of models (that share parameters).

Each binary mask is one model, gets trained on only ~one datapoint.

Dropout puede mejorar la generalización



Embeddings y Dropout no solucionan todos los problemas con los datos tabulados

- Los problemas con la alta correlación entre variables y el alto desbalance de las clases son transversal a todas las técnicas de Deep Learning.
- Debido a esto, las técnicas para enfrentarlos las cubriremos en otros capítulos, al revisar los modelos donde originalmente fueron aplicadas.
- Sin embargo, aunque hayan sido propuestas en otro contexto, siguen siendo aplicables a datos tabulados. Dos ejemplos son:
 - TabNet: Attentive Interpretable Tabular Learning (<https://arxiv.org/pdf/1908.07442.pdf>)
 - Neural Oblivious Decision Ensembles for Deep Learning on Tabular Data (<https://arxiv.org/abs/1909.06312>)

Cuáles son los conceptos centrales de este capítulo inicial

- ML moderno se centra en el aprendizaje de representaciones
- Fortaleza de DL: aprendizaje de features jerárquicas composicionales.
- Proceso requiere grandes cantidades de datos y cómputo.
- MLPs presentan teóricamente un esquema altamente poderoso para reconocer patrones.
- Uso complejo debido a su rápido sobreajuste.
- Para datos tabulados, el restringir el dominio mediante *embeddings* y utilizar *dropout* alivia gran parte de los problemas.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



INF3812 – Deep Learning

Arquitecturas neuronales fundamentales de Deep Learning

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación