

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



INF3812 – Deep Learning

Redes Neuronales Convolucionales (CNN)

Hans Löbel


Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación

¿Necesitamos redes distintas para datos visuales?

- Tal como vimos anteriormente, los MLP fracasan catastróficamente en conjuntos de datos visuales más desafiantes que MNIST.
- Por ejemplo, FMINIST presenta mayor variación intraclase, en parte dada por un posicionamiento no constante de los patrones visuales principales.

Label	Description	Examples
0	T-Shirt/Top	
1	Trouser	
2	Pullover	
3	Dress	
4	Coat	
5	Sandals	
6	Shirt	
7	Sneaker	
8	Bag	
9	Ankle boots	


¿Por qué pasa esto con los MLP?



Imaginemos que tenemos un problema de clasificación de imágenes urbanas



Además del excesivo número de parámetros, ¿qué podemos decir sobre la idoneidad de la estructura de un MLP para procesar imágenes?




- Imagen de 640x480 a colores
- 128 neuronas en primera capa
- $640 \times 480 \times 3 \times 128 \approx 120\text{MM}$ de parámetros solo en la primera capa!!!!
- Cada neurona ve todo simultáneamente, lo que genera una cantidad excesiva de parámetros.
- No hay equivanianza con respecto a la posición de los elementos visuales.


Veamos un poco qué pasa en la corteza visual de los mamíferos

Areas V1 – V5

(A) Medial view of functional areas



(B) Lateral view of functional areas




V1 = Primary visual cortex
V2–V5 = Extrastriate cortex


¿Qué debemos incluir entonces en una red que permita procesar adecuadamente datos visuales?

1. Representación composicional jerárquica
2. Profundidad
3. ????

Areas V1 – V5




Hubel y Wiesel (1960s) investigaron los patrones de estímulo visual en mamíferos






youtu.be/IOHayh06LJ4





youtu.be/Cw5PKV9Rj3o

Hubel y Wiesel (1960s) mostraron que patrones básicos de estímulo visual en mamíferos son detectados por **células (neuronas) específicas, altamente localizadas**




Además, neuronas responden a patrones locales y se organizan de manera **jerárquica**, aumentando progresivamente el nivel de **abstracción** de los patrones detectados




¿Qué debemos incluir entonces en una red que permita procesar adecuadamente datos visuales?

1. Representación composicional jerárquica
2. Profundidad
3. Detección de patrones/embeddings locales, equivariantes a la ubicación


Areas V1 – V5



¿Cómo podemos capturar este comportamiento con una red neuronal?





- Podemos usar neuronas locales con parámetros compartidos que cubran la entrada (ventana deslizante).
- Proveen una reducción significativa en el número de parámetros (no depende de la conectividad)
- Además, dado su tamaño, permiten capturar patrones locales en cualquier posición.



Como la salida de esta operación es también una imagen, no hay problema en aplicar múltiples capas secuenciales que operen de la misma manera

Este comportamiento puede ser modelado mediante **convoluciones**

- La convolución permite modelar neuronas como filtros locales que son aplicados en toda la imagen, de manera independiente en cada posición.
- Intuitivamente, miden cuánto se parece el filtro al sector de la imagen sobre el cual es aplicado.
- Salida de una neurona convolucional ahora entrega un mapa (antes era un número), que indica donde se podría encontrar el patrón capturado por la neurona.




¿Qué resuelve realmente una convolución?

- Reduce drásticamente la cantidad de parámetros
- Obliga a buscar patrones locales
- Permite detectar el mismo patrón en muchas posiciones
- A diferencia de un MLP, no rompe la estructura espacial de las imágenes, al trabajar sobre ellas sin aplanarlas.

¿Qué debemos incluir entonces en una red que permita procesar adecuadamente datos visuales?

1. Representación composicional jerárquica
2. Profundidad
3. Detección de patrones locales, invariantes a la ubicación


Areas V1 – V5




Uniendo todo esto, llegamos a una nueva arquitectura de red


Redes convolucionales (CNN) utilizan convoluciones como elemento central

- Están formadas (generalmente) por capas convolucionales, de *pooling* y *fully connected*.
- Disminuyen drásticamente el número de parámetros, en comparación con los MLP.
- Menos propensas al sobreajuste, gracias a su sesgo inductivo.






Antes de cualquier detalle técnico, “veamos” cómo funciona una red convolucional



<https://poloclub.github.io/cnn-explainer/>


Antes de cualquier detalle técnico, “veamos” cómo funciona una red convolucional



https://adamharley.com/nn_vis/


Convolution Layer

32x32x3 image



Convolution Layer

32x32x3 image



5x5x3 filter




Convolve the filter with the image
i.e. “slide over the image spatially,
computing dot products”

$$f[x,y] * g[x,y] = \sum_{n_1=-\infty}^{\infty} \sum_{n_2=-\infty}^{\infty} f[n_1,n_2] \cdot g[x-n_1,y-n_2]$$

↑
elementwise multiplication and sum of
a filter and the signal (image)

Convolution Layer

32x32x3 image



Filters always extend the full depth of the input volume

5x5x3 filter




Convolve the filter with the image
i.e. “slide over the image spatially,
computing dot products”


$$f[x,y] * g[x,y] = \sum_{n_1=-\infty}^{\infty} \sum_{n_2=-\infty}^{\infty} f[n_1,n_2] \cdot g[x-n_1,y-n_2]$$

↑
elementwise multiplication and sum of
a filter and the signal (image)

Convolution Layer




Convolution Layer




Convolution Layer


consider a second, **green** filter



For example, if we had 6 5x5 filters, we'll get 6 separate activation maps:




We stack these up to get a “new image” of size 28x28x6!



Examples time:


Input volume: **32x32x3**
10 5x5 filters

Number of parameters in this layer?



Examples time:

Input volume: **32x32x3**
10 **5x5** filters




Number of parameters in this layer?

each filter has $5*5*3 + 1 = 76$ params (+1 for bias)


=> $76*10 = 760$

Comparemos el número anterior, con el número de parámetros de una capa *fully connected* para un caso similar




- Imagen de 32x32
- Capa *fully connected* de 10 neuronas con bias
- 10.250 parámetros

La situación es en realidad aún peor para los MLP, ya que si usamos una imagen algo más grande como entrada (p. ej. 256x256), el número de parámetros de la primera capa convolucional no cambiaría, pero la de un MLP se elevaría por sobre el medio millón.




A closer look at spatial dimensions:




7x7 input (spatially)
assume 3x3 filter

A closer look at spatial dimensions:



7x7 input (spatially)
assume 3x3 filter


A closer look at spatial dimensions:



7x7 input (spatially)
assume 3x3 filter

7

A closer look at spatial dimensions:



7x7 input (spatially)
assume 3x3 filter

7


A closer look at spatial dimensions:

7

7

7x7 input (spatially)
assume 3x3 filter


A closer look at spatial dimensions:



7x7 input (spatially)
assume 3x3 filter


=> 5x5 output

A closer look at spatial dimensions:




7x7 input (spatially)
assume 3x3 filter
applied **with stride 2**

A closer look at spatial dimensions:




7x7 input (spatially)
assume 3x3 filter
applied **with stride 2**

A closer look at spatial dimensions:




7x7 input (spatially)
assume 3x3 filter
applied **with stride 2**
=> 3x3 output!

A closer look at spatial dimensions:




7x7 input (spatially)
assume 3x3 filter
applied **with stride 3?**

A closer look at spatial dimensions:



7x7 input (spatially)
assume 3x3 filter
applied **with stride 3?**

doesn't fit!
cannot apply 3x3 filter on
7x7 input with stride 3.



Output size:

$$(N - F) / \text{stride} + 1$$

e.g. $N = 7$, $F = 3$:

$$\text{stride } 1 \Rightarrow (7 - 3) / 1 + 1 = 5$$

$$\text{stride } 2 \Rightarrow (7 - 3) / 2 + 1 = 3$$

$$\text{stride } 3 \Rightarrow (7 - 3) / 3 + 1 = 2.33 \therefore \backslash$$

In practice: Common to zero pad the border

0	0	0	0	0	0			
0								
0								
0								
0								

e.g. input 7x7

3x3 filter, applied with **stride 1**

pad with 1 pixel border => what is the output?


7x7 output!

in general, common to see CONV layers with stride 1, filters of size $F \times F$, and zero-padding with $(F-1)/2$. (will preserve size spatially)

e.g. $F = 3 \Rightarrow$ zero pad with 1

$F = 5 \Rightarrow$ zero pad with 2

$F = 7 \Rightarrow$ zero pad with 3




Examples time:

Input volume: **32x32x3**

10 5x5 filters with stride 1, pad 2

Output volume size: ?



Examples time:


Input volume: **32x32x3**


10 **5x5** filters with stride **1**, pad **2**

Output volume size:

$(32 + 2 * 2 - 5) / 1 + 1 = 32$ spatially, so


32x32x10






Pooling layer

- makes the representations smaller and more manageable
- operates over each activation map independently:




MAX POOLING



Fully Connected Layer (FC layer)


- Contains neurons that connect to the entire input volume, as in ordinary Neural Networks



Veamos un caso de estudio

ImageNet Classification with Deep Convolutional Neural Networks

A. Krizhevsky, I. Sutskever, and G. E. Hinton (NeurIPS 2012)



1958 Perceptron

1974 Backpropagation

Handwritten Recognition
1998



General Object
Detection
2008

No more funds
awkward silence (AI Winter)


1969

Perceptron criticized



1995

SVM reigns




2005

Human
Detection




2012

Deep Learning
Rises



AlexNet fue uno de los primeros ejemplos exitosos de ConvNets




- Además de utilizar redes convoluciones, introdujo una serie de “trucos” muy útiles para el entrenamiento de redes.
- Sin embargo, el gran diferenciador fue el ser capaz de aprender efectivamente de un set de datos órdenes de magnitud mayor que los existentes hasta ese momento.

ImageNet: la primera base de datos visual práctica de gran escala

- La base para la gran mayoría de los trabajos iniciales redes convolucionales para reconocimiento visual utiliza ImageNet.
- Más de 15M de imágenes divididas en 22K categorías.
- Imágenes están relacionadas por una estructura de grafo, que captura relaciones entre ellas.
- Fueron recolectadas de la web y rotuladas utilizando Amazon Mechanical Turk.


IMAGENET




ImageNet: la primera base de datos visual práctica de gran escala


- Para realizar el entrenamiento de AlexNet, se utilizó un subconjunto de ImageNet, conocido como ILSVRC-XXXX (donde XXXX es el año).
- 1K categorías, 1.2M de imágenes de entrenamiento (1.2K por categoría).
- 50K imágenes de validación y 150K de test.
- Imágenes RGB de distintas resoluciones, pero escaladas a 256x256 para esta aplicación.
- Métricas de error top-1 y top-5.

IMAGENET





Input: $224 \times 224 \times 3 = 150528$ pixels



● Layer 1:

- nFilters = 96, Size = 11×11 , Depth = 3.
- nParams (weights) = $96 \times 11 \times 11 \times 3 = 34848$.
- Stride = 4, max-pooling = $3 \times 3:1$, nNeurons (outputs) = $55 \times 55 \times 96 = 290400$.
(obs: they use 3 zero-padding, then $(227 - 11)/4 + 1 = 55$)

● Layer 2:

- nFilters=256, Size = 5×5 , Depth = 96.
- nParams = $256 \times 5 \times 5 \times 96 = 614400$.
- Stride=1, max-pooling = $3 \times 3:2$, nNeurons= $27 \times 27 \times 256 = 186624$.

● Layer 3:


- nFilters = 384, Size = 3×3 , Depth = 256.
- nParams = $384 \times 3 \times 3 \times 256 = 884736$.
- Stride=1, max-pooling = none, nNeurons = $13 \times 13 \times 384 = 64896$.

● Layer 4:

- nFilters= 384, Size= 3×3 , Depth= 384.
- nParams = $384 \times 3 \times 3 \times 384 = 1327104$.
- Stride=1, max-pooling = none, nNeurons= $13 \times 13 \times 384 = 64896$.

● Layer 5:

- nFilters = 256, Size= 3×3 , Depth= 384.
- nParams = $256 \times 3 \times 3 \times 384 = 884736$.
- Stride=1, max-pooling = $3 \times 3:2$, nNeurons= $13 \times 13 \times 256 = 43264$.



- Layer 6: Fully connected to previous layer

- nParams = $6 \times 6 \times 256 \times 4096 = 37.748.736$.
- nNeurons = 4096.


- Layer 7 : Fully connected to previous layer

- nParams = $4096 \times 4096 = 16.777.216$.
- nNeurons = 4096.

- Layer 8: Fully connected to previous layer


- nParams = $4096 \times 1000 = 4.096.000$.
- nNeurons = 1000.

AlexNet fue entrenada utilizando “solo” 2 GPUs



- Entrenada utilizando SGD en dos Nvidia GTX 580 con 3GB de VRAM durante una semana.
- Algunos números aproximados para cuantificar el tamaño:
 - $\approx 650K$ neuronas
 - $\approx 60M$ de parámetros
 - $\approx 630M$ de conexiones


AlexNet fue entrenada utilizando “solo” 2 GPUs



- AlexNet fue uno de los primeros trabajos en cambiar las no linealidades clásicas por ReLU.
- Esto permitió que el entrenamiento fuera varias veces más rápido.

¿Cómo controlar el sobreajuste en redes con gran cantidad de parámetros?


- Capas densas del final son igualmente propensas a sobreajustarse.
- Para evitar esto, se introdujo en 2012 una técnica llamada **Dropout**, aplicada a las capas densas.
- **Dropout** “apaga” aleatoriamente neuronas en estas capas durante el entrenamiento.
- El efecto neto es que las neuronas no pueden “confiar” en las otras, por lo que aprenden representaciones más robustas.
- Más detalles la próxima clase.



Continuemos con los datos

- Si bien el set de datos es grande, el tamaño de la red obliga a aumentarlo aún más.
- Para esto se utilizaron técnicas de aumento de datos
- Por cada imagen se tomaron 5 subimágenes de 224x224 (4 esquinas y centro).
- Este proceso también se repite para el reflejo de cada imagen.
- Con esto, lograron aumentar 10 veces el tamaño efectivo del set de datos.
- Finalmente, a cada imagen se le resta la media de cada canal de color

IMAGENET






Aumento de datos puede verse como otra forma de controlar la complejidad de una red




Aumento de datos puede verse como otra
forma de controlar la complejidad de una red


T



Aumento de datos puede verse como otra forma de controlar la complejidad de una red




La combinación de todo esto generó resultados sorprendentes para la época




- Error top-5: 15.3%
- Error top-1: 26.2%
- Error humano: aprox. 8%


La combinación de todo esto generó resultados sorprendentes para la época




La combinación de todo esto generó resultados sorprendentes para la época



La combinación de todo esto generó resultados sorprendentes para la época



La combinación de todo esto generó resultados sorprendentes para la época



Rendimiento ha continuado mejorando



(a) Siberian husky



(b) Eskimo dog

- En la actualidad, las arquitecturas para reconocimiento visual son bastante más profundas (cientos de capas) y tiene algunos otros detalles que revisaremos la próxima clase.
- Mejores métodos tienen alrededor de 89% top-1 y 99% top-5.
- Algunas muestras con código pueden verse en <https://paperswithcode.com/sota/image-classification-on-imagenet>

Cuáles son los conceptos centrales de esta clase

- Redes convoluciones (en 2012) permitieron resolver problemas que tenían los MLP gracias a el uso de convoluciones (y otros detalles más).
- El aspecto central de las CNN es el aprendizaje de features locales en un esquema composicional jerárquico profundo.
- Si bien no son un modelo de la corteza visual, evidencia biológica valida el esquema de construcción de las CNN.
- Simplicidad y buenos resultados llevaron a estas redes a ser las más utilizadas durante bastante tiempo.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



INF3812 – Deep Learning

Redes Neuronales Convolucionales (CNN)

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación