

GABRIELA ARRIAGADA BRUNEAU

Los sesgos del algoritmo

LA IMPORTANCIA
DE DISEÑAR UNA
INTELIGENCIA
ARTIFICIAL ÉTICA E
INCLUSIVA

Los sesgos del algoritmo
de GABRIELA ARRIAGADA

© 2024 de la obra por GABRIELA ARRIAGADA

© 2024 de la primera edición por LA POLLERA EDICIONES

Primera edición: mayo 2024

ISBN: 978-956-6267-25-6

Edición: Daniel Campusano

Asistencia editorial: Camila Chomali

Diseño: Pablo Martínez

LA POLLERA EDICIONES

www.lapollera.cl

ediciones@lapollera.cl

Instagram: [@lapolleraediciones](https://www.instagram.com/lapolleraediciones)



Índice

Introducción	7
Capítulo I	
Certezas e incertezas: los reales alcances de la IA	13
Capítulo II	
Discriminación, sesgos y feminismo en IA	29
Capítulo III	
Otros principios éticos de IA y su relación con la inclusividad	55
Capítulo IV:	
Hacia dónde debemos ir	75

Introducción

Cuando se habla de ética en inteligencia artificial se piensa en cómo hacer “algoritmos éticos”, en cómo lograr una “inteligencia artificial justa”, en los principios que deben guiar su desarrollo, en las responsabilidades que tienen quienes crean y usan estos sistemas. Y sin duda, estas aristas del tema dominan las discusiones sobre la ética aplicada, pero en mi caso hay un aspecto que me interesa muchísimo y he estudiado en particular: la inclusividad.

La ética aplicada se enfoca en resolver preguntas sobre problemas o situaciones concretas. No reflexiona sobre “qué es lo bueno”, ni tampoco busca desarrollar teorías morales: se identifican problemas éticos y se buscan metodologías y justificaciones críticas para decidir el curso de acción. En los últimos siete u ocho años, desde fines del 2015, aproximadamente, los cuestionamientos éticos ligados a la IA han surgido como una línea de investigación central en el desarrollo de esta tecnología. Y dentro de los temas de debate, uno de los más discutidos ha sido el problema de los sesgos y discriminación.

Algunos libros y artículos académicos, por ejemplo, han resaltado debates sobre sesgos raciales a partir del caso COMPAS en Estados Unidos. COMPAS fue un algoritmo utilizado para

evaluar el riesgo de reincidencia de los acusados, es decir, cuál era la probabilidad de que volvieran a cometer un crimen, e informar de ese riesgo a los jueces que decidirían si se asignaba una medida cautelar. Su uso fue criticado tras una investigación de ProPublica en 2016, que reveló una tendencia a predecir erróneamente un mayor riesgo de reincidencia entre los delincuentes negros en comparación con los blancos, aun cuando —en la práctica— se corroboró que quienes habían sido catalogados de alto riesgo no volvieron a reincidir y quienes fueron catalogados de bajo riesgo sí lo hicieron.

Este hallazgo generó preocupaciones sobre cómo el uso de algoritmos podría perpetuar las desigualdades existentes en el sistema de justicia penal, destacando la necesidad de transparencia, auditorías independientes y regulaciones que aseguren la implementación justa y sin prejuicios de la IA en contextos críticos. Pero, a la vez, se inició un debate académico sobre qué es lo que entendemos como justo, qué es lo que queremos lograr con implementar IA en contextos críticos, y cómo los sesgos sociales —en este caso proveniente de los datos de entrenamiento— reflejan la discriminación latente que sufren las personas de minorías raciales.

Estas discusiones sobre la discriminación en IA avanzaron en distintos contextos a medida que los sistemas se implementaban en ámbitos como la educación, la minería, los diagnósticos de salud, las labores de servicio al cliente, los créditos bancarios, etc. Y fueron surgiendo soluciones técnicas para abordar los sesgos y mitigarlos: nuevas métricas de justicia para asegurar paridad en el trato de diferentes poblaciones en un modelo, y criterios generales para asegurar que, ciertos sesgos o variables, no afectaran las representatividades en modelos de IA.

Los avances han sido valiosos y empezaron a practicarse en diversos desarrolladores de IA y, también, integrarse en los currículos que educan a los futuros profesionales. Sin embargo,

eso es solo una dimensión del problema porque los sesgos reflejan una realidad sociotécnica mucho más profunda. Los sesgos nos preocupan porque nos llevan a cometer discriminaciones o tratos injustos, pero, en el mismo punto, debemos entenderlos en sus múltiples facetas. Aun cuando tengamos una gobernanza de datos apropiada, protocolos de mitigación de sesgos robustos y evaluaciones constantes del impacto de los sistemas creados, esto no es suficiente. Podemos ver a los sesgos como instancias indeseadas, o podemos entenderlos dentro de una red de influencias que se manifiestan en instancias específicas, pero que —al entender su origen y contexto— podemos comprender qué está detrás de ese sesgo. Por esto, solo para comenzar, existe una discusión importantísima sobre cómo entendemos los problemas de discriminación, representatividad e inclusividad al adoptar esta tecnología.

En este libro busco compartir mis ideas, inquietudes y reflexiones sobre la importancia de adoptar una visión sociotécnica para avanzar en perspectivas de inclusividad en el desarrollo de la IA. La idea es aplicar una ética contextualizada a las necesidades de aquellos grupos que han sido invisibilizados en la sociedad, particularmente, las minorías de género y las minorías neurodivergentes. Desde luego no vengo a ofrecerles soluciones incuestionables, pero sí compartirles una narrativa, una perspectiva, y una experiencia personal para enfocar ciertos problemas éticos y avanzar hacia estas soluciones, las cuales, por supuesto, requieren un trabajo íntimo desde la interdisciplina.

En específico, vengo a mostrarles cómo yo entiendo y vivo estos problemas, y de este modo, abrir el diálogo sobre lo que es pensar la ética de IA desde una mente “neuroqueer”. Porque, a propósito, recién de adulta supe de mi identidad de género no binaria y, a mis treinta años, fui diagnosticada —por fin— como parte del espectro autista. Estas experiencias importan, pues al descubrirme y encontrarme pude liberarme de las barreras que

me habían impuesto. Nunca olvidaré las veces que negaron mis experiencias. Nunca olvidaré que debí enmascarar mi comportamiento y sufrir en silencio porque profesionales de la salud y gente a mi alrededor me negaban quién era. “Es que tú no puedes ser autista”, me decían. “Porque eres demasiado sociable”. “Porque te va bien en el colegio”. “Porque no te ves discapacitada”.

Me costó mirar atrás y comprender por qué tuve tantos problemas para encajar, por qué sufría tanto de ansiedad, por qué enfermaba tantas veces en el año a pesar de tener un cuerpo saludable, por qué nunca sentía que estaba incluida en ningún lugar, excepto en mi hogar y con amigos que, con el tiempo, descubrí que también eran neurodivergentes.

Desde el momento en que pude comprender cuáles eran mis verdaderas necesidades y comprobar que, aunque fueran invisibles a ojos de otros, eran reales, recién comencé a entender la inclusión no como una aspiración, sino como una necesidad humana básica. Y así no dejé de pensar cómo traducir estas motivaciones a mi trabajo y desarrollar una ética aplicada a la IA que debe, desde su práctica integrada, desarrollar sistemas inclusivos más allá de lo técnico. Pero esto, desde luego, no es una tarea fácil. Por una parte se requiere que el desarrollo de la IA integre objetivos de inclusividad en todo su ciclo de vida. Y esto, a su vez, demanda un compromiso del ecosistema completo, de quienes diseñan, desarrollan, implementan, usan y, también, evalúan y legislan, pues debe haber un alineamiento que reconozca y valore la diversidad de experiencias humanas: solo así podemos asegurarnos de que las nuevas tecnologías reflejen y respeten esa diversidad.

Esto último requiere que la inclusividad sea considerada un eje transversal en la educación en IA. No basta con integrar módulos de ética en los programas de estudio, o incluir la relevancia de los principios éticos en auditorías o protocolos gubernamentales. Estos pasos son necesarios, pero no suficientes. Como

sociedad necesitamos desarrollar una alfabetización ética crítica profunda, que capacite a los profesionales para que puedan identificar y contrarrestar activamente efectos indeseados de la IA, y al mismo tiempo, asistir a usuarios o afectados por el uso de estas tecnologías. Debemos romper las brechas de injusticia epistémica que puedan existir.

En palabras simples, el concepto de injusticia epistémica —acuñado por la filósofa Miranda Fricker— se refiere a formas concretas en que grupos de personas son sistemáticamente marginados en su capacidad de conocedores. Podemos distinguir dos formas: el testimonio y la hermenéutica. La injusticia epistémica testimonial ocurre cuando el discurso de alguien es desacreditado debido a prejuicios sobre su identidad social. La injusticia hermenéutica, en tanto, ocurre cuando las experiencias de un grupo social no están representadas en la cultura dominante, por lo que esos grupos deben luchar por comprender y comunicar sus experiencias.

Si queremos desarrollar sistemas o adoptar prácticas que no caigan en injusticia epistémica, debemos asegurarnos de que esas experiencias y voces sean representadas y acreditadas como válidas para entrenar e implementar soluciones. Así, lograr inclusividad implicaría comprometerse con métodos de diseño que sean participativos, donde comunidades afectadas y usuarios finales sean partícipes en la definición de lo que es una IA justa y equitativa. Para esto, lo más sensato y perdurable, será fortalecer una colaboración estrecha entre disciplinas como la tecnología, las ciencias sociales y las humanidades. Poner en la mesa todas las variables y, mediante una perspectiva sociotécnica, lograr una comprensión más rica y matizada del impacto de la IA.

Capítulo I

**Certezas e incertezas:
los reales alcances de la IA**

**Iniciando el viaje:
agreguemos colores a una discusión metalizada**

¿Cuál es la verdad? ¿De qué manera nos acercamos a la verdad? Para aproximarnos, creo que no basta simplemente ver cómo suceden las cosas o saber por qué suceden. Todos los aspectos de nuestra existencia ameritan una conversación más profunda y se hace necesario conectar diversas disciplinas y vivencias para llegar o aproximarse a *la* verdad, o a *eso* que está detrás de nuestras inquietudes.

En esta búsqueda —en esta lluvia de interrogantes— me topé con la ética aplicada: un nicho maravilloso para ahondar en los desafíos que nos rodean y preguntarnos, por ejemplo, por qué consideramos a un ser como persona o no persona, o cuáles son nuestras responsabilidades morales en relación a los animales. Estudié estas distinciones cuando estaba haciendo mi pregrado en Filosofía, sobre todo leyendo a Peter Singer, un filósofo muy conocido por el tema de la liberación animal y por incluir a animales no humanos dentro de la definición de persona. Temas fascinantes que tenían diversas bajadas y, sobre todo, un sentido social.

Años después, en 2017, tuve la suerte de seguir estudiando y comencé a observar el boom de temas relacionados a los datos y la inteligencia artificial. Por entonces, presencié las discusiones

influenciadas por casos como Cambridge Analytica, cuando las elecciones presidenciales de Estados Unidos fueron manipuladas a través de redes sociales como Facebook para generar datos tendenciados. Cuando se abrieron estos debates éticos, todos querían tipificar la discusión y decir “la ética de datos va a ser esto, la ética de inteligencia artificial va a ser esto otro”; pero a mí, la verdad, no me hacía sentido cómo se presentaba la problemática, o al menos no intuitivamente. Yo veía que los debates se centraban en temas macro de las grandes compañías, y que, a pesar de que las consecuencias de sus acciones afectaban a una mayoría de la población, la narrativa que dominaba instalaba la pregunta de cómo mejorar los sistemas, pero nunca cuestionaba si es que usarlos era algo necesario o —en primer lugar— beneficioso. Me sonaba, una vez más, a un debate entre gente privilegiada sobre asuntos privilegiados, y especialmente de un privilegio empujado por el norte global, aun cuando las consecuencias de estos juegos de poder nos afectaban en el otro lado del mundo.

Cuando escuchaba conceptos como la brecha digital y las faltas de acceso a tecnología, me preguntaba qué pasaba con la otra mitad del mundo. Existen problemáticas en Latinoamérica o África que no se presentan de la misma manera, que responden a otros orígenes u obstáculos que debemos comprender y poner en perspectiva. Así me fui motivando a dilucidar lo que había detrás. Me pareció que la discusión se estaba abriendo y me gustó pensar que todo esto se estaba construyendo, que no existían antecedentes de lo que se estaba gestando. Sentí que había una oportunidad única, que podía explorar temas y contribuir con alguna experiencia y un punto de vista diferente. Hay definiciones que aún no están claras y esto —como desafío científico— por supuesto que siempre resulta atractivo.

Así empecé a interesarme por algo bien específico dentro de la ética de la IA que son los temas de sesgos y justicia. Un


tema presente en las directrices mundiales, privadas, institucionales y gubernamentales. Por esta misma transversalidad, me hacía ruido cómo la gente hablaba de justicia, en particular, porque la terminología utilizada en IA no es el concepto de *justice* en inglés, sino *fairness*. Este término en IA y aprendizaje de máquinas, se refiere, primordialmente, a la corrección de sesgos algorítmicos. En español no tenemos esa distinción y, quizás, podríamos entenderlo como “imparcialidad” (pero no alcanza a ser realmente preciso). Fairness, por tanto, tiene una connotación bastante técnica y tiene que ver con cómo un modelo es capaz o no de discriminar frente a ciertos grupos o individuos.

Hay muchas métricas que calculan qué tan capaz es un modelo de identificar, clasificar y predecir ciertas variables para un grupo. Al pensar la idea de fairness, me pregunté de qué hablaban estas personas y consideré que el concepto era “metalizado”. Todo se veía como una bolita metalizada, muy brillante, muy tecnológica, muy futurística, pero vacía por dentro. Todo parecía tratarse de métricas, algo frío.

Y al respecto, varios investigadores han criticado esta obsesión por las soluciones tecnológicas desde el “tecnocentrismo” y el “tecnosolucionismo”. Grandes compañías y desarrolladores adoptan esta postura y, al entender la tecnología como algo neutro y objetivo, les permite tratar a los sesgos desde la misma tecnología. Esto, sin embargo, simplifica los factores éticos y sociales que están en el corazón del problema.

En específico, la profesora estadounidense Meredith Broussard habla del “tecnochovinismo”, una creencia en que la tecnología es siempre la mejor solución, lo que lleva a quitarle valor a las habilidades y experiencias humanas. Broussard llama a cuestionarnos si es que estamos usando los instrumentos correctos, ya que a veces la mejor opción para solucionar los problemas sigue siendo nuestra propia realidad.

Considerando lo anterior, me convencí de que el fairness debía contener mucho más en el fondo: aristas institucionales, políticas, sociales, y no solo contener, claro, sino interactuar con estas dimensiones de justicia.



En esta búsqueda me encontré con mujeres poderosas como Kate Crawford, Safiya Noble, Cathy O’Neil, Joy Buolamwini, Caroline Criado-Pérez, Catherine D’Ignazio, Lauren Klein o Timnit Gebru. Ellas empezaron a decir “esto no basta”, “necesitamos contexto”, “necesitamos preguntarnos qué es la discriminación”, “necesitamos pensar cómo definimos una discapacidad”. Si nos interesan esas minorías —sistemáticamente discriminadas por un algoritmo— debemos entenderla en sus dimensiones. Y si bien la revolución de la IA ha simplificado muchas discusiones, es posible plantearse cómo lograr una inclusión real desde el feminismo, cómo podemos ayudar a fortalecer la igualdad de trato y la representatividad.

En este sentido, el feminismo en la filosofía de las ciencias, y aplicado a estas nuevas tecnologías, lo hace de una manera tan bella, tan sofisticada y tan contextual, que ahonda en la manera que se están definiendo las nuevas perspectivas dentro de la misma ética. Y lo que busca la visión sociotécnica es, precisamente, contextualizar, ir hacia quienes van a ser afectados y situar sus realidades, conocimientos y necesidades. Si vamos a crear

un modelo que se utilizará en el Ministerio de Salud, por ejemplo, debemos ser capaz de entender a quiénes va a afectar, cómo los va a afectar, qué diferencias puede haber al interpretar un diagnóstico. Se deben considerar todas las complejidades implicadas. El enfoque sociotécnico busca que podamos entender el problema social como un todo. Que esa bolita metálica del criterio de *fairness*, se transforme en algo brillante, suave, acogedor, que no se cierre a un tecnocentrismo, sino se abra a una visión social de diferentes enfoques, colores, matices.

Como docente suelo transmitir estas ideas a mis estudiantes. A mis estudiantes mujeres (quienes siguen siendo la minoría en carreras altamente masculinas); a mis estudiantes hombres (quienes deben reconocer y hacerse cargo de estos problemas); a mis estudiantes trans, no binarios o de otras minorías de género (que buscan ser visibilizadas); y por supuesto, a mis estudiantes del espectro neurodivergente, con discapacidades visuales o auditivas, o que vengan de realidades económicas y sociales de vulnerabilidad. Sus experiencias importan, y deben comprender el mundo que se está gestando: un mundo altamente tecnológico que nos ofrece muchas oportunidades y visiones capaces de modelar nuevas realidades que puede incluirlos, pero, del mismo modo, también excluirlos. Mi intención es traspasar esa inquietud filosófica, e ir gestando instancias de cuidado e inclusividad.

Parte de mi objetivo es transformar la noción del desarrollo tecnocéntrico de la IA, ya sea por falta de conocimiento o por una creencia de que la tecnología es la solución a problemas sociales. Problematicar, asimismo, la idea de que las soluciones tecnológicas van a ser la solución a todos nuestros problemas, o que deban ser el centro de nuestros esfuerzos para avanzar como sociedad. Porque la tecnología depende de lo social y lo social se alimenta de la tecnología. Porque lo que genera transformaciones robustas y profundas es la conexión de los seres humanos, la naturaleza

y nuestro contexto, lo cual incluye la tecnología. Así, una vez situados en este ecosistema tecnológico, social y ético, es cuando realmente tenemos una revolución tecnológica exitosa y, más temprano que tarde, podemos sembrar las semillas y ver florecer una ética aplicada que fomente esta ansiada inclusividad.

¿Qué es la IA?

Una buena manera de definirla es imaginarla como un programa computacional capaz de aprender y simular como nosotros pensamos: cómo aprendemos, cómo entendemos y clasificamos aspectos en nuestra vida diaria. Esta inteligencia ayuda a un sistema computacional a entender cosas, a tomar decisiones, realizar tareas de clasificación, identificación y predicción. A esta altura, la IA ya es capaz de autoentrenarse, optimizarse, aprender a través de ejemplos y experiencias que nosotros le entregamos mediante la información que manejamos o accedemos.

Pero, dentro del concepto mismo, hay un debate sobre qué es realmente una inteligencia. Esto ha generado diferentes perspectivas, y es importante aclarar que no se trata simplemente de una inteligencia falsa o artificial.

Hay diferentes aspectos del debate.

Por una parte, hay personas que creen que la inteligencia natural o humana es superior y, por lo tanto, ni siquiera debiese llamarse inteligencia artificial: que en realidad deberíamos hablar de herramientas o capacidades, pero no definirla como inteligencia. Parte del debate, en este sentido, incluye a quienes creen que hay aspectos propios del humano que nunca van a ser “artificializables”, como por ejemplo la creatividad, las emociones, la conciencia, si es que llegamos a alguna definición de conciencia.

Sin embargo, la IA ha desarrollado diferentes áreas de estudio y herramientas específicas que le permiten hacer distintas cosas que nosotros utilizamos día a día. Hace muchos años

existen objetos que funcionan a través de IA y, en esta línea, tenemos el aprendizaje automático que consiste en enseñar a los sistemas computacionales a aprender a partir de ejemplos. Cuando tú le muestras muchas veces al computador tu perro, o tu gato, eventualmente ese sistema va a ser capaz de distinguir a tu mascota de todos los otros animalitos y decir “ahí está tu perrito”, “ahí está tu gatito”. La gracia de entrenar a un sistema de aprendizaje automático es que, eventualmente, podrías darle la siguiente información: “Cuando veas que es mi gato, entonces dale tal porción de comida”. Una cámara con un aprendizaje automático entrenado, identificará la cara de tu gato y no la de otro gato. Eso implica una toma de decisiones y, en ese sentido, es eso lo que vamos a distinguir de una IA.

Pero es importante entender que la IA no funciona de la misma manera en que los humanos tomamos decisiones. Si lo pensamos bien, tenemos distintas motivaciones para tomar una decisión, y es probable que la mayoría de ellas sean poco lógicas o estructuradas. A veces tomamos una decisión de qué comer porque sentimos el impulso o el antojo. O qué lugares visitar porque lo vimos en película, o escuchamos relatos de amigos. Así, se hace muy importante desmitificar que la IA —que distingue patrones— está programada. Es cierto que, según lo que se le dice que haga o no haga, se entrenará para hacerlo de manera efectiva, rápida y concreta, pero no tomará una decisión ni tendrá la capacidad de deliberar o ponderar opciones de manera profunda. Al menos tal y como existe hoy, la IA no tiene la capacidad de razonar moralmente, sino solo de imitar decisiones que tienen un impacto moral.

Ahora bien, existe otra herramienta —otra área de la IA— que son las redes neuronales. Estas últimas son un intento de “computacionalizar” el cerebro humano, y de nuevo, esto puede sonar como si estuviésemos “creando un cerebro artificial”, pero no es tan así. Las neuronas del cerebro se interconectan y comunican

entre ellas y nos dan impulsos para realizar acciones (o básicamente para existir). De alguna manera, mientras más utilizamos nuestro cerebro y más interconexiones realizamos, más cosas podemos lograr de manera cognitiva.

Cuando somos guaguas y estamos recién generando esos caminos neuronales, somos limitados sobre qué podemos comprender y qué no; cuando ya estamos en el jardín infantil, en tanto, tenemos mucho más desarrollo de caminos neuronales, lo que nos permite tener conversaciones más amplias, identificar cuando necesitamos ir al baño, aprender a leer, reconocer colores, etc. Las máquinas funcionan de esa manera y, por eso, pareciera que imitan este paso de neuronas. Pero, en realidad, lo que hacen es utilizar capas de diferentes iteraciones que les permiten profundizar su conocimiento.

Las características de las redes neuronales, a diferencia de otros tipos de aprendizaje, son muy complejas y permiten utilizar grandes cantidades de información para afinar la manera en que el modelo computacional pueda realizar una acción. Si uno tiene una imagen (y quiere que el modelo aprenda a reconocerla), esa imagen se divide en muchísimos píxeles: píxeles como los que uno ve en una foto, o los que antes se veían en la televisión cuando cada pixel cuadradito era un tipo de entrada que se le da a la red neuronal. Todas esas entradas, luego pasan por una serie de procesos donde hay diferentes capas; y lo que hacen las capas es darles diferentes pesos a estas imágenes: a cada píxel le dan un peso para que sea reconocible y vaya formando la imagen. Le podemos preguntar a la red neuronal: “¿Me podrías decir qué hay en la imagen?”. Y, usualmente, las primeras veces que entrenamos un modelo no nos va a decir qué es esa imagen. No pasa automáticamente ni por arte de magia. Así como a un niño se le enseña que un color amarillo no es naranja, no es verde, no es azul; la máquina también debe aprender qué son todos esos píxeles y qué es lo que está creando o identificando.

De este modo, cuando le preguntamos a una máquina si una figura es un círculo, un cuadrado o un triángulo, le damos un círculo descompuesto en muchos píxeles y nos responde: hay un 70% de probabilidad de que esto sea un cuadrado. Y, como retroalimentación, le respondemos: “No, máquina, no es tan cuadrado. Dale más píxeles al círculo, menos píxeles al triángulo, menos píxeles al cuadrado”, y así —después de repetir muchas veces el proceso— es capaz de distinguir qué figura es, idealmente, con un porcentaje de precisión sobre el 80%. Cuando dice “esto es un círculo”, recién consideramos que la máquina ya es capaz de distinguir círculos de cuadrados o triángulos.

Así se entrenan, del mismo modo, los sistemas de identificación facial o de identificación de objetos. Cuando abrimos la cámara del teléfono y utilizamos las nuevas aplicaciones que nos permiten decir qué es este objeto, cuál es su marca, pasaron por entrenamiento de modelos y siguen patrones bastante similares.

Qué no es IA y sus limitaciones

Ya existen diversos aspectos que funcionan con inteligencia artificial y tenemos expectativas poco realistas sobre sus capacidades. Pero si tuviéramos que explicar sus limitaciones deberíamos relacionarlas a su falta de sentido común: la comprensión de nuestro entorno, leer códigos sociales, tomar decisiones arraigadas a un razonamiento profundo y prudente.

Como personas entendemos y somos capaces de justificar nuestras acciones —incluso si son emocionales o impulsivas—, pero la IA no tiene esa capacidad. Recordemos que es un sistema computacional entrenado: utiliza datos y una serie de reglas y parámetros que son evaluados por humanos; e incluso, cuando logra realizar procesos automatizados, sigue limitado por ese constructo computacional. No podemos hablar de un sistema que se guía por un *sentido común*. La IA aprende a partir

de bases de datos y de entrenamiento, pero no comprende qué está aprendiendo.

La IA no tiene nuestras complejidades sentimentales, ni tampoco comprende el humor. Puede imitarlo según patrones, pero no lo *siente*. Considerar esto es importante para evitar antropomorfizar a la IA, fenómeno que sucede cuando tenemos menor conocimiento sobre cómo funcionan las tecnologías. Y que pasa *aún más* cuando tienen una interacción específica con nosotros, como pueden ser los chatbots que generan una conversación y, al imitar o predecir qué es lo que uno quisiese escuchar, tendemos a sincronizarnos con lo que esperamos que esa tecnología sea capaz de hacer.

Desde pequeños solemos ponerle nombre a nuestro computador, o nos referimos a objetos como parte de nuestros amigos (un peluche, un cojín, etcétera), y lo mismo pasa con tecnologías modernas como Alexa o Siri. Pero cuando la IA opera en contextos de vulnerabilidad, sí debemos tener ojo porque, justamente, es en esos ambientes donde un robot puede estar a cargo de una persona que tiene discapacidades, ya sean cognitivas, afectivas o físicas (como puede ser una persona de tercera edad con Alzheimer, un niño ciego, o una joven con síndrome post traumático). En estos casos, es muy importante que la antropomorfización se detenga o se controle, porque puede causar mucho más daño a largo plazo.

A partir de sus mencionadas características de aprendizaje, no podemos hablar de una IA súper inteligente. Es cierto que existe un debate sobre la IA general —a la que se espera que lleguemos algún día— como un punto donde la humanidad se tope con un sistema completamente autónomo que, quizás, tenga factores evolutivos y se desarrolle por sí misma. Pero en este libro nos enfocaremos en el hoy, en cómo la IA nos afecta o nos puede ayudar en esta época.

Por mucho tiempo ha habido una percepción de que el trabajo hecho por la IA o por algoritmos es más objetivo, neutro o

más justo, pero esto no es así. En efecto, la IA es falible y puede cometer errores porque carece de autocrítica, no puede justificar sus decisiones, sigue dependiendo de los seres humanos y es nuestra labor estar pendientes de cómo está impactando nuestro contexto. La IA, en otras palabras, no viene a resolvernó la existencia, pero puede ayudarnos a mejorarla. Nos permite alcanzar análisis de información que antes no teníamos, y aunque hemos llegado a niveles de procesamiento cada vez más poderosos, no debemos olvidar que la IA, por sí sola, no significa algo. Nosotros la significamos.

Significando la IA: un sistema sociotécnico

La revolución tecnológica de las últimas décadas nos ha impulsado a navegar fronteras éticas que ya han sido constantemente disputadas a lo largo de la historia. Hace pocos años, referirse a los robots o a una supercomputadora que se apodere de todo, era sencillamente hablar de ciencia ficción, pero hoy es parte de una discusión diaria. Aunque el tema implica mitos y verdades, ya no es fruto de nuestra imaginación.

Hoy todos ocupamos innovaciones tecnológicas que usan IA en nuestra vida diaria: al operar nuestros teléfonos y los GPS de los autos, al utilizar asistentes virtuales, editores de texto o imágenes, al atender algoritmos de recomendación de contenido, etc. Porque la IA no solo ha avanzado en su relación con la sociedad, sino que de a poco —a veces de manera persuasiva y silenciosa— ha moldeado la forma en que trabajamos, en que nos comunicamos, e incluso —me atrevería a decir— cómo pensamos. Nos ha llevado a alcanzar un nivel de variables mucho mayor y, por esto, nos permite entender los problemas de manera diferente. Pero, además, nos hace facilitar procesos epistémicos, es decir, cómo conocemos algo, cómo procesamos información nueva; lo que comienza a generar nuevos caminos de conocimiento en una era de inmediatez.

La teoría de sistemas sociotécnicos se originó posterior a otra de las grandes revoluciones sociales y tecnológicas: la revolución industrial. Buscaba establecer las interacciones entre obreros y máquinas, dada la complejización de interacciones y relaciones que las nuevas dinámicas de trabajo traían consigo. De una manera análoga, es posible hablar de un entendimiento sociotécnico de la IA y su ecosistema, diseño, desarrollo, uso e implementación. Esto último nos plantea preguntas renovadas sobre el impacto ético, en especial porque, a diferencia de los otros desarrollos tecnológicos que encerraban un debate (la clonación, los anticonceptivos, energía nuclear, etc.), los avances de la IA no logran asentarse lo suficiente porque, como van cambiando continuamente, los debates éticos no maduran de inmediato y no dejan de acumular nuevas aristas.

Siempre vemos más atrás del desarrollo científico, pero, en este caso, la brecha se hace cada vez más grande. Avanzamos y seguimos avanzando, pero no nos detenemos a reflexionar, y es ahí donde la ética aplicada ofrece un espacio de análisis. Es difícil detener los progresos computacionales, pues es innegable que la IA nos trae diversas mejoras y utilidades, no solo en el ámbito científico sino en nuestra vida diaria. ¿Pero cómo podemos ir pensando esas adaptaciones? ¿Cómo podemos generar estos diálogos?

Para mí, esta reflexión se inicia al adoptar una perspectiva integral donde tomamos temas del derecho, la sociología, la antropología, la filosofía, la ciencia de datos y las hacemos conversar. Ya no se trata simplemente de debatir y definir posturas disciplinares aisladas, porque la mayoría de las veces no tenemos respuestas y el nivel de permeación del tema es transversal. Y como, además, necesitamos tomar decisiones prácticas ahora, no mañana ni en diez años, es fundamental que estas perspectivas se planteen de manera inter y multidisciplinaria.

Nadie dice que encontraremos soluciones definitivas, porque lo más natural es que muten continuamente. Y no basta con

pensar el problema en sí, sino debemos que entender las dimensiones de su aplicación, los temas de sesgo, de privacidad, de transparencia, las responsabilidades, las pérdidas de empleo, y un largo etcétera. Porque la gran diferencia de la IA con otros entes que son objeto de la ética —como el medioambiente o los animales—, es que no está viva, que la hemos creado nosotros y, por ende, es un instrumento que extiende nuestra capacidad cognitiva y moral. Nosotros tomamos decisiones respecto a cómo modelar un auto que se maneja solo: debemos decidir cuándo frena y, si tiene que salvar a alguien, a quién va a salvar. Esas inquietudes y decisiones no son banales y, probablemente, serían diferentes en cada cultura según sus idearios y legislaciones.

Para entender: la misma idea de utilizar algoritmos para clasificar personas, ya implica una decisión moral muy significativa. ¿En virtud de qué clasificamos a las personas? La IA, en ese sentido, necesita de esta perspectiva sociotécnica, porque no se trata simplemente de una innovación tecnológica. A diferencia de la imprenta o la electricidad —adelantos que eran realidades tangibles para facilitarnos la vida—, la IA es parte de un ecosistema que entrelaza la tecnología, la sociedad, y los valores humanos. El estudio sociotécnico de la IA va más allá de decidir cómo funciona y para qué la vamos a usar. Lo que nos interesa son las dimensiones culturales, económicas, políticas y éticas de su despliegue.

Al diseñar tecnología en IA, debemos asumir que las políticas y vulnerabilidades están interactuando entre ellas y establecen diferentes patrones según las necesidades y contextos específicos. Un problema de justicia en África, en Latinoamérica, o en Europa, se va a manifestar con variables diferentes. Por esto no hablamos simplemente de “fairness” como ese término frío y mecánico, sino de justicia. La IA ha desencadenado conocimientos y necesidades que demandan ser enfrentadas desde un pensamiento crítico de los problemas, los riesgos, y los beneficios que

conlleve. Podemos recordar el conocido caso del científico Robert Oppenheimer: decisiones humanas-políticas lograron que una teoría que en sí misma no es dañina lo sea. ¿Pero cómo decidimos aplicarla? ¿Qué es lo dañino? Entender esas sutilezas son tremendamente importantes a la hora de proyectar los nuevos alcances computacionales.

En síntesis, no podemos hacer sociotecnología solo desde la matemática aplicada, o solo desde la filosofía. Nuestra sociedad requiere de un entendimiento de nuestras complejidades, de problemas o focos que implican diversas disciplinas y, quizás más importante, un entendimiento contextual de experiencias y necesidades de aquellos que se ven afectados, positiva o negativamente por la IA.

Capítulo II

Discriminación, sesgos y feminismo en IA

Conocimientos situados y “objetividad fuerte”

Hay varias categorías de sesgos que podemos encontrar en el ecosistema de la inteligencia artificial: los sesgos cognitivos, sociales o técnicos, son los más comunes y cada cual tiene otra lista de tipos de sesgo. Por ejemplo, un sistema de IA diseñado para hacer un análisis de sentimientos en texto, como puede ser la revisión de evaluaciones (reviews) o posts en redes sociales, puede estar sesgado debido a las sutilezas del lenguaje que no distingue, y que pueden discriminar maneras de expresarse de diferentes culturas o hablantes no nativos.

Esto último refleja tanto un sesgo cultural —adoptado por la IA en virtud de los datos de entrenamiento— como también de un sesgo técnico, de “heurística de disponibilidad”, que surge por una falta de diversidad de datos de entrenamiento que genera resultados sesgados. Y para contextualizar el origen de los sesgos, el feminismo de datos y las teorías feministas de filosofía de las ciencias, nos ofrecen un marco robusto para analizar estos desafíos éticos.

¹ Se refiere a nuestra tendencia a sobreestimar la probabilidad de un evento que tal vez no es tan frecuente, basado en la información que tenemos disponible o más presente. Por ejemplo, cuando vemos una película de ataques de tiburón, y luego creemos o asociamos el riesgo de ser atacados como un riesgo real, a pesar de no ser muy alto. Asimismo, un sistema de IA puede tener este sesgo, al realizar un análisis de probabilidad en virtud de los datos que tiene disponibles por su entrenamiento, en especial en las primeras instancias de prueba.


Al respecto, hay dos conceptos clave para mostrar la importancia que estas tradiciones teóricas pueden tener en la discusión. Los conocimientos situados de Donna Haraway y “la objetividad fuerte” de Sandra Harding, critican el ideal de una perspectiva universal y no-sesgada de la ciencia. El concepto de conocimientos situados de Haraway es de 1988, publicado en la revista *Feminist Studies*. Su propuesta argumenta en contra de una visión neutral de la ciencia: esa perspectiva asociada a una percepción de que se puede hacer ciencia desde una vista “desde la nada”. Esta visión neutral alude a tener una perspectiva del mundo que no está encarnada, es decir, que el conocimiento científico está desconectado de nuestras experiencias pues contextualizarlo en ellas intervendría en su contra. Lo que Haraway critica, de manera directa, es que hay una falsedad en esas aspiraciones de objetividad, pues no podemos hacer vista ciega a nuestra propia experiencia que, por supuesto, se desarrolla en un contexto social, cultural y personal único.

Así, lo que Haraway nos propone es hacer ciencia desde “los conocimientos situados”, aquellos que vienen de un punto de vista específico y que está inextricablemente influenciado por la posición de cada individuo. Nuestra posición en el mundo está influenciada, a su vez, por múltiples factores como nuestro género, nivel educativo, círculos sociales, el lugar en el que nacimos, y todo aquello en nuestra historia de vida que puede afectar cómo entendemos un problema y de qué manera los conocemos.

¿Pero cómo se relaciona esto con la ética, los sesgos, y la IA? Haraway argumentó que esta idea de conocimientos situados podía reconocer la parcialidad inherente del quehacer científico: un conocimiento que se reconoce en sus limitaciones y sus propios sesgos. La objetividad de la ciencia se originaría en la riqueza y diversidad de las experiencias humanas. Por esto mismo resalta la importancia de incluir la diversidad de

voces y puntos de vista en el desarrollo del conocimiento, en especial de quienes han sido históricamente marginalizados de este proceso.

Así, esa bolita metalizada del debate de “fairness” se comienza a transformar en un orbe de color y luz. De esta manera, debemos entender la creación de IA como una respuesta de su contexto social e histórico, de los intereses y motivaciones de sus creadores; y si buscamos un desarrollo de la IA más ético e inclusivo, debemos poner en cuestión, tal y como lo hizo Haraway, las formas de producción de conocimiento que nos provee esta tecnología.



En la misma línea, el concepto de “objetividad fuerte” de Harding, nos habla de las limitaciones que tiene el concepto tradicional de objetividad en la ciencia, el cual está cargado de esa idea de neutralidad y distancia de lo personal o imparcialidad. En respuesta a estas tradiciones —que generan diferenciales de poder al reflejar los intereses de grupos dominantes en el desarrollo científico—, Harding propone que hablemos de una “objetividad fuerte” que, por el contrario, requiere cuestionar los presupuestos que tiene el quehacer científico, incluyendo las posturas de quienes están a cargo de empujar su desarrollo. Esto implica hacerse cargo de cómo la ciencia ha marginalizado a grupos de la sociedad, ya sea por no hacerlos partícipes de este desarrollo, o por no incluir sus realidades y necesidades en las preguntas que lideran la investigación.

El punto clave, finalmente, es tratar de incluir las perspectivas que permitan que las dimensiones sociales sean reconocidas inherentemente al proceso científico. Estos cambios de perspectiva, por tanto, no tienen solo un trasfondo teórico, sino implicaciones prácticas que llevan a los científicos, y en este caso a los desarrolladores de la IA, a tener una actitud reflexiva sobre sus metodologías y decisiones y, por supuesto, el impacto que su trabajo tiene en la sociedad.



Se pueden englobar diversos esfuerzos para abordar problemas de sesgo en IA, buscando promover la diversidad y la inclusión. Recordemos que las inteligencias artificiales dependen de los datos y, como muchas veces están sesgados, se replican en los sistemas. Por mucho tiempo, esa neutralidad y objetividad de la ciencia hizo que investigaciones respondieran a los intereses y necesidades de ciertos grupos privilegiados. Algunos estudios dermatológicos, por ejemplo, se hacían preferentemente en personas blancas; patologías cardíacas eran tipificadas en base a sintomatología de hombres blancos; y una gran cantidad de datos entrenaba asistentes de voz que provenían de operadoras: una profesión primordialmente realizada por mujeres.

Tenemos la sociedad donde existen patrones, prácticas y tendencias que reflejan injusticias sociales sistémicas y que aportan al desarrollo de la IA. También están los datos que entrenan la IA, que pueden ser poco representativos o sufrir de otras falencias, como patrones de sesgo y discriminación integradas en las distribuciones de datos. A su vez, el diseño de sistemas de IA puede tener propuestas poco inclusivas, sesgos cognitivos al formular los problemas y dificultades con el monitoreo de su implementación. Estos factores terminan influyendo en el uso, lo que puede llevar a exacerbar problemas sociales de inequidad, facilitar un uso discriminatorio de la IA, o ahondar en brechas digitales que permitan a la población beneficiarse de la tecnología.

Sabiendo que diferentes dimensiones de desarrollo e impacto están involucradas, es complejo responder a la pregunta sobre cómo prevenir que un sistema —alimentado por datos de una sociedad sesgada— no los replique. Y es que no basta con aplicar ciertas técnicas de mitigación a los sets de datos, sino generar un cambio cultural.

Analicemos brevemente el ejemplo de estereotipos de género en la investigación. Muchas veces hablamos de las diferencias que hay en el desarrollo de las disciplinas STEM debido a la baja representación de mujeres, pero hay algo mucho más específico, que tiene que ver con los estereotipos de género durante la investigación. Es decir, cuando detectamos un problema y buscamos una solución, no basta simplemente con abordarlo desde una mirada integral, sino desde las experiencias de género que le dan una narrativa a ese problema.

Por lo tanto, no basta simplemente con tener un equipo solo de mujeres o un equipo altamente diverso, ya que eso no garantizaría resolver bien un posible sesgo de género. Desde mi posición, para lograr una integración efectiva se debe adoptar el punto de vista situado y fuertemente objetivo, como lo plantean

Haraway y Harding. Podemos enfrentar esos estereotipos de género y mostrar diferencias e inclusiones más allá de las experiencias propias que pudieron estar en ese equipo.

Por ejemplo, ¿qué pasa si en este grupo son todas mujeres, pero son todas mujeres que viven con ciertos privilegios? ¿Van a entender el contexto y la narrativa de un algoritmo que busque ayudar a mujeres que han sido maltratadas, que sufren vulnerabilidades físicas, psicológicas y económicas? Probablemente no. Y no porque no entiendan el problema, sino porque las narrativas nos entregan una riqueza de información muy diferente a la estadística y la teoría.

Por esto es tan importante trabajar desde una visión socio-técnica, e incluir a los incumbentes. Si yo quiero modelar algo para ayudar a una comunidad, debo ir a esa comunidad, conocer a las personas que yo quiero ayudar, entender su problema y levantarlo desde ahí. No buscar una estadística, no buscar simplemente los datos históricos, sino contrastar, analizar. Esto, obviamente, implica conseguir mayor financiamiento y tiempo, razón por la cual muchas empresas o instituciones prefieren no hacerlo o no pueden gestionarlo. Porque, la verdad, la inversión en una metodología de diseño de un sistema que sea realmente inclusivo y que sea realmente diverso, va a requerir trabajo y será a largo plazo.

En palabras simples, las claves del feminismo de IA se relacionan con abordar estos sesgos de género (y de otras desigualdades estructurales como las diferencias en clases sociales, nivel educativo, discapacidades), promover la diversidad de la IA, pero no solo en una diversidad en equipos de desarrollo, sino en el entendimiento del problema en el proceso de diseño. Lograr un diseño inclusivo y que tenga una perspectiva feminista, implica considerar necesidades y experiencias de todos, y por supuesto, asegurar que estas tecnologías sean accesibles, transparentes, y beneficiosas.

Interseccionalidad

La interseccionalidad reconoce que las personas tenemos múltiples identidades: yo no soy solo mujer; soy una mujer que, además, me identifico como no binaria, autista, latina, y esos aspectos me hacen ser quién soy y dicen mucho sobre mi experiencia de vida, pero también sobre mis necesidades y limitaciones. Usualmente, los modelos de IA no tienen en cuenta esas intersecciones, precisamente porque tipificamos grupos o individuos en variables ya establecidas.

De este modo, podemos agrupar personas en edad, género y ubicación geográfica, pero no es lo único que habla sobre nosotros. Una persona trans tiene necesidades biológicas y psicológicas particulares únicas, así como una persona de la tercera edad con discapacidades físicas que tiene patrones de comportamiento y comorbilidades. Por lo tanto, el criterio para agrupar, clasificar o predecir en un modelo de IA, deberá —en un escenario ideal— tener variables y datos de entrenamiento diferentes. Esto permitirá incluir la mayor cantidad de necesidades específicas y, a la vez, compensar la falta de datos o las limitaciones del modelo. Finalmente, para asegurar una menor discriminación en un mundo altamente violento y agresivo, todas esas interseccionalidades son relevantes para entender qué se está modelando, cómo se está modelando y con qué fin.

Normalmente, a quienes trabajan con IA se les enseña cómo generar una buena gobernanza de datos, recolectarlos, limpiarlos, seleccionarlos, analizarlos, y cómo hacer buenos modelos algorítmicos, considerando mitigación de sesgos, criterios de explicabilidad y transparencia. Porque esta idea de interseccionalidad no es una tema de la ingeniería o la ciencia de datos, sino una idea social, antropológica, ética. Y esta misma idea también tiene mucho que ver con el rol feminista de IA, como potenciador educativo y de concientización.

Es muy bonito cuando quienes trabajan y hacen activismo desde el feminismo en IA, buscan hacer contenido accesible, abierto y gratuito. Algo tan simple como que existan investigaciones en castellano, que se trabaje desde grupos de trabajo diversos, que se lleven a áreas rurales que no tengan acceso al mismo contenido. Llevarlo físicamente a zonas sin internet son acciones que rompen las brechas de analfabetización.

Las tecnologías de IA tienen el potencial de perpetuar y desafiar las disparidades que tenemos en la sociedad. Y lo que busca el feminismo en esta área es que la equidad y la justicia sean el principio que mueva cualquier diseño de un sistema. Aunque, por supuesto, existan agendas políticas de por medio, el constructo más esencial del feminismo de IA es ese espíritu sociotécnico que junta a todos estos factores y actores haciéndolos parte de una misma narrativa. Y yo creo que eso es lo más bonito, porque no busca diferenciar, no busca lo típico de establecer binarios y categorías. Nosotros no solo encajamos en una categoría, y la IA puede encontrar maneras de hacer que aquello que nos hace más humanos nos siga haciendo humanos, y que no lo reemplacemos con una automatización o clasificación binaria.

Feminismo en IA desde Latinoamérica

Los objetivos del feminismo en IA ofrecen algo muy importante para nuestra región. Sabemos que en el hemisferio sur seguimos siendo muy dependientes de las decisiones geopolíticas y tecnológicas de Europa Central y Norteamérica. Y en este aspecto, el sur global tiene bastantes características que se benefician de sobremanera con estas visiones sociotecnológicas feministas. No solo porque sean inclusivas o tengan que ver con la discriminación, sino porque ponen énfasis en lo significativo que es apoderarnos de nuestro contexto.

A nivel latinoamericano, ya no estamos hablando únicamente de lo que hace Estados Unidos, Reino Unido u Holanda, sino de lo que buscamos hacer nosotros y de qué manera nos podrían ayudar los sistemas de IA. Por supuesto, y como dijimos antes, primero debemos estudiar las complejidades y necesidades específicas que tenemos en nuestra región para guiar el diseño de nuevas herramientas de sistematización e identificación de problemas. Por ejemplo, salvar lenguas indígenas, encontrar nuevas rutas para la descentralización, ayudar a gente en sectores rurales aislados, sistematizar estudios históricos sobre influencias colonialistas, entender traspasos políticos propios, temas de salud y educación, especialmente en poblaciones vulnerables.

En Latinoamérica estamos en una etapa crucial de entender la importancia de nuestra soberanía de datos. No somos solo una fuente de datos que el norte global puede explorar, usar, o explotar, sino que podemos utilizarlos para romper las desigualdades locales: para empoderarnos sobre lo que creemos relevante y ser conscientes de los problemas que implica atender nuestras sensibilidades culturales. Al feminismo de IA, en particular, le preocupa atender esa diversidad y sensibilidad cultural y que no se impongan valores o sesgos eurocéntricos.

Cuando hablamos de representatividad, la discusión que se tiene en un país más desarrollado —donde por ejemplo exista la legislación de pago igualitario para mujeres, acceso a la salud universal— no es nuestra realidad y, obviamente, no va a ser lo mismo modelar un programa para un país que tiene altas desigualdades socioeconómicas y mantiene estigmas históricos. En síntesis, considerar la idiosincrasia de nuestra región es de suma importancia para alimentar esta red de elementos y factores sociotécnicos que nos permiten tomar decisiones sobre cómo queremos utilizar la tecnología y, por supuesto, con qué fines.

Porque la única manera de poder diseñar una tecnología justa y eficaz no es a través de lo meramente técnico (por ejemplo un

porcentaje de eficiencia), sino de la integración y el entendimiento de las necesidades de las personas.

Discriminación de género: mujeres

En nuestra sociedad tenemos sesgos sociales, cognitivos y técnicos que influyen en el desarrollo de estas tecnologías. Los estereotipos de género con los que convivimos se traspasan a nuestros sesgos cognitivos, es decir, a la forma en que planteamos un problema y cómo visualizamos una solución. Esto, a la vez, se traduce en sesgos técnicos, o cómo un modelo de IA aprende de esa fusión de los propios sesgos. O, en otras palabras, cómo entendemos un problema que puede estar sesgado socialmente.

La discriminación de género es uno de los tipos de discriminación más recurrentes y discutidos y, por lo tanto, fácil de imaginarlo replicado en sistemas automatizados. Uno de los ámbitos donde se percibe esto es en el diagnóstico médico. Por ejemplo, la detección de las enfermedades cardíacas en mujeres refleja una falta de precisión en comparación a los hombres. A menudo, los algoritmos y los modelos utilizados para el diagnóstico de enfermedades cardíacas se basan en datos históricos, porque, justamente, buscamos que estos sistemas sean capaces de desarrollar estos diagnósticos en virtud de la información que disponemos. El problema es que muchas de estas investigaciones y fichas médicas están altamente sesgadas en favor de los hombres, en particular de hombres blancos. Esto genera que los algoritmos puedan subestimar el riesgo de enfermedad cardíaca en mujeres y provocar diagnósticos erróneos o retrasados.

Varias investigaciones han reivindicado la relevancia de manejar datos de enfermedades crónicas en mujeres, personas de diferentes etnias y que viven en diversas partes del mundo. Estas aproximaciones pueden variar desde la alimentación y

las características raciales, y el resultado no va a ser el mismo si comparamos a una persona que vive en un lugar altamente contaminado con otra que no. Nuestra cultura dicta cómo nos cuidamos, cómo entendemos nuestro cuerpo y qué tipo de alimentación tenemos.

Como adelantamos, es conocida la desigualdad en la investigación médica que, históricamente, se ha centrado en pruebas clínicas y de entrenamiento en pacientes masculinos. Esto provoca que nuevos modelos puedan estar sesgados hacia la población masculina y, posiblemente, lleven a que no se reconozcan los síntomas atípicos que hay en mujeres. Por ejemplo, hay un estigma muy relacionado con el dolor y tiene que ver con cómo entendemos una enfermedad. Una vez, en medio de una investigación, conocí a un equipo que estaba desarrollando un sistema de procesamiento del lenguaje natural en salud. Estaban analizando datos que tenían que ver con ginecología y, muchas veces, esas informaciones y diagnósticos estaban escritos de una forma limitada. Se usaban eufemismos, no se hablaba con terminología clínica, se hablaba del problema sin reflejar la complejidad que probablemente el paciente pudiese estar explicando.

En el ámbito médico, hay sesgos culturales que muchas veces tienen que ver con invisibilizar ciertas experiencias de vida. Es conocido que el dolor femenino se ve muchas veces influenciado por cómo los médicos creen que ese dolor está exagerado, que no está bien tipificado, que hay una exageración que puede deberse a las hormonas. Todos estos estereotipos provocan que tengamos una sintomatología mal clasificada o mal tipificada. Entonces, al presentar síntomas atípicos, podría creerse que se debe a un infarto, una gastritis o una situación de estrés: alguna causa —algunos síntomas— que no serán reconocidos por la sociedad ni los datos médicos y, por ende, por algún sistema de IA que comience a entrenarse. Como los algoritmos no tendrían en cuenta síntomas atípicos en los historiales de patologías que se

manifiestan diferentes en mujeres, podrían generarse problemas de retrasos en el diagnóstico y tratamiento de las enfermedades.

Muchas veces nos concentramos en que debemos entrenar mejor la inteligencia, pero en realidad esto es una red de influencias. La manera en que entendemos ese problema, cómo buscamos una solución y la forma en que lo relacionamos con la persona a la que le queremos entregar una solución, se torna muy relevante. Cuando estamos hablando de sesgos de género, no hablamos simplemente de que hay muchos estereotipos, sino de cómo esos estereotipos reflejan una falta de interacción en nosotros como sociedad: por qué se invisibiliza constantemente las experiencias de las personas.

Esto puede observarse, por ejemplo, a la hora de utilizar algún traductor online. Si bien ahora están siendo un poco más específicos, usualmente ocurría que traducían idiomas de manera neutral, y se generaban ciertos problemas porque mostraba prejuicios. Si en una frase original en inglés, se hablaba de cómo traducir “doctor” o “enfermera” (que sería *doctor* y *nurse*), en inglés ambos son términos neutros y aplican tanto a hombres como a mujeres. La traducción automática al español muestra que *doctor* se traduce como “el doctor”, es decir, hombre, y que *nurse* se traduce automáticamente como “la enfermera”.

Esto último refleja cómo existe en ciertos idiomas un estereotipo muy arraigado sobre las profesiones y qué tipo de personas las ejercen. Y esto se nota aún más en lenguajes que tienen una alta connotación de género, en su gramática y estructura. Este tipo de discriminación es relevante no solo por el hecho de que falla, sino porque puede influir en nuestra percepción y la comunicación de contextos profesionales, educativos o culturales.

El hecho de que algo salga primero o segundo en un buscador o traductor, genera inconscientemente la perpetuación de un estereotipo, sobre todo cuando estamos hablando de herramientas que están siendo utilizadas por adolescentes, niños o incluso más

pequeños, quienes están consumiendo y asociando ciertos roles de género. Esto también pasa bastante en motores como Google: si se busca “cientista de datos”, aparecen en su mayoría hombres de lentes con un determinado tipo de vestimenta trabajando en un computador. No hay una representación diversa. Más allá de qué tan específico es respecto a la cantidad de mujeres que efectivamente están en un área determinada (se calculan solamente cerca de un 25% de mujeres trabajando en áreas de las ciencias duras y de las ciencias exactas), el hecho de que la representatividad no tiene la intención de reflejar de manera estricta cómo está constituida la sociedad, las representaciones —como narrativas sociales— buscan generar posibilidades y ayudar a una persona a entender que existen más formas de ser.

Discriminación de género: comunidad LGBTQ+

La representación de las minorías es lo que genera nuevas maneras de entender, de comunicar y aceptar el mundo. Por esto, más allá de mejorar la precisión de un sistema y la equidad que representa (o qué tan arraigado está en un análisis estadístico de la sociedad), se trata de cuidar la narrativa que lo acompaña.

La integración de la comunidad LGTBQ+ en temas de inteligencia artificial, sigue muy retrasada. Cuando hablamos de sesgo de género, usualmente hablamos de hombre o mujer, pero no integramos perspectivas no binarias o de personas trans o bisexuales. En algunos nuevos tests en los que se busca incluir a personas no binarias o mujeres y hombres trans, ocurre algo curioso: cuando se utilizan imágenes de diferentes estereotipos de personas no binarias —personas trans o drag queens—, se suele estereotipar cómo se ve esa persona. Si buscamos una persona identificada como lesbiana, existe un estereotipo de mujer con cierto corte de pelo, con cierta ropa, con piercings, tatuajes; y si hablábamos de una persona gay, arroja un hombre que, de

nuevo, tiene cierto tipo de cabello y formas definidas de presentarse corporalmente.

Cuando se buscaba sobre las personas en drag, en tanto, usualmente aparecían las que se conocen como *Fishy*: drag queens muy femeninas, muy reinas. Y como hay muchos tipos de drag, debiese aparecer —al igual que buscar una persona heterosexual— un espectro muy variado de personas y estilos. La categorización, sin embargo, es muy difícil porque estamos tratando de entrenar a una máquina para que reconozca visualmente a una persona. Y, la verdad, ni nosotros mismos podemos asegurar hoy día la orientación sexual de una persona por su apariencia.

Acá me cuestiono qué es lo que realmente queremos lograr con el reconocimiento facial o el reconocimiento de imágenes y, de paso, me pregunto: ¿Necesitamos realmente estas categorías? ¿Hay categorías que no debiésemos tratar de estructurar? Si yo quiero buscar mujer o persona jugando a la pelota, la gracia es que tengamos una serie de personas jugando fútbol y que no sea solo un niño o un hombre. Y es que cuando estamos tratando de trabajar con máquinas que son tan estructuradas, que funcionan en un lenguaje de programación que es binario y categorizante, perdemos de foco sobre qué es lo que queremos hacer cuando buscamos hacer esa clasificación.

Puede ser que para ciertos propósitos sea necesario estereotipar. ¿Qué quiero decir con esto? Imaginemos que estamos enseñándole a una IA a que sea capaz de dar diferentes opciones para un *prompt* de generación de imágenes: si yo —para asegurar la diversidad— le propongo que me genere diez imágenes diferentes de “persona leyendo un libro”, tengo que entrenarle con esa diversidad. Cada entrenamiento tiene que hacer que distinga que la persona podría estar recostada, en silla de ruedas, usar lentes, o incluso ser ciega y estar leyendo en braille o en un dispositivo digital.

En el fondo, lo que hacemos es entrenarle a categorizar diversidades. Pero la idea tampoco es decir qué se puede distinguir cuando una persona es o no es algo, sino el hecho de que una persona leyendo un libro puede verse de todas estas maneras. La pregunta de fondo busca entender por qué queremos tener un recurso de IA que nos permita identificar fácilmente a diferentes personas. Es a eso a lo que podemos apuntar cuando estudiamos aspectos desde la ética aplicada de la IA. No se trata de tomar las cosas tal y como se nos dan, o simplemente de que yo diga que seguí el protocolo para poder etiquetar mis datos, que no falté a la privacidad de nadie y entonces eliminé todas las variables que me permitieran evitar sesgo técnico. No. Eso no es suficiente, y la discusión más importante está en esa creación de narrativas, de realidades, en la representación de las diferentes experiencias de vida.

Es relevante porque cuando uno tiene una IA y la lleva a la sociedad, esta interactúa con ella y reacciona —entre comillas— como se le da la gana. Un tiempo atrás, existió un chatbot de Microsoft y también otro en Corea que se entrenaban a través de las interacciones con los usuarios, (es decir, eran “abiertos”). Y, por supuesto, las personas comenzaron a reproducir discursos de odio homofóbicos, racistas y una serie de otras cosas indeseables. El chatbot comenzó a aprender de eso y empezó a replicar y amplificar esa manera de hablar, de referirse a alguien, de entender un problema. Cabe preguntarse, entonces, hasta qué punto vamos a dejar que la IA se desarrolle libremente.

Desde luego bajaron el chatbot y lo cerraron. ¿Pero cuál era el propósito de entrenarlo en virtud de lo que hacen las personas? Era simplemente obtener más datos. ¿Por qué no había limitaciones, por ejemplo, a la hora de detectar un discurso de odio? ¿Por qué no existía algún nivel de protección de cómo el sistema interactuaba con las personas? Si realmente nos preocupara cómo una tecnología es capaz de penetrar en la manera de interactuar

con un usuario (y todas las sensibilidades y vulnerabilidades que tenemos en la sociedad), no dejaríamos que eso pasara. En esta línea, todo lo que tiene que ver con la integración de otros géneros —o la integración de comunidades minoritarias en este respecto—, va de la mano no solo con los sesgos algorítmicos que se pueden generar con los datos de entrenamiento, sino, también, con un problema muy profundo: fueron diseñadas por sesgo.

Cuando la máquina comete un error (ya sea que no identifique el género de una persona), pensamos que simplemente no está bien entrenada y que hay que darle más datos, pero para una persona que se reconoce con cierto género, ser mal identificada por una máquina que le dice que no es lo que se siente y considera, es una forma de violencia.

¿Qué ha pasado, por ejemplo, con las máquinas de identificación facial en personas trans que están en pleno proceso, y las identifican más como su sexo biológico en vez del sexo que están adoptando? Todas esas microagresiones son violencia. Y esa violencia, usualmente, no la asociamos a una discriminación tangible, sino que asumimos que la IA “cometió un error”. Pero la verdad no cometió un error, sino que fueron diseñadas con baja representación de diversidades.

¿Es posible que una IA cometa ese tipo de violencia? No de manera consciente, pero, al fin y al cabo, lo que nos tiene que importar más allá de los tecnicismos, es que eso puede dañar la experiencia de una persona. Y eso, a nivel ético, es extremadamente importante porque nos lleva a profundizar en una idea de identidad. La importancia de la representación de esa identidad y la identificación de esa identidad nos importa.

Para poder expresarnos de la manera que consideremos que nos identifica, es muy importante que la tecnología esté a la par con esa identificación. No que nos someta a mayores limitaciones de las que ya tenemos en la sociedad. Imaginemos llamar a un banco para resolver un problema y que tenga el reconocimiento

de voz automático. Supongamos que somos una persona trans que está pasando por el tratamiento de transición y nuestra voz está cambiando. La IA del sistema de atención al cliente puede detectar fraude y nos amenaza con suspender la cuenta si no podemos comprobar que somos nosotros. ¿Por qué? Porque el sistema de reconocimiento ha concluido que nuestra voz no es lo suficientemente masculina, porque nuestra voz es la asociada al género del carnet de identidad que coincide con los registros. Y, por lo tanto, no nos reconoce.

La des-inclusión y la neurodivergencia

Este tipo de discriminación conlleva un riesgo significativo porque no se trata de que pongamos mal una clave y nos bloqueen la tarjeta; tampoco es equivalente a que haya mala señal o no haya escuchado bien la voz. Nos está diciendo directamente: “Tú no eres lo suficientemente algo”, “yo no te reconozco por quien eres”. Muchas veces, estas connotaciones no se piensan a la hora de diseñar sistemas y la pregunta central es ¿estamos incluyendo a todos los usuarios y usuarias? ¿Estamos incluyendo esas experiencias?

Y en esta línea, algo similar puede ocurrir con el reconocimiento de voz: una aplicación que usa IA para traducir audios, puede tener menor precisión en personas que tienen acentos marcados y, por lo tanto, funcionar menos efectivamente en personas que más lo necesitan. Imaginemos una persona con un acento marcado, de una región específica de Colombia, que intenta usar una aplicación de reconocimiento de voz que traduce del español al inglés. La aplicación ha sido entrenada con datos de hablantes de español neutro o internacional, y muy pocos datos de entrada provienen de hablantes con acentos marcados o dialectos regionales específicos. Cuando esta persona intenta usar la aplicación para traducir frases comunes

que querría usar en un viaje (“¿Dónde está el baño?”), la aplicación no reconoce o no procesa correctamente su acento. En lugar de recibir traducciones precisas, se encuentra con errores y malentendidos. Por ejemplo, la aplicación podría traducir incorrectamente “¿Dónde está el baño?” por *Where is the dance?* debido a la dificultad para reconocer la palabra “baño” con el acento específico del usuario que puede sonar como “baile”.

La IA se infiltra en nuestras vidas, no simplemente en el uso, sino en cómo podemos estar siendo catalogados y evaluados y, por tanto, des-incluidos. Cuando hablamos de la discriminación que la IA puede tener, no estamos hablando simplemente de errores: hablamos de truncar oportunidades, de alterar las experiencias identitarias.



Considerando lo anterior, debemos entender la profundidad de las posibles violencias que puede generar una IA. Quizás no para el 90% de la población, pero sí para ese diez que importa tanto como el resto. Así, es importante que cuando hablemos de discriminación no lo hagamos simplemente de una discriminación explícita, sino que nos preguntemos por qué falla. ¿Falla porque es un aspecto de limitación técnica, porque sus datos son limitados, porque no son suficientemente variados, o porque la manera en que estamos comprendiendo la solución del problema es la que está fallando?

Yo me he dedicado a pensar el impacto que puede tener la IA en las neurodivergencias. Yo misma soy neurodivergente, muchos de mis amigos, familiares, colegas, y estudiantes también lo son, y por suerte, es un tema que nuestra sociedad ha avanzado en discutirlo, y esperamos que se incluya como parte de una discusión profunda en el ámbito legislativo, laboral, educacional y social.

La discriminación contra personas neurodivergentes en IA puede manifestarse también de diversas maneras, usualmente, por sesgos y falta de consideración de perfiles cognitivos diversos. Por ejemplo, ocurre que se están utilizando algoritmos para la contratación y sabemos que estos pueden estar sesgados de diferentes maneras, pero, en particular, para las neurodivergencias las herramientas de selección están impulsadas para discriminar en virtud de ciertos criterios, capacidades, actividades o experiencias de vida.

Existe un perfil de cómo debiese actuar un postulante en una entrevista laboral, cómo debiese comportarse. Y pasa mucho con las personas neurodivergentes que no tienen caminos de vida tan lineales, o no tienen una manera de expresarse que, tal vez, sea la que va a detectar los patrones esperables de una entrevista. Entonces, las herramientas de selección impulsadas por IA pueden que no estén preparadas para distinguir patrones neurodivergentes de manera positiva. De hecho, no lo están para diferentes estilos de comunicación, ya que no son convencionales o sus trayectorias profesionales son atípicas. No las va a detectar porque no ha sido entrenada para eso, porque la sociedad no ha sido entrenada para identificarlas ni para valorarlas. Una vez más, no se trata, simplemente, de decir que no tenemos suficientes datos: se trata de entender cómo podemos mejorar esta situación. Y lo inmediato es convocar a las personas neurodivergentes, entender sus complejidades y evaluar cuáles son los aspectos que más los afectan.

A la hora de analizar, debemos entender que estas respuestas dependen de su crianza, sus limitaciones, sus grados de discapacidad, qué tipos de habilidades ha desarrollado y qué limitaciones cognitivas o sociales tiene. Porque, casi siempre, las barreras de accesibilidad se piensan para discapacidades físicas o más evidentes.

Cuando nos metemos a un sitio web y nos aparece un chatbot, por ejemplo, frecuentemente nos preocupamos de una persona que no puede ver o escuchar, o que tiene algún grado de daltonismo, y eso hace que se generen diferentes arreglos en un sistema de interacción para acomodar a esas personas. ¿Pero qué pasa con una persona que entiende todo literalmente? ¿O con una persona que le altera la luz, el sonido alto, o la voz robótica de un chatbot porque les genera una sensación de incomodidad y no es capaz de distinguir tonos? ¿O una persona con dislexia o déficit atencional que responde mejor a textos resaltados o con estructuras diferentes?

Las personas neurodivergentes tienen dificultades para entender comportamientos que para ellos no son nocivos y que el resto puede malinterpretarlos: referirse a algo de manera demasiado concreta, o decir cosas que pueden ser entendidas como un insulto. Por esto, ciertos filtros de ciberacoso pueden generar censura respecto a cómo ellos se expresan. Puede que la interacción que se tenga con la digitalización no sea la más amena, porque no se puede reconocer cuáles son las intenciones detrás del uso de ciertos emoticones, imágenes, textos, voces; pero, ciertamente, existen posibilidades y estrategias para hacerlo más llevadero.

Imaginemos un chatbot diseñado para moderar una plataforma en línea y detectar un ciberacoso. Una persona neurodivergente, que tiende a comunicarse de manera muy literal y directa, podría escribir un mensaje diciendo: “No, eso es absurdo, no tiene sentido”, en respuesta a otra persona que buscaba expresar

una experiencia personal o emocional, pero que lo hace de una manera gramaticalmente incorrecta. Aunque la intención de la persona no sea insultar, sino expresar una opinión franca sobre una acción específica, el chatbot podría interpretar la respuesta como “insensible” u ofensiva y censurar el comentario o sancionar al usuario.

Este tipo de interacción podría ser frustrante para la persona neurodivergente, ya que su forma natural de expresarse es malinterpretada por los sistemas automáticos. Además, si esta persona usa emojis o imágenes de manera no convencional, el chatbot podría no ser capaz de interpretar correctamente la intención detrás de su uso, lo que podría llevar a malentendidos o a una comunicación menos efectiva.

Al tratar problemas de género, así como se plantea repensar nuestra manera de hablar, de conectarnos con esas narrativas que están arraigadas en nuestra sociedad y que impiden cambios sociales profundos, creo también que hay una oportunidad de pensar cómo queremos integrar la IA respecto a las discapacidades, en particular, las neurodivergencias. Existen muchas oportunidades de tecnologías educativas. Podemos personalizarlas para que personas con ciertas limitaciones sociales o cognitivas puedan sentirse más incluidas en el aula y en su interacción con nuevos conocimientos. Y para eso, desde luego, la IA puede ser muy útil. Puede utilizarse a través de robots, aplicaciones o juegos, instrumentos que creen oportunidades, faciliten las experiencias educativas y, de este modo, no aislarlas necesariamente de un entorno más tradicional. Pensemos en el caso de los robots asistentes programados con IA para ayudar a estudiantes con trastorno del espectro autista. Estos robots pueden enseñar habilidades sociales básicas, como el reconocimiento de emociones y la interacción social adecuada, mediante la repetición y la presentación de escenarios en un formato consistente y tranquilizador.

También existen aplicaciones que permiten personalizar la experiencia educativa para estudiantes con dislexia, por ejemplo, ajustando el tipo de letra, el espaciado entre palabras y líneas, y el color de fondo para mejorar la legibilidad. Además, estas aplicaciones pueden utilizar la IA para adaptar los ejercicios de lectura al nivel y al progreso del estudiante.

Al mismo tiempo, puede servir para temas de diagnóstico. Si podemos entrenar a la IA para que sea capaz de reconocer patrones, gestos, maneras, tonos y comportamientos que son típicos de neurodivergencias (o que al menos haya suficientes patrones que sean identificables) nos puede ayudar, sobre todo con diagnósticos tempranos para personas en el espectro autista, con dislexia, discalculia, o déficit atencional.

Uno de los grandes problemas que ha existido con la neurodivergencia en la historia es que no solo ha sido estigmatizada, sino que existen muchos diagnósticos tardíos. Hay ciertos patrones que pueden ser atípicos para una persona neurotípica, ya que suelen asociarse a trastornos obsesivos compulsivos o ansiedad (y que de hecho fue mi experiencia). Estos diagnósticos equivocados se deben al intento de encasillar y sesgar comportamientos.

Hoy tenemos la oportunidad de generar estudios, de realizar intervenciones que nos permitan identificar de manera temprana aspectos que podrían significar una neurodivergencia, lo cual no solo se traduce en una intervención inicial, que es fundamental para que exista un apoyo constante en el desarrollo de esa persona, sino que también hay un aspecto muy importante: ser reconocido.

Como dije anteriormente, cuando nos sabemos diferentes, reconocemos que la diferencia no es un problema, sino simplemente una manera de ser que es reconocida, apoyada y fomentada por su entorno, por la sociedad, por sus compañeros, su familia, su colegio, etc. Y para abordar esta posible discriminación, lo más importante es tener en cuenta este criterio de inclusividad.

No hablemos de la ética de IA como si se tratase solo sobre la máquina: la ética de IA, en realidad, surge y funciona en virtud de a quién ayuda, y en ese sentido, entender a quién estamos ayudando es extremadamente importante.

Considerando la diversa gama de perfiles cognitivos, ya existen muchos estereotipos sobre qué significa, por ejemplo, ser autista, ya que en Hollywood o en películas o series suele asociarse a una persona que padece su genialidad y, al mismo tiempo, no posee capacidades sociales básicas. Pero, desde luego, este estereotipo no representa a otros cientos de casos diferentes. Hay personas autistas que son extremadamente artísticas, otras que no tienen ninguna súperhabilidad, otras que tienen limitaciones visuales o auditivas.

También existe esta idea relacionada con el déficit atencional, que antes se asociaba a la irritabilidad, al exceso de energía, a la incapacidad de poder quedarse quietos; y ahora, con los nuevos estudios, sabemos que hay personas hiperactivas que son calmadas, pasivas, o que sufren de *hiper focus*, es decir, se enfocan tanto en una sola cosa que son incapaces de ver lo que pasa a su alrededor y eso les altera las rutinas cuando comen, se bañan, o deben calcular los tiempos de traslado.

Hay tantas cosas que son propias de las neurodivergencias que siempre se han asociado a la flojera, a la procrastinación, a la irresponsabilidad. Y por esto es necesario colaborar con comunidades y organizaciones neurodivergentes para obtener retroalimentación y entender cómo la IA puede ser un gran aliado y facilitarles la vida. Pensemos el ejemplo de cómo ayudamos a una persona que tiene autismo no verbal: la IA puede sobrepasar esta dificultad en comunicar qué es lo que sienten, qué es lo que les pasa y así ayudarlo a expresarse utilizando una interfaz computacional con la que se sientan cómodos. Niños que pueden estar sufriendo un dolor físico muy fuerte, pero que no pueden comunicarlo efectivamente, se beneficiarían de tener una interfaz que

personalice la manera de expresar eso que se está sintiendo. Es una manera de integrarlo y decirle “bienvenido al mundo”.

La neurodiversidad es un aspecto que se ha vuelto transversal en las discusiones de políticas públicas y legislaciones, pero también de aspectos éticos sociales. ¿Cómo la incluimos en el trabajo, por ejemplo? Aceptar la neurodiversidad en el campo laboral, significa esperar distintos modos y rendimientos. Hay quienes son altamente funcionales, otros menos, y la IA puede ayudar en este desempeño configurando alertas, enviando recordatorios, generando resúmenes de reuniones, etc.

La incorporación de la IA en la rutina puede facilitar mucho lo que hacen las personas neurodivergentes. Aparte de darles facilidades para tener diferentes horarios, tener oficinas con luces menos fuertes y con menos ruido, o que tengan la facilidad de ir a ciertos lugares para tener un descanso, es muy importante entender cómo la tecnología ya puede ser parte de esa transformación.

Los programadores de IA deben preguntarse de qué manera diseñar e implementar la tecnología. ¿De qué manera corregimos los sesgos? ¿Qué definiciones de justicia podríamos considerar? ¿Cómo funcionan las estadísticas matemáticas para hacer que un sistema de IA utilice, por ejemplo, una equidad o paridad predictiva que trate a diferentes grupos de la misma manera? Todas esas preguntas y nociones matemáticas pueden permitir hacer la IA más inclusiva. Pero, una vez más, deben ser capaces de hacerse preguntas sobre las experiencias y necesidades de aquellos que son afectados por estas decisiones.

Capítulo III

Otros principios éticos de IA y su relación con la inclusividad

Protección de datos

Además de problemas relacionados a la justicia y el sesgo, hay otros principios fundamentales para lograr una integración inclusiva en el desarrollo de la inteligencia artificial. Uno de ellos es la privación y protección de los datos de estas minorías. La privacidad en IA se refiere a la protección de la información de las personas y a la preservación de su derecho a la privacidad. Incluye diferentes aspectos, como preocupaciones y consideraciones que se relacionan con la forma en que los sistemas de IA pueden recopilar, procesar y utilizar datos privados, y cómo estas acciones pueden socavar la privacidad de diferentes individuos o grupos.

Las preocupaciones de privacidad en IA se tratan con diferentes técnicas. Una muy conocida es la de identificación: un proceso donde se eliminan o modifican algunos elementos de una serie o una tabla de datos personales para proteger la privacidad de las personas. En el caso de los datos de una clínica o un hospital, la tabla mostrará una columna con el nombre de algún paciente, su fecha de nacimiento y la enfermedad por la que fue ingresado. En este caso, el nombre del paciente está asociado a un código. El problema de esta medida es que la desidentificación es insuficiente porque, aún así, se pueden reconocer los otros datos indirectos o características que permitan deducir o inferir la identidad de la persona.

Existe un caso conocido que demuestra cómo la combinación de datos puede generar grandes problemas de privacidad. En 2006, Netflix publicó unos registros que revelaban cientos de miles de valoraciones que los usuarios hacían de diferentes películas o series entre los años 1999 y 2005, con el objetivo de mejorar el algoritmo de recomendación. Los usuarios que participaron fueron reducidos a un identificador numérico para su anonimato. Dicho identificador se utilizó únicamente para saber qué valoraciones pertenecían al mismo usuario. Sin embargo, un equipo de investigadores demostró que podían conectar esas identificaciones con las valoraciones de sus usuarios por referencias cruzadas, mediante la conexión entre el conjunto de datos que Netflix reveló y otro conjunto de datos públicamente abierto, como las calificaciones de películas en el sitio web de IMDB. Mediante esta mezcla de datos fueron capaces de identificar cuáles de los usuarios en IMDB entregaban los datos específicos que habían sido anonimizados en Netflix. La idea detrás de este “boicot” de los investigadores fue demostrar que no basta con anonimizar u ocultar cierta parte de la información porque es muy fácil correlacionar datos. Y sobre todo hoy, ya que existe una gran disponibilidad de datos digitalizados, ya sea entregados por nosotros mismos mediante redes sociales.

En Chile, en particular, existe una obsesión con la entrega de información personal. Hasta en el supermercado se entrega el RUT y, solo recientemente, el Servicio al Consumidor está tratando de crear regulaciones para que no puedan compartirse las bases de datos. A su vez, tenemos un nivel escandaloso de *spam* telefónico de empresas que tienen acceso a nuestros números, que saben dónde estamos, a qué banco nos asociamos, qué compañía de teléfono tenemos contratada, etcétera. Estas prácticas son violaciones a la privacidad, optimizadas y excedidas gracias a la IA, gracias a los bots, y a una serie de algoritmos que les permite procesar los datos de cientos de personas.

Estas técnicas de identificación para proteger la privacidad suelen usar la sustitución de datos directos, como cambiar datos reales por falsos. Otra técnica es la alteración de los datos temporales, como las marcas de tiempo. De este modo, algunas personas, para protegerse a sí mismas cuando están posteando un video o cuando viajan, establecen marcas de tiempo para que se desconozca su ubicación en tiempo real.

Otra técnica es el ruido aditivo que consiste en agregar pequeñas modificaciones a los datos para ocultar la información personal. Existe también la anonimización de imágenes para mantener la identidad de una persona en privado porque está haciendo alguna declaración que ponga en riesgo su seguridad. Pero esto es, más bien, un problema técnico por el que se siguen desarrollando técnicas mucho más sofisticadas para la protección de datos. Se trabaja mucho en ciberseguridad. Existen hackers que se dedican a probar sistemas de privacidad y encontrar soluciones constantemente actualizadas por el avance de la tecnología.

El problema de fondo es ético y me interesa mucho porque tiene que ver con el enfoque que estamos discutiendo en este libro: cómo la sociedad, la tecnología, las ideas políticas y la ética conviven y crean un gran sistema. Y la privacidad, si bien tiene todas estas connotaciones prácticas, también se asocia a vivir una vida con dignidad. Nuestra privacidad es un derecho que nos permite cumplir ciertas libertades. Es un derecho fundamental, una piedra angular en lo que nosotros entendemos como democracia. La privacidad es una instancia de dignidad, una forma de libertad que se incorpora a las estructuras sociales y su defensa es parte de una lucha política mucho más amplia por criterios de igualdad, de ciudadanía y de democracia. El derecho a la privacidad impone límites en el ejercicio del poder, pero cuando se trata de la IA es interesante discutir cómo podemos garantizar esos derechos que son inherentemente sociales y políticos.

Quisiera adentrarme en la idea de este derecho humano a la privacidad desde la perspectiva de género y la representatividad de género. Esto plantea una serie de cuestiones que requieren examinar las experiencias vividas de la privacidad, psicológicas, sexuales, patrimoniales, morales, tanto dentro de la digitalidad como fuera de ella. Y la experiencia de privacidad de todas las personas derivadas de su género, su orientación sexual, sus características sexuales e identidad de género, debieran ser entendidas y tipificadas en esa experiencia vivida.

La importancia de esto radica en que grandes movimientos que tratan temas de privacidad y manipulación de datos, están muy instalados en Latinoamérica porque hay una extensión de lo que se entiende como el control patriarcal o abusivo. Las voces de las mujeres y niñas en el ámbito público son silenciadas y, si bien hemos avanzado, la situación en países como México, Colombia o El Salvador, sigue siendo extremadamente agresiva. Hay estigmatización, humillación y aislamiento social a ciertas personas que tienen alguna identificación de género o que pertenecen a la comunidad LGBTQ+.

Esto, por supuesto, puede derivar en problemas de salud mental. Se conocen casos de suicidios de personas estigmatizadas por condiciones de género, impactos en la reputación, acoso, intimidación, y hostigamiento tanto online como fuera de la virtualidad. De este modo, no se trata simplemente de violaciones a la privacidad, ya que, si bien la población en general está expuesta, hay vulnerabilidades que exacerban y hacen aún más relevante entender las dimensiones de privacidad asociadas a ciertas minorías o grupos en nuestra población.

Se ha estudiado que la revelación de la orientación sexual y de identidad de género puede generar muchas inflexiones de privacidad y abuso, especialmente si se trata de personas transgénero y, además, de color. Han ocurrido hasta persecuciones que terminan en peligro físico o delitos de odio. Así, lo más importante

y lo central es que las experiencias de violación a la privacidad, aunque puedan ser técnicamente homogéneas, no son éticamente homogéneas. Las incursiones pueden tener un mayor impacto en personas LGBTQ+ debido a la discriminación asociada a la disminución de autoestima, al daño psicológico, físico y moral que puede traer. Las mujeres, incluso, informan mayores niveles de estrés emocional por sus experiencias de violencia en línea por acosos. Las personas transgénero pueden experimentar riesgos específicos y únicos por su revelación de identidad de género. Es por esto que no basta con entender la privacidad como un fenómeno legal y técnico, sino entenderlo como la manifestación de esa experiencia en diferentes realidades.

Lo anterior va de la mano con decisiones que en nuestro país no terminamos de desarrollar: los derechos de las mujeres. Por ejemplo, ¿qué pasa con la privacidad de datos respecto a búsquedas que tengan que ver con acceso al aborto en un país en donde todavía no hay un aborto libre? Esto afecta a los países de diferentes maneras según las legislaciones que tengan, pero muchos datos de tribunales, de acceso por tramitaciones públicas o, incluso, si es que la seguridad o la privacidad no son primordiales en ciertos servicios de salud, puede haber violaciones a la privacidad que terminan exponiendo, en este caso, a mujeres o personas que estén embarazadas y que decidan voluntariamente terminar su embarazo.

Pero esto no necesariamente tiene que ver con IA de manera directa. Las dimensiones de la privacidad en el mundo de la IA cuestionan cómo un modelo algorítmico puede traspasar ciertas barreras y generar discriminación o poca transparencia. Pero, también, es importante considerar que siendo los datos digitalizados el “alimento” de los sistemas, no podemos distinguirlo como un problema separado.

Actualmente, en nuestro país se está tramitando —después de casi una década de discusión— la ley de protección de datos

personales. Hoy no se protegen las intervenciones de datos por lo que la población queda, en general, a merced de que las instituciones decidan tener buenas auditorías y buenas prácticas. Este es un problema transversal que hemos naturalizado mucho. Así como hemos hablado antes de esta antropomorfización de la IA, me parece que hay otro aspecto relevante que tiene que ver con ese “alimento” de información que lleva a preguntarnos: ¿Cuáles son los datos públicos y cuáles son los privados?

Estamos generando datos constantemente y muchas veces no dimensionamos lo que entregamos a compañías multinacionales, al gobierno, a empresas privadas. Nos exponemos, a veces innecesariamente, a sufrir violaciones a nuestra privacidad, a nuestra autonomía y a sufrir ciertas discriminaciones. Me parece que es muy importante entender que proteger nuestros datos es tanto o más relevante que nuestra idea de privacidad asociada a cómo una IA puede o no inmiscuirse para utilizar esos datos. Es un problema mucho más primario.

Una manera en la que la privacidad se mezcla con estas discriminaciones es la creación de algoritmos que, al tipificar perfiles de datos, suelen hacer publicidad dirigida por género o que hace distinciones de género. Entonces, plataformas publicitarias que están impulsadas por IA y utilizan datos personales para entrenarse, terminan mostrando anuncios que refuerzan estereotipos de género, o promueven productos o servicios de manera discriminatoria. Existe el caso de LinkedIn, donde trataron de aplicar un algoritmo que priorizaba puestos de trabajos de alto nivel de gerencia o de ingenieros altamente demandados a hombres. El algoritmo no ofrecía la misma oferta a mujeres bajo la razón de que no tenían el perfil que buscaban. Así, que obtengan más datos de nosotros y nos tipifiquen a un nivel demasiado microscópico, puede hacer que se generen problemas de justicia y discriminación. Todas estas cosas están extremadamente interconectadas.

Otro aspecto que me interesa resaltar tiene que ver con las neurodivergencias y la privacidad. Las personas neurodiversas pasamos una cantidad considerable de tiempo utilizando tecnologías. En numerosos estudios se ha observado una mayor probabilidad de que los niños, niñas y niñas neurodiversos, en particular aquellos que tienen autismo y deficiencia atencional, pasan mucho tiempo en línea en comparación con sus compañeros neurotípicos. Sus hábitos persisten en la adultez, lo que hace que se genere una especie de dependencia.

Por lo tanto, como hay cierta parte de la población neurodivergente que puede ser extremadamente vulnerable a la manipulación, es muy importante que exista alfabetización digital para contrarrestar problemas de privacidad. Esto puede aplicarse a otras partes de la población que son altamente vulnerables por motivos similares, como, por ejemplo, personas de la tercera edad que tienden a tener una baja alfabetización digital. Es importante que uno de los aspectos relacionados con la privacidad sea la seguridad en los espacios digitales a pesar de la creencia popular que asume que las personas neurodiversas, al pasar mucho tiempo en las tecnologías digitales, las conocen muy bien y saben cómo protegerse.

Respecto a esto último, las personas neurodiversas desarrollan relaciones muy fuertes con personas que no conocen en la realidad, precisamente, porque tienen una confianza mayor en comparación a personas neurotípicas, similar a lo que pasa en la niñez. Se conectan con otras personas de intereses e ideales similares y generan conversaciones de nicho, por lo que comparten información que quizás no debiesen compartir tan fácilmente. Y como sienten que están en un espacio digital, seguro, y son incapaces de distinguir la autenticidad de la manipulación, comparten en exceso sus detalles personales. Está en nuestra configuración cerebral lo que se conoce en inglés como el *oversharing*, que es compartir demasiado. O el TMI, *too much*

information. Sin embargo, aunque pueda parecer entre amigos algo anecdótico o simpático, cuando se traspasa al área digital, el compartir exceso de detalles personales y confiar altamente en desconocidos porque hay sentimientos de aislamiento social y dificultades para controlar impulsos, hace que no se identifiquen intenciones ocultas.

Esto aplica no solo a la niñez, sino también a personas en estados psicoemocionales extremadamente vulnerables (personas con depresión, síndrome postraumático, etcétera), un área en la cual se está generando muchísima IA, sobre todo a través de chatbots. Los niños, niñas y niños adolescentes con neurodivergencia son más propensos a enfrentar ciberacoso, por lo que es importante hablar del concepto de seguridad digital y su alfabetización. Muchas veces tendemos a creer que estar saludable es alejarnos de la tecnología, pero en realidad estamos en un proceso donde la tecnología es inherente a nuestros hábitos. Y por esto mismo, al hablar de salud integral, corporal, física y emocional, debemos agregar una salud digital que es la manera en que entramos a un mundo donde la IA puede estar manejando diferentes intereses y dejándonos expuestos a riesgos.

Estos aspectos son particularmente relevantes en nuestro país, a diferencia de otros países como Estados Unidos, Reino Unido, Francia, Australia, donde los diagnósticos y la tipificación de la neurodivergencia son mucho más conocidos. En Chile, y en general en Latinoamérica, estamos muy atrasados en esta materia. Nosotros recién somos pioneros en la nueva ley TEA, pero existen muchas otras neurodivergencias que no están tipificadas. Hay mucha ayuda que no está siendo establecida, sobre todo en esta área. Tenemos una baja inversión a nivel de política pública en cómo estamos integrando conocimientos digitales en la población. Y no estamos hablando solamente de cómo enseñamos a individuos de nuestra población a protegerse y a usar la tecnología, sino también a profesionales que cumplen diferentes roles en nuestra sociedad.

Por ejemplo, la protección de la información de salud es particularmente sensible, pero además hay un tema con las decisiones de revelar un diagnóstico. Esto aplica en los ejemplos mencionados anteriormente sobre personas transgénero, sobre lo invisibilizado que es el debate sobre niños intersexos que sufren una violación a su capacidad de decidir. Estos son casos que, usualmente, son tipificados de cierta forma y se les hace tratamientos médicos con hormonas por arbitrariedad de los mismos padres. Existen casos donde, incluso, las neurodivergencias se exponen a que se sepa un diagnóstico cuando la persona no está lista para compartirlo.

Asimismo, aún existen estigmas por sufrir ansiedad y una serie de otras patologías. Para las personas neurodiversas, la decisión de oficializar su diagnóstico es personal y la divulgación de esos datos puede ser altamente dañina para adaptaciones en su trabajo o en el colegio, porque puede llevar a la discriminación. La privacidad de la información en salud es importante para ayudar a la integración de personas neurodiversas, pero también aplica a otras minorías respecto a otras discapacidades físicas como podrían ser las personas daltónicas, disléxicas, personas ciegas o sordas.

Existen aplicaciones y webs de IA que no se adaptan a las necesidades y preferencias específicas de usuarios neurodiversos y de otras discapacidades, vulnerando sus derechos al acceso de información y a los servicios. Si no entendemos realmente cuáles son las necesidades que ellos tienen, no podemos proteger los datos que puedan estar utilizando por una aplicación de cierta accesibilidad. En un mundo donde tratamos constantemente de meter la IA en todo, si no dimensionamos qué criterios de privacidad y manejo de datos están detrás —y cómo eso se puede traducir o no en un impacto social en la vida específica de las personas— simplemente estamos incorporando una IA poco ética.

Transparencia: el derecho a conocer

Por supuesto que la inteligencia artificial de hoy no es la misma de décadas atrás: antes teníamos algoritmos o estructuras lógicas accesibles, sabíamos cuál era la relación, sabíamos qué era lo que entraba y salía. El nivel de complejidad era mucho más limitado, no porque no pudiésemos conceptualizar otros desarrollos algorítmicos, sino, simplemente, no teníamos el poder de cómputo para poder automatizarlo. Pero ahora sí lo tenemos y sigue creciendo día a día.

Debemos considerar que estos sistemas son altamente complejos de entender e implican entrenar una red neuronal: una serie de capas de entrada donde los datos de una imagen se dividen en muchos píxeles, y que, finalmente, logra darle diferentes pesos a cada uno de esos píxeles hasta distinguir cómo ese conjunto de minipíxeles hace una imagen y no otra. Si es un círculo, un cuadrado, o un triángulo; si es un gato, un perro, un auto; la red es capaz de identificarlo y hace lo mismo con el contexto, con los números, con los diferentes datos que podamos entregarle.

Por ejemplo, hoy estamos viendo masivamente cómo se utiliza la IA para replicar voces de cantantes famosos: esto lo hacen las redes neuronales y son altamente opacas a diferencia de antes cuando teníamos un algoritmo muy simple que le decíamos “si la persona en una prueba se saca un 1, un 2, un 3, un 4, significa esto o lo otro”. En este último caso, simplemente se utilizaba una tabla de información y se intentaba automatizar algo. Pero las redes neuronales no hacen eso, sino una serie de micropasos lógicos que nosotros programamos. Le decimos: tienes que aprender a distinguir, a clasificar, a predecir; y para entrenarse, utiliza muchos datos y repite procesos hasta aprender a hacerlo correctamente. A este proceso le llamamos aprendizaje profundo.

La profundidad también tiene que ver con todas estas capas de diferentes iteraciones que va haciendo el modelo de red neural.

El problema con esto es que si, por ejemplo, utilizamos un sistema de IA que es altamente complejo y opaco, yo no puedo saber exactamente qué está haciendo con los datos que le entrego, pero sí puedo saber que si le doy “X” datos, me da “Y” resultado.

A nivel técnico, podemos ver la idea de transparencia desde dos perspectivas: la transparencia ética y la transparencia técnica. ¿Pero cómo entendemos esta transparencia? Si yo digo que un modelo es transparente, significa que entendemos cómo funciona ese sistema y ese modelo. Yo puedo decir: “Aquí entregamos estos datos”, y el algoritmo o el modelo algorítmico básicamente toma los datos A, B, C y D, y hace un determinado tipo de correlación, de relación, de predicción. Nos dio este resultado y utilizó diferentes variables.

Saber cuáles son los procesos ejecutados hace un sistema más transparente: lo hace más accesible a todos los usuarios, pero también a los desarrolladores y a cualquier otra parte que esté interesada en entender cómo funciona. Ahora bien, también necesitamos conocer y entender mecanismos que son internos del sistema: qué datos se utiliza, quién proporciona esos datos y cómo se manejan. Es decir, no solo requerimos transparencia del sistema, sino también transparencia de procesos, y aquí entra una dimensión intermedia que nos da el paso a la dimensión ética. Nuevamente: el hecho de que un sistema de IA esté entrenado con ciertos datos y no otros, es una decisión humana. Y no solo interesa saber por qué hace lo que hace, sino cómo esas decisiones están arraigadas en los comportamientos humanos.

La transparencia, en este sentido, se transforma en algo crucial para la responsabilidad y la confianza porque esta depende de datos, o más específicamente, de que los usuarios confíen en entregar sus datos (ya sea de manera automatizada o informativa) y que, al respecto, existan responsabilidades. Porque recordemos que uno de los grandes aportes que hace la transparencia es reforzar el derecho a la explicación.

Explicabilidad: el derecho a entender

La disrupción que nos generan estas tecnologías requiere que tengamos derecho a pedir explicaciones. Si el sistema de IA comete un error y, de alguna manera, me discrimina a mí o discrimina a un grupo de personas, sí hay un problema de privacidad. La explicabilidad, en este sentido, tiene una dimensión técnica y otra ética.

Es muy posible que, mientras más complejo sea el sistema, menor transparencia vamos a conocer. Y en este línea se han desarrollado técnicas que permiten hacer que modelos opacos —modelos cuyo funcionamiento interno es difícil de entender, incluso para los expertos que lo han diseñado— sean más transparentes y por lo tanto explicables. Hay toda una área de desarrollo de la IA que se dedica a generar estos sistemas de explicabilidad, y que sirven, por ejemplo, para visualizar cuáles son los pesos que le da una red neuronal a la identificación de imágenes. Un sistema de IA puede considerarse explicativo porque proporciona cierta claridad sobre el proceso de toma de decisiones de procesamiento de datos y llega a ciertas conclusiones específicas (lo que entendemos como factores de influencia).

Si un sistema está tratando de clasificar o está tratando de predecir algo, naturalmente va a buscar patrones lógicos. Va a priorizar algo y, en parte, esa prioridad de tareas se la dará la instrucción humana. Pero los nuevos modelos con redes neuronales que tienen una capacidad de cómputo y procesamiento tan alto, tienen lo que se llama comportamientos emergentes. Es decir, son capaces de comportarse de cierta manera que no necesariamente era lo esperado debido a que no es una consecuencia directa de la instrucción humana, sino que emerge de una serie de derivaciones que el modelo es capaz de hacer. Aunque no sepamos a cabalidad exactamente qué está sucediendo,

el hecho de que podamos saber que eso está ocurriendo, ya ayuda a tener mayor explicabilidad.

Para superar esta idea de las cajas negras, no se trata simplemente de buscar más transparencia, sino que de equilibrar ciertas confidencialidades de la tecnología y los derechos que tienen las personas a saber ciertas cosas sobre la tecnología. Se produce, de esta forma, una pugna entre qué tan transparente tiene que ser algo, y cuál es mi derecho a saber qué es lo que está ocurriendo. Y en este punto es interesante preguntarse qué entendemos por una “buena explicación” en IA. Y no hablamos de qué tan correcta, precisa u optimizada es una técnica para hacer explicable un modelo (la parte técnica), sino de la capacidad de explicar procesos a las personas interesadas.

Proveer explicaciones es desafiante porque tenemos patrones sociales que nos hacen recibir las explicaciones de mejor o peor manera según diferentes variables, contextos y sensibilidades. Lo que se plantea Tim Miller, un académico experto en IA, es que hay una serie de características que debemos tener en consideración para dar una buena explicación. Primero, debemos considerar que las explicaciones humanas tienden a ser contrastantes, y esto quiere decir que usualmente nuestro cerebro mejora la información cuando se nos da un ejemplo que genera contraste. No basta con explicar que el pasto es verde, sino que también debemos explicar por qué el pasto no es azul. Por qué ocurre algo y por qué no ocurre algo: los contrafacticos. O del mismo modo, imaginar casos en los que no podría ser posible que algo ocurra: considerar una especie de antagonismo que nos permita entender y dimensionar por qué un modelo de IA está haciendo A y no B.

Miller dice que las explicaciones tienen que ser —en cierto modo— sesgadas. Y esto puede sonar contraintuitivo, pero es altamente necesario. Y como revisamos anteriormente, hay que disminuir sesgos cuando estos provocan un daño para ciertas

personas o ciertos grupos. Nuestros cerebros son bastante limitados en comparación a los cómputos que pueden hacer estos sistemas, y por lo tanto, es importante seleccionar información y atender el dilema de la transparencia.

¿Qué nivel de transparencia y explicabilidad es necesario para diferentes actores? ¿Qué elementos se deben privilegiar por sobre otros? Hablamos siempre de una explicabilidad técnica, de una transparencia técnica, pero ¿qué es lo que debemos transparentar, cómo, por qué, a quién?

Recordemos que debemos identificar quiénes van a verse afectados por lo que estamos haciendo, y tenemos que considerar el nivel de simplificación con que entregamos la información. ¿De qué manera vamos a llegar a una persona con baja alfabetización digital y que tiene una desconfianza intrínseca contra la tecnología; o por el contrario, a una persona que es experta en regulación de IA? Por supuesto que para cada caso necesitamos explicaciones diferentes.

Lo otro es que las probabilidades no importan tanto como creemos. Usualmente, tenemos una tendencia a dar porcentajes y a valorar las estadísticas duras: la probabilidad de riesgo, la probabilidad de que falle, etcétera. Y si yo le digo a un grupo de desarrolladores: “Miren, hay una probabilidad de éxito de un 83 o un 93%”, van a decir “esto es fantástico”, “esto nos sirve”. Pero estas probabilidades no necesariamente sirven para otro tipo de personas que no están pensando en las dimensiones técnicas, de cuánto rinde, o qué tan bien optimizado, o cuán exitoso es un sistema. Porque, normalmente, lo que le interesa a la gente son las causas. Preguntarse por qué algo está funcionando de esta manera y no de otra. Y eso nos remite no solo a entender por qué un sistema podría darle más peso a algo que a otra cosa. En este sentido, las generalidades estadísticas para explicar por qué ocurren los hechos no sirven mucho.

Es parecido a la obsesión que tenemos con las encuestas o con la idealización de porcentaje en nuestra sociedad: hemos reducido la delincuencia o la pobreza en un tanto por ciento, ok, ¿pero cómo se traduce eso? ¿Por qué se redujo ese porcentaje? ¿Es porque hay menor pobreza, o es porque hay una desnivelación estadística? ¿Qué significa eso para las personas que siguen en ese porcentaje? ¿Las personas que salieron de ese porcentaje de la medición anterior están realmente mejor?

Las preguntas reales quizás son otras y, por lo mismo, las explicaciones que vemos y las justificaciones dadas en los sistemas de IA, tienen que considerar esto. En este sentido, Miller plantea que las explicaciones son sociales y nuestras socializaciones son transferencias de conocimientos. ¿Cómo explicamos algo mediante una conversación? No basta con dar un dato, no basta con un porcentaje, no basta con que yo le diga “aquí está el modelo, mira esta tabla”: esto es tan inútil como cuando ponen esos términos de servicio que nadie lee, o cuando hay explicaciones extremadamente técnicas desde lo legal para poder explicarle a alguien por qué se llegó a cierta resolución.

A veces, los tecnicismos no llevan a ninguna parte y las explicaciones tienen que ser sociales, tienen que ser pensadas en relación con las creencias que tiene un explicador. Entonces, todas estas distinciones de cómo entendemos cognitivamente lo que es una buena explicación, son extremadamente relevantes para reforzar un proceso sociotécnico, donde no nos interese simplemente la interacción que tenemos desde las herramientas, sino también cómo hacemos que esto signifique algo para quienes están involucrados. Y esto es importante cuando hablamos de los impactos que puede tener una falta de transparencia, o falta de explicabilidad en minorías neurodivergentes, o también en otras minorías que pueden ser como las que hemos hablado, minorías de género, personas de la tercera edad, mujeres, etcétera.

Explicabilidad para personas neurodivergentes

Dentro de esa noción de explicación y de transparencia, hay personas neurodivergentes que tienen interacciones que hacen percibir al mundo de manera diferente. Una explicación puede ser altamente clara y directa para una persona neurotípica, pero confusa para una persona neurodivergente. Esta última puede tomárselo extremadamente literal o no entender el mismo significado y contexto.

Cuando se entrega un documento especificando los procesos (con gráficos, números u otras indicaciones que quizás son muy claros), podrá ser comprendido por una persona con entrenamiento lector, pero no tanto por una persona disléxica, sordomuda, o que tenga una incapacidad visual. Y al respecto hay sistemas que se están trabajando incipientemente para tener sistemas de educación adaptativa, sobre todo destinada a personas con diferentes neurodivergencias y capacidades cognitivas.

Sin embargo, cuando se utiliza IA para personalizar el contenido educativo (y respetar los diferentes ritmos), deben considerarse muchas variables. Cada estudiante tiene una capacidad y una necesidad educativa muy diferente. Y puede proporcionárseles un material inadecuado si el sistema llega a etiquetar erróneamente a estudiantes neurotípicos o neurodivergentes como bajo rendimiento, porque no fueron capaces de completar una tarea en cierto tiempo, o porque demostraron una dificultad con cuestiones que el sistema considera que son conocimiento básico. En este sentido, el *input* de los estudiantes y profesores será fundamental para alimentar al sistema, actualizarlo y personalizarlo.

Esto es una cadena, y el involucramiento real y el uso de la IA responsable se basa, en gran parte, en su proceso de seguimiento. Si lo que queremos es una personalización certera y responsable, esto va a requerir muchos ensayos y errores, y es muy importante transparentar qué se está haciendo con los datos.

Algo parecido puede ocurrir con los softwares de reconocimiento facial o emocional. Los sistemas de reconocimiento en IA, suelen usar datos que no incluyen suficientes variaciones o expresiones emocionales de personas neurodivergentes. La mayoría de las bases de datos son *open source*, y están habilitadas para que cualquier persona las use para entrenar modelos: la mayoría de las tipificaciones indican que una cara “está feliz”, “está sonriendo”, “está mostrando los dientes”, o “es una sonrisa muy pronunciada”. Y esto puede no representar lo mismo en personas que no expresan sus emociones de esa manera, y en la aplicación pueden generarse malinterpretaciones o discriminaciones. Es importante, de este modo, saber cómo se pondera el sistema, qué es lo que hace y si es que lo hace erróneamente. Que las personas sepan, a la vez, que los modelamientos pueden fallar en ciertos porcentajes.

En síntesis, el primer nivel de la pirámide es la *transparencia*, y esta se logra cuando hay suficiente información sobre cómo se desarrolla el modelo, qué variables incluye, con qué finalidad, en qué contexto se ha entrenado, probado e implementado, quién lo hizo y por qué. En segundo lugar tenemos la *explicabilidad*, que podemos entenderla como la manera en que funciona el modelo: cómo se comporta y calcula un algoritmo, cómo se adecúa el nivel de información según el contexto y a quien se le esté comunicando. Y en tercer lugar, en la punta de la pirámide, está la *interpretabilidad* que intenta explicar por qué funciona el modelo de esta manera. La interpretabilidad es un estado cúlmine donde logramos discernir por qué el modelo o el algoritmo ha determinado una salida en específico.

Es decir, cuando hablamos de modelos interpretables, no hablamos simplemente de ver lo que hicieron los modelos, sino comprender por qué en el proceso de desarrollo se decidió usar estos datos (y no otros), o por qué no funciona bien para determinadas personas. Esto último sería un logro de desarrollo responsable.

Capítulo IV:
Hacia dónde debemos ir

Un viaje compartido

Para establecer la relación entre el humano y la inteligencia artificial, no debemos preguntarnos solo acerca de los objetivos que buscamos alcanzar, sino de cómo generar un viaje de coevolución y colaboración. La IA está siendo parte de nuestras vidas en muchas dimensiones, desde su uso como herramienta hasta el modo en que entendemos las cosas. Utilizar la IA para simplificar ciertos procesos nos da más tiempo, nos permite enfocarnos en otras cosas y eso es parte de la evolución de diferentes aspectos sociales que enfrentaremos en los próximos años.

El desarrollo de la IA es una historia compartida. Somos cómplices en su desarrollo. La idea de creatividad, sabiduría y ética se irán entrelazando con los objetivos y los usos que le demos a la inteligencia que tendrán las máquinas en el futuro cercano. La participación humana debe alinearse a nuestros valores y necesidades, enfatizando la incorporación de experiencias y perspectivas diversas.

Desde el punto de vista de las perspectivas neurodivergentes (y considerando sus múltiples enfoques cognitivos), no solo se trata de entender cómo respetarlas, sino además de pensar el modo en que ellas puedan ayudar a crear estos sistemas de IA: plantear alternativas, formular problemas y encontrar soluciones. Por ejemplo, existe un programa de contratación de Microsoft diseñado especialmente para personas autistas, que

reconoce sus fortalezas y las aplica en roles específicos para el desarrollo de la IA. El desafío, entonces, es acoplar y considerar el conocimiento, capacidad y creatividad de las neurodivergencias para abordar diversas estrategias de resolución de problemas.

Desde los enfoques feministas, debemos desafiar y remodelar las estructuras de poder. Cuando hablo de una mirada feminista en la ética de la IA, estoy hablando de cuestionarnos cómo desarrollamos sistemas que trabajen activamente contra sesgos sociales arraigados y que operen desde esa contextualización situada e inclusiva.

Hay aportes fantásticos que han hecho diferentes autoras como Judy Bachman o Erin Young, donde exploran la intersección entre el feminismo y la IA, y donde, entre otros temas, abordan injusticias laborales. En el futuro veremos muchas diferencias sobre cómo se adaptará la fuerza laboral a esta era: cómo se automatizarán algunos procesos y se generarán otras habilidades. Al respecto, la naturaleza histórica y evolutiva de las divisiones de género en la fuerza laboral, va a impactar tanto el desarrollo de la tecnología como en nuestro desarrollo social.

A propósito, existe una serie de representaciones culturales de lo que significa ser un científico de datos o un ingeniero en IA, por supuesto, predominantemente masculina. Y considerando las transformaciones de paradigma social y nuevas narrativas culturales, que una mujer o una persona no binaria diga “yo quiero dedicarme a esto”, “yo puedo tener una visión mucho más matemática o abstracta de un problema”, es un avance muy significativo.

Por otro lado, uno de los grandes debates de los últimos años es el uso de modelos predictivos para diferentes cosas, pero, en particular, para fines policiales. La policía predictiva reproduce enfoques patriarcales sobre violencia de género, a la vez que moldea cómo se entiende y aborda dicha violencia. Para usarlo

efectivamente, debiésemos considerar el papel de los sistemas carcelarios que perpetúan violencias sancionadas por el Estado y que establecen una serie de desigualdades. La misma estructura que estamos tratando de enfrentar con un sistema automatizado, no soluciona el problema porque no entiende los patrones de esa narrativa cultural, de esa narrativa de violencia. Asimismo, observamos manifestaciones de capitalismo racial, o una nueva tendencia de explotación de personas de color a nivel mundial por la industria tecnológica. Esto sucede, sobre todo, en empresas occidentales que explotan grupos desfavorecidos bajo lógicas de empleabilidad y opresión.

Por todo lo anterior, y reforzando la idea medular de este ensayo, no podemos comprender un desarrollo ético y bien argumentado que no sea desde una visión sociotécnica: por muchas de las razones que se han discutido en el libro, la IA está profundamente entrelazada en un tejido tecnológico que depende de la información que entregamos. Y los datos no son algo neutral, un número, una fecha; sino una historia, una narrativa. Aprender a interpretarlos correctamente y poder configurarlos, es uno de los mayores desafíos del futuro. Porque seguirá existiendo más capacidad y sofisticación en el procesamiento de datos: los relojes que recogen nuestros datos, la huella para entrar a nuestros computadores, eran métodos que asociábamos a obras de ciencia ficción o a la CIA, y ahora los vemos naturalizados.

Es tarea de nosotros entender qué implican y cómo nos afectan estos datos. Los institutos, los centros, las empresas de tecnología y las universidades deben reforzar centros interdisciplinarios: sociólogos, antropólogos, filósofos, personas del arte, la música. Así, por ejemplo, colaboraciones entre investigadores de IA y psicólogos, ha permitido el desarrollo de sistemas de IA para tratar pacientes con Alzheimer. Esto mejora el apoyo a la salud mental y cuida a los trabajadores del área que exponen su propio bienestar en el cuidado.

En este viaje colaborativo entre la máquina y el humano, la dimensión ética marcará la diferencia. No podemos crear herramientas vacías que no estén alineadas con lo que esperamos de nuestro desarrollo social, porque la responsabilidad de la IA abarca una creación de sistemas transparentes. Y para esto, se necesitarán regulaciones que apoyen una visión de riesgos para involucrar a los diversos interesados en el desarrollo de la IA y, de paso, asegurar que los sistemas mejoren las capacidades humanas y se mantengan alineados a los derechos humanos bajo principios de equidad y justicia. Todas las decisiones que tomemos hoy, sabemos, están gestando lo que encontraremos mañana.

Cuando se generó el primer avance significativo en términos de capacidad de cómputo, se crearon sistemas de arquitectura avanzada de redes neuronales que revolucionaron la manera de desarrollar sistemas. Era el juguete nuevo, pero como la legislación estaba mucho más atrás, no existió un apoyo integral sobre qué se estaba haciendo y por qué se hacía. No se cuestionaba, solo se testeaba. Y ahora estamos en un punto donde ya no vale la pena seguir empujando el desarrollo tecnológico que no está anclado en un desarrollo ético. El futuro de la IA no será por líneas paralelas, sino desde un vínculo, desde una complicidad donde se junta con lo humano. No es posible seguir avanzando como si se tratase de una carrera técnica de quién llega primero a encontrar la mejor IA, o el más preciso análisis de datos. ¿Por qué llegar a eso? ¿Cuál es la intención? ¿Cómo se va a aplicar? ¿A quién va a beneficiar o a quién va a afectar? No podemos desarrollar más IA sin una buena justificación moral de por qué estamos haciendo lo que estamos haciendo.

Estos enfoques reactivos se alejan de la dimensión ética con que debemos manejar el asunto. En los programas de gobernanza, se discute por años un problema de seguridad, de educación, de salud, y cuando el sistema no da más, se proponen soluciones “parche”. Lo mismo está ocurriendo con la IA y la

ética. Lo común ha sido identificar y eliminar sesgos, pero este enfoque de arreglar problemas específicos no es holístico ya que no considera el contexto ni una visión más amplia. Es similar a tratar de reparar una grieta en vez de asegurarnos que los cimientos sean sólidos. Y esos cimientos ya no son sólidos cuando existen empresas o sistemas con intereses capitalistas, con intereses de inversión política y económica, cuyas estrategias ya son insuficientes.

El asunto está en definir normas sociales. Y esto podría implicar tomar decisiones conscientes sobre cómo la IA debería equilibrar y ponderar decisiones. No se trata simplemente de eliminar un sesgo, sino de lograr un impacto equitativo. Un cambio de narrativa cultural. Un cambio de paradigma. No basta con una lista de principios o protocolos de gobernanza de datos y auditorías, sino algo fundamental que es la comprensión holística de la naturaleza, y esto implicaría crear sistemas que consideren la inclusión a la hora de abordar problemas complejos, equilibrando la técnica y la ética para salir de soluciones metalizadas y armar un arcoiris de posibilidades.

Como sociedad debemos tomar las riendas del desarrollo político y tecnológico para lograr una IA responsable, lo que depende de cómo la estudiamos y la enseñamos. He estado analizando mallas curriculares en nuestro país, donde noto una deficiencia transversal de una ética robusta en la IA. ¿Cuál es el conocimiento que les entregamos a las nuevas generaciones para que sean capaces de hacer ese cambio de paradigma? ¿Cómo enrumbaremos un enfoque que advierta sobre el peligro de la IA en cuanto a la brecha social y económica de quienes tienen acceso a la tecnología y quienes no?

En un futuro no muy lejano, este enfoque holístico debe ser integrado en todas las carreras y sobre todo en las que trabajan en el desarrollo de sistemas. Parte importante de una ética de la IA implica que todas las personas, todos los profesionales, todos

LOS SEGOS DEL ALGORITMO

los ciudadanos, nos hagamos cargo y seamos partícipes de este cambio de paradigma. Y no basta con establecer responsabilidades generales o hablar de los principios a considerar. Se trata de prepararnos para un futuro donde la IA no es simplemente una avanzada tecnológica, sino una presencia sólida, inevitable, pero sobre todo justa.

Referencias

- Bijker, W. E., & Law, J. (1992). *Shaping technology/building society: Studies in sociotechnical change*. The MIT Press. <https://hdl.handle.net/2027/heb01128.0001.001>
- Bolukbasi, T., Chang, K.-W., Zou, J., Saligrama, V., & Kalai, A. (2016). Man is to computer programmer as woman is to homemaker? Debiasing word embeddings. *Proceedings of the 30th International Conference on Neural Information Processing Systems*, 4356–4364.
- Broussard, M. (2018). *Artificial Unintelligence: How Computers Misunderstand the World*. MIT Press.
- Buolamwini, J., & Gebru, T. (2018). Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification. *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 77–91. <https://proceedings.mlr.press/v81/buolamwini18a.html>
- Chopra, A. K., & Singh, M. P. (2018). Sociotechnical Systems and Ethics in the Large. *Proceedings of the 2018 AAAI/ACM Conference on AI, Ethics, and Society*, 48–53. <https://doi.org/10.1145/3278721.3278740>
- Crawford, K. (2021). *The Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. Yale University Press. <https://blackwells.co.uk/bookshop/product/Atlas-of-AI-by-Kate-Crawford/9780300209570>
- Criado-Perez, C. (2019). *Invisible Women: Exposing Data Bias in a World Designed for Men*. Vintage Publisher.
- Davis, M. C., Challenger, R., Jayewardene, D. N. W., & Clegg, C. W. (2014). Advancing socio-technical systems thinking: A call for bravery. *Applied Ergonomics*, 45(2), 171–180. <https://doi.org/10.1016/j.apergo.2013.02.009>
- D'Ignazio, C., & Klein, L. F. (2020). *Data Feminism*. MIT Press.
- Haraway, D. (1988). Situated Knowledges: The Science Question in Feminism and the Privilege of Partial Perspective. *Feminist Studies*, 14(3), 575–599. <https://doi.org/10.2307/3178066>
- Harding, S. (1992). Rethinking Standpoint Epistemology: What Is “Strong Objectivity”? In *Feminist Epistemologies*. Routledge.
- Harding, S. (2015). *Objectivity and Diversity: Another Logic of Scientific Research*. University of Chicago Press. <https://press.uchicago.edu/ucp/books/book/chicago/O/bo19804521.html>

- Miller, T. (2019). Explanation in artificial intelligence: Insights from the social sciences. *Artificial Intelligence*, 267, 1–38. <https://doi.org/10.1016/j.artint.2018.07.007>
- Narayanan, A., & Shmatikov, V. (2006, October 18). *How To Break Anonymity of the Netflix Prize Dataset*. arXiv.Org. <https://arxiv.org/abs/cs/0610105v2>
- Noble, S. (2018). *Algorithms of Oppression: How Search Engines Reinforce Racism*. NYU Press. <https://nyupress.org/9781479837243/algorithms-of-oppression>
- O’Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown Publishing Group.

Recursos recomendados

- Coeckelbergh, M. (2020). *AI Ethics*. MIT Press.
- Crawford, K., Dobbe, R., Dryer, T., Genevieve, F., Green, B., Kaziunas, E., Kak, A., Mathur, V., McElroy, E., Nill Sanchez, A., Raji, D., Lisi Rankin, J., Richardson, R., Schultz, J., Myers West, S., & Whittaker, M. (2019). *AI Now 2019 Report*. AI Now Institute. https://ainowinstitute.org/AI_Now_2019_Report.html.
- Eubanks, V. (2018). *Automating inequality: How high-tech tools profile, police, and punish the poor* /. St. Martin’s Press.
- Selbst, A. D., Boyd, D., Friedler, S. A., Venkatasubramanian, S., & Vertesi, J. (2019). Fairness and Abstraction in Sociotechnical Systems. *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 59–68. <https://doi.org/10.1145/3287560.3287598>

Cómic sobre el uso responsable de datos:
https://dataresponsibly.github.io/comics/vol1/mirror_es.pdf

Cómic sobre los sesgos en IA:
https://dataresponsibly.github.io/we-are-ai/comics/vol4_es.pdf

Para el interior de este libro
se usó papel Bond de 80 grs
y couché de 300 grs. para la portada.
Esta edición de 1300 ejemplares se imprimió
en el taller Eclipse.