PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Fundamentos Matemáticos de Inteligencia Artificial

Clase 5

Manuel A. Sánchez

2026.04.13

Probabilidades

1. Eventos y probabilidades
2. Probabilidad condicional e independencia
3. Ley de Bayes
4. Clasificador Naïve Bayes
5. Aplicación Práctica: Clasificación de Vinos
6. Variables Aleatorias y Distribuciones de Probabilidad
7. De Bernoulli a Deep Learning
8. Valor esperado
9. Distribuciones Conjuntas y Dependencia

Overview: Probabilidad y Estadística

Probabilidad (Enfoque Generativo): Conocemos el modelo (la distribución y sus parámetros) y predecimos el comportamiento de los datos futuros (las muestras).

Estadística (Inferencia y Machine Learning): Observamos los datos reales (entrenamiento) y buscamos inferir o "aprender" el modelo (la distribución subyacente) que los gener

Textos de Referencia recomendados:

Pattern Recognition and Machine Learning (C. Bishop). Capítulos 1 y 2.

Probabilistic Machine Learning: An Introduction (K. Murphy). Capítulo 2.

Deep Learning (Goodfellow, Bengio, Courville). Capítulo 3: Probability and Information Theory.

Eventos y probabilidades

Introducción y motivación

¿Por qué estudiar Probabilidad en Inteligencia Artificial?

El mundo real es ruidoso, los datos son incompletos y el futuro es incierto. La teoría de probabilidades nos provee el **lenguaje matemático riguroso** para cuantificar esa incertidumbre y permitir que los algoritmos tomen decisiones óptimas.

Contenidos

Fundamentos: Espacios muestrales, axiomas y reglas de probabilidad (suma y producto).

Actualización de Creencias: Independencia, probabilidad condicional y el **Teorema de Bayes**.

Modelamiento de Datos: Variables aleatorias, distribuciones clásicas, esperanza y varianza.

Garantías de Aprendizaje: Reglas de transformación y teoremas límite.

El Espacio de Probabilidades $(\Omega, \mathcal{A}, P)$

Un modelo matemático de cualquier experimento aleatorio (o proceso de generación de datos) se define por una tupla de tres elementos:

Espacio Muestral (Ω): El conjunto de todos los resultados individuales posibles (*outcomes*).

Ejemplo: El conjunto de todas las posibles imágenes de 256×256 píxeles.

Espacio de Eventos ($\mathcal{A}$): Una colección de subconjuntos de Ω a los que podemos asignarles una probabilidad (nuestras "consultas" sobre los datos).

Ejemplo: Definimos el evento A como el subconjunto de "imágenes que contienen un gato".

Medida de Probabilidad (P): Función $P : \mathcal{A} \to \mathbb{R}$ que asigna a cada evento $A \in \mathcal{A}$ un número $0 \leq P(A) \leq 1$, cuantificando la certeza de que ocurra.

Ejemplo: La probabilidad real de que una imagen al azar contenga un gato.

Axiomas de Probabilidad

Definición. Una **medida de probabilidad** es una función $P : \mathcal{A} \to [0, 1]$ que asigna un nivel de certeza a cada evento y satisface los tres axiomas de Kolmogorov:

I. **No negatividad:** Para todo evento $E \in \mathcal{A}$, $0 \leq P(E) \leq 1$.

II. **Normalización:** La probabilidad del espacio muestral completo es 1, $P(\Omega) = 1$.

III. σ**-aditividad:** Para cualquier sucesión de eventos **mutuamente disjuntos** (es decir, que no pueden ocurrir al mismo tiempo):

$$P\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} P(E_i)$$

Nota: En IA, el segundo axioma implica que nuestro modelo debe distribuir su "presupuesto" de creencia (1.0) entre todas las posibilidades disponibles.

Propiedades y Espacios Discretos

Regla de la Suma y Cota de la Unión

Eventos Disjuntos: Si A y B no se sobreponen, la probabilidad de su unión es la suma de sus probabilidades individuales.

Cota de la Unión (Boole): Para cualquier colección de eventos (aunque se sobrepongan), se cumple siempre que:

$$P\left(\bigcup E_i\right) \leq \sum P(E_i)$$

Espacio de Probabilidad Discreto Si el espacio muestral Ω es finito o numerable ($\Omega = \{a_1, a_2, \dots\}$), podemos definir la probabilidad mediante una **función de masa**:

$$P(A) = \sum_{i:a_i \in A} p_i, \quad \text{donde } p_i = P(\{a_i\}) \text{ y } \sum p_i = 1$$

Aplicación en IA: Esto es lo que ocurre en problemas de clasificación (ej. clasificar un dígito del 0 al 9).

Eventos y Probabilidades

Observación. Un caso especial muy común ocurre cuando el experimento aleatorio tiene un número finito de resultados que son **igualmente probables**. En este caso, la medida de probabilidad está dada por la regla clásica de Laplace:

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{casos favorables}}{\text{casos posibles totales}}$$

donde $|A|$ denota la cardinalidad (número de elementos) del conjunto A.

Notación de Conjuntos. Usaremos operaciones de conjuntos para definir eventos compuestos:

$$\begin{aligned}
\text{Intersección (Y):} \quad & E_1 \cap E_2 \\
\text{Unión (O):} \quad & E_1 \cup E_2 \\
\text{Diferencia (Sólo } E_1\text{):} \quad & E_1 - E_2 \\
\text{Complemento (NO):} \quad & \bar{E} = E^c = \Omega - E
\end{aligned}$$

Teorema: Probabilidad de la Unión y Complemento

Theorem

Para cualquier par de eventos E_1 y E_2 (disjuntos o no), se cumple la regla general de la suma:

$$P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2)$$

Además, la probabilidad de que un evento NO ocurra (su complemento) es:

$$P(\bar{E}_1) = 1 - P(E_1)$$

Demostración del Teorema de la Unión

Demostración. Podemos expresar E_1 y E_2 separando su intersección:

$$P(E_1) = P(E_1 - (E_1 \cap E_2)) + P(E_1 \cap E_2)$$
$$P(E_2) = P(E_2 - (E_1 \cap E_2)) + P(E_1 \cap E_2)$$

Además, la unión $E_1 \cup E_2$ se puede particionar en tres eventos mutuamente disjuntos:

$$E_1 \cup E_2 = (E_1 - (E_1 \cap E_2)) \cup (E_2 - (E_1 \cap E_2)) \cup (E_1 \cap E_2)$$

Aplicando el axioma de aditividad a estos tres conjuntos disjuntos:

$$P(E_1 \cup E_2) = P(E_1 - (E_1 \cap E_2)) + P(E_2 - (E_1 \cap E_2)) + P(E_1 \cap E_2)$$

Sustituyendo los términos despejados de las primeras ecuaciones, obtenemos:

$$P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2). \quad \blacksquare$$

Ilustración Geométrica

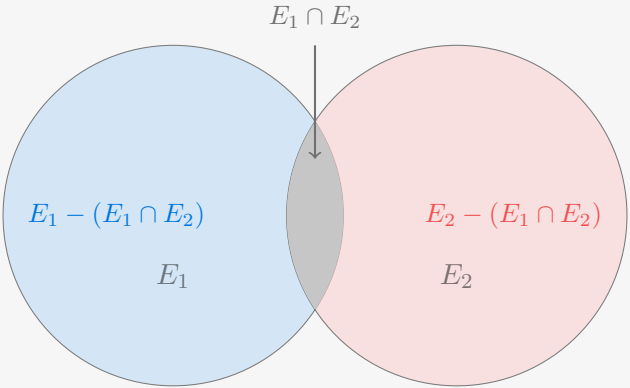

Eventos y probabilidades

Ejemplo. Considere la probabilidad de que al lanzar 3 monedas los resultados sean:

a) Exactamente 2 caras

b) Al menos 2 caras

c) Ninguna cara

Espacio muestral $\Omega = \{\texttt{ccc}, \texttt{ccs}, \texttt{csc}, \texttt{css}, \texttt{scc}, \texttt{scs}, \texttt{ssc}, \texttt{sss}\}$

Eventos:

a) Exactamente 2 caras: $\{\texttt{ccs}, \texttt{csc}, \texttt{scc}\}$

b) Al menos 2 caras: $\{\texttt{ccc}, \texttt{ccs}, \texttt{csc}, \texttt{scc}\}$

c) Ninguna cara: $\{\texttt{sss}\}$

Ejemplo: Lanzamiento de Monedas

Considere el experimento de lanzar 3 monedas honestas.

Espacio muestral: $\Omega = \{\texttt{ccc}, \texttt{ccs}, \texttt{csc}, \texttt{css}, \texttt{scc}, \texttt{scs}, \texttt{ssc}, \texttt{sss}\}$ (8 casos posibles).

Determinamos la probabilidad de los siguientes eventos:

a) **Exactamente 2 caras:** Casos favorables $= \{\texttt{ccs}, \texttt{csc}, \texttt{scc}\}$.

$$P(\text{Exact. 2 caras}) = 3/8$$

b) **Al menos 2 caras:** Casos favorables $= \{\texttt{ccc}, \texttt{ccs}, \texttt{csc}, \texttt{scc}\}$.

$$P(\text{Al menos 2 caras}) = 4/8 = 1/2$$

c) **Ninguna cara:** Casos favorables $= \{\texttt{sss}\}$.

$$P(\text{Ninguna cara}) = 1/8$$

Ejemplo: Lanzamiento de Monedas Cargadas

¿Qué sucede si las monedas no son honestas? Suponga que en cada lanzamiento la probabilidad de que salga cara es p y que salga sello es $q = 1 - p$.

Asumiendo que los lanzamientos son **independientes**, la probabilidad se multiplica:

$$P(\mathtt{ccc}) = p^3, \quad P(\mathtt{ccs}) = p^2 q, \quad \ldots \quad , P(\mathtt{sss}) = q^3.$$

Entonces, recalculamos la probabilidad de obtener exactamente 2 caras (sumando las probabilidades de los 3 casos favorables):

$$P(\text{Exactamente 2 caras}) = P(\mathtt{ccs}) + P(\mathtt{csc}) + P(\mathtt{scc}) = 3p^2 q = 3p^2(1-p).$$

Nota: Esto es un adelanto de la Distribución Binomial que veremos en las próximas secciones.

Ejercicios Clásicos de Conteo: Póker

Un juego de póker corresponde a seleccionar 5 cartas (sin reposición) de un mazo de 52 cartas.

Pintas: $\{$`Diamante, Trébol, Corazón, Pica`$\}$ (4 en total)

Tipos: $\{A, 2, 3, \ldots, 10,$ J, Q, K$\}$ (13 en total)

Determine la probabilidad de obtener:

a) **Póker:** La mano contenga 4 cartas del mismo tipo.

b) **Full House:** La mano contenga 3 cartas de un Tipo y 2 cartas de otro Tipo.

c) **Color (Flush):** Todas las cartas en la mano sean de la misma Pinta.

d) **Escalera (Straight):** La mano consista en tipos consecutivos.

e) **Escalera de Color (Straight Flush).**

(Sugerencia: Utilice la fórmula de combinatorias $\binom{n}{k}$ para contar los casos favorables y totales).

El Problema del Cumpleaños (Anti-intuitiva)

Problema: Si hay n personas en una sala, ¿qué tan grande debe ser n para tener al menos un **50% de probabilidad** de que al menos 2 personas compartan su día de cumpleaños?

Usamos la regla del complemento:

$$\begin{aligned} P(\geq 2 \text{ cump. coinciden}) &= 1 - P(\text{Nadie comparte cumpleaños}) \\ P(\text{Nadie comparte}) &= \left(\frac{365}{365}\right)\left(\frac{364}{365}\right)\left(\frac{363}{365}\right)\cdots\left(\frac{365-n+1}{365}\right) \\ &= \frac{365!}{(365-n)! \cdot 365^n} \end{aligned}$$

Respuesta sorprendente: Para $n = 23$, pasamos la línea del 50% de probabilidad ($P(\text{Nadie comparte}) \approx 0.4927$). ¡En un grupo de solo 23 personas, es más probable que dos compartan cumpleaños a que no lo hagan!

Probabilidad condicional e independencia

Probabilidad Condicional

En la práctica, a menudo calculamos probabilidades sabiendo que **cierta información ya es verdadera**.

Definición. La **probabilidad condicional** de que un evento E ocurra dado que el evento F ya ocurrió es:

$$P(E|F) = \frac{P(E \cap F)}{P(F)}, \qquad \text{(asumiendo } P(F) > 0\text{)}$$

Interpretación: Nuestro "universo" se reduce de Ω a F, y buscamos la proporción de E que vive dentro de F.

Eventos Independientes

Definición. Dos eventos E y F se dicen **independientes** si saber que F ha ocurrido no cambia la probabilidad de que E ocurra ($P(E|F) = P(E)$).
Despejando de la fórmula condicional, esto equivale a:

$$P(E \cap F) = P(E)P(F)$$

Además, los eventos $E_1, \ldots, E_k$ son mutuamente independientes si y sólo si, para cualquier subconjunto de índices I:

$$P\left(\bigcap_{i \in I} E_i\right) = \prod_{i \in I} P(E_i)$$

Ejemplo: El Problema de Monty Hall

Contexto: Un concurso con 3 puertas (1 auto, 2 cabras). Eliges una puerta. El presentador abre otra revelando una cabra. ¿Te conviene cambiar de puerta?

Eventos:

E: Eliges la puerta correcta al principio (Prob $= 1/3$).

F: Ganas el auto si decides **cambiar** de puerta.

Usando el Teorema de Probabilidad Total (que formalizaremos pronto):

$$\begin{aligned} P(F) &= P(F|E)P(E) + P(F|\bar{E})P(\bar{E}) \\ &= (0) \cdot \left(\frac{1}{3}\right) + (1) \cdot \left(\frac{2}{3}\right) = \frac{2}{3} \end{aligned}$$

Conclusión: Sí, cambiar duplica tus probabilidades de ganar.

Ejemplo eventos independientes

Sea S la suma de los resultados del lanzamiento de 2 dados y sean los eventos:

$$E: \text{ suma es impar}, \qquad F: \text{ suma es menor a } 8$$

Determine:

a) $P(E)$

b) $P(F)$

c) $P(E \cap F)$

d) $P(F|E)$

Ejemplo eventos independientes

Sea S la suma de los resultados del lanzamiento de 2 dados y sean los eventos:

$$E: \text{ suma es impar}, \qquad F: \text{ suma es menor a } 8$$

Determine:

a) $P(E) =$

b) $P(F)$

c) $P(E \cap F)$

d) $P(F|E)$

Ejemplo eventos independientes

Sea S la suma de los resultados del lanzamiento de 2 dados y sean los eventos:

$$E: \text{ suma es impar}, \qquad F: \text{ suma es menor a } 8$$

Determine:

a) $P(E) =$

b) $P(F) =$

c) $P(E \cap F)$

d) $P(F|E)$

Ejemplo eventos independientes

Sea S la suma de los resultados del lanzamiento de 2 dados y sean los eventos:

$$E: \text{ suma es impar}, \qquad F: \text{ suma es menor a } 8$$

Determine:

a) $P(E) =$

b) $P(F) =$

c) $P(E \cap F) =$

d) $P(F|E)$

Ejemplo eventos independientes

Sea S la suma de los resultados del lanzamiento de 2 dados y sean los eventos:

$$E: \text{ suma es impar}, \qquad F: \text{ suma es menor a } 8$$

Determine:

a) $P(E) =$

b) $P(F) =$

c) $P(E \cap F) =$

d) $P(F|E) =$

Ejemplo eventos independientes

Tenemos un dado y los eventos

$$E: \text{ resultado es par}, \quad F: \text{ resultado es } 1, 2, 3, 4$$

$$P(E) = \frac{1}{2}$$
$$P(F) = \frac{2}{3}$$
$$P(E \cap F) = \frac{1}{3}$$

Ley de Bayes

Regla de producto

Theorem

Para toda sucesión de eventos $A_1, A_2, ..., A_n$*,*

$$P[A_1 A_2 \cdots A_n] = P[A_1]P[A_2|A_1]P[A_3|A_1 A_2] \cdots P[A_n|A_1 \cdots A_{n-1}]$$

Ley de probabilidad total

Theorem (Ley de probabilidad total)

Sean $E_1, E_2, \ldots, E_n$ *eventos mutuamente disjuntos en un espacio muestral* Ω*, y tales que*

$$\bigcup_{j=1}^{n} E_j = \Omega.$$

Entonces,

$$P(B) = \sum_{i=1}^{n} P(B \cap E_i) = \sum_{i=1}^{n} P(B|E_i)P(E_i)$$

Ley de Bayes

Theorem (Ley de Bayes)

Asuma que $E_1, E_2, \ldots, E_n$ *son eventos mutuamente disjuntos tales que*

$$\bigcup_{j=1}^{n} E_j = \Omega.$$

Entonces,

$$P(E_j|B) = \frac{P(E_j \cap B)}{P(B)} = \frac{P(B|E_j)P(E_j)}{\sum_{i=1}^{n} P(B|E_i)P(E_i)}$$

Ejemplo: Aplicación de Ley de Bayes

Tenemos 3 monedas, 2 de ellas honestas y 1 cargada que da cara con probabilidad $2/3$. No sabemos cual de las monedas está cargada. Hacemos el siguiente experimento: lanzamos las 3 monedas, la primera y segunda moneda da cara y la tercera sello. Determine la probabilidad que la primera moneda sea la cargada.

Solución. Definimos los eventos:

$$\begin{aligned} E_i &: \text{ evento de que la } i\text{ -ésima moneda sea la cargada} \\ B &: \text{ evento ccs} \end{aligned}$$

Tenemos $P(E_1) = \frac{1}{3}, \quad P(E_2) = \frac{1}{3}, \quad P(E_3) = \frac{1}{3}$

$$P(B|E_1) = \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{6}, \quad P(B|E_2) = \frac{1}{2} \cdot \frac{2}{3} \cdot \frac{1}{2} = \frac{1}{6}, \quad P(B|E_3) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{2}$$

Ejemplo (moneda cargada): Aplicación de Ley de Bayes

Tenemos 3 monedas, 2 de ellas honestas y 1 cargada que da cara con probabilidad $2/3$. No sabemos cual de las monedas está cargada. Hacemos el siguiente experimento: lanzamos las 3 monedas, la primera y segunda moneda da cara y la tercera sello. Determine la probabilidad que la primera moneda sea la cargada.

Solución.

$$
\begin{aligned}
P(E_1|B) &= \frac{P(B|E_1)P(E_1)}{\sum_{i=1}^{3} P(B|E_i)P(E_i)} \\
&= \frac{P(B|E_1)P(E_1)}{P(B|E_1)P(E_1) + P(B|E_2)P(E_2) + P(B|E_3)P(E_3)} \\
&= \frac{2}{5}
\end{aligned}
$$

El resultado del experimento incrementa la posibilidad de que la primera moneda sea la cargada de $1/3$ a $2/5$.

Ejemplo (Clasificador de Spam): Aplicación de Ley de Bayes

Un filtro de correos analiza la presencia de la palabra **"Descuento"**. Historicamente, sabemos que:

El 20% de todos los correos que recibimos son Spam.
Si un correo es Spam, hay un 70% de probabilidad de que contenga la palabra "Descuento".
Si un correo NO es Spam (Ham), hay solo un 5% de probabilidad de que contenga la palabra "Descuento".

Problema: Llega un correo nuevo y contiene la palabra "Descuento". ¿Cuál es la probabilidad real de que sea Spam?

Solución. Definimos: E_1: Es Spam, E_2: No es Spam, B: Contiene "Descuento".

$$P(E_1|B) = \frac{P(B|E_1)P(E_1)}{P(B|E_1)P(E_1) + P(B|E_2)P(E_2)}$$
$$= \frac{(0.70)\cdot(0.20)}{(0.70)\cdot(0.20) + (0.05)\cdot(0.80)} = \frac{0.14}{0.14 + 0.04} = 0.777$$

Ejemplo: Aplicación de Ley de Bayes

Tenemos un test de covid que es certero en un 95% para las personas que si tiene covid, pero solo un 78% para aquellas que no tienen el virus. La información del dia de hoy indica una positividad del 0.3%. Determine la probabilidad que una persona tenga covid dado que el test dio positivo.

Solución. Definimos los eventos:

$$\begin{aligned} E_1 &: \text{ una persona testeada tiene covid} \\ E_2 &: \text{ una persona testeada no tiene covid} \\ B &: \text{ una persona testeada da positivo} \end{aligned}$$

$$P(B|E_1) = 0.95, \quad P(B|E_2) = 1 - 0.78, \quad P(E_1) = 0.003, \quad P(E_2) = 0.997$$

Ejemplo: Aplicación de Ley de Bayes

Tenemos un test de covid que es certero en un 95% para las personas que si tiene covid, pero solo un 78% para aquellas que no tienen el virus. La información del dia de hoy indica una positividad del 0.3%. Determine la probabilidad que una persona tenga covid dado que el test dio positivo.

Solución.

$$
\begin{aligned}
P(E_1|B) &= \frac{P(B|E_1)P(E_1)}{P(B|E_1)P(E_1) + P(B|E_2)P(E_2)} \\
&= \frac{(0.95)\cdot(0.003)}{(0.95)\cdot(0.003) + (1-0.78)\cdot(0.997)} \\
&= 0.012826.
\end{aligned}
$$

Clasificador Naïve Bayes

Introducción al Clasificador Naïve Bayes

El **Clasificador Naïve Bayes** es un modelo probabilístico fundamental en Inteligencia Artificial, basado en la aplicación directa del Teorema de Bayes.

El Problema de Clasificación: Dado un vector de atributos $x = [x_1, x_2, \ldots, x_n]^\top \in \mathbb{R}^n$, queremos asignar x a una de K clases posibles $\{C_1, C_2, \ldots, C_K\}$.

Utilizando el Teorema de Bayes, calculamos la **probabilidad a posteriori** de cada clase dado el dato x:

$$P(C_k|x) = \frac{P(x|C_k)P(C_k)}{P(x)}$$

Nuestra regla de decisión será elegir la clase C_k que maximice esta probabilidad.

La Hipótesis "Naïve" (Ingenua)

Calcular la probabilidad conjunta $P(x|C_k) = P(x_1, \ldots, x_n|C_k)$ es computacionalmente intratable en altas dimensiones debido a la **maldición de la dimensionalidad** (requeriría observar todas las combinaciones posibles de atributos).

El modelo asume "ingenuamente" que todos los atributos x_i son **mutuamente independientes** dada la clase C_k.

$$P(x_1, \ldots, x_n|C_k) = P(x_1|C_k) \cdot P(x_2|C_k) \cdots P(x_n|C_k) = \prod_{i=1}^{n} P(x_i|C_k)$$

A pesar de que esta hipótesis casi nunca se cumple en el mundo real (ej. en un texto, la palabra "oferta" y "descuento" sí están correlacionadas), el modelo funciona sorprendentemente bien en la práctica.

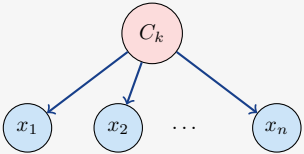

La Regla de Decisión (MAP)

Sustituyendo el supuesto ingenuo en el Teorema de Bayes, obtenemos:

$$P(C_k|x) = \frac{P(C_k)\prod_{i=1}^{n} P(x_i|C_k)}{P(x)}$$

Optimización: Dado que el denominador $P(x)$ (la evidencia) es constante y exactamente igual para todas las clases, podemos ignorarlo para propósitos de maximización. Así, obtenemos la regla de decisión **Maximum A Posteriori (MAP)**:

$$\hat{y} = \arg\max_{k\in\{1,\ldots,K\}} \left(P(C_k) \prod_{i=1}^{n} P(x_i|C_k) \right)$$

$P(C_k)$: **Prior** (Probabilidad a priori de la clase).

$\prod P(x_i|C_k)$: **Likelihood** (Verosimilitud de los datos).

Entrenamiento del Modelo (Fase de Ajuste)

"Entrenar" un modelo Naïve Bayes consiste simplemente en usar estadística descriptiva para calcular los parámetros a partir del conjunto de entrenamiento de tamaño N:

Cálculo del Prior $P(C_k)$: Frecuencia relativa de la clase.

$$P(C_k) = \frac{N_{C_k}}{N}$$

Cálculo de la Verosimilitud $P(x_i|C_k)$: Depende del tipo de datos.

Datos Categóricos (Multinomial/Bernoulli): Conteo de frecuencias de la palabra o atributo i en la clase k.

Datos Continuos (Gaussiano): Se asume que $P(x_i|C_k) \sim \mathcal{N}(\mu_{ik}, \sigma_{ik}^2)$. El entrenamiento consiste en calcular la media y la varianza empírica del atributo i para la clase k.

Aplicación Práctica: Clasificación de Vinos

El Dataset de Vinos (Wine Dataset)

Descripción del Problema:
Contamos con los resultados de un análisis químico realizado a vinos cultivados en la misma región de Italia, pero derivados de **tres cultivares diferentes** (Clases 0, 1 y 2).

El análisis determinó las cantidades de **13 componentes** presentes en cada uno de los tres tipos de vinos.

Objetivo: Entrenar un modelo de Inteligencia Artificial capaz de adivinar el tipo de vino (la clase) basándose únicamente en sus 13 mediciones químicas.

Selección del Modelo: Naïve Bayes Gaussiano

A diferencia del filtro de Spam (donde contábamos palabras discretas), nuestros datos ahora son números **continuos** (ej. Alcohol = 13.2%).

La Asunción Gaussiana: Para modelar la verosimilitud (Likelihood) $P(x_i|C_k)$, el clasificador asume que los valores continuos asociados a cada clase están distribuidos según una **Distribución Normal (Gaussiana)**.

$$P(x_i|C_k) = \frac{1}{\sqrt{2\pi\sigma_{ik}^2}} \exp\left(-\frac{(x_i - \mu_{ik})^2}{2\sigma_{ik}^2}\right)$$

Entrenamiento: El algoritmo simplemente agrupa los vinos por su clase y calcula la **media** (μ) y la **varianza** (σ^2) de cada uno de los 13 atributos químicos.

Variables Aleatorias y Distribuciones de Probabilidad

Variables Aleatorias

Definición. Una **variable aleatoria** X es una función $X : \Omega \to \mathbb{R}$ que mapea resultados de un experimento a números reales, de modo que podemos medir su probabilidad.

Función de Distribución Acumulada (CDF): Es la herramienta fundamental para caracterizar una V.A. X, denotada por $F(x)$:

$$F(x) = P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\})$$

Variables Aleatorias Discretas: Son aquellas cuyo rango es un conjunto finito o **infinito numerable**. La probabilidad de un valor puntual se define mediante la suma de las probabilidades de los resultados que mapean a ese valor:

$$P(X = x) = \sum_{\omega \in \Omega : X(\omega) = x} P(\omega)$$

Función de Masa de Probabilidad

Para una V.A. discreta, definimos la **Función de Masa de Probabilidad** (función de densidad) $f(x)$ como:

$$f(x) = P(X = x)$$

donde se satisfacen las propiedades: $0 \leq f(x) \leq 1$ y $\sum_x f(x) = 1$.

Propiedad de la CDF Discreta: La función $F(x)$ es una **función constante a trozos** (monótona no decreciente) que presenta saltos en los puntos donde existe masa de probabilidad:

$$F(x) = \sum_{x_i \leq x} f(x_i)$$

El tamaño del salto en x_i es exactamente $f(x_i)$.

Modelos de Probabilidad Discreta

$P(X = x) = f(x)$ (Función de Masa de Probabilidad)

Nombre	Notación	Función de Masa $f(x)$	Parámetros
Bernoulli	Bern(p)	$p^x(1-p)^{1-x}$	$p \in [0,1]$
Binomial	Bin(n,p)	$\binom{n}{x}p^x(1-p)^{n-x}$	$n \in \mathbb{N}, p \in [0,1]$
Multinomial	Mult$(n,\boldsymbol{p})$	$\frac{n!}{x_1!\cdots x_k!}p_1^{x_1}\cdots p_k^{x_k}$	$\sum p_i = 1, \sum x_i = n$
Poisson	Pois(λ)	$\frac{e^{-\lambda}\lambda^x}{x!}$	$\lambda > 0$
Geométrica	Geom(p)	$(1-p)^{x-1}p$	$p \in (0,1]$
Hipergeom.	Hyper(N,K,n)	$\frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}}$	$N,K,n \in \mathbb{N}$

Ejemplo: Control de Calidad (Dist. Hipergeométrica)

Escenario: Muestreo sin reemplazo de un lote finito.

N: Número total de items en el lote.

K: Número de items defectuosos en el lote.

n: Tamaño de la muestra extraída.

x: Número de items defectuosos encontrados en la muestra.

La probabilidad de encontrar exactamente x defectuosos se calcula como:

$$f(x) = P(X = x) = \frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}}$$

Interpretación en Ciencia de Datos: Si observamos un valor x muy alto, esto nos da evidencia estadística para rechazar el lote o inferir que el parámetro K es mayor de lo reportado (Inferencia).

Variables Aleatorias Continuas y Densidad (PDF)

A diferencia del caso discreto, una **variable aleatoria continua** puede tomar cualquier valor dentro de un intervalo de números reales (ej. tiempo de respuesta de un servidor, o el valor del peso en una red neuronal).

Función de Densidad de Probabilidad (PDF): Una V.A. continua X se caracteriza por una función $f(x) \geq 0$ tal que el área total bajo la curva es exactamente 1 ($\int_{-\infty}^{\infty} f(x)dx = 1$).

En el caso continuo, la probabilidad de observar un valor **exacto** es siempre cero: $P(X = c) = 0$. La densidad $f(x)$ **NO** es una probabilidad; solo podemos calcular probabilidades sobre **intervalos**.

Cálculo de Probabilidades Continuas

Función de Distribución Acumulada (CDF): Para una V.A. continua, la CDF (probabilidad acumulada) se obtiene integrando la función de densidad desde $-\infty$ hasta el valor x:

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(u)du$$

Probabilidad en un Intervalo: La probabilidad de que la variable caiga entre dos valores a y b corresponde geométricamente al **área bajo la curva** de la PDF:

$$P(a < X \leq b) = F(b) - F(a) = \int_{a}^{b} f(x)dx$$

Nota en IA: Calcular probabilidades continuas se reduce a un problema de integración (o más frecuentemente, aproximación numérica).

Modelos de Probabilidad Continua

Nombre	Notación	Función de Densidad $f(x)$	Dominio
Uniforme	$\text{Unif}(a, b)$	$\frac{1}{b-a}$	$x \in [a, b]$
Normal	$\mathcal{N}(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$	$x \in \mathbb{R}$
Exponencial	$\text{Exp}(\lambda)$	$\lambda e^{-\lambda x}$	$x \geq 0$
Gamma	$\text{Gamma}(\alpha, \beta)$	$\frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$	$x > 0$
Beta	$\text{Beta}(\alpha, \beta)$	$\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1}$	$x \in [0, 1]$
Student-t	t_ν	$\frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$	$x \in \mathbb{R}$

Nota en IA: La distribución Normal fundamenta el Error Cuadrático Medio (MSE). Beta y Gamma se utilizan como distribuciones a priori en inferencia Bayesiana.

De Bernoulli a Deep Learning

Clasificación Binaria y la Distribución de Bernoulli

En Inteligencia Artificial, el problema más común es la **clasificación binaria** (ej. predecir si un tumor es maligno o benigno, si un correo es spam o no).

Codificación de Etiquetas: Definimos la respuesta correcta como $y \in \{0, 1\}$.

El Modelo Predictivo: Nuestra red neuronal (o modelo logístico) procesa un dato x y retorna una probabilidad estimada $\hat{p} \in (0, 1)$ de que la clase sea 1.

Si asumimos que cada etiqueta y es una variable aleatoria generada por un proceso de Bernoulli con parámetro $\hat{p}$, su Función de Masa de Probabilidad se escribe compactamente como:

$$P(Y = y|x) = \hat{p}^y (1 - \hat{p})^{1-y}$$

Comprobación: Si $y = 1$, la fórmula retorna $\hat{p}$. Si $y = 0$, la fórmula retorna $(1 - \hat{p})$.

Optimización: Máxima Verosimilitud (MLE)

Supongamos que tenemos un conjunto de entrenamiento con N datos independientes: $\{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\}$. Nuestro modelo produce N predicciones $\{\hat{p}_1, \hat{p}_2, \ldots, \hat{p}_N\}$.

La Función de Verosimilitud (Likelihood): ¿Cuál es la probabilidad de que nuestro modelo haya generado exactamente las etiquetas y que observamos en la realidad? Multiplicamos las probabilidades individuales:

$$\mathcal{L}(\hat{p}) = \prod_{i=1}^{N} P(Y = y_i | x_i) = \prod_{i=1}^{N} \hat{p}_i^{y_i} (1 - \hat{p}_i)^{1-y_i}$$

Objetivo del Machine Learning: Queremos ajustar los pesos de nuestra red neuronal para **maximizar** esta verosimilitud $\mathcal{L}(\hat{p})$.

El Nacimiento de la "Cross-Entropy Loss"

Maximizar un producto de miles de probabilidades causa *underflow* numérico (las multiplicaciones colapsan a 0).

Log-Verosimilitud Negativa: 1. Aplicamos el logaritmo natural ($\log$) para transformar productos en sumas.
2. Multiplicamos por -1 porque en optimización computacional (PyTorch/TensorFlow) los algoritmos siempre buscan **minimizar** una función de pérdida (Loss Function).

$$\begin{aligned}\text{Loss} &= -\log \mathcal{L}(\hat{p}) = -\log \left(\prod_{i=1}^{N} \hat{p}_i^{y_i} (1-\hat{p}_i)^{1-y_i} \right) \\ &= -\sum_{i=1}^{N} \left[y_i \log(\hat{p}_i) + (1-y_i) \log(1-\hat{p}_i) \right]\end{aligned}$$

Ejemplo 1: Variable Aleatoria (Caso Equiprobable)

Consideremos el lanzamiento de dos monedas honestas. Definimos la variable aleatoria X como el **número total de caras**.

El espacio muestral es $\Omega = \{\texttt{cc}, \texttt{cs}, \texttt{sc}, \texttt{ss}\}$. La función $X : \Omega \to \mathbb{R}$ realiza el siguiente mapeo:

$$X(\texttt{cc}) = 2, \quad X(\texttt{cs}) = 1, \quad X(\texttt{sc}) = 1, \quad X(\texttt{ss}) = 0$$

Los valores posibles que toma X son $\{0, 1, 2\}$. Calculamos su **Función de Masa de Probabilidad**:

$$\begin{aligned} P(X = 2) &= P(\{\texttt{cc}\}) = 1/4 \\ P(X = 1) &= P(\{\texttt{cs}, \texttt{sc}\}) = 2/4 = 1/2 \\ P(X = 0) &= P(\{\texttt{ss}\}) = 1/4 \end{aligned}$$

Ejemplo 2: Variable Aleatoria (Caso No Equiprobable)

Tenemos una urna con bolas verdes (v) y rojas (r). La probabilidad de extraer una bola verde es 0.3.

Experimento: Extraemos dos bolas **con reemplazo** (eventos independientes). Definimos X como el **número de bolas verdes extraídas**. Valores posibles: $\{0, 1, 2\}$.

Calculamos la probabilidad para cada valor de X:

$$P(X = 2) = P(\{v, v\}) = P(v) \cdot P(v) = (0.3)(0.3) = \mathbf{0.09}$$
$$P(X = 1) = P(\{v, r\}) + P(\{r, v\}) = (0.3)(0.7) + (0.7)(0.3) = \mathbf{0.42}$$
$$P(X = 0) = P(\{r, r\}) = (0.7)(0.7) = \mathbf{0.49}$$

Comprobación de sanidad: $0.09 + 0.42 + 0.49 = 1.0$ *(La suma de todas las masas de probabilidad debe ser 1).*

Valor esperado

Valor esperado

Definición. El valor esperado de una variable aleatoria continua X con función de densidad f, denotada por $E[X]$ es definido por

$$E[X] = \int_{-\infty}^{\infty} x f(x) dx.$$

Definición. El valor esperado de una variable aleatoria discreta X, denotado por $E[X]$, está dado por

$$E[X] = \sum_{x} x f(x) = \sum_{i} i P(X = i)$$

donde la suma es sobre todos los valores en el rango de X.

Propiedades del Valor Esperado

- Si aplicamos una función $h(X)$ a nuestra variable aleatoria, su valor esperado es el promedio ponderado de esa función:

$$E[h(X)] = \int_{-\infty}^{\infty} h(x)f(x)dx \quad \text{(Caso Continuo)}$$

- **Linealidad de la Esperanza :** Sean X e Y variables aleatorias, y a, b, c constantes reales. Entonces:

$$E[X+Y] = E[X] + E[Y]$$
$$E[aX+b] = aE[X] + b$$

Ejemplo 1: Suma de Dos Dados

Sea X la variable aleatoria que representa la suma de los resultados al lanzar 2 dados honestos.

Método 1:)

$$
\begin{aligned}
E[X] &= \sum_{i=2}^{12} iP(X=i) \\
&= 2\left(\frac{1}{36}\right) + 3\left(\frac{2}{36}\right) + \cdots + 7\left(\frac{6}{36}\right) + \cdots + 12\left(\frac{1}{36}\right) = 7
\end{aligned}
$$

Método 2: Definimos X_1 como el resultado del primer dado y X_2 como el segundo. Sabemos que $E[X_1] = E[X_2] = 3.5$.

$$E[X] = E[X_1 + X_2] = E[X_1] + E[X_2] = 3.5 + 3.5 = 7$$

Ejemplo 2: Variables Indicadoras (El Guardarropa)

Problema: n clientes dejan sus abrigos en un guardarropa. El asistente pierde los tickets y devuelve los n abrigos **al azar**. ¿Cuál es el número esperado de personas que reciben su abrigo correcto?

Sea X el total de personas con el abrigo correcto. Calcular la PMF de X es muy difícil. Pero podemos usar **Variables Indicadoras**:

$$X_i = \begin{cases} 1 & \text{si la persona } i \text{ recibe su abrigo correcto} \\ 0 & \text{si no} \end{cases}$$

Notemos que $X = \sum_{i=1}^{n} X_i$. $E[X] = E\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} E[X_i]$
Como la probabilidad de que la persona i reciba su abrigo es $\frac{1}{n}$, entonces $E[X_i] = 1 \cdot \frac{1}{n} + 0 = \frac{1}{n}$. Finalmente: $E[X] = n \cdot \left(\frac{1}{n}\right) = \mathbf{1}$.

Varianza

Definición. La **varianza** de una variable aleatoria X con función de densidad f, denota por $Var(X)$ (a veces σ^2), está definida por

$$Var[X] = E[X - E[X]]^2 = E[X^2] - (E[X])^2$$

*Nota: La **Desviación Estándar** es simplemente $\sigma = \sqrt{Var(X)}$. Se utiliza porque tiene las mismas unidades físicas que la variable X.*

Esperanza y Varianza de Distribuciones Clásicas

Distribución	Notación	$E[X]$	$\text{Var}[X]$
Bernoulli	$\text{Bern}(p)$	p	$p(1-p)$
Binomial	$\text{Bin}(n,p)$	np	$np(1-p)$
Poisson	$\text{Pois}(\lambda)$	λ	λ
Uniforme	$\text{Unif}(a,b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Normal	$\mathcal{N}(\mu,\sigma^2)$	μ	σ^2
Exponencial	$\text{Exp}(\lambda)$	$1/\lambda$	$1/\lambda^2$
Gamma	$\text{Gamma}(\alpha,\beta)$	α/β	α/β^2
Student-t	t_ν	0 $(\nu > 1)$	$\frac{\nu}{\nu-2}$ $(\nu > 2)$

Función Generadora de Momentos

Definición. La función generadora de momentos M de una variable aleatoria X está definida por

$$M(s) = E[\exp(sX)], \quad s \in \mathbb{R}.$$

Observación. Las funciones generadoras de momentos de dos variables aleatorias coinciden si y sólo si las variables aleatorias tienen la misma distribución de probabilidad.

Función Generadora de Momentos (FGM)

Definición. La FGM $M(s)$ de una variable aleatoria X transforma el cálculo de integrales complejas en derivadas simples:

$$M(s) = E[e^{sX}]$$

Utilidad en Estadística e IA:

Generar Momentos: La derivada n-ésima de $M(s)$ evaluada en $s = 0$ nos da el momento de orden n: $\frac{d^n}{ds^n} M(s)\Big|_{s=0} = E[X^n]$. Con esto calculamos medias y varianzas rápidamente.

Identidad: Si dos variables tienen la misma FGM, tienen **exactamente la misma distribución**. Es la herramienta matemática usada para demostrar el Teorema del Límite Central.

Ejemplo de momentos, distribución Γ

Sea $X \sim \text{Gamma}(\alpha, \lambda)$. Para $s < \lambda$, la función generadora de momentos de X en s está dada por

$$\begin{aligned} M(s) = E[\exp(sX)] &= \int_0^\infty \exp(sx) \frac{\exp(-\lambda x)\lambda^\alpha x^{\alpha-1}}{\Gamma(\alpha)} \\ &= \left(\frac{\lambda}{\lambda - s}\right)^\alpha \int_0^\infty \frac{\exp(-(\lambda - s)x)(\lambda - s)^\alpha x^{\alpha-1}}{\Gamma(\alpha)} dx \\ &= \left(\frac{\lambda}{\lambda - s}\right)^\alpha. \end{aligned}$$

$$M'(s)|_{s=0} = \left((\alpha \frac{\lambda^\alpha}{(\lambda - s)^{\alpha+1}}) \right) |_{s=0} = \frac{\alpha}{\lambda}$$

Distribuciones Conjuntas y Dependencia

Distribuciones Conjuntas de Probabilidad

Definición. Sean $X_1, X_2, ..., X_n$ variables aleatorias. Defina el vector $X = [X_1, ..., X_n]^\top$ con distribución de probabilidad conjunta F definida por:

$$F(x_1, ..., x_n) = P(X_1 \leq x_1, ..., X_n \leq x_n)$$

Un vector aleatorio X que toma valores en $\mathbb{R}^n$ tiene una **función de densidad conjunta** f si:

$$P(X \in B) = \int_B f(x_1, \ldots, x_n)\, dx_1 \ldots dx_n$$

Distribuciones Marginales: Las funciones de densidad de cada componente se recuperan integrando (o sumando) sobre las demás variables. Para $X = [X_1, X_2]^\top$:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2)\, dx_2$$

Independencia de Variables Aleatorias

Ahora que tenemos la distribución conjunta, podemos definir la independencia formalmente.

Theorem (Caracterización de independencia)

Las variables aleatorias $X_1, ..., X_n$ con densidades marginales $f_{X_1}, ..., f_{X_n}$ y densidad conjunta f son ***independientes*** *si y sólo si su conjunta se factoriza:*

$$f(x_1, ..., x_n) = f_{X_1}(x_1) \cdots f_{X_n}(x_n), \quad \textit{para todo } x_1, ..., x_n.$$

En Machine Learning, casi siempre asumimos que los datos de entrenamiento son **Independientes e Idénticamente Distribuidos (i.i.d.)**. Esto es lo que nos permitió usar la productoria $\prod$ en el Clasificador Naïve Bayes.

Covarianza

Si dos variables *no* son independientes, necesitamos medir cómo varían juntas.

Covarianza: Mide la dirección de la dependencia lineal entre dos variables.

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

Propiedad Clave: Si X e Y son independientes, entonces $E[XY] = E[X]E[Y]$, y por lo tanto $\text{Cov}(X, Y) = 0$.

Precaución: El inverso no siempre es cierto. $\text{Cov}(X, Y) = 0$ implica que no hay relación *lineal*, pero podría existir una fuerte dependencia no lineal.

PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE