



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Fundamentos Matemáticos de Inteligencia Artificial

Clase 7

Manuel A. Sánchez
2026.04.27

Optimización

- 1 Cálculo en una variable
- 2 Cálculo multivariable
- 3 Convexidad
- 4 Método de Newton
- 5 Método del descenso del gradiente
- 6 Método Levenberg-Marquardt para NLS

Cálculo en una variable

Función de una variable

Considere una función $f : \mathbb{R} \rightarrow \mathbb{R}$, entonces

La pendiente de la recta secante que pasa por los puntos $(x, f(x))$ y $(x + h, f(x + h))$ está dada por

$$m = \frac{f(x + h) - f(x)}{(x + h) - x} = \frac{f(x + h) - f(x)}{h}$$

esto es la razón de cambio promedio.

La pendiente de la recta tangente que pasa por el punto $(x, f(x))$ está dada por

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x + h) - f(x)}{h}$$

la razón de cambio instantáneo.

Ilustración

Considere la función

$$f(x) = x^4 + 7x^3 + 5x^2 - 17x + 3$$


$$f'(x) = 4x^3 + 21x^2 + 10x - 17$$

$$f''(x) = 12x^2 + 42x + 10$$

Comentar acerca de:

Mínimo local y mínimo global.

Máximo local y máximo global.



Funciones diferenciables

Definición. Una función $f : \mathbb{R} \rightarrow \mathbb{R}$ se dice **diferenciable** en un punto $x = a$ si su **derivada** en el punto

$$f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h} \text{ existe}$$

Demostrar que el límite anterior existe significa

$$\lim_{h \rightarrow 0^-} \frac{f(a+h) - f(a)}{h} = \lim_{h \rightarrow 0^+} \frac{f(a+h) - f(a)}{h}$$

Si una función f es diferenciable en todo punto en su dominio entonces simplemente decimos que f es **diferenciable**.

Ejemplos de funciones no diferenciables

a) Una función discontinua, como una constante por partes como por ejemplo

$$f(x) = \begin{cases} 0, & \text{si } x < 0, \\ 1, & \text{si } x \geq 0 \end{cases} \quad \text{no es diferenciable en } x = 0.$$

b) Una función que se indetermina en algún punto, por ejemplo

$$f(x) = \frac{1}{x-1} \quad \text{no es diferenciable en } x = 1.$$

c) Una función continua pero con puntas en algún punto, como por ejemplo

$$f(x) = |x| \quad \text{no es diferenciable en } x = 0.$$

Propiedades de funciones diferenciables

Sean f, g funciones tales que sus derivadas existen en x entonces:

1) $(f \pm g)'(x) = f'(x) \pm g'(x).$

2) $(fg)'(x) = f'(x)g(x) + f(x)g'(x).$ Regla del producto.

3) $(f/g)'(x) = \frac{f'(x)g(x) - f(x)g'(x)}{g(x)^2},$ con $g(x) \neq 0.$ Regla del cociente.

4) $f(g(x))' = f'(g(x))g'(x).$ Regla de la cadena.

Derivadas de algunas funciones

$$\frac{d}{dx}(c) = 0, \quad c \in \mathbb{R}$$

$$\frac{d}{dx}(\sin(x)) = \cos(x)$$

$$\frac{d}{dx}(a^x) = a^x \ln(a), \quad a > 0$$

$$\frac{d}{dx}(x^n) = nx^{n-1}$$

$$\frac{d}{dx}(\cos(x)) = -\sin(x)$$

$$\frac{d}{dx}(\log_a(x)) = \frac{1}{x \ln(a)}, \quad a > 0$$

Polinomios de Taylor


Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función con n -veces diferenciable en un punto $x = a$. Entonces, definimos el polinomio de Taylor en torno al punto a , aproximación de f cerca de $x = a$, como

$$T_n(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x - a)^k$$

Ejemplos aproximación de Taylor

1) Considere la función $\cos(x)$. El polinomio de Taylor de orden 4 que aproxima a esta función cerca de $x = 0$ es:


$$\begin{aligned} T_3(x) &= \cos(0) + (\cos'(0))x + (\cos''(0))\frac{x^2}{2} \\ &\quad + (\cos^{(3)}(0))\frac{x^3}{6} + (\cos^{(4)}(0))\frac{x^4}{24} \\ &= 1 - \frac{x^2}{2} + \frac{x^4}{24}. \end{aligned}$$



Ejemplos aproximación de Taylor

Considere la función $\exp(x)$. El polinomio de Taylor de orden n que aproxima a esta función cerca de $x = 0$ es:

$$T_n(x) = \sum_{k=0}^n \frac{(\exp)^{(k)}(0)}{k} x^k = \sum_{k=0}^n \frac{x^k}{k!}$$



Cálculo multivariable

Función multivariable

Considere una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$, es decir, $f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$. Definimos el **gradiente** de f , $\nabla f : \mathbb{R}^n \rightarrow \mathbb{R}^n$, al vector

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f}{\partial x_1}(\mathbf{x}), \dots, \frac{\partial f}{\partial x_n}(\mathbf{x}) \right] \in \mathbb{R}^n$$

donde cada una de las componentes es la **derivada parcial** de f respecto a una componente del vector $\mathbf{x}$, es decir

$$\frac{\partial f}{\partial x_i}(\mathbf{x}) = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_i + h, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}, \quad 1 \leq i \leq n.$$

Ejemplo gradiente

Considere la función $f(x_1, x_2, x_3) = (x_1 + \exp(x_2))^2 + \ln(x_2 x_3)$. Calculamos el gradiente de esta función.

$$\frac{\partial f}{\partial x_1} = 2(x_1 + \exp(x_2))$$

$$\frac{\partial f}{\partial x_2} = 2(x_1 + \exp(x_2)) \exp(x_2) + \frac{x_3}{x_2 x_3}$$

$$\frac{\partial f}{\partial x_3} = \frac{x_2}{x_2 x_3}$$

Por lo tanto

$$\nabla f(x_1, x_2, x_3) = [2(x_1 + \exp(x_2)), 2(x_1 + \exp(x_2)) \exp(x_2) + \frac{x_3}{x_2 x_3}, \frac{x_2}{x_2 x_3}] \in \mathbb{R}^3.$$

Derivada direccional

Observación. Podemos interpretar la i -ésima derivada parcial de una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ como la razón de cambio en la dirección dada por el vector canónico $\mathbf{e}_i$, es decir,

$$\frac{\partial f}{\partial x_i}(\mathbf{x}) = \nabla f(\mathbf{x}) \cdot \mathbf{e}_i, \quad \mathbf{e}_i = [0, \dots, 1, \dots, 0]$$

Definición. Sea $v \in \mathbb{R}^n$, entonces la derivada direccional de f en la dirección del vector v se define por

$$D_v f(\mathbf{x}) = \nabla f(\mathbf{x}) \cdot v$$

La interpretamos como la razón de cambio de f en la dirección de v .

Dirección de cambio más rápido

Pregunta. ¿En que dirección la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ tiene la mayor razón de cambio?

Dirección de cambio más rápido

Pregunta. ¿En que dirección la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ tiene la mayor razón de cambio?
Si v apunta en la misma dirección que $\nabla f(\mathbf{x})$

Matriz Hessiana

Considere una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$, es decir, $f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$. Definimos la matriz Hessiana $H \in \mathbb{R}^{n \times n}$ por

$$H_{ij}(\mathbf{x}) = \frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}), \quad 1 \leq i, j \leq n.$$

Aproximación de Taylor. Considere la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$, y asuma que su matriz Hessiana existe en un punto $\mathbf{x}$. Entonces su aproximación de Taylor de orden 2 se escribe para puntos cercanos $\mathbf{x} + \Delta \mathbf{x}$ por

$$f(\mathbf{x} + \Delta \mathbf{x}) \approx T_2(\mathbf{x}) = f(\mathbf{x}) + (\Delta \mathbf{x})^\top \nabla f(\mathbf{x}) + \frac{1}{2}(\Delta \mathbf{x})^\top H(\mathbf{x})\Delta \mathbf{x}.$$

Función multivariable multivariada

Sea $\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ definida por

$$\mathbf{f}(\mathbf{x}) = [f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})] \in \mathbb{R}^m, \mathbf{x} \in \mathbb{R}^n.$$

Entonces la matriz Jacobiana $J \in \mathbb{R}^{m \times n}$ se define por

$$J_{ij} = \frac{\partial f_i}{\partial x_j}; \quad J(\mathbf{x}) = \begin{bmatrix} \partial f_1 / \partial x_1 & \dots & \partial f_1 / \partial x_n \\ \vdots & \ddots & \vdots \\ \partial f_m / \partial x_1 & \dots & \partial f_m / \partial x_n \end{bmatrix} = \begin{bmatrix} \nabla f_1(\mathbf{x}) \\ \vdots \\ \nabla f_m(\mathbf{x}) \end{bmatrix}$$

Ejemplo: Matriz Jacobiana

Sea $A \in \mathbb{R}^{m \times n}$ y considere la función $\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ definida por

$$\mathbf{f}(\mathbf{x}) = A\mathbf{x} = \begin{bmatrix} A_{1:} \\ A_{2:} \\ \vdots \\ A_{m:} \end{bmatrix} \mathbf{x} = \begin{bmatrix} A_{1:\mathbf{x}} \\ A_{2:\mathbf{x}} \\ \vdots \\ A_{m:\mathbf{x}} \end{bmatrix} = [f_1, f_2, \dots, f_m]^\top$$

Entonces

$$\frac{\partial f_1}{\partial x_1} = A_{11}, \quad \frac{\partial f_2}{\partial x_1} = A_{21}, \quad \frac{\partial f_1}{\partial x_2} = A_{12}, \quad \frac{\partial f_i}{\partial x_j} = A_{ij}$$

Por lo tanto $J(\mathbf{x}) = A$

Ejemplo. Compuesta de funciones.

Sean las funciones $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, y $g : \mathbb{R} \rightarrow \mathbb{R}^2$, definidas por

$$f(x_1, x_2) = \exp(x_1 x_2^2), \quad g(t) = \begin{bmatrix} t \cos(t) \\ t \sin(t) \end{bmatrix} = \begin{bmatrix} g_1(t) \\ g_2(t) \end{bmatrix}$$

Defina la función compuesta $h : \mathbb{R} \rightarrow \mathbb{R}$ por $h(t) = (f \circ g)(t) = f(g(t))$. Entonces

$$\frac{dh}{dt} = J_f(g(t)) \cdot J_g(t) = \left[\frac{\partial f}{\partial x_1}(g(t)), \frac{\partial f}{\partial x_2}(g(t)) \right] \cdot \begin{bmatrix} \frac{\partial g_1}{\partial t}(t) \\ \frac{\partial g_2}{\partial t}(t) \end{bmatrix}$$

$$\frac{\partial f}{\partial x_1}(\mathbf{x}) = x_2^2 \exp(x_1 x_2^2)$$

$$\frac{\partial f}{\partial x_2}(\mathbf{x}) = 2x_1 x_2 \exp(x_1 x_2^2)$$

Ejemplo. Compuesta de funciones.

$$\frac{\partial f}{\partial x_1}(g(t)) = t^2 \sin^2(t) \exp(t^3 \cos(t) \sin^2(t))$$

$$\frac{\partial f}{\partial x_2}(g(t)) = 2t^2 \sin(t) \cos(t) \exp(t^3 \cos(t) \sin^2(t))$$

$$\frac{\partial g_1}{\partial t}(t) = \cos(t) - t \sin(t)$$

$$\frac{\partial g_2}{\partial t}(t) = \sin(t) + t \cos(t)$$

Por lo tanto

$$\begin{aligned} \frac{dh}{dt} &= t^2 \sin(t) \exp(t^3 \cos(t) \sin^2(t)) \left(\sin(t) \cos(t) - t \sin^2(t) + 2 \cos(t) \sin(t) + 2t \cos^2(t) \right) \\ &= t^2 \sin(t) \exp(t^3 \cos(t) \sin^2(t)) \left(3 \sin(t) \cos(t) + t(3 \cos^2(t) - 1) \right) \end{aligned}$$

Ejemplo. Gradiente de la pérdida de mín. cuadrados.

Considere el modelo lineal

$$\hat{y} = \Phi\theta, \quad \theta \in \mathbb{R}^D, \quad \Phi \in \mathbb{R}^{N \times D}$$

Dadas observaciones y definimos la función de pérdida cuadrática

$$L(e) = \|e\|_2^2; \quad e = y - \Phi\theta$$

Queremos encontrar: $\frac{\partial L}{\partial \theta} \in \mathbb{R}^D$. Entonces:

$$\frac{\partial L}{\partial \theta} = \frac{\partial L}{\partial e} \frac{\partial e}{\partial \theta}; \quad \frac{\partial L}{\partial e} = 2e^\top \in \mathbb{R}^N, \quad \frac{\partial e}{\partial \theta} = -\Phi \in \mathbb{R}^{N \times D}$$

Entonces

$$\frac{\partial L}{\partial \theta} = -2e^\top \Phi = 2(y - \Phi\theta)^\top \Phi.$$

argmin/argmax

Definición. Dado un conjunto $X \subseteq \mathbb{R}^n$ y una función $f : X \rightarrow \mathbb{R}$, el argumento del mínimo (o máximo) de f es el conjunto de valores $\mathbf{x} \in X$ para los cuales la función $f(\mathbf{x})$ es mínimo. Analogamente definimos el argumento del máximo de f . Estos se denotan por

$$\operatorname{argmin}_{\mathbf{x} \in X} f(\mathbf{x}), \quad \operatorname{argmax}_{\mathbf{x} \in X} f(\mathbf{x})$$

Ejemplo. Sea la función $f : X \rightarrow \mathbb{R}$, $f(\mathbf{x}) = x_1^2 + x_2^2$. Entonces

$$\operatorname{argmin}_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x}) = \left\{ \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\}$$

Convexidad

Funciones convexas

Definición. Un conjunto C se dice **convexo**, si para cada $x, y \in C$, y para cada escalar θ , con $0 \leq \theta \leq 1$, tenemos que

$$\theta x + (1 - \theta)y \in C.$$

Definición. Sea $f : \mathbb{R}^D \rightarrow \mathbb{R}$ una función cuyo dominio es un conjunto convexo. La función f es una **función convexa** si para todo $\mathbf{x}, \mathbf{y}$ en el dominio de la f , y para cada escalar θ , con $0 \leq \theta \leq 1$, tenemos que:

$$f(\theta \mathbf{y} + (1 - \theta)\mathbf{x}) \leq \theta f(\mathbf{y}) + (1 - \theta)f(\mathbf{x}).$$

Convexidad y diferenciabilidad

Theorem (Condición de convexidad de primer orden.)

Si una función $f : X \subseteq \mathbb{R}^D \rightarrow \mathbb{R}$, con X convexo, es diferenciable entonces podemos decir que esta es convexa si y sólo si para cada $\mathbf{x}, \mathbf{y}$ en el dominio de f se tiene que:

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x}) \cdot (\mathbf{y} - \mathbf{x})$$

Demostración. Mostremos el caso $D = 1$. Asumamos primero que f es convexa y $x, y \in X$, entonces

$$f(x + \theta(y - x)) \leq (1 - \theta)f(x) + \theta f(y) = f(x) - \theta f(x) + \theta f(y)$$

Convexidad y diferenciabilidad

se sigue que, para todo $0 \leq \theta \leq 1$, tenemos

$$\frac{f(x + \theta(y - x)) - f(x)}{\theta} + f(x) \leq f(y)$$
$$\theta \rightarrow 0^+ \quad f'(x)(y - x) + f(x) \leq f(y)$$

Ahora mostramos el recíproco. Asumimos que f satisface que para $x, y, z \in X$ con $z = \theta y + (1 - \theta)x$, con $0 \leq \theta \leq 1$

$$f(y) \geq f(z) + f'(z)(y - z), \quad f(x) \geq f(z) + f'(z)(x - z)$$

Multiplicando la primera desigualdad por θ y la segunda por $1 - \theta$ obtenemos

$$\theta f(y) + (1 - \theta)f(x) \geq f(z) = f(\theta y + (1 - \theta)x)$$

lo que demuestra que f es convexa.

Convexidad y diferenciabilidad

Theorem

Asuma que una función $f : \mathbb{R}^D \rightarrow \mathbb{R}$ es dos veces diferenciable, así su matriz Hessiana existe en cada punto del dominio de f . Entonces f es convexa si y sólo si el dominio de f es convexo y la matriz Hessiana es semidefinida positiva en cada punto del dominio de f .

Semi-definida positiva: $\mathbf{x}^\top A \mathbf{x} \geq 0, \quad \forall \mathbf{x} \in \mathbb{R}^D$

Mínimo global

Theorem

Si $f : \mathbb{R}^D \rightarrow \mathbb{R}$ es una función convexa, entonces todo mínimo local es un mínimo global.

Propiedad de funciones convexas.

Theorem

Si $f : \mathbb{R}^D \rightarrow \mathbb{R}$ está definida por

$$f(\mathbf{x}) = g(\mathbf{y} \cdot \mathbf{x} + b), \quad \mathbf{y} \in \mathbb{R}^D, b \in \mathbb{R}$$

donde $g : \mathbb{R} \rightarrow \mathbb{R}$ es una función convexa. Entonces f es convexa.

Ejemplos

Preguntas:

- 1) Sea $f(\mathbf{x}) = (\mathbf{y} \cdot \mathbf{x} + b)^2$. Para $\mathbf{y} \in \mathbb{R}^D$ y $b \in \mathbb{R}$ fijos, es f una función convexa en $\mathbb{R}^D$?
- 2) Sea $f(\mathbf{x}) = \ln(1 + \exp(-\mathbf{y} \cdot \mathbf{x} + b))$. Para $\mathbf{y} \in \mathbb{R}^D$ y $b \in \mathbb{R}$ fijos, es f una función convexa en $\mathbb{R}^D$?

Propiedad de funciones convexas

Theorem

Si las funciones $f_i : \mathbb{R}^D \rightarrow \mathbb{R}$, $1 \leq i \leq n$, son convexas. Entonces:

La función $\max_{1 \leq i \leq n} f_i(\mathbf{x})$ es también convexa.

La función $\sum_{i=1}^n a_i f_i(\mathbf{x})$ es también convexa si $a_i \geq 0$.

Ejemplos.

- 1 Sea la función $f(x) = |x|$. Observe que f no es diferenciable en $x = 0$. Es f una función convexa?
- 2 Sea la función lineal $f(x) = \mathbf{c} \cdot \mathbf{x}$. Es f convexa? Es f estrictamente convexa?
- 3 Sea la función cuadrática $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top S\mathbf{x}$, con S simétrica y definida positiva. Es f convexa? Es f estrictamente convexa?

Normas

Las normas de vectores interpretadas como funciones son convexas. Esto es, si $f(\mathbf{x}) = \|\mathbf{x}\|$, entonces f es una función convexa.

Además la bola unitaria, es decir los puntos tales que $\|\mathbf{x}\| \leq 1$, es un conjunto convexo de vectores $\mathbf{x}$. Esto se observa de la propiedad:

$$\|\theta \mathbf{x} + (1 - \theta) \mathbf{y}\| \leq \theta \|\mathbf{x}\| + (1 - \theta) \|\mathbf{y}\|$$

Veamos algunos ejemplos de normas en $\mathbb{R}^2$.

$$1 \quad \|\mathbf{x}\|_1 = |x_1| + |x_2|$$

$$2 \quad \|\mathbf{x}\|_2 = \sqrt{x_1^2 + x_2^2}$$

$$3 \quad \|\mathbf{x}\|_\infty = \max\{|x_1|, |x_2|\}$$

Método de Newton

Problema no lineal

Buscamos al punto $\mathbf{x}^*$ donde se alcanza el mínimo de una función diferenciable $F : \mathbb{R}^n \rightarrow \mathbb{R}$.

En otras palabras, buscamos $\mathbf{x}^* = \operatorname{argmin}_{\mathbf{x}} F(\mathbf{x})$.

Como la función es diferenciable sabemos que:

$$\nabla F(\mathbf{x}^*) = 0.$$

Propondremos un método para esolver esta ecuación **no lineal**.

Supongamos que estamos en un punto cercano $\mathbf{x}_k$ a la solución $\mathbf{x}^*$ y queremos movernos a un nuevo punto $\mathbf{x}_{k+1}$ mas cerca de la solución.

Como escogemos $\mathbf{x}_{k+1}$?

Método de Newton

Cerca del punto $\mathbf{x}_k$ el gradiente ∇F es bien aproximado por el plano tangente, esto es

$$\nabla F(\mathbf{x}_k + \Delta \mathbf{x}_k) \approx \nabla F(\mathbf{x}_k) + H(\mathbf{x}_k)((\mathbf{x}_k + \Delta \mathbf{x}_k) - \mathbf{x}_k)$$

Esto nos indica como escoger la próxima aproximación $\mathbf{x}_{k+1}$:

$$\text{Método de Newton: } \mathbf{x}_{k+1} = \mathbf{x}_k - (H(\mathbf{x}_{k+1}))^{-1} \nabla F(\mathbf{x}_k)$$

Esto es equivalente a encontrar $\mathbf{x}_{k+1}$ como el argumento del mínimo del polinomio de Taylor de orden 2 en $\mathbf{x}_k$, es decir,

$$\mathbf{x}_{k+1} = \underset{\mathbf{x}}{\operatorname{argmin}} T_2(\mathbf{x}); \quad T_2(\mathbf{x}_k) = F(\mathbf{x}_k) + \nabla F(\mathbf{x}_k) \cdot (\mathbf{x} - \mathbf{x}_k) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_k)^\top H(\mathbf{x}_k) (\mathbf{x} - \mathbf{x}_k)$$

Convergencia

Theorem

Si $F : \mathbb{R}^D \rightarrow \mathbb{R}$ es una función dos veces diferenciable, entonces la iteración de Newton $\mathbf{x}_{k+1}$ dado $\mathbf{x}_k$ satisface que

$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\| \leq C \|\mathbf{x}_k - \mathbf{x}^*\|^2$$

Esto es, convergencia cuadrática

Ejemplo

Considere la función $F(x) = \frac{1}{3}x^3 - 4x$. Entonces

$$\nabla F(x) = x^2 - 4, \quad H(x) = 2x.$$

La iteración de Newton entonces queda para x_k dado

$$x_{k+1} = x_k - \frac{1}{2x_k} (x_k^2 - 4) = \frac{x_k}{2} + \frac{2}{x_k}.$$

Método de Newton

Que tan bien funciona en la práctica?

El algoritmo converge muy rápido si x_0 está cerca del óptimo x^* . Si esto no sucede no podemos confiar que la derivada de x_0 sea útil.

Una forma de rectificar estos casos es usando **backtracking**.

Escogemos $\alpha < 1/2$ y $\beta < 1$. La idea es reducir el paso Δx de la iteración por un factor de β hasta tener certeza que $x_{k+1} = x_k + \beta \Delta x$ es tal que:

$$F(x_k + \beta \Delta x) \leq F(x_k) + \alpha \beta \nabla F(x_k) \Delta x$$

Método del descenso del gradiente

Método del descenso del gradiente

Consideramos nuevamente el problema de minimizar una función $f : \mathbb{R}^D \rightarrow \mathbb{R}$, diferenciable

$$\mathbf{x}^* = \operatorname{argmin}_{\mathbf{x} \in \mathbb{R}^D} f(\mathbf{x})$$

La iteración del método del descenso del gradiente se escribe como:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \gamma_k \nabla f(\mathbf{x}_k)$$

donde γ_k es un parámetro de paso (learning rate) adecuado, de tal forma que la sucesión

$$f(\mathbf{x}_0) \geq f(\mathbf{x}_1) \geq f(\mathbf{x}_2) \geq \dots \geq f(\mathbf{x}_n) \geq$$

converge a un mínimo local de f .

Búsqueda de línea exacta

Exact line search. Es una estrategia para determinar la longitud del paso de manera que minimice la función en la dirección del gradiente. En otras palabras, queremos encontrar el tamaño del paso γ_k que minimiza la función a lo largo de la dirección del gradiente.

Esto se puede hacer utilizando métodos de optimización univariados, como el método de búsqueda en línea de Brent o el método de Newton.

$$\min_{\gamma} G(\gamma) := \min_{\gamma} \mathbf{x} - \gamma \nabla f(\mathbf{x})$$

Interpretación geométrica


Para el caso $n = 2$ podemos interpretar el método:

$$\nabla f(x_1, x_2) = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2} \right]$$

es la dirección más pronunciada y perpendicular a la curva de nivel de la $f(x_1, x_2) = \text{constante}$.

Ejemplo.

$$f(x_1, x_2) = ax_1^2 + bx_2^2$$
$$\nabla f(x_1, x_2) = 2ax_1 + 2bx_2$$



Ejemplo Zig-Zag

Considere la función $f(x_1, x_2) = \frac{1}{2}(x_1^2 + bx_2^2)$. La iteración del descenso del gradiente para esta función resulta:

$$\begin{bmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \end{bmatrix} = \begin{bmatrix} x_1^{(k)} \\ x_2^{(k)} \end{bmatrix} - \gamma_k \begin{bmatrix} x_1^{(k)} \\ bx_2^{(k)} \end{bmatrix}$$

Exact line search

$$\min_{\gamma_k} f(x_1^{(k+1)}, x_2^{(k+1)}) = \min_{\gamma_k} \frac{1}{2} \left((x_1^{(k)} - \gamma_k x_1^{(k)})^2 + b(x_2^{(k)} - \gamma_k bx_2^{(k)})^2 \right) =: \min_{\gamma_k} G(\gamma_k)$$

$$\text{Entonces: } G'(\gamma_k) = 0 \longrightarrow -x_1^{(k)}(1 - \gamma_k) - b^2 x_2^{(k)}(1 - b\gamma_k) = 0$$

$$\text{De donde: } \gamma_k = \frac{(x_1^{(k)})^2 + (bx_2^{(k)})^2}{(x_1^{(k)})^2 + b^3(x_2^{(k)})^2}$$

Ejemplo Zig-Zag

Comenzando la iteración con el punto $(x_1^{(0)}, x_2^{(0)}) = (b, 1)$ obtenemos $\gamma_0 = \frac{2}{1+b}$ y así

$$x_1^{(1)} = b \left(\frac{b-1}{b+1} \right), \quad x_2^{(1)} = \left(\frac{b-1}{b+1} \right)$$

Para la siguiente iteración calculamos $\gamma_1 = \frac{2}{1+b}$ y así

$$x_1^{(2)} = b \left(\frac{b-1}{b+1} \right)^2, \quad x_2^{(2)} = \left(\frac{b-1}{b+1} \right)^2$$

Calculando sucesivamente obtenemos $\gamma_k = \frac{2}{1+b}$ y


$$x_1^{(k)} = b \left(\frac{b-1}{b+1} \right)^k, \quad x_2^{(k)} = \left(\frac{b-1}{b+1} \right)^k$$

Ejemplo Zig-Zag

Además calculamos el valor de la función de pérdida

$$f(x_1^{(k)}, x_2^{(k)}) = \left(\frac{1-b}{1+b}\right)^{2k} f(x_1^{(0)}, x_2^{(0)}) = \left(\frac{1-b}{1+b}\right)^{2k} \frac{1}{2}(b^2 + b)$$

Observe que si b es cercano a 0, la iteración disminuye lentamente.



Análisis del método de descenso de gradiente

Asuma que f es una función estrictamente convexa y dos veces diferenciable, y además asuma que existen constante $m, M > 0$ tales que:

$$mI \leq H(x) \leq MI; \quad H_{ij}(x) = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

Sea la función $G(\gamma_k) = f(x_k - \gamma_k \nabla f(x_k))$, entonces:

$$G(\gamma_k) \leq f(x_k) - \gamma \|\nabla f(x_k)\|_2^2 + \frac{M\gamma^2}{2} \|\nabla f(x_k)\|_2^2$$

El mínimo se alcanza para $\gamma = 1/M$, así

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2M} \|\nabla f(x_k)\|_2^2$$

Por otro lado,

$$f(x^*) \geq f(x_k) - \frac{1}{2m} \|\nabla f(x_k)\|_2^2$$

Así concluimos que

Análisis del método de descenso de gradiente

Algorithm 1: Backtracking

Input : $x, f(x), \nabla f(x)$

Output: Siguiente iteración

Escoger α, β :, $0 \leq \alpha \leq 0.5, 0 \leq \beta \leq 1$;

Inicializar $\gamma = 1$;

while $f(x - \gamma \nabla f(x)) > f(x) - \alpha \gamma \|\nabla f(x)\|^2$ **do**

$\gamma = \beta \gamma$;

end

return $x - \gamma \nabla f(x)$

Análisis del método de descenso de gradiente

Si suponemos que $0 \leq \gamma_k \leq 1/M$, entonces:

$$G(\gamma_k) \leq f(x_k) - \frac{1}{2}\gamma_k \|\nabla f(x_k)\|_2^2 \leq f(x_k) - \alpha\gamma_k \|\nabla f(x_k)\|_2^2, \quad \alpha < \frac{1}{2}$$

Se sigue que backtracking termina con $\gamma = 1$ o $\gamma \geq \beta/M$, escribimos

$$f(x_{k+1}) \leq f(x_k) - \min\{\alpha, \beta\alpha/M\} \|\nabla f(x_k)\|_2^2.$$

Así, podemos concluir tal como en el caso anterior

$$f(x_{k+1}) - f(x^*) \leq (1 - \min\{\alpha, \beta, \alpha/M\})(f(x_k) - f(x^*))$$

Descenso con momentum

La iteración del descenso con momentum se escribe:

$$x_{k+1} = x_k - \gamma z_k, \quad z_k = \nabla f(x_k) + \beta z_{k-1}$$

Ejemplo. Sea $f(x) = \frac{1}{2}x^\top Sx$, con S simétrica y definida positiva $\nabla f(x) = Sx$. Seguimos los vectores propios de S , $Sq = \lambda q$,

$$\begin{aligned} x_k &= c_k q & c_{k+1} &= ck - \gamma d_k \\ z_k &= d_k q & -\lambda x_{k+1} + d_{k+1} &= \beta d_k \end{aligned}$$

Escoger γ y β que minimizar:

$$\max\{|e_1(\lambda)|, |e_2(\lambda)|\}, \quad \text{para } \lambda_{\min}(S) \leq \lambda \leq \lambda_{\max}(S).$$

Para este ejemplo, la solución es:

$$\gamma = \left(\frac{2}{\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}}} \right)^2, \quad \beta = \left(\frac{\sqrt{\lambda_{\max}} - \sqrt{\lambda_{\min}}}{\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}}} \right)^2$$

Método Levenberg-Marquardt para NLS

Problema de mínimos cuadrados lineales

Sea el conjunto de m puntos de datos (t_i, y_i) . Queremos ajustar una función $\hat{y}(t, p)$ que depende, de forma lineal, de n parámetros $p = (p_1, \dots, p_n)$. Suponga que escribimos los parámetros $p = (C, D)$, y ajustamos $\hat{y} = C + Dt$. Entonces

$$E(p) = E(C, D) = \sum_{i=1}^m (y_i - \hat{y}_i)^2 = (y_1 - C - Dt_1)^2 + \dots + (y_m - C - Dt_m)^2$$

Este es el **Square loss**. Queremos minimizar $E(p)$. Calculamos ∇E e igualamos a cero. Tanto $\partial E / \partial C$ y $\partial E / \partial D$ son lineales, entonces nos queda el problema de encontrar C, D

$$Jp = J \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = y; \quad \underbrace{J^\top J \hat{p} = J^\top y}_{\text{Ec. normales}}$$

Mínimos cuadrados no lineales

Sea el conjunto de m puntos de datos (t_i, y_i) . Queremos ajustar una función $\hat{y}(p)$ que depende, de forma **no lineal**, de n parámetros $p = (p_1, \dots, p_n)$. Al minimizar el error total, suma de cuadrados, esperamos n ecuaciones no lineales:

$$E(p) = \sum_{i=1}^m (y_i - \hat{y}_i)^2 = (y - \hat{y}(p))^{\top} (y - \hat{y}(p)) = y^{\top} y - 2y^{\top} \hat{y}(p) + \hat{y}(p)^{\top} \hat{y}(p)$$

Queremos minimizar el **square loss** $E(p)$,

$$\nabla E = 2J^{\top} (y - \hat{y}(p)) = 0, \quad \text{con} \quad J = \frac{\partial y}{\partial p}(\hat{p})$$

Método Levenberg-Marquardt para NLS

Tenemos las iteraciones:

$$\text{Descenso del gradiente: } p_{k+1} - p_k = -sJ^\top(y - \hat{y}(p_k))$$

$$\text{Newton (aproximado): } J^\top J(p_{k+1} - p_k) = J^\top(y - \hat{y}(p_k))$$

Entonces

$$\begin{aligned} E(p + \Delta p) &\approx (y - \hat{y}(p) - J\Delta p)^\top (y - \hat{y}(p) - J\Delta p) \\ &= E(p) - 2(y - \hat{y}(p))^\top (J\Delta p) + \Delta p^\top J^\top J\Delta p \end{aligned}$$

Así obtenemos el método:

$$\text{Levenberg-Marquardt: } (J^\top J - \lambda I)(p_{k+1} - p_k) = J^\top(y - \hat{y}(p_k))$$

para un parámetro λ .



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE