



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Fundamentos Matemáticos de Inteligencia Artificial

IMT3850. Clase 7

Manuel A. Sánchez
2026.04.27

Probabilidades. Contenidos:

- 1 Dependencia multivariada
- 2 Función Generadora de Momentos
- 3 Desigualdades de Concentración
- 4 Leyes Límite (LLN y CLT)
- 5 Muestras
- 6 Estimación de parámetros y ajuste de distribución

Dependencia multivariada

Covarianza y Correlación

Si dos variables *no* son independientes, necesitamos medir cómo varían juntas.

Covarianza: Mide la dirección de la dependencia lineal.

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

Demostración:

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\ &= E[XY - E[X]Y - E[Y]X + E[X]E[Y]] \\ &= E[XY] - E[E[X]Y] - E[E[Y]X] + E[E[X]E[Y]] \\ &= E[XY] - E[X]E[Y] - E[Y]E[X] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y].\end{aligned}$$

Covarianza y Correlación

Correlación de Pearson: Es la covarianza estandarizada al rango $[-1, 1]$.

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Precaución: Si X e Y son independientes, entonces $\text{Cov}(X, Y) = 0$. Sin embargo, el inverso no siempre es cierto: covarianza cero sólo implica que no hay relación *lineal*, pero podría existir una fuerte dependencia no lineal.

En efecto, considere $X \sim$ uniforme con valores $\{-1, 0, 1\}$, y sea $Y = X^2$.

$$E[X] = \frac{1}{3}(-1 + 0 + 1) = 0$$

$$E[Y] = E[X^2] = \frac{1}{3}((-1)^2 + 0^2 + 1^2) = 2/3$$


$$E[XY] = E[X^3] = \frac{1}{3}((-1)^3 + 0^3 + 1^3) = 0$$

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 0 - (0)(2/3) = 0$$

Conclusión: X e Y están relacionadas ($Y = X^2$), pero su la covarianza es nula.

Visualización: Correlación vs. Dependencia

La correlación de Pearson (ρ) sólo es capaz de "ver" relaciones que se pueden trazar con una línea recta.



Función Generadora de Momentos

Función Generadora de Momentos

Momentos: $E[X^n]$.

Definición. La función generadora de momentos M de una variable aleatoria X está definida por

$$M(s) = E[e^{sX}] = \sum_x e^{sx} P(X = x), \quad s \in \mathbb{R}.$$

Observación. Las funciones generadoras de momentos de dos variables aleatorias coinciden si y sólo si las variables aleatorias tienen la misma distribución de probabilidad.

Función Generadora de Momentos (FGM)

Definición. La FGM $M(s)$ de una variable aleatoria X "empaqueta" todos los momentos estadísticos (media, varianza, asimetría) en una sola función continua:

$$M(s) = E[e^{sX}] = \int_{-\infty}^{\infty} e^{sx} f(x) dx \quad (\text{Trans. Laplace})$$

Sus 2 Superpoderes en IA:

Propiedad de Derivadas: Transforma integrales complejas en derivadas simples.

El momento n -ésimo es: $\left. \frac{d^n}{ds^n} M(s) \right|_{s=0} = E[X^n]$.

La Huella Dactilar (Unicidad): Si dos variables tienen exactamente la misma FGM, **tienen la misma distribución**. Usaremos esto para demostrar el Teorema del Límite Central más adelante.

Ejemplo: FGM Poisson

$X \sim \text{Poisson}(\lambda)$. Así $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$. Entonces

$$m(t) = \sum_k k e^{t\lambda} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_k \frac{(e^t \lambda)^k}{k!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t - 1)}$$

Así

$$m'(t) = e^{\lambda(e^t - 1)} \lambda e^t, \quad m'(0) = \lambda = E[X]$$

$$m''(t) = e^{\lambda(e^t - 1)} (\lambda e^t)^2 + e^{\lambda(e^t - 1)} \lambda e^t, \quad m''(0) = \lambda^2 + \lambda$$

lo que implica que

$$\text{Var}(X) = E[X^2] - E[X]^2 = \lambda^2 + \lambda - \lambda = \lambda.$$

Ejemplo: FGM Normal

$X \sim \text{Normal}(0, 1)$. Así $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$. Entonces

$$m(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{tx} e^{-\frac{1}{2}x^2} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(x-t)^2 + \frac{1}{2}t^2} dx = e^{-\frac{1}{2}t^2}.$$

Ejemplo: FGM Exponencial

$X \sim \text{Exp}(\lambda)$. Así $f(x) = \lambda e^{-\lambda x}$. Entonces

$$m(s) = \int_0^{\infty} e^{st} \lambda e^{-\lambda t} dt = \left[\frac{\lambda}{s - \lambda} e^{(s-\lambda)t} \right]_0^{\infty} = \frac{\lambda}{\lambda - s}, \quad s < \lambda$$

Desigualdades de Concentración

El Riesgo Empírico vs. Riesgo Real

El Problema Fundamental del Machine Learning: Entrenamos nuestros modelos usando una muestra finita de n datos. Calculamos el **Error Empírico** ($\bar{X}_n$) en ese dataset. Sin embargo, lo que realmente nos importa es el **Error Real** (μ) sobre datos futuros invisibles.

¿Cómo podemos garantizar matemáticamente que $\bar{X}_n \approx \mu$?

Las **Desigualdades de Concentración** nos dan límites matemáticos duros (garantías) de que el promedio de una muestra no se desviará demasiado de su valor esperado, sin importar qué distribución extraña tengan los datos.

Desigualdad de Markov (El límite más básico)

Theorem (Markov)

Sea X una variable aleatoria que solo toma valores no negativos ($X \geq 0$). Entonces, para toda constante $a > 0$:

$$P(X \geq a) \leq \frac{E[X]}{a}$$

Ejemplo en IA (Tasa de Error): Supongamos que el error esperado de nuestro modelo en producción es $E[\text{Error}] = 5\%$. ¿Cuál es la probabilidad del peor escenario, es decir, que el error sea mayor al 20% en un lote de datos?

$$P(\text{Error} \geq 20\%) \leq \frac{5\%}{20\%} = 0.25 \quad (25\%)$$

Desigualdad de Markov

Demostración. Como $X > 0$, tenemos lo siguiente

$$\begin{aligned} E[X] &= \int_0^{\infty} x f_x(x) dx \\ &= \int_0^t x f_x(x) dx + \int_t^{\infty} x f_x(x) dx \\ &\geq \int_t^{\infty} x f_x(x) dx \\ &\geq t \int_t^{\infty} f_x(x) dx \\ &= P(X \geq t). \end{aligned}$$

Desigualdad de Markov

Demostración. Como $X \geq 0$, tenemos lo siguiente

$$\begin{aligned} E[X] &= \sum_x xP(X = x) \\ &\geq \sum_{x \geq a} xP(X = x) \\ &\geq \sum_{x \geq a} aP(X = x) \\ &\geq a \sum_{x \geq a} P(X = x) \\ &= aP(X \geq a) \end{aligned}$$

Ejemplo: desigualdad de Markov

Probabilidad de obtener al menos $3n/4$ caras en una sucesión de n lanzamientos de monedas

$$X_i = \begin{cases} 1 & \text{si la } i\text{-ésima moneda es cara,} \\ 0 & \text{en otro caso,} \end{cases} \quad X = \sum_{i=1}^n X_i, \quad \text{número de caras.}$$

Entonces,


$$E[X_i] = P(X_i = 1) = \frac{1}{2}, \quad E[X] = \sum_{i=1}^n E[X_i] = \frac{n}{2}.$$

Aplicando la desigualdad de Markov

$$P(X \geq \frac{3n}{4}) \leq \frac{E[X]}{3n/4} = \frac{n/2}{3n/4} = \frac{2}{3}.$$

Desigualdad de Markov

Observación. Como vemos en la demostración la desigualdad de Markov omite una parte de la integral, es decir, hay una diferencia (considerable) entre ambos lados de la desigualdad.



Desigualdad de Markov

Observación. Un caso especial de la desigualdad de Markov se da cuando $X = |Y - \mu|^2$, para alguna variable aleatoria Y con media μ y varianza σ^2 . Al aplicar la desigualdad de Markov, nos queda

$$P(|Y - \mu| \geq a) = P(|Y - \mu|^2 \geq a^2) \leq \frac{E[|Y - \mu|^2]}{a^2} = \frac{\sigma^2}{a^2}$$

Esta desigualdad se conoce como la **desigualdad de Chebyshev**.

Desigualdad de Chebyshev

Theorem (Chebyshev)

Si conocemos la varianza ($\text{Var}[X] = \sigma^2$), podemos acotar qué tan probable es que la variable se aleje de su propia media μ :

$$P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}$$

Aplicación: Reemplazando $a = k\sigma$, obtenemos $P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$.

Esto demuestra que, sin importar cuál sea la distribución subyacente de los datos (normal, asimétrica, bimodal), la probabilidad de que un dato caiga a más de 3 desviaciones estándar de la media es siempre menor a $1/9 \approx 11\%$.

Ejemplo: desigualdad de Chebyshev

Lanzamiento de una moneda n veces. Queremos acotar la probabilidad de obtener mas que $3n/4$ caras. Nuevamente hacemos

$$X_i = \begin{cases} 1 & \text{si el } i\text{-ésimo lanzamiento es cara,} \\ 0 & \text{en otro caso,} \end{cases} \quad X = \sum_{i=1}^n X_i, \quad \text{número de caras.}$$

Entonces

$$E[X_i] = \frac{1}{2}, \quad E[X_i^2] = \frac{1}{4}, \quad Var[X_i] = \frac{1}{4}, \quad Var[X] = \frac{n}{4}.$$

Aplicamos la desigualdad de Chebyshev

$$P(X \geq \frac{3}{4}n) \leq P(|X - E[X]| \geq \frac{n}{4}) \leq \frac{Var[X]}{(n/4)^2} = \frac{4}{n}.$$

Ejemplo: coleccionador de cupones

Sea X una variable aleatoria que representa el número de cajas para coleccionar los n cupones tiene esperanza

$$E[X] = nH_n$$

Así, al aplicar la desigualdad de Markov obtenemos

$$P(X \geq 2nH_n) \leq \frac{1}{2}$$

Definimos

X_i : variables aleatorias geométricas con parámetro $\frac{(n-i+1)}{n}$

Entonces

$$X = \sum_{i=1}^n X_i, \quad X_i \text{ independientes,} \quad Var[X] = \sum_{i=1}^n Var[X_i]$$

Ejemplo: coleccionador de cupones

$$\text{Var}[X_i] = \frac{1 - (n - i + 1)/n}{((n - i + 1)/n)^2} \leq \frac{n^2}{(n - i + 1)^2}$$

Se sigue que

$$\text{Var}[X] \leq \sum_{i=1}^n \frac{n^2}{(n - i + 1)^2} \leq \frac{n^2 \pi^2}{6}$$

Entonces La desigualdad de Chebyshev implica

$$P(|X - nH_n| \geq nH_n) \leq \frac{n^2 \pi^2 / 6}{n^2 H_n^2} \approx \mathcal{O}(1/(\log(n))^2)$$

Ejemplo: coleccionador de cupones

$$\text{Var}[X_i] = \frac{1 - (n - i + 1)/n}{((n - i + 1)/n)^2} \leq \frac{n^2}{(n - i + 1)^2}$$

Se sigue que

$$\text{Var}[X] \leq \sum_{i=1}^n \frac{n^2}{(n - i + 1)^2} \leq \frac{n^2 \pi^2}{6}$$

Entonces La desigualdad de Chebyshev implica

$$P(|X - nH_n| \geq nH_n) \leq \frac{n^2 \pi^2 / 6}{n^2 H_n^2} \approx \mathcal{O}(1/(\log(n))^2)$$

$$P(X \geq 2nH_n) \leq \frac{n^2 \pi^2 / 6}{n^2 H_n^2} \approx \mathcal{O}(1/(\log(n))^2)$$

Ejemplo: lanzamiento de dado

Problema. Suponga que se lanzan dos dados n veces. Es posible dar una buena estimación del total valor de los n lanzamientos?

Solución. Si calculamos el valor esperado y la varianza, encontramos que

$$\mu = E[X] = 7n, \quad \sigma^2 = \frac{35}{6}n$$

Al aplicar la desigualdad de Chebyshev, encontramos que la suma final es en el intervalo

$$\left[7n - 10\sqrt{\frac{35n}{6}}, 7n + 10\sqrt{\frac{35n}{6}}\right]$$

en al menos el 99% de todos los experimentos.

Desigualdad de Hoeffding

Theorem (Hoeffding)

Sean $X_1, X_2, \dots, X_n$ variables i.i.d. acotadas ($a \leq X_i \leq b$). Sea $\bar{X}_n$ el promedio de la muestra y μ la media real. Para cualquier $\varepsilon > 0$:

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq 2 \exp \left(-\frac{2n\varepsilon^2}{(b-a)^2} \right)$$

A diferencia de Markov o Chebyshev (que decaen polinomialmente), Hoeffding garantiza que la probabilidad de error decrece **exponencialmente** a medida que aumentamos el tamaño de la muestra n . Esta es la base matemática de la teoría PAC (*Probably Approximately Correct*) en Machine Learning.

Chebyshev vs. Hoeffding: La Ventaja Exponencial

Vía Chebyshev:

Aplicado a la media muestral $\bar{X}_n$:

$$P(|\bar{X}_n - \mu| \geq a) \leq \frac{\sigma^2}{na^2}$$


Decae a una tasa polinomial ($1/n$) y requiere conocer la varianza σ^2 .

Vía Hoeffding:

Para variables acotadas $X_i \in [0, 1]$:

$$P(|\bar{X}_n - \mu| \geq a) \leq 2 \exp(-2na^2)$$

Decae a una tasa **exponencial** (e^{-n}) y **No** requiere conocer la varianza, solo los límites.



Ejemplo Práctico: ¿Cuántos datos necesito etiquetar?

Problema: Quieres garantizar con un **95% de confianza** que el error que ves en tu *dataset* de entrenamiento está, a lo sumo, a $\varepsilon = 0.05$ (5%) del error real del modelo en producción. ¿De qué tamaño (n) debe ser tu dataset?

Solución con Hoeffding: Queremos que la probabilidad de que se rompa nuestra tolerancia sea ≤ 0.05 (para tener un 95% de certeza).

$$\begin{aligned}2 \exp(-2n\varepsilon^2) &\leq \delta \\2 \exp(-2n(0.05)^2) &\leq 0.05 \\-0.005n &\leq \ln(0.025) \approx -3.689 \\n &\geq 738\end{aligned}$$

Conclusión: Solo necesitas etiquetar **738 imágenes** para tener garantías estadísticas sólidas, sin importar si tienes 1 millón de imágenes en total.

Leyes Límite (LLN y CLT)

El Comportamiento Asintótico de la Muestra

En las secciones anteriores vimos que el promedio muestral $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ es una variable aleatoria con $E[\bar{X}_n] = \mu$ y varianza $\text{Var}[\bar{X}_n] = \frac{\sigma^2}{n}$.

La Pregunta Asintótica: ¿Qué sucede matemáticamente con esta variable aleatoria a medida que recolectamos "Big Data" ($n \rightarrow \infty$)?

Dos teoremas fundamentales responden a esta pregunta:

Ley de los Grandes Números (LLN): Nos dice *hacia dónde* converge el promedio.

Teorema del Límite Central (CLT): Nos dice *cómo* se distribuyen los errores alrededor de ese promedio mientras converge.

Ley de los Grandes Números (LLN)

Theorem (Ley Débil de los Grandes Números)

Sean $X_1, X_2, \dots, X_n$ variables aleatorias i.i.d. con media μ y varianza finita. Si definimos la media muestral como $\bar{X}_n = \frac{1}{n} \sum X_i$, entonces para cualquier $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P\left(|\bar{X}_n - \mu| \geq \varepsilon\right) = 0$$

Significado Práctico: Si recolectamos suficientes datos ($n \rightarrow \infty$), el promedio de nuestra muestra (*dataset*) convergerá al valor real de la población. Esto justifica por qué recolectar "Big Data" mejora el entrenamiento empírico de nuestros algoritmos.

Ley Débil de los Grandes Números (LLN)

Theorem (Ley Débil)

Sean $X_1, X_2, \dots, X_n$ variables aleatorias i.i.d. con media μ y varianza σ^2 finita. El promedio muestral $\bar{X}_n$ converge a μ **en probabilidad**.

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \varepsilon) = 0 \quad \text{para cualquier } \varepsilon > 0$$

La Demostración: Podemos demostrar este teorema fundamental en una sola línea, usando Chebyshev

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}[\bar{X}_n]}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}$$

Es evidente que cuando $n \rightarrow \infty$, el término derecho colapsa a 0.

Ejemplo: Ley débil de grandes números

Considere una sucesión de ensayos de Bernoulli con

$$X_i = \begin{cases} 1 & \text{si el } i\text{-ésimo ensayo es exitoso,} \\ 0 & \text{en otro caso.} \end{cases}$$

Entonces

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

es la frecuencia relativa de ensayos exitosos en n ensayos y $E[X_i]$ es la probabilidad p de éxito del ensayo i -ésimo. La Ley débil nos dice que si consideramos a número n fijo suficientemente grande, la probabilidad que la frecuencia relativa converja a p está garantizada.

Ejemplo: El Problema del Encuestador

Queremos inferir el resultado p un referendum, la fraccion de la poblacion que votará Si.

Sea la variable aleatoria X_i , la i -ésima persona (seleccionada, aleatoria e independientemente)

$$X_i = \begin{cases} 1, \text{vota Si} \\ 0, \text{vota No} \end{cases}$$

Entonces $E[X_i] = p$

Sea $\bar{X}_n = \frac{1}{n}(X_1 + X + 2 + \dots + X_n)$ la fraccion que vota Si en una muestra de tamaño n .

Queremos un error de 1%, esto es $|\bar{X}_n - p| < 0.01$. Probamos con $n = 10^4$, asi

$$P(|\bar{X}_n - p| \geq 0.01) \leq \frac{\sigma^2}{10^4(0.01)^2} = \frac{p(1-p)}{10^4(0.01)^2} \leq \frac{1}{4}.$$

Esto no parece ser aceptable, entonces busquemos n . Queremos por ejemplos 5%, entonces

Ley Fuerte de los Grandes Números (SLLN)

Theorem

Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $E[|X_i|] < \infty$ y media μ . Entonces, para todo $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P \left(\sup_{k \geq n} |\bar{X}_k - \mu| > \varepsilon \right) = 0$$

En otras palabras, $\bar{X}_n$ converge a μ a.s. (casi seguramente).

Ley Fuerte de los Grandes Números (SLLN)

La Ley Débil nos asegura que una "foto" en el futuro lejano se verá bien. La **Ley Fuerte** es mucho más estricta: nos garantiza que la "película" completa del promedio se estabilizará sin saltos anómalos.

Theorem (Ley Fuerte)

*Bajo condiciones similares (solo requiere $E[|X_i|] < \infty$), el promedio muestral converge a la media real **casi seguramente** (c.s.):*

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$$

En Machine Learning nunca podemos calcular el "Riesgo Real" (el error sobre todos los datos posibles del universo). Solo podemos calcular el "Riesgo Empírico" (el error en nuestro dataset). La Ley Fuerte es la garantía absoluta de que, con "Big Data", la trayectoria de nuestro error de entrenamiento se anclará permanentemente al error real.

Diferencia Clave: Ley Débil vs. Ley Fuerte

¿Por qué tenemos dos leyes si ambas concluyen que $\bar{X}_n$ se acerca a μ ? La gran diferencia radica en los **tipos de convergencia** a lo largo del tiempo.

Ley Débil (La "Foto")

Convergencia en Probabilidad

Si tomas una foto del error en un paso n inmenso, es casi seguro que estará muy cerca de μ .

Sin embargo, permite que, si sigues observando hasta el infinito, la línea dé "saltos anómalos" de vez en cuando.

Uso teórico: Sirve para demostrar que un estimador estadístico es *consistente*.

Ley Fuerte (La "Película")

Convergencia Casi Segura

Si observas la *trayectoria completa* desde hoy hasta el infinito, se anclará a μ y nunca más divergirá.

Las trayectorias que dan "saltos locos" infinitamente tienen una probabilidad estricta de 0.

Uso práctico (IA): Garantiza que el entrenamiento iterativo de tu modelo será estable en el tiempo.

Más allá de Chebyshev: Garantías en el Tiempo

La desigualdad de Chebyshev es una herramienta de "punto fijo": nos dice qué tan probable es que $\bar{X}_n$ esté lejos de μ en un **paso n específico**.

Sin embargo, en procesos iterativos (como el entrenamiento de una red neuronal), nos interesa saber si el proceso se mantuvo "bajo control" en **todo momento**.

Theorem (Desigualdad de Kolmogorov)

Sean $X_1, \dots, X_n$ variables aleatorias independientes con $E[X_i] = 0$ y $\text{Var}(X_i) = \sigma_i^2 < \infty$. Sea $S_k = \sum_{i=1}^k X_i$ la suma parcial. Entonces, para cualquier $\varepsilon > 0$:

$$P\left(\max_{1 \leq k \leq n} |S_k| \geq \varepsilon\right) \leq \frac{\text{Var}(S_n)}{\varepsilon^2} = \frac{\sum_{i=1}^n \sigma_i^2}{\varepsilon^2}$$

Chebyshev vs. Kolmogorov: ¿Cuál es la diferencia?

¿Por qué es tan sorprendente este resultado?

Chebyshev: Acota la probabilidad de que el **último punto** de la trayectoria sea extremo.

Kolmogorov: Acota la probabilidad de que **cualquier punto** de la trayectoria (desde el paso 1 hasta el n) haya superado el umbral.

Conexión con la Ley Fuerte (SLLN)

Esta es la pieza que faltaba: al acotar el **máximo** de las sumas parciales, Kolmogorov nos permite usar el Lema de Borel-Cantelli para demostrar que las trayectorias "malas" (que se escapan de la media) dejan de ocurrir casi seguramente. Es el motor matemático que permite pasar de la Ley Débil a la Ley Fuerte.

Teorema del Límite Central (CLT)

La LLN nos dice que el promedio converge a la media, pero *¿cómo* es la distribución de ese promedio mientras converge?

Theorem (Teorema del Límite Central)

La variable estandarizada del promedio muestral converge en distribución a una Normal Estándar $\mathcal{N}(0, 1)$:

$$\lim_{n \rightarrow \infty} P\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq t\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t \exp\left(-\frac{x^2}{2}\right) dx$$

No importa si los datos originales son uniformes, exponenciales o bimodales. Si promediamos suficientes muestras independientes, la distribución de ese promedio **siempre** será una campana de Gauss.

Teorema del límite central

Theorem

Sean $X_1, X_2, \dots, X_n$ una sucesión de variables aleatorias independientes e idénticamente distribuidas con media μ y varianza σ^2 .

Sean $\bar{X}_n = (1/n) \sum_{i=1}^n X_i$ y $\bar{\sigma}_n^2 = \sigma^2/n$. Entonces $(\bar{X}_n - \mu)/\bar{\sigma}_n$ converge a una distribución normal con media 0 y varianza 1, $N(0, 1)$, esto es

$$\lim_{n \rightarrow \infty} P[(\bar{X}_n - \mu)/\bar{\sigma}_n \leq t] = \Phi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t \exp\left(-\frac{x^2}{2}\right) dx$$

donde $\Phi(t)$ es la función de distribución acumulada de una normal standard.


Ejemplo. Teorema del límite central en acción

Sean $\{X_i\}$ una sucesión variables aleatorias con $X_i \sim \mathcal{U}[0, 1]$.

Considere la sucesión

$$\overline{X}_1, \overline{X}_2, \overline{X}_3, \dots, \overline{X}_n, \quad \text{con} \quad \overline{X}_k = \frac{1}{k} \sum_{i=1}^k X_i$$

Ejemplo. Teorema del límite central en acción



El "Milagro" Estadístico en Ciencia de Datos

Por qué es matemáticamente mágico: El teorema **NO** exige que conozcamos la distribución original de los datos. La población original X_i puede ser asimétrica, bimodal, o una caja negra incomprensible. Al promediar suficientes muestras, el resultado **siempre** será una campana de Gauss perfecta.

Justificación en Inteligencia Artificial

En un *dataset* real, el "ruido" o error de una medición es la suma de miles de pequeños factores independientes (temperatura del sensor, estática, errores humanos, etc.). Por el CLT, la suma de estos miles de errores inobservables **debe** tener una distribución Normal. ¡Por esto las Redes Neuronales usan el **Error Cuadrático Medio (MSE)** asumiendo errores Gaussianos!

Teorema del Límite Central Multivariado

Como en Inteligencia Artificial trabajamos con vectores de múltiples características (*features*), el CLT se generaliza naturalmente al espacio M -dimensional.

Theorem (CLT Multivariado)

Sean $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ vectores aleatorios i.i.d. con vector de medias $\boldsymbol{\mu}$ y matriz de covarianza finita $\boldsymbol{\Sigma}$. Defina el vector promedio $\bar{\mathbf{X}}_n$. Entonces:

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}) \quad \text{cuando } n \rightarrow \infty$$

Esta es la razón teórica por la cual en la Sección 3 modelamos los clusters de datos (GMM, PCA) usando los "anillos" de la matriz de covarianza de la Gaussiana Multivariada. La geometría de la IA es Gaussiana por culpa del CLT.

Muestras

¿Qué es una Muestra (Sample)?

En la práctica, no tenemos acceso a toda la población (la distribución real $f(x)$). Solo tenemos un *dataset*.

Definición Formal: Una **muestra** de tamaño n es una colección de variables aleatorias $X_1, X_2, \dots, X_n$ que son independientes e idénticamente distribuidas (i.i.d.) provenientes de la población.

A partir de la muestra, calculamos **estimadores** (que también son variables aleatorias):

$$\text{Media Muestral: } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \implies E[\bar{X}] = \mu, \quad \text{Var}[\bar{X}] = \frac{\sigma^2}{n}$$

$$\text{Varianza Muestral: } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \implies E[S^2] = \sigma^2$$

Muestreo Aleatorio y Estimadores

Población (Realidad)

Total de elementos: N

Media real: $\mu = \frac{1}{N} \sum X_i$

Varianza real: $\sigma^2 = \frac{1}{N} \sum (X_i - \mu)^2$

Muestra (Dataset)

Tamaño de muestra: n

Media muestral: $\bar{X} = \frac{1}{n} \sum X_i$

Varianza muestral: $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$

Propiedades de los Estimadores:

Insesgadez: El promedio de la muestra es un estimador ideal: $E[\bar{X}] = \mu$.

El Problema del Sesgo en la Varianza: Si dividimos por n en lugar de $n - 1$, **subestimamos** la varianza real. Por eso usamos la corrección de Bessel ($n - 1$).

Error Estándar: La incertidumbre de nuestra media decrece con el tamaño de muestra:
 $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$.

Ejemplo Práctico: Testeo Agrupado (Pooled Testing)

El Problema: Necesitamos testear a 1000 conscriptos del ejército para detectar una enfermedad rara que afecta solo al 0.2% de la población ($p = 0.002$). Hacer 1000 tests individuales es muy costoso.

La Solución Algorítmica:

Dividimos a los 1000 conscriptos en 10 grupos de 100 personas.

Mezclamos una fracción de la sangre de las 100 personas de un grupo y hacemos **un solo test** a la mezcla.

Si la mezcla da negativo, las 100 personas están sanas (usamos 1 test).

Si la mezcla da positivo, hacemos 100 tests individuales adicionales a ese grupo (usamos $1 + 100 = 101$ tests).

Preguntas: a) ¿Cuál es el máximo número de tests posibles?

b) ¿Cuál es el mínimo número de tests posibles?

Ejemplo Práctico: Testeo Agrupado (Pooled Testing)

El Problema: Necesitamos testear a 1000 conscriptos del ejército para detectar una enfermedad rara que afecta solo al 0.2% de la población ($p = 0.002$). Hacer 1000 tests individuales es muy costoso.

La Solución Algorítmica:

Dividimos a los 1000 conscriptos en 10 grupos de 100 personas.

Mezclamos una fracción de la sangre de las 100 personas de un grupo y hacemos **un solo test** a la mezcla.

Si la mezcla da negativo, las 100 personas están sanas (usamos 1 test).

Si la mezcla da positivo, hacemos 100 tests individuales adicionales a ese grupo (usamos $1 + 100 = 101$ tests).

Preguntas: a) ¿Cuál es el máximo número de tests posibles? **1010 tests.**

b) ¿Cuál es el mínimo número de tests posibles? **10 tests.**

Optimización de Recursos usando Valor Esperado

c) ¿Cuántos tests **esperamos** realizar en promedio con este método?

Sea Z el número total de tests. Definimos la variable indicadora para cada grupo $i \in \{1, \dots, 10\}$:

$$Z_i = \begin{cases} 1 & \text{si el test de la mezcla del grupo } i \text{ da positivo} \\ 0 & \text{si da negativo} \end{cases}$$

El total de tests es $Z = 10 + 100 \sum_{i=1}^{10} Z_i$. Aplicando la linealidad de la esperanza:

$$E[Z] = 10 + 100 \sum_{i=1}^{10} E[Z_i]$$

¿Cuál es la probabilidad de que un grupo dé positivo? Es el complemento de que *todos* estén sanos:

$$E[Z_i] = P(Z_i = 1) = 1 - P(100 \text{ personas sanas}) = 1 - (1 - 0.002)^{100} \approx \mathbf{0.181}$$

Garantías vs. Asintóticas: El Encuestador (95% Confianza)

Retomemos el problema del encuestador: queremos estimar la intención de voto p con un error máximo del 1% ($\varepsilon = 0.01$) y un **95% de confianza**. Sabiendo que en el peor caso (empate) la varianza es $\sigma^2 = p(1 - p) \leq 0.25$. ¿A cuántas personas (n) debemos encuestar?

Vía Chebyshev (Garantía Dura)

$$P(|\bar{X}_n - p| \geq 0.01) \leq \frac{0.25}{n(0.01)^2} \leq 0.05$$
$$\implies n \geq \mathbf{50,000}$$

Es una verdad absoluta.

Prepara para el peor escenario.

Vía CLT (Aproximación)

Buscamos $P\left(|Z| \leq \frac{0.01}{0.5/\sqrt{n}}\right) = 0.95$.
Sabemos que $Z_{0.975} \approx 1.96$.

$$\implies n \geq \mathbf{9,604}$$

Asume convergencia a Gaussiana.

Nota de clase: Si usáramos Hoeffding, la fórmula $2 \exp(-2n(0.01)^2) \leq 0.05$ nos daría $n \geq 18,445$. ¡Relajar la confianza del 99% al 95% reduce los costos a casi la mitad en todos los métodos estadísticos!

Estimación de parámetros y ajuste de distribución

El Problema Inverso: Aprendizaje de Modelos

Hasta ahora, asumíamos los parámetros (μ, σ, λ) como conocidos. En IA, enfrentamos el **Problema Inverso**.

Enfoque Clásico: El proceso físico sugiere una distribución (ej. decaimiento radiactivo $\rightarrow$ Poisson). Usamos datos para hallar el λ que mejor describe la realidad.

Enfoque Moderno (ML): Los datos son complejos (imágenes, texto, turbulencia). Probablemente no se ajusten a una distribución simple. Sin embargo, estimar momentos (media, varianza) sigue siendo el primer paso para normalizar datos o entrenar modelos de mezcla (GMM).

Método de los Momentos (MoM)

Es el método más intuitivo de estimación. Se basa en la **Ley de los Grandes Números**: los momentos muestrales convergen a los momentos poblacionales.

Idea central:

Expresar los parámetros desconocidos Θ como funciones de los momentos teóricos: $\mu_k = E[X^k]$.

Estimar los momentos teóricos usando los datos (momentos muestrales):

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Resolver el sistema de ecuaciones para despejar $\hat{\Theta}$.

Ejemplo 1: Distribución de Poisson

Sea $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$, donde λ es desconocido (ej. número de clics por minuto).

Sabemos que para una Poisson:

$$E[X] = \lambda$$

Igualamos el momento teórico con el muestral:

$$\hat{\lambda} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Resultado: El estimador de momentos para λ es simplemente el promedio de los datos observados.

Ejemplo 2: Distribución Normal

Sea $X_i \sim \mathcal{N}(\mu, \sigma^2)$. Tenemos dos parámetros desconocidos $\Theta = [\mu, \sigma^2]$. Necesitamos dos ecuaciones (dos momentos).

$$\text{1er Momento: } \mu = E[X] \implies \hat{\mu} = \bar{X}_n$$

$$\text{2do Momento: } \sigma^2 = E[X^2] - (E[X])^2 \implies \hat{\sigma}^2 = \hat{\mu}_2 - (\hat{\mu}_1)^2$$

Donde $\hat{\mu}_2 = \frac{1}{n} \sum X_i^2$. Substituyendo:

$$\hat{\sigma}^2 = \frac{1}{n} \sum X_i^2 - \bar{X}_n^2 = \frac{1}{n} \sum (X_i - \bar{X}_n)^2$$

Conclusión: Hemos "aprendido" la campana de Gauss que mejor se ajusta a nuestros datos a través de sus momentos.



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE