Interrogacion 1 - IMT3850 - 2026

- Fecha de entrega 13 de abr en 19:30
- Puntos 22
- Preguntas 16
- Disponible después de 13 de abr en 18:10
- Límite de tiempo 60 minutos
- Intentos permitidos 2

Instrucciones

Instrucciones de la interrogación:

1. La prueba consta de 10 preguntas de elección múltiple (1 punto cada una) y 6 preguntas de desarrollo (2 puntos cada una).
2. Se mostrará una pregunta a la vez y usted podrá regresar a preguntas anteriores.
3. Las respuestas malas no restan puntaje.
4. La fecha de la evaluación es lunes 13 de abril de 20:10 a 21:20 horas.
5. **Usted debe entregar su prueba a más tardar a las 21:20 horas. De no hacerlo su prueba quedará como atrasada y no será corregida.**
6. Todo acto de deshonestidad académica será sancionado con nota mínima 1.0. Recuerde la declaración de honestidad académica.
7. Si usted se ve imposibilitado de rendir la interrogación por razones técnicas, deberá dar aviso al profesor del curso y al coordinador del magíster justificando una inasistencia apropiadamente.

Volver a realizar el examen

Historial de intentos

	Intento	Hora	Puntaje
MÁS RECIENTE	Intento 1	54 minutos	9 de 22 *

* Algunas preguntas no se han calificado

ⓘ Las respuestas correctas estarán disponibles el 13 de abr en 19:30.

Puntaje para este intento: 9 de 22 *
* Algunas preguntas no se han calificado
Entregado el 13 de abr en 19:04
Este intento tuvo una duración de 54 minutos.

Pregunta 1

1 / 1 pts

En el modelo matemático de un perceptrón (neurona artificial), la operación principal es calcular $f(x) = w^\top x + b$. ¿Qué representa geométricamente la ecuación $w^\top x + b = 0$?

- (selected) Un hiperplano afín que actúa como frontera de decisión separando el espacio en dos semi-espacios.
- El cálculo de la distancia euclidiana entre el vector de pesos w y la entrada x.
- Una parábola que encierra a los ejemplos clasificados como positivos.
- La proyección ortogonal del vector de datos x sobre el vector de pesos w.

Pregunta 2

1 / 1 pts

En un sistema dinámico lineal poblacional modelado por $x_{t+1} = Ax_t$, donde el vector x_t representa la cantidad de individuos por rango de edad. Matemáticamente, predecir el estado de la población en el instante $(t+k)$ (a partir del estado inicial x_0) requiere:

- (selected) Calcular la multiplicación de la matriz elevada a la potencia k por el estado inicial: $A^k x_0$.
- Calcular la pseudoinversa de Moore-Penrose de la matriz A.
- Resolver el sistema de ecuaciones lineales $Ax_{t+k} = x_0$.
- Calcular el vector transpuesto $A^\top x0$.

Pregunta 3

1 / 1 pts

Dada una matriz A, ¿cómo podemos calcular su factorización QR?

- Primero se encuentra A^{-1} la matriz inversa de A, luego se calcula la matriz triangular superior R
- Se utiliza el método de la potencia para descomponer la matriz en una matriz ortogonal y una matriz triangular superior.
- (selected) Se utiliza el método de Gram-Schmidt para descomponer la matriz en una matriz ortogonal y una matriz triangular superior.
- Se utiliza el método de eliminación de Gauss para descomponer en triangular inferior y triangular superior

Pregunta 4

1 / 1 pts

Si tienes un sistema sobredeterminado, ¿qué método es el más adecuado para encontrar una solución aproximada?

- (selected) Método de los mínimos cuadrados
- Método de eliminación de Gauss
- Método del descenso del gradiente

- Factorización LU

Pregunta 5

1 / 1 pts

En la práctica computacional, para obtener una base ortonormal a partir de un conjunto de vectores, se prefiere el algoritmo de Gram-Schmidt Modificado (MGS) por sobre el algoritmo Clásico. ¿A qué se debe esta elección?

- El MGS reduce drásticamente el número total de operaciones de punto flotante (flops) necesarias.
- El MGS es numéricamente más estable, mitigando la pérdida de ortogonalidad causada por los errores de redondeo del computador.
- El algoritmo clásico solo es aplicable si la matriz inicial ya es ortogonal.
- El MGS evita completamente el cálculo de normas euclidianas y raíces cuadradas.

Incorrecto

Pregunta 6

0 / 1 pts

Considere la descomposición LU de una matriz $A \in \mathbb{R}^{2\times 2}$ dada por las matrices

$$L = \begin{pmatrix} 1 & 0 \\ -1/2 & 0 \end{pmatrix}, \quad U = \begin{pmatrix} 2 & 2 \\ 0 & 3 \end{pmatrix}, \quad P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Entonces, ¿cual es la solución del sistema lineal $Ax = b$?, para

$$b = \begin{pmatrix} 3 \\ 0 \end{pmatrix}$$

- $x = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$
- $x = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$
- $x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$
- El sistema no tiene solucion.

Pregunta 7

1 / 1 pts

Suponga que los vectores $v_1, v_2, \ldots, v_d$ forman una base ortogonal de $\mathbb{R}^d$. Construimos la matriz

$V = [v_1 \; v_2 \; \ldots \; v_d]$

Suponga que $x \in \mathbb{R}^d$ es tal que $V^\top x = 0$. Entonces podemos concluir que:

- El vector x no existe ya que siempre se tiene que $V^\top x \neq 0$ cuando $v_1, v_2, \ldots, v_d$ es una base ortonormal.
- El vector x debe ser el vector cuyas componentes son siempre igual a 1.
- El vector x es un elemento de la base canónica.
- El vector x siempre corresponde al vector nulo 0.

Pregunta 8

1 / 1 pts

En un problema de regresión o ajuste de datos, el sistema $Ax \approx b$suele estar sobredeterminado e inconsistente ($b \notin \mathrm{im}(A)$). Para hallar el vector $\hat{x}$ que minimiza el error cuadrático $\|Ax - b\|_2^2$, se debe resolver analíticamente un sistema conocido como "ecuaciones normales". ¿Cuál es este sistema?

- $Ax = A^\top b$
- $AA^\top x = b$
- $A^\top Ax = A^\top b$
- $A^\top x = b$

Pregunta 9

1 / 1 pts

Dada una matriz A de dimensiones $m \times n$ (con $m \geq n$) de rango completo de columnas, su factorización QR reducida es $A = QR$. ¿Qué estructura poseen las matrices resultantes?

- Q tiene columnas ortonormales $(Q^\top Q = I_{n\times n})$ y R es una matriz triangular superior invertible.
- Q es triangular inferior y R es una matriz ortogonal.
- Ambas son matrices diagonales que contienen los valores propios de A.
- Q es una matriz de permutación y R es una matriz en forma escalonada.

Pregunta 10

1 / 1 pts

Sea $A \in \mathbb{R}^{m\times n}$una matriz "alta" ($m > n$, más observaciones que atributos) proveniente de un conjunto de datos sobre-determinado. ¿Cuál de las siguientes afirmaciones sobre sus propiedades de invertibilidad es correcta?

- Si sus columnas son linealmente independientes, A posee una inversa por la izquierda, pero no puede tener una inversa por la derecha.
- A siempre es invertible por la derecha, lo que garantiza una solución exacta para cualquier sistema $Ax = b$.
- A es completamente invertible y su matriz inversa A^{-1}tiene dimensiones $n \times m$.

- Si sus filas son linealmente independientes, $\boldsymbol{A}$ posee una inversa por la izquierda.

Pregunta 11

Aún no calificado / 2 pts

Suponga que está modelando la probabilidad de transición de clientes entre tres distintos planes de suscripción de su empresa mes a mes, utilizando un sistema dinámico discreto $\boldsymbol{x_{t+1} = Ax_t}$. La matriz estocástica $\boldsymbol{A}$ codifica estas tasas de transición. Explique cómo el cálculo de los valores y vectores propios de la matriz $\boldsymbol{A}$ permite predecir la distribución de clientes a largo plazo. ¿Qué condición espectral específica garantiza que el sistema convergerá a un estado estacionario estable?

Su respuesta:

Si A es diagonalizable, $A = V\Lambda V^{-1}$, entonces $x_t = A^t x_0 = V\Lambda^t V^{-1} x_0$. Esto descompone la evolución en modos independientes escalados por λ_i^t. Los modos con $|\lambda_i| < 1$ decaen, los de $|\lambda_i| = 1$ persisten.

Toda matriz estocástica tiene $\lambda_1 = 1$ como autovalor, con $|\lambda_i| \leq 1$ para los demás. El vector propio asociado a $\lambda_1 = 1$ es el estado estacionario ($Av_1 = v_1$).

La condición espectral para convergencia es que $\lambda_1 = 1$ sea el único autovalor de módulo 1, y $|\lambda_i| < 1$ para todos los demás. Así, cuando $t \to \infty$, todos los otros modos se extinguen y $x_\infty = c_1 v_1$. La distribución converge al autovector dominante sin importar x_0.

Pregunta 11 : Condición espectral

Si A es diagonizable descompone en

$A = VAV^{-1}$

siendo... $A = \text{diag}(\lambda_1, \lambda_2, \lambda_3)$

Evoluciona a:

$x_t = A^t x_0 = VA^t V^{-1} x_0$

Por lo tanto el modelo diverge.

Se observa qué es un modelo estacionario. Una vez se alcanza la distribución no cambia

Convergencia

Se requiere que $\lambda_1 = 1$

↳ # Sea el único valor propio del módulo 1

y que:

$|\lambda_i| < 1 \ \forall i \geq 2$

Pregunta 12

Aún no calificado / 2 pts

Considere una plataforma de comercio electrónico. Se cuenta con una gran matriz de interacción M de tamaño $m \times n$ m(clientes, n productos), la cual es extremadamente dispersa (sparse) porque la mayoría de los clientes solo interactúa con una pequeña fracción del catálogo. Explique detalladamente cómo usaría una aproximación de bajo rango mediante SVD ($M \approx U_k \Sigma_k V_k^\top$) para predecir qué productos recomendar a un usuario. ¿Qué significado geométrico o latente le atribuye a las filas de la matriz truncada U_k y a las filas de V_k ?
Su respuesta:

$M \in \mathbb{R}^{m \times n}$ es la matriz de interacciones (clientes × productos), extremadamente dispersa. Se calcula la SVD y se trunca a rango k: $M \approx U_k \Sigma_k V_k^\top$. Por Eckart-Young, esta es la mejor aproximación de rango k en norma Frobenius.

Las filas de U_k representan a cada cliente como un vector en un espacio latente de dimensión k. Cada coordenada codifica afinidad con un factor latente (ej. preferencia por tecnología, sensibilidad al precio).

Las filas de V_k representan a cada producto en el mismo espacio latente. Los valores singulares σ_i ponderan la importancia de cada factor.

La predicción es $\hat{M}_{ij} = \Sigma\, \sigma_l \cdot u_{il} \cdot v_{jl}$, un producto interior en el espacio latente. Si cliente y producto apuntan en direcciones similares, la puntuación es alta. Se recomiendan los productos no consumidos con mayor puntuación.

La aproximación de bajo rango filtra el ruido y captura los patrones dominantes. La elección de k se hace por validación cruzada.

Pregunta 13
Aún no calificado / 2 pts
En el ajuste de un modelo por mínimos cuadrados ordinarios, buscamos un vector $\hat{x}$ que minimice el residual $\|r\|_2^2$, donde $r = b - A\hat{x}$. Utilizando conceptos de cálculo vectorial y espacios generados (espacio columna), demuestre matemáticamente o argumente de forma geométrica por qué el vector residual óptimo debe ser estrictamente ortogonal a la imagen de la matriz $A(\mathrm{im}(A))$. Demuestre cómo esta condición geométrica de ortogonalidad deriva directamente en las Ecuaciones Normales.
Su respuesta:

Geométricamente, $A\hat{x}$ debe ser la proyección ortogonal de b sobre im(A). El punto más cercano a b dentro de un subespacio es su proyección ortogonal, por lo que el residuo $\hat{r} = b - A\hat{x}$ debe ser perpendicular a todo vector en im(A).

Analíticamente, se define $J(x) = \|b - Ax\|_2^2 = b^\top b - 2b^\top Ax + x^\top A^\top Ax$. Derivando e igualando a cero: $\nabla J = -2A^\top b + 2A^\top Ax = 0$, lo que da $A^\top(A\hat{x} - b) = 0$, es decir $A^\top \hat{r} = 0$. Cada columna de A es ortogonal al residuo.

Desde $A^\top \hat{r} = 0$, sustituimos $\hat{r} = b - A\hat{x}$ y obtenemos $A^\top b - A^\top A\hat{x} = 0$, lo que da las ecuaciones normales: $A^\top A\hat{x} = A^\top b$. Si A tiene rango completo, $\hat{x} = (A^\top A)^{-1}A^\top b$

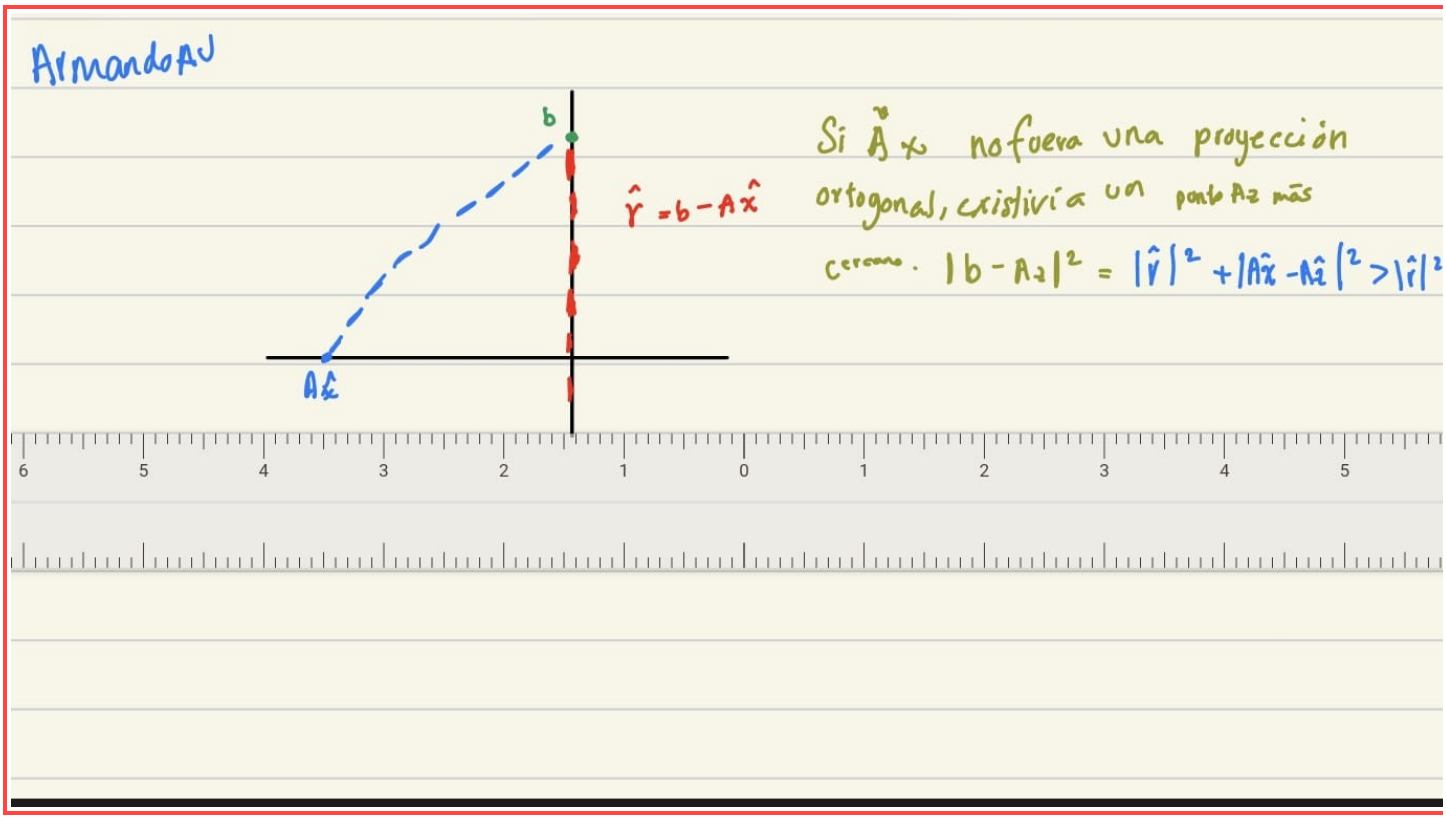

Pregunta 14

Aún no calificado / 2 pts

En el Análisis de Componentes Principales, el primer paso algorítmico obligatorio es "centrar los datos" (restar el vector de la media a cada observación) antes de calcular la matriz de covarianza o extraer los vectores singulares. Si un analista de datos inexperto omite este paso y aplica PCA directamente sobre datos fuertemente desplazados del origen, ¿qué información capturará erróneamente la primera "componente principal"? Argumente en base a la relación entre el origen de coordenadas, la nube de datos y la maximización de la varianza.

Su respuesta:

En PCA se centra $B = X - 1\cdot\bar{x}^\top$ y se calcula la covarianza $C = (1/(N-1))B^\top B$. La varianza mide dispersión respecto a la media, no respecto al origen.

Sin centrar, $X^\top X = B^\top B + N\cdot\bar{x}\bar{x}^\top$. El término $N\cdot\bar{x}\bar{x}^\top$ domina cuando $\|\bar{x}\|$ es grande. La varianza en dirección v sin centrar es: $(1/N)\|Xv\|^2 = \mathrm{Var}(X^\top v) + (\bar{x}^\top v)^2$. El sesgo $(\bar{x}^\top v)^2$ se maximiza cuando v apunta hacia $\bar{x}$.

La primera componente capturará erróneamente la dirección del vector media, es decir, la dirección del centroide respecto al origen. No captura variabilidad intrínseca, sino la

posición promedio de los datos, que es información trivial.

Las componentes siguientes también se distorsionan, y la proporción de varianza explicada queda inflada artificialmente para PC1.

Pregunta 15
Aún no calificado / 2 pts

El algoritmo del Perceptrón clásico actualiza iterativamente un vector de pesos $\boldsymbol{w}$ mediante la regla

$$\boldsymbol{w} \leftarrow \boldsymbol{w} + \eta y_i \, \boldsymbol{x}_i$$

cuando comete un error, buscando un hiperplano separador $\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b = 0$. Suponga que los datos de entrenamiento consisten en observaciones sanas (clase -1) agrupadas en un denso círculo cerca del origen, rodeadas por un anillo de observaciones anómalas (clase 1). Analice qué ocurrirá si ejecuta el algoritmo del Perceptrón sobre este conjunto. Proponga y describa una estrategia (transformación matemática de los datos $\boldsymbol{x}_i$) que permita resolver este problema sin abandonar la arquitectura de clasificación lineal.

Su respuesta:

El Perceptrón básicamente intenta encontrar una línea recta (o un hiperplano, en general) que separe las clases. En dos dimensiones, eso es una línea. Y una línea no puede separar un círculo interno de un anillo externo. Los datos no se pueden separar con una línea recta, así que el algoritmo nunca se estabiliza: se la pasa oscilando sin converger.

La solución es transformar los datos usando un mapeo $\varphi(x) = (x_1, x_2, x_1^2 + x_2^2)$. Básicamente, agregamos como tercera coordenada la norma al cuadrado $\|x\|_2^2$. En tres dimensiones, los puntos normales tienen $\|x\|^2$ chico y los anómalos lo tienen grande. Con eso, un hiperplano de la forma $w_1x_1 + w_2x_2 + w_3(x_1^2 + x_2^2) + b = 0$ ya sí puede separar las clases. El chiste es que el Perceptrón se sigue aplicando igual, pero ahora sobre $\varphi(x_i)$, sin cambiar la arquitectura lineal.

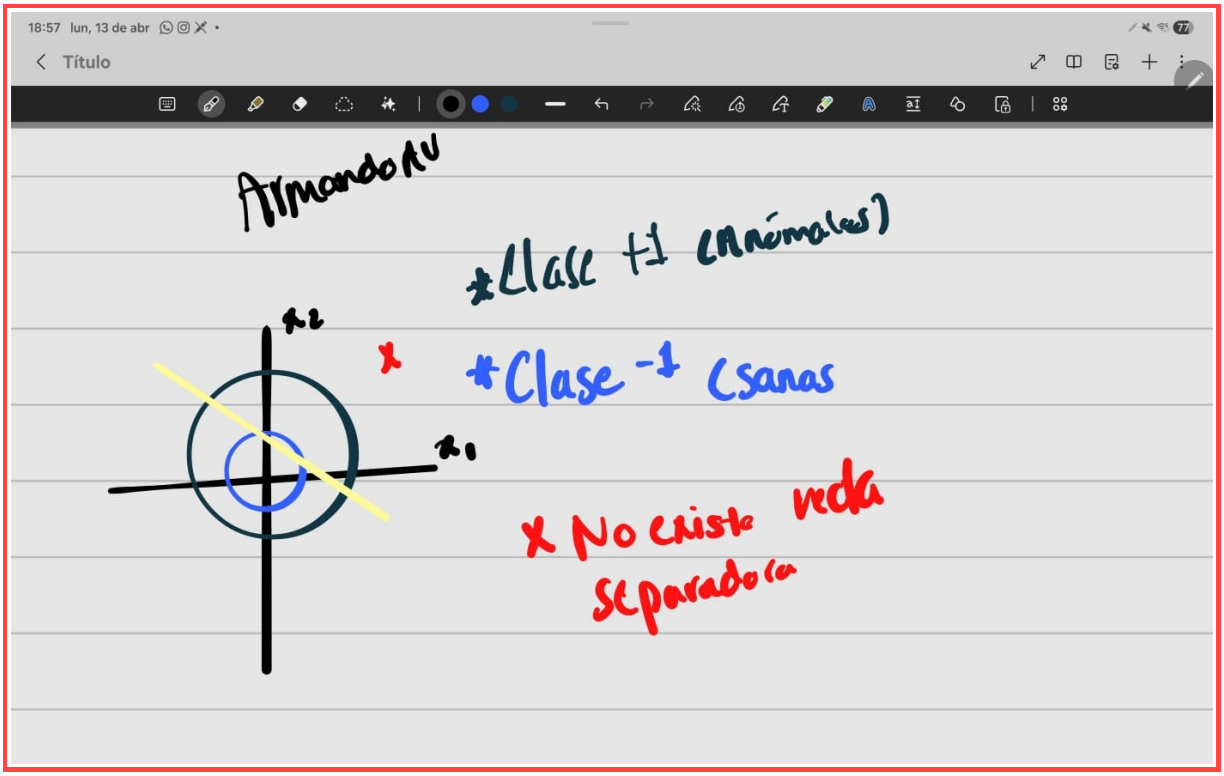

Pregunta 16

Aún no calificado / 2 pts

De al menos dos ejemplos de conceptos básicos que Algebra Lineal que son utilizados en aplicaciones y algoritmos de inteligencia artificial. Para esto, explique claramente: 1. el concepto, 2. donde se utiliza, 3. en que se aplica.

Su respuesta:

Ejemplo 1: Producto Interior. $x^\top y = \Sigma x_i y_i$, mide similitud direccional entre vectores. Se utiliza en el Perceptrón: $f(x) = \mathrm{sgn}(w^\top x + b)$. El producto $w^\top x$ mide cuánto se alinea la entrada con los pesos. La ecuación $w^\top x + b = 0$ define un hiperplano que separa las clases. Se aplica en clasificación binaria (ej. spam), donde la regla $w \leftarrow w + \eta y_i x_i$ ajusta los pesos iterativamente.

Ejemplo 2: SVD. $A = U\Sigma V^\top$, toda matriz admite esta descomposición en rotación-escalamiento-rotación. La truncación a rango k es la mejor aproximación por Eckart-Young. Se utiliza en PCA: se centra la data, se calcula SVD, y las primeras k columnas de V son las componentes principales. Se aplica en Eigenfaces (reconocimiento facial), compresión de imágenes, y análisis genómico (4000 dims → 3 dims para separar grupos patológicos).

Puntaje del examen: 9 de 22

* Algunas preguntas no se han calificado