



Pontificia Universidad Católica de Chile

Instituto de Ingeniería Matemática y Computacional

Magíster en Inteligencia Artificial

Tarea 2

Fundamentos Matemáticos para la
Inteligencia Artificial

IMT3850 · 2025-1

Alumno: Armando A.V.

Profesor: Manuel A. Sánchez

Fecha: Mayo 2026

Índice

1. Pregunta 1: Variables Aleatorias (5 puntos)	2
1.1. Solución	2
2. Pregunta 2: Algoritmo Random Quicksort (15 puntos)	2
2.1. Implementación	2
2.2. Resultados Experimentales	2
2.3. Análisis	2
3. Pregunta 3: Convexidad (10 puntos)	3
3.1. Demostración ($\Rightarrow$)	3
3.2. Demostración ($\Leftarrow$)	3
4. Pregunta 4: Descenso de Gradiente (15 puntos)	3
4.1. Formulación	3
4.2. Resultados	4
4.3. Análisis	4
5. Pregunta 5: Garantías Estadísticas y TLC (15 puntos)	4
5.1. a) Cota de Chebyshev	4
5.2. b) Teorema del Límite Central	4
5.3. Comparación	4
5.4. c-d) Simulación	5
6. Pregunta 6: Algoritmo de Mediana Aleatoria (10 pts — Bonus)	5
6.1. Algoritmo	5
6.2. Verificación	5
7. Conclusiones	5

1. Pregunta 1: Variables Aleatorias (5 puntos)

Enunciado: Sean x, y variables aleatorias independientes con $E[x] = E[y] = 0$ y $\text{Var}(x) = \text{Var}(y) = 1$. Determine la media μ_Z y la matriz de covarianza de $Z = (x, y, ax + by)$ con $a, b \in \mathbb{R}$.

1.1. Solución

Vector de medias:

$$\mu_Z = \begin{pmatrix} E[x] \\ E[y] \\ E[ax + by] \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

Matriz de covarianza: $\Sigma_Z = E[ZZ^\top]$

Usando independencia ($\text{Cov}(x, y) = 0$) y $\text{Var}(x) = \text{Var}(y) = 1$:

- $\text{Cov}(x, ax + by) = a\text{Var}(x) + b\text{Cov}(x, y) = a$
- $\text{Cov}(y, ax + by) = a\text{Cov}(y, x) + b\text{Var}(y) = b$
- $\text{Var}(ax + by) = a^2\text{Var}(x) + b^2\text{Var}(y) + 2ab\text{Cov}(x, y) = a^2 + b^2$

$$\Sigma_Z = \begin{pmatrix} 1 & 0 & a \\ 0 & 1 & b \\ a & b & a^2 + b^2 \end{pmatrix}$$

2. Pregunta 2: Algoritmo Random Quicksort (15 puntos)

2.1. Implementación

Se implementó el quicksort aleatorio con conteo de comparaciones. En cada llamada recursiva, se elige un pivote uniformemente al azar y se cuentan las comparaciones realizadas (una por cada elemento distinto al pivote).

2.2. Resultados Experimentales

Se ejecutó el algoritmo para $n = 100, 200, \dots, 5000$ con 30 repeticiones por tamaño. Los resultados se muestran en la Figura 1.

*[Gráfico generado en el notebook Jupyter]
Comparaciones promedio vs. $2n \ln(n)$ y $2n$*

Figura 1: Comparaciones del quicksort aleatorio vs. cotas teóricas.

2.3. Análisis

1. El número promedio de comparaciones crece como $O(n \log n)$, consistente con $E[C(n)] \leq 2n \ln(n)$.
2. El promedio empírico se mantiene por debajo de $2n \ln(n)$ para todos los tamaños.
3. El ratio empírico/ $2n \ln(n) \approx 0,7$, confirmando la constante teórica $\approx 1,39 \ln(n) = 2 \ln(n) / \ln(4)$.

3. Pregunta 3: Convexidad (10 puntos)

Enunciado: Sea $f : \mathbb{R}^d \rightarrow \mathbb{R}$ diferenciable. Demostrar:

$$f \text{ convexa} \iff f(y) \geq f(x) + \nabla f(x)^\top (y - x) \quad \forall x, y$$

3.1. Demostración ($\Rightarrow$)

Hipótesis: f convexa, i.e., $\forall x, y$ y $\theta \in [0, 1]$:

$$f(x + \theta(y - x)) \leq (1 - \theta)f(x) + \theta f(y)$$

Reordenando:

$$\frac{f(x + \theta(y - x)) - f(x)}{\theta} \leq f(y) - f(x)$$

Tomando $\theta \rightarrow 0^+$ (derivada direccional):

$$\nabla f(x)^\top (y - x) \leq f(y) - f(x)$$

Por lo tanto: $f(y) \geq f(x) + \nabla f(x)^\top (y - x)$. ✓

3.2. Demostración ($\Leftarrow$)

Hipótesis: $f(y) \geq f(x) + \nabla f(x)^\top (y - x)$ (*)

Sea $z = \theta y + (1 - \theta)x$ para $\theta \in [0, 1]$. Aplicamos (*) desde z :

1. Con $x \leftarrow z$, $y \leftarrow y$:

$$f(y) \geq f(z) + \nabla f(z)^\top (y - z) \quad (\text{i})$$

2. Con $x \leftarrow z$, $y \leftarrow x$:

$$f(x) \geq f(z) + \nabla f(z)^\top (x - z) \quad (\text{ii})$$

Multiplicamos (i) por θ y (ii) por $(1 - \theta)$ y sumamos:

$$\theta f(y) + (1 - \theta)f(x) \geq f(z) + \nabla f(z)^\top \underbrace{[\theta(y - z) + (1 - \theta)(x - z)]}_{=\theta y + (1 - \theta)x - z = 0}$$

Por lo tanto:

$$\boxed{\theta f(y) + (1 - \theta)f(x) \geq f(\theta y + (1 - \theta)x)}$$

Esto demuestra que f es convexa. ■

4. Pregunta 4: Descenso de Gradiente (15 puntos)

4.1. Formulación

Minimizar $L(\theta) = \frac{1}{2N} \|X\theta - y\|^2$ con:

- Gradiente: $\nabla L(\theta) = \frac{1}{N} X^\top (X\theta - y)$
- Gradiente estocástico (muestra i): $g_i = x_i(x_i^\top \theta - y_i)$
- Hessiano: $H = \frac{1}{N} X^\top X$

Tasas de aprendizaje:

- γ_{clases} (GD): Búsqueda exacta de línea $\gamma = \frac{g^\top g}{g^\top H g}$
- γ_{clases} (SGD): $\gamma = \frac{1}{L_{\text{máx}}}$ donde $L_{\text{máx}} = \max_i \|x_i\|^2$
- $\gamma(t) = \log(t + 2)$: Tasa creciente (divergencia esperada)

4.2. Resultados

Método	γ	Lineal	Cuadrático
GD	γ_{clases} (exact LS)	Converge (~ 5 iter)	Converge (~ 10 iter)
GD	$\log(t+2)$	Diverge	Diverge
SGD	$1/L_{\text{máx}}$	Converge (con varianza)	Converge (con varianza)
SGD	$\log(t+2)$	Diverge	Diverge

Cuadro 1: Resumen de convergencia por método y tasa de aprendizaje.

4.3. Análisis

- La búsqueda exacta de línea es óptima para GD en funciones cuadráticas.
- Para SGD, $\gamma = 1/\max_i \|x_i\|^2$ garantiza estabilidad cuando se usan gradientes de una sola muestra.
- $\gamma = \log(t+2)$ crece sin cota, violando $\gamma < 2/\lambda_{\text{máx}}(H)$, causando divergencia.

5. Pregunta 5: Garantías Estadísticas y TLC (15 puntos)

Clasificador con $p = P(\text{acierto}) = 0,85$, $\varepsilon = 0,01$, $\delta = 0,05$.

5.1. a) Cota de Chebyshev

$$P(|\bar{X}_n - p| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \leq \delta$$

Despejando: $n \geq \frac{\sigma^2}{\varepsilon^2\delta}$
 Con $\sigma^2 = p(1-p) = 0,1275$:

$$n_{\text{Cheb}} \geq \frac{0,1275}{0,01^2 \cdot 0,05} = 25,500$$

5.2. b) Teorema del Límite Central

$$P(|\bar{X}_n - p| \geq \varepsilon) \approx 2 \left(1 - \Phi \left(\frac{\varepsilon\sqrt{n}}{\sigma} \right) \right) \leq \delta$$

Necesitamos: $\frac{\varepsilon\sqrt{n}}{\sigma} \geq z_{1-\delta/2} = 1,96$

$$n_{\text{CLT}} \geq \left(\frac{z_{0,975}}{\varepsilon} \right)^2 \sigma^2 = \left(\frac{1,96}{0,01} \right)^2 \cdot 0,1275 \approx 4,899$$

5.3. Comparación

El CLT requiere $\sim 5\times$ menos muestras que Chebyshev (4,899 vs 25,500), ya que usa la distribución asintótica en lugar de una cota universal.

5.4. c-d) Simulación

Se simularon 10,000 repeticiones con $n = n_{\text{CLT}}$ y $p = 0,85$. La proporción empírica $P(|\bar{X} - p| \geq \varepsilon) \leq \delta$, confirmando la garantía del CLT.

6. Pregunta 6: Algoritmo de Mediana Aleatoria (10 pts — Bonus)

6.1. Algoritmo

Implementación basada en el algoritmo de clase:

1. Muestrear $\sqrt{n} \cdot \log(n)$ elementos de S .
2. Ordenar la muestra y usar cuantiles para acotar el rango $[d, u]$ donde está la mediana.
3. Filtrar S al rango $[d, u]$ y verificar que la mediana esté contenida.
4. Si el filtro es válido, ordenar el subconjunto reducido y extraer la mediana.
5. Repetir si falla (probabilidad exponencialmente pequeña).

6.2. Verificación

El algoritmo fue verificado para $n = 101, 1001, 5001, 10001$ contra `np.median`, obteniendo resultados idénticos en todos los casos.

7. Conclusiones

1. **Q1:** La media y covarianza se derivan de la linealidad de la esperanza y propiedades de combinaciones lineales.
2. **Q2:** El quicksort aleatorio confirma $O(n \log n)$ comparaciones en promedio.
3. **Q3:** La equivalencia convexidad $\iff$ condición de primer orden se demuestra en ambas direcciones.
4. **Q4:** La elección de γ es crítica: búsqueda exacta (GD) y $1/L_{\text{máx}}$ (SGD) convergen; $\log(t)$ diverge.
5. **Q5:** El TLC es más eficiente que Chebyshev ($\sim 5\times$ menos muestras).
6. **Q6:** El algoritmo aleatorio de mediana funciona en $O(n)$ esperado.