



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Taller 1

Word Embeddings (Word2Vec) y Modelado de Tópicos

CBOW frente a Skip-gram, analogías vectoriales,
proyección PCA y agrupamiento de documentos
sobre un corpus de economía chilena

Integrantes del grupo

Julyinho Merlin Toledo Rios
Armando Arredondo Valle
Thyare Graciela Parra Santander

Maestría en Inteligencia Artificial
INF3820 – Procesamiento de Lenguaje Natural
Prof. Rodrigo Andres Sandoval Urrich
Pontificia Universidad Católica de Chile

Agosto de 2026

1. Introducción

Los *word embeddings* son representaciones densas de palabras en un espacio vectorial continuo, aprendidas a partir de la coocurrencia de términos en un corpus. Word2Vec ([Mikolov et al., 2013a,b](#)) popularizó dos arquitecturas para construirlas: CBOW (*Continuous Bag of Words*), que predice una palabra objetivo a partir de su contexto, y Skip-gram, que invierte el problema y predice el contexto a partir de la palabra objetivo. La promesa de ambas es que la geometría del espacio resultante codifica relaciones semánticas, de modo que la proximidad entre vectores y las operaciones aritméticas sobre ellos permiten recuperar analogías y agrupar textos por tema.

Este informe reporta los resultados del Taller 1 del curso, cuyo objetivo es cuádruple: comparar empíricamente CBOW y Skip-gram, operar algebraicamente con los embeddings para identificar relaciones semánticas, proyectar el espacio de alta dimensión a dos dimensiones mediante PCA, y construir un agrupador de tópicos a partir de *document embeddings* obtenidos por promedio de vectores. El material de trabajo es un corpus sintético de doce oraciones sobre economía e industria en Chile (minería, energía, finanzas y regulación ambiental), lo que introduce una restricción que resulta ser el hilo conductor de todo el análisis: con tan poca evidencia, buena parte de lo que se observa se explica más por el tamaño del corpus que por las propiedades teóricas de cada arquitectura.

El documento se organiza como sigue. La Sección 2 describe el corpus y la configuración experimental. Las secciones 3 a 6 presentan los resultados de los cuatro ejercicios: comparación de arquitecturas, aritmética de analogías, proyección PCA y modelado de tópicos con K-Means. La Sección 7 recoge la discusión final sobre las limitaciones del promedio de vectores, la comparación frente a métodos clásicos y el aporte de los embeddings contextuales. La Sección 8 cierra con las conclusiones.

2. Corpus y configuración experimental

2.1 Descripción del corpus

El corpus está compuesto por doce oraciones en español, construidas para cubrir cuatro ejes temáticos de la economía chilena: minería, energía, finanzas y regulación ambiental. La Tabla 1 lista los documentos junto con el eje temático que se les puede asignar por inspección, referencia que se usará más adelante para evaluar la calidad del agrupamiento automático.

Tabla 1: Corpus de trabajo: doce documentos y su tema asignado por inspección.

ID	Documento	Tema
D1	La minería de cobre en el norte de Chile requiere alta eficiencia energética	Minería/Energía
D2	El litio es un mineral clave para la transición energética y las baterías	Minería/Energía
D3	El banco central ajustó la tasa de interés para controlar la inflación acumulada	Finanzas
D4	Las instituciones financieras evalúan el riesgo crediticio en la economía local	Finanzas
D5	La energía solar y eólica lideran la matriz limpia en la región de Antofagasta	Energía
D6	El precio del cobre impacta directamente los ingresos fiscales del Estado chileno	Minería/Finanzas
D7	Los analistas económicos proyectan un crecimiento moderado del producto interno bruto	Finanzas
D8	Proyectos de minería verde buscan reducir el consumo de agua en procesos industriales	Minería/Ambiental
D9	La regulación ambiental exige evaluaciones de impacto para nuevos proyectos de energía	Ambiental
D10	El sistema financiero local mantiene altos estándares de liquidez y capitalización	Finanzas
D11	La producción de litio en los salares requiere innovaciones en extracción directa	Minería
D12	La tasa de desempleo y la inflación influyen en las decisiones del banco central	Finanzas

2.2 Preprocesamiento y configuración de los modelos

Cada documento se tokenizó con la utilidad `simple_preprocess` de Gensim ([Řehůřek y Sojka, 2010](#)), que normaliza a minúsculas y descarta puntuación y tokens muy cortos, y a continuación se filtraron las palabras vacías del español provistas por NLTK. El resultado son doce listas de tokens de contenido: por ejemplo, D1 queda reducido a `[minería, cobre, norte, chile, requiere, alta, eficiencia, energética]`.

Este dato es relevante para interpretar todo lo que sigue: tras el filtrado, cada documento conserva entre siete y nueve tokens. Es decir, el corpus completo ronda el centenar de tokens de contenido y la mayoría de las palabras del vocabulario aparece una o dos veces.

Los modelos se entrenaron con dimensión de embedding igual a 60, ventana de contexto 3, frecuencia mínima 1 y 200 épocas, fijando la semilla en 42. El entrenamiento se ejecutó con un solo hilo de trabajo, condición necesaria para que la semilla garantice reproducibilidad exacta: con varios hilos el orden de las actualizaciones asincrónicas deja de ser determinista. Se entrenaron dos modelos con idéntica configuración salvo la arquitectura, uno CBOW y otro Skip-gram.

3. Ejercicio 1: entrenamiento comparativo CBOW frente a Skip-gram

3.1 Vecinos más cercanos de *cobre*

La Tabla 2 presenta las tres palabras más similares a **cobre** en cada arquitectura bajo la configuración base.

Tabla 2: Tres vecinos más cercanos de **cobre** por arquitectura (**window**=3, similitud coseno).

Puesto	CBOW		Skip-gram	
	Palabra	Similitud	Palabra	Similitud
1.ž	solar	0,642	local	0,928
2.ž	local	0,636	solar	0,914
3.ž	requiere	0,618	matriz	0,913

La observación central es que ambas arquitecturas devuelven prácticamente los mismos vecinos (**solar** y **local** aparecen en las dos listas), de modo que la diferencia relevante no está en qué palabras se recuperan sino en los puntajes. CBOW entrega similitudes entre 0,618 y 0,642, mientras que en Skip-gram los tres primeros superan 0,913 y quedan casi empatados entre sí.

La explicación está en la forma de entrenar de cada arquitectura. Skip-gram genera un ejemplo de entrenamiento por cada par (palabra, contexto), de manera que con 200 épocas sobre doce oraciones el espacio termina fuertemente comprimido: casi todos los vectores apuntan en direcciones parecidas, las similitudes se inflan y el modelo pierde capacidad de discriminar entre un vecino y otro. CBOW, en cambio, promedia los vectores del contexto antes de predecir, lo que suaviza las actualizaciones y deja un espacio menos saturado, en el que los puntajes todavía permiten ordenar candidatos.

Llama la atención que ninguno de los dos modelos entregue términos del dominio minero para **cobre**. Revisando el corpus la razón es clara: **cobre** aparece solo en dos documentos (D1, sobre eficiencia energética, y D6, sobre ingresos fiscales), y con esa evidencia el modelo no alcanza a anclar la palabra a un campo semántico. Sus vecinos terminan siendo simplemente términos con los que coocurre.

3.2 Sensibilidad al tamaño de la ventana

Para la pregunta 1.2 se repitió el entrenamiento variando **window** entre 3 y 10, manteniendo constante todo lo demás. La Tabla 3 resume los resultados.

Tabla 3: Tres vecinos más cercanos de **cobre** al variar el tamaño de ventana.

Ventana	CBOW	Skip-gram
3	solar (0,642), local (0,636), requiere (0,618)	local (0,928), solar (0,914), matriz (0,913)
5	local (0,748), requiere (0,737), impacta (0,728)	requiere (0,973), local (0,973), impacta (0,972)
7	requiere (0,744), solar (0,727), verde (0,721)	requiere (0,979), proyectos (0,978), matriz (0,975)
10	solar (0,768), local (0,745), requiere (0,729)	solar (0,982), local (0,982), requiere (0,980)

Los vecinos de **cobre** no se especializan en minería al aumentar la ventana; ocurre lo contrario. Se vuelven más genéricos y cada vez más difíciles de separar entre sí: con **window** = 10 en Skip-gram los tres primeros quedan entre 0,980 y 0,982, es decir, la geometría se aplana hasta el punto en que casi cualquier palabra del corpus queda cerca de **cobre**.

En teoría una ventana pequeña captura relaciones locales y sintácticas, ligadas a la posición de la palabra en la oración, mientras que una ventana amplia captura relaciones temáticas. Aquí pesa más una consideración práctica: como cada oración conserva entre siete y nueve tokens tras eliminar las palabras vacías, una ventana de 10 cubre la oración completa y el contexto de cada palabra pasa a ser todo su documento. En esas condiciones dos palabras resultan similares por el solo hecho de compartir oración, lo que homogeneiza el espacio. De hecho, los vecinos que se repiten en todas las configuraciones (**requiere**, **local**, **solar**) son palabras que coocurren con **cobre** o que aparecen en varias oraciones, no términos propios de la minería. En un corpus de este tamaño, agrandar la ventana no especializa la representación: solo diluye la señal.

4. Ejercicio 2: álgebra vectorial y analogías semánticas

Se evaluó la analogía *cobre es a minería lo que inflación es a X* mediante la operación $v_{\text{minería}} - v_{\text{cobre}} + v_{\text{inflación}}$, y se recuperaron las palabras más cercanas al vector resultante en ambos modelos. La Tabla 4 presenta los cinco primeros resultados.

Tabla 4: Palabras más cercanas al vector $v_{\text{minería}} - v_{\text{cobre}} + v_{\text{inflación}}$.

Puesto	Skip-gram		CBOW	
	Palabra	Similitud	Palabra	Similitud
1.ž	minería	0,8209	minería	0,6290
2.ž	inflación	0,7978	inflación	0,5077
3.ž	impacto	0,7432	impacto	0,4038
4.ž	tasa	0,7218	crediticio	0,2989
5.ž	crediticio	0,7094	influyen	0,2726

4.1 Interpretación del espacio vectorial

Antes de interpretar conviene una precisión metodológica: como la consulta se hizo pasando el vector resultante en bruto y no los nombres de las palabras, la función de búsqueda no excluye los términos de entrada. Por eso **minería** (0,8209) e **inflación** (0,7978) encabezan la lista, algo esperable dado que el vector resultante conserva buena parte de ambos. Lo informativo son las primeras palabras nuevas: **impacto** (0,7432), **tasa** (0,7218) y **crediticio** (0,7094), todas del ámbito financiero y monetario.

La relación que captura el modelo es la de un concepto con el dominio que lo gestiona. Así como **cobre** es el objeto material de la **minería**, la **inflación** es la variable central del aparato monetario, en el que la **tasa** es el instrumento de control y el banco central la institución que la administra. La resta $v_{\text{minería}} - v_{\text{cobre}}$ aísla, de forma gruesa, la dirección de “actividad que engloba al objeto”, y al sumarla a **inflación** el vector cae en la zona del espacio ocupada por los términos de política monetaria. Que esto funcione con doce oraciones se explica porque el corpus es fuertemente temático: **inflación** coocurre únicamente con **banco**, **central** y **tasa**.

4.2 Estrategias para mejorar la precisión de la analogía

La estrategia de mayor rendimiento es partir de embeddings preentrenados sobre corpus masivos: `word2vec-google-news-300` para inglés o, en nuestro caso, alternativas en español como los vectores del *Spanish Billion Word Corpus* o `fastText` en español (Bojanowski et al., 2017). Esos modelos ya observaron millones de contextos en los que **cobre** aparece junto a **minería**, **yacimiento** o **Codelco**, de modo que la dirección de la analogía viene aprendida de manera robusta, mientras que en nuestro corpus esa relación depende de apenas dos coocurrencias. La vía alternativa es ampliar el corpus, por ejemplo con miles de noticias económicas chilenas; también funciona, pero alcanzar el mismo nivel exige mucho más esfuerzo. Entre las opciones preentrenadas, `fastText` tiene la ventaja adicional de operar con subpalabras, lo que le permite generalizar incluso a términos no vistos en entrenamiento.

4.3 Sensibilidad de la analogía a la arquitectura

Al repetir la operación con CBOW (columnas derechas de la Tabla 4) la dirección semántica se conserva solo parcialmente. **impacto** y **crediticio** reaparecen, señal de que el vector sigue apuntando a la zona financiera, pero la analogía se degrada de forma apreciable: las similitudes caen a menos de la mitad (0,4038 frente a 0,7432 para la primera palabra nueva) y **tasa**, que era el resultado más limpio en Skip-gram, desaparece del top-5, reemplazada por **influyen**, semánticamente poco informativa.

La razón está en cómo distribuye los pesos cada arquitectura. CBOW promedia los vectores del contexto antes de predecir, lo que suaviza las representaciones y hace que las palabras frecuentes dominen el aprendizaje, mientras que las poco frecuentes reciben actualizaciones diluidas; en este corpus casi todo el vocabulario aparece una o dos veces. Skip-gram entrena cada par palabra-contexto por separado y deja a los términos raros con vectores mejor definidos. Como la aritmética de analogías requiere que **cobre**, **minería** e **inflación** tengan direcciones nítidas, la arquitectura que mejor representa palabras infrecuentes, es decir Skip-gram, entrega el resultado más interpretable. Con CBOW el concepto general se conserva, pero la precisión se pierde.

5. Ejercicio 3: reducción de dimensionalidad y visualización

Se extrajo el vocabulario completo del modelo Skip-gram junto con sus vectores de 60 dimensiones y se proyectó a dos dimensiones mediante PCA. La Figura 1 muestra la proyección resultante con las etiquetas de cada término.




Figura 1: Proyección PCA de los embeddings de palabras del modelo Skip-gram (60 dimensiones a 2 dimensiones). Los dos primeros componentes explican en conjunto un 24,37 % de la varianza.

5.1 Varianza explicada y agrupaciones observadas

Antes de buscar agrupaciones conviene cuantificar cuánta información sobrevive a la proyección: PC1 explica un 19,77 % de la varianza y PC2 un 4,60 %, para un total de 24,37 %. El gráfico es, por tanto, un resumen bastante parcial del espacio original.

Aun así se distinguen agrupaciones lógicas, más como vecindades difusas que como conglomerados nítidos. La más clara es la financiera: *inflación*, *banco*, *central*, *interés*, *economía*, *evalúan* y *controlar* ocupan una franja contigua en la zona centro-inferior del plano. Hacia el centro-derecha superior se organiza una vecindad minero-energética con *minería*, *verde*, *agua*, *litio*, *energía*, *eólica* y *evaluaciones*.

5.2 Preservación de las cercanías tras la proyección

Para evaluar objetivamente si la cercanía semántica sobrevive a la reducción se compararon, para cuatro pares de interés, la similitud coseno en el espacio original de 60 dimensiones con la distancia euclidiana en el plano proyectado. La Tabla 5 recoge estos valores junto con la distancia media entre todos los pares del vocabulario en 2D, que sirve

como referencia.

Tabla 5: Preservación de cercanías tras la proyección PCA. La distancia 2D media entre todos los pares del vocabulario es 0,054.

Par	Coseno en 60D	Distancia en 2D	¿Se preserva?
banco – central	0,825	0,017	Sí, muy por debajo de la media
inflación – tasa	0,872	0,032	Sí, por debajo de la media
cobre – minería	0,876	0,050	No, queda en la media
litio – baterías	0,758	0,111	No, al doble de la media

El resultado es desigual. El par **inflación-tasa**, con coseno 0,872 en 60 dimensiones, queda a distancia 0,032 en el plano, y **banco-central** (0,825) a 0,017; ambos claramente por debajo de la distancia media de 0,054, lo que indica que esas relaciones sobreviven a la proyección. El par **cobre-minería**, en cambio, presenta la similitud más alta del conjunto en 60 dimensiones (0,876) pero queda a 0,050 en 2D, prácticamente la distancia promedio; en la Figura 1 **cobre** aparece en el extremo derecho, lejos de **minería**. El caso **litio-baterías** es aún más extremo, con una distancia proyectada que duplica la media.

Aquí se manifiesta la limitación estructural de PCA: al tratarse de una proyección lineal que maximiza la varianza global, no ofrece garantía alguna de conservar las vecindades locales. La dirección que unía **cobre** con **minería** sencillamente no quedó alineada con los dos primeros componentes. Para estudiar vecindades locales sería más apropiado t-SNE (van der Maaten y Hinton, 2008), que optimiza justamente la preservación de la estructura local en lugar de la varianza global.

6. Ejercicio 4: modelado de tópicos con *document embeddings*

Cada documento se representó mediante *mean pooling*, es decir, el promedio de los vectores Skip-gram de las palabras presentes en el vocabulario del modelo, descartando los tokens fuera de vocabulario. Sobre la matriz de doce representaciones resultante se aplicó K-Means con $K = 3$. La Tabla 6 presenta la asignación obtenida.

Tabla 6: Asignación de documentos a tópicos mediante K-Means ($K = 3$) sobre *document embeddings*.

Cluster	Documentos	Lectura temática
1	D1, D4, D5, D7, D8, D9, D10	Mezcla de minería, energía, regulación ambiental y finanzas; sin tema unificador
2	D2, D6, D11	Commodities y su valor económico (litio y precio del cobre)
3	D3, D12	Política monetaria (banco central, tasa, inflación)

6.1 Calidad y coherencia del agrupamiento

La separación funcionó a medias. El cluster 3 quedó impecable: aisló exactamente los dos documentos de política monetaria, que comparten casi todo su vocabulario (**banco, central, tasa, inflación**). El cluster 2 también admite lectura, con un matiz: reúne los dos documentos sobre litio con el del precio del cobre, de modo que más que minería en sentido estricto conforma un tópico de commodities y su valor económico.

El problema es el cluster 1, que operó como cajón de sastre. Mezcla documentos minero-energéticos con tres claramente financieros: D4 (instituciones financieras y riesgo crediticio), D10 (sistema financiero, liquidez y capitalización) y D7 (analistas y producto interno bruto), que por tema deberían haber caído junto al cluster 3. Esos tres son los documentos fuera de lugar.

El *mean pooling* explica en buena medida esa asignación. Al promediar todos los vectores del documento, los términos discriminativos (**crediticio, liquidez**) se diluyen entre palabras genéricas que cruzan todo el corpus (**local, requiere, proyectan, evalúan**), que como se vio en el Ejercicio 1 son precisamente las que el modelo dejó cerca de todo. El promedio arrastra los *document embeddings* hacia el centro común del espacio, y esos documentos financieros terminan más próximos al centroide genérico del cluster 1 que al núcleo monetario, que es pequeño y compacto.

6.2 Representación global frente a local: alternativas al promedio simple

En este taller los artículos y preposiciones se filtraron con las palabras vacías de NLTK antes de entrenar, de modo que no contaminan directamente el promedio. El fenómeno de fondo, sin embargo, persiste bajo la forma de lo que podría llamarse palabras vacías de dominio: términos como **requiere, local** o **proyectos**, frecuentes en el corpus pero

poco útiles para distinguir tópicos, pesan en el promedio exactamente igual que `litio` o `crediticio`. De no haberse eliminado las palabras vacías el efecto sería peor: al ser las más frecuentes, dominarían el promedio y empujarían todos los documentos hacia un mismo punto del espacio, borrando las diferencias temáticas.

Una mejora directa consiste en ponderar el promedio con TF-IDF, multiplicando cada vector por la relevancia del término en el documento respecto del corpus. Bajo ese esquema `crediticio`, raro y discriminativo, pesaría mucho más que `requiere`, transversal. Una variante más refinada es SIF (*Smooth Inverse Frequency*), que pondera cada palabra por $a/(a + p(w))$ y además remueve el primer componente principal común a todos los documentos (Arora et al., 2017). Si se quiere abandonar el promedio por completo, Doc2Vec (Le y Mikolov, 2014) o codificadores de oraciones como SBERT (Reimers y Gurevych, 2019) aprenden la representación del documento de forma directa, sin construirla por agregación.

7. Discusión y reflexión final

7.1 Sesgos y limitaciones del promedio de vectores

Las limitaciones del *mean pooling* son varias y algunas ya se manifestaron en el Ejercicio 4. La primera es que el promedio trata todas las palabras por igual: un término clave como `crediticio` pesa lo mismo que un comodín como `requiere` y, como los comodines aparecen en todas partes, terminan arrastrando los documentos hacia el centro del espacio, que es exactamente el mecanismo que formó el cajón de sastre del cluster 1.

La segunda es que se pierde por completo el orden y la estructura de la oración: “el banco limita el riesgo” y “el riesgo limita al banco” producen el mismo vector, y una negación como “no subió la tasa” no altera la representación. Tercero, un documento que aborda dos temas queda colapsado en un punto intermedio que no representa bien a ninguno; con textos más largos que estas oraciones de ocho tokens el efecto sería considerablemente peor.

A ello se suman las limitaciones heredadas de Word2Vec: cada palabra tiene un único vector aunque posea varios sentidos, y el espacio arrastra los sesgos del corpus de entrenamiento. Si en los textos la minería apareciera siempre asociada a conflicto ambiental, esa carga quedaría incrustada en los vectores y pasaría directamente al promedio.

7.2 K-Means sobre embeddings frente a LDA y TF-IDF

En el manejo de sinónimos la ventaja de los embeddings es clara. TF-IDF, y LDA (Blei et al., 2003) que trabaja sobre conteos de palabras, tratan cada término como una dimensión independiente: “vivienda” y “casa” son columnas distintas, y dos documentos que usan una u otra no comparten nada aunque hablen de lo mismo. En el espacio de embeddings esos sinónimos quedan próximos por haber aparecido en contextos similares, de modo que K-Means puede agrupar documentos temáticamente parecidos aunque no compartan una sola palabra. En nuestro corpus el efecto se aprecia con **energética**, **energía** y **eólica**, que para TF-IDF serían términos sin relación alguna.

Con los términos no vistos la comparación es más pareja de lo que suele suponerse. Un Word2Vec entrenado desde cero tampoco puede hacer nada con una palabra fuera de su vocabulario: simplemente la descarta, tal como ocurre en la función de *document embedding* de este taller, igual que TF-IDF, que no dispone de columna para ella. Las salidas reales son fastText, que construye el vector de una palabra nueva a partir de sus subpalabras, o el uso de embeddings preentrenados con vocabularios amplios en los que es infrecuente que falte un término del dominio. En síntesis: los embeddings son superiores en sinónimos siempre, y en términos no vistos solo si se emplea la variante adecuada.

7.3 Embeddings contextuales frente a Word2Vec

Para esta industria el salto a modelos contextuales como BERT (Devlin et al., 2019) o su versión en español BETO (Cañete et al., 2020) sería considerable, por dos razones.

La primera es la polisemia, abundante en el lenguaje económico y minero chileno: **central** puede designar el banco central o una central eléctrica, **matriz** puede referirse a la matriz energética o a una casa matriz, y **banco** y **tasa** tienen además usos cotidianos. Word2Vec asigna un único vector por palabra, mezcla de todos sus sentidos, lo que acerca artificialmente documentos financieros y energéticos. En nuestro corpus **central** solo aparece junto a **banco**, pero en un corpus real del sector ese cruce sería un problema constante. Un modelo contextual genera un vector distinto por cada aparición según su contexto, de modo que “central” en “banco central subió la tasa” y en “central de ciclo combinado” quedarían apropiadamente distantes.

La segunda razón es el tamaño del corpus, que fue la limitación transversal de todo el taller: con doce oraciones, un Word2Vec entrenado desde cero produce un espacio saturado y vecinos genéricos. BETO viene preentrenado sobre miles de millones de palabras en español, por lo que llega con representaciones ya robustas y solo requiere ajuste fino, o bien puede usarse directamente para obtener embeddings de oración con los que resolver

el agrupamiento del Ejercicio 4, donde probablemente los tres documentos financieros del cluster 1 habrían caído donde corresponde.

El costo es computacional: la inferencia es mucho más pesada que una consulta a una tabla de vectores, y para vocabulario muy específico del rubro (nombres de yacimientos, jerga regulatoria) puede seguir siendo necesario un ajuste fino con textos del sector. Aun así, para clasificar o agrupar documentos de esta industria el intercambio resulta conveniente en la mayoría de los casos.

8. Conclusiones

El taller cumplió sus cuatro objetivos, y el resultado más consistente entre todos los ejercicios es que el tamaño del corpus condicionó cada uno de los hallazgos.

Respecto de la comparación de arquitecturas, CBOW y Skip-gram recuperaron esencialmente los mismos vecinos para **cobre**, pero con escalas de similitud muy distintas: Skip-gram produjo un espacio saturado, con los tres primeros vecinos por sobre 0,91 y prácticamente indistinguibles entre sí, mientras que CBOW conservó puntajes que permiten ordenar candidatos. El experimento con la ventana confirmó que, cuando la ventana supera el largo típico de la oración, el contexto de cada palabra pasa a ser su documento completo y el espacio se homogeneiza en lugar de especializarse.

En la aritmética de analogías, Skip-gram entregó el resultado más interpretable, recuperando **impacto**, **tasa** y **crediticio** como los primeros términos nuevos y capturando así la relación entre un concepto y el dominio que lo gestiona. La misma operación en CBOW conservó la dirección semántica pero con la mitad de la similitud, lo que confirma que la arquitectura que mejor representa palabras infrecuentes es la adecuada para este tipo de operación en corpus pequeños.

La proyección PCA mostró sus límites de manera cuantificable: los dos primeros componentes retienen solo un 24,37 % de la varianza, y aunque las vecindades financieras se preservaron (**banco-central** a 0,017 y **inflación-tasa** a 0,032 frente a una media de 0,054), el par de mayor similitud en el espacio original, **cobre-minería**, quedó a distancia promedio en el plano. Una proyección lineal que maximiza varianza global no garantiza preservar la estructura local.

Por último, el modelado de tópicos con *mean pooling* y K-Means separó correctamente el núcleo de política monetaria y un tópico de commodities, pero dejó un cluster residual que mezcló temas minero-energéticos con tres documentos financieros. El diagnóstico es el mismo que atraviesa todo el informe: el promedio no ponderado permite que las palabras

transversales dominen la representación y desplacen los documentos hacia el centro del espacio. Las alternativas identificadas, ponderación TF-IDF, SIF, Doc2Vec y codificadores contextuales de oración, apuntan justamente a corregir ese problema, y son la línea natural de continuación de este trabajo.

Referencias

- Arora, S., Liang, Y. y Ma, T. (2017). A simple but tough-to-beat baseline for sentence embeddings. *International Conference on Learning Representations (ICLR)*.
- Blei, D. M., Ng, A. Y. y Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022.
- Bojanowski, P., Grave, E., Joulin, A. y Mikolov, T. (2017). Enriching word vectors with subword information. *Transactions of the ACL*, 5, 135–146.
- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H. y Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. *PML4DC at ICLR 2020*.
- Devlin, J., Chang, M.-W., Lee, K. y Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL-HLT*, 4171–4186.
- Le, Q. y Mikolov, T. (2014). Distributed representations of sentences and documents. *Proceedings of ICML*, 32, 1188–1196.
- Mikolov, T., Chen, K., Corrado, G. y Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv:1301.3781*.
- Mikolov, T., Sutskever, I., Chen, K., Corrado, G. y Dean, J. (2013). Distributed representations of words and phrases and their compositionality. *Advances in Neural Information Processing Systems*, 26, 3111–3119.
- Reimers, N. y Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of EMNLP-IJCNLP*, 3982–3992.
- Řehůřek, R. y Sojka, P. (2010). Software framework for topic modelling with large corpora. *Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks*, 45–50.
- van der Maaten, L. y Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.

Anexo. Reproducibilidad

Todos los resultados reportados provienen de la ejecución del notebook `Taller_1_Word_Embedding_con_w2v.ipynb`. La configuración empleada fue: Gensim 4.4.0, palabras vacías del español de NLTK, `vector_size = 60`, `window = 3`, `min_count = 1`, `epochs = 200`, `seed = 42` y `workers = 1`. El entrenamiento con un único hilo es condición necesaria para la reproducibilidad exacta: con varios hilos, el orden de las actualizaciones asincrónicas deja de ser determinista y la semilla no basta para fijar el resultado. PCA y K-Means se ejecutaron con `random_state = 42`, y K-Means con `n_init = 10`.